

Detecção Automatizada de Ocultações Estelares


Curvas de luz e Machine Learning

Defesa de Mestrado

Thiago Laidler Vidal Cunha

Orientador: Dr. Julio Camargo

Observatório Nacional 2026




- Ocultações estelares: o fenômeno
- O problema e os dados
- Machine Learning
- Resultados
- Quaoar e conclusões

1

Ocultações Estelares

medir o invisível com uma sombra


O que é uma ocultação




Um corpo pequeno passa na frente de uma estrela: a luz "pisca". (Chariklo e seus anéis — ilustração: L. Maquet)

A sombra varre a Terra

Object Diam Tmax dots <> ra_offset_dec
Umbriel 1169 km 68.3s 60 s <> +0.0 +0.0





year-m-d	h:m:s UT	ra_dec_J2000	candidate	C/A	P/A	vel	Delta	G*	long
2020-09-21	08:24:38.650	02 30 28.8466	+14 19 36.377	0.224	356.62	-17.12	19.02	13.3	271





Cada observador no caminho da sombra vê o desaparecimento em um instante diferente. (Umbriel, 2020)

Da câmera à curva de luz



Frames de vídeo → fotometria → curva de luz. É este o objeto que analisamos.

Por que vale a pena: ciência de precisão






Cada curva vira uma corda; as cordas desenham o corpo: tamanho e forma com precisão de km.

centenas/milhares

1 par de olhos


de curvas acumuladas em arquivos
e novas campanhas

por curva, na triagem manual




Alguma curvas são de difícil interpretação

A proposta: uma pipeline de triagem



Banco de dados → normalização → características (features) → 4 classificadores → probabilidade de ocultação.

De onde vêm os dados



id	object_name	observation_date	source_portal	additional_metadata
18	2000SW106	2017-12-01	Manual Import	observer: Unknown, is_positive: True
19	2000TK17	2012-03-01	Manual Import	observer: Unknown, is_positive: True
20	2000WV132	2020-07-01	Manual Import	observer: Unknown, is_positive: True
21	2001HS35	2020-09-01	Manual Import	observer: Unknown, is_positive: True
22	2001HS35	2020-09-01	Manual Import	observer: PNosworthy, is_positive: True
23	2001US197	2020-10-01	Manual Import	observer: TimHaymes, is_positive: True
24	2002KX14	2018-09-01	Manual Import	observer: DHerald, is_positive: True
25	2002KX14	2018-09-01	Manual Import	observer: WHanna, is_positive: True
26	2002WC19	2018-12-01	Manual Import	observer: SKerr, is_positive: True
27	2003GG42	2019-02-01	Manual Import	observer: DeshmukhShishir, is_positive: True
28	2003UP55	2020-12-01	Manual Import	observer: Unknown, is_positive: True
29	2005RM43	2019-02-01	Manual Import	observer: AGilmore, is_positive: True
30	2007JJ43	2020-05-01	Manual Import	observer: DeanHooper, is_positive: True
31	2014EZ51	2019-02-01	Manual Import	observer: Unknown, is_positive: True
32	Abundantia	2017-12-01	Manual Import	observer: BobDunford, is_positive: True
33	Abundantia	2017-12-01	Manual Import	observer: Unknown, is_positive: True
34	Abundantia	2017-12-01	Manual Import	observer: SMessner, is_positive: True
35	Abundantia	2017-11-01	Manual Import	observer: Unknown, is_positive: True
36	Academia	2020-11-01	Manual Import	observer: EricFrappa, is_positive: True
37	Academia	2016-10-01	Manual Import	observer: JerryBardecker, is_positive: True
38	Adelheid	2017-12-01	Manual Import	observer: Unknown, is_positive: True
39	Adelheid	2017-12-01	Manual Import	observer: TBarry, is_positive: True

VizieR (B/occ) + Grupo do Rio → banco SQLite único: todas as curvas e metadados em duas tabelas consultáveis.

O conjunto de dados rotulado

1693

curvas de luz no total

802

positivas (reais, com ocultação)

891

negativas
702 sintéticas · 186 recortes reais · 3 nativas

Negativas reais quase não são catalogadas. Simulador físico (Gomes-Ferrante & Braga-Ribas) preenche a lacuna.

Formando o dataset:

Cada curva de luz será reduzida a um vetor de parâmetros. Esses parâmetros serão as informações necessárias para o modelo

Média do fluxo

$$\mu = \frac{1}{N} \sum_{i=1}^N F(t_i)$$



DP do fluxo

$$\sigma = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (F(t_i) - \mu)^2}$$

Fluxo mínimo/máximo

$$F_{\min} = \min_{1 \leq i \leq N} F(t_i), \quad F_{\max} = \max_{1 \leq i \leq N} F(t_i)$$

Resultado t-student de cada quartil da curva



Profundidade

$$\text{depth} = \max(0, \text{baseline} - \min_i F(t_i)).$$

$$\text{drawdown}(i) = F(t_i) - \max_{1 \leq j \leq i} F(t_j),$$

$$\text{Max_Drawdown} = \min_i \text{drawdown}(i).$$

Formando o dataset:

Cada curva de luz será reduzida a um vetor de parâmetros. Esses parâmetros serão as informações necessárias para o modelo





Figure 2. Detection of an occultation using the legacy method.


Sinal-Ruído da queda

$$\text{SNR}_{\text{dip}} = \frac{\text{depth}}{\sigma_{\text{baseline}}}$$




Estadística de Kolmogorov-Smirnov (comparação de distribuições de cada percentil)

Features pós tratamento Savitzky-Golay filter




A curva vira números: exemplo positivo



Curva	Occ_depth	SNR do dip	Savgol_std	Max_Drawdown
Umbriel — A. Scheck (positiva)	0,43	7,0	0,142	-0,74
Umbriel — N. Carlson (negativa)	0,31	4,4	0,069	-0,59

Curva com ocultação → a linha dela na tabela: queda mais funda, SNR maior, dispersão maior.

A curva vira números: exemplo negativo



Curva	Occ_depth	SNR do dip	Savgol_std	Max_Drawdown
Umbriel — A. Scheck (positiva)	0,43	7,0	0,142	-0,74
Umbriel — N. Carlson (negativa)	0,31	4,4	0,069	-0,59


A curva sem evento vira números menores nas mesmas colunas. É este contraste que o classificador aprende.

2

Machine Learning


Quatro modelos, todos interpretáveis

Classificação supervisionada




- Aprender com exemplos rotulados (positiva / negativa)
- Saída: probabilidade p de haver ocultação
- Decisão: $p \geq \text{limiar } \tau$ (padrão 0,5) $\rightarrow$ "positiva"

Árvores de decisão...




DECISION TREE



Uma árvore faz perguntas simples, uma característica por vez: cada resposta restringe a região do espaço de dados, até que uma folha decida a classe.


Árvores de decisão... florestas e boosts



-  classificadores avaliados nesta dissertação
-  conceito ou algoritmo de referência


Famílias de modelos baseados em árvore de decisão

Floresta aleatória




Uma árvore erra; um comitê de árvores descorrelacionadas erra muito menos. A aleatoriedade nos dados e nas características é o que reduz a variância

Gradient Boosting




Em Boosting, as árvores são treinadas em sequência, e não em paralelo: cada nova árvore corrige os erros das anteriores.

Por que comitês funcionam



- Erros independentes se cancelam na votação (Teorema do Júri de Condorcet)
- 4 modelos: Regressão Logística, Random Forest, XGBoost, CatBoost
- Árvores informam a importância de cada feature

Avaliar sem se enganar



- Teste sempre em curvas que o modelo nunca viu
- Validação cruzada (5 dobras) confirma estabilidade
- Métricas: precisão, sensibilidade, F1, AUC-ROC

Validação cruzada esquematizada. As 5 rodadas produzem média $\pm$ desvio padrão do desempenho, em vez de um único número que pode depender de um recorte favorável dos dados.

Métricas de performance

		Predicted	
		Positive	Negative
Actual	Positive	TP	FN
	Negative	FP	TN

- Teste sempre em curvas que o modelo nunca viu
- Validação cruzada (5 dobras) confirma estabilidade
- Métricas: precisão, sensibilidade, F1, AUC-ROC


$$\text{Acurácia} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{Precisão} = \frac{TP}{TP + FP}$$


$$\text{Sensibilidade} = \frac{TP}{TP + FN}$$

$$F_1 = 2 \cdot \frac{\text{Precisão} \cdot \text{Sensibilidade}}{\text{Precisão} + \text{Sensibilidade}} = \frac{2TP}{2TP + FP + FN}$$



Métricas de performance



- Teste sempre em curvas que o modelo nunca viu
- Validação cruzada (5 dobras) confirma estabilidade
- Métricas: precisão, sensibilidade, F1, AUC-ROC



Das 28 à 11 features



Suavização, profundidade, duração, testes estatísticos... análise de redundância: 28 → 11 sem perder desempenho.

3

Resultados

Seis experimentos, um padrão


Seis experimentos, desempenho estável

Exp.	Configuração	Teste	Melhor F1	AUC-ROC
1	28 features	misto 80/20	0,9937	≥ 0,9997
2	11 features (enxuta)	misto 80/20	0,9906	≥ 0,9995
3	11 features	só curvas reais	0,9821	≥ 0,9950
4	14 features	misto 80/20	0,9906	≥ 0,9996
5	13 features	misto 80/20	0,9905	≥ 0,9996
6	12 features (sem K-Means)	misto 80/20	0,9906	≥ 0,9997


Melhor F1 por experimento: 0,982–0,994: o desempenho não depende de uma escolha feliz.

Separação das classes (Experimento 2)

Curvas ROC - Comparação de Modelos





Matrizes de Confusão




Curvas ROC coladas no canto ideal; erros contados nos dedos. Os 4 modelos, estatisticamente equivalentes (McNemar).

E se o teste tiver só curvas reais?





Teste 100% real: F1 $\approx$ **0,98** (queda de $\sim$ 1 ponto). Consistente com a física, não o simulador.

Importância não é insubstituibilidade





- K-Means: a feature "mais importante" das árvores
- Removida → F1 não cai (features colineares compensam)
- Lição: importância alta $\neq$ informação exclusiva

Onde o modelo erra



Falsos negativos são curvas que até olhos humanos discutiriam. Ruído alto, quedas rasas.

O limiar τ : sensibilidade quase de graça




- Perder um evento custa MUITO mais que revisar um alarme
- Baixar τ : sensibilidade de **99,4%** no teste (+5 alarmes em 179 negativas)
- Pós-processamento: sem retreinar nada

4

Prova de fogo: Quaoar


Curva real, externa ao treino, cedida por Pereira et al. (2023)

A curva completa



Corpo principal + anéis Q1R e Q2R (o fino). O modelo nunca viu Quaoar: $p \approx 0,99$ para a curva inteira.

Caçando estruturas por recortes



Janela a janela: anéis fortes passam ($p = 0,96\text{--}0,999$)... mas as travessias do anel fino Q2R "reprovam" ($p = 0,04\text{--}0,08$).

O sinal fraco ainda é sinal

86x


$T = 0,03$

0

anel fino real vs. ruído parecido
(0,043 vs 0,0005)


recupera as duas travessias
do anel fino Q2R

falsos alarmes nesta curva



O que importa não é a probabilidade absoluta, é a separação entre evento e ruído.


Lição estrutural: janelas maiores diluem



Ampliar a janela REDUZ a probabilidade: features globais diluem quedas curtas → motivação para janela deslizante.

Dificuldades e como foram enfrentadas

- Dados heterogêneos e dispersos → banco SQLite unificado
- Só **3** negativas reais nativas → simulador físico + recortes de curvas reais
- Redundância de features → análise sistemática: 28 → 11
- Eventos curtos e rasos → limiar τ ajustável por campanha



Conclusões

0,98–0,99

F1 robusto em 6 experimentos
(4 modelos, teste real incluído)

99,4%

sensibilidade com τ ajustado
sem retreinamento


86×

separação anel real vs. ruído
em dado externo (Quaoar)

Uma ferramenta reproduzível de triagem e priorização: pronta para revisitar arquivos de curvas.

Trabalhos futuros

- Janela deslizante + features locais (detectar anéis finos direto)
- Ampliar negativas reais nativas (colaborações e campanhas)
- Redes neurais (CNN / ODNet) sobre a série bruta
- Triagem em tempo quase-real nas campanhas do Grupo do Rio



Obrigado.

Dr. Júlio Camargo (orientação) · Grupo do Rio

W. Gomes-Ferrante & F. Braga-Ribas (simulador) · C. L. Pereira (dados de Quaoar)

Banca examinadora · família e amigos





Material de apoio

slides extras


Análise complementar: e sem ML, dava?

	Classificador	Teste	F1	AUC
—	Limiar em 1 feature (Occ_depth)	misto 80/20	0,905	0,972
—	Limiar em 1 feature (Occ_depth)	só reais	0,948	0,966
ML	XGBoost (11 features)	misto 80/20	0,9906	0,9995
ML	XGBoost (11 features)	só reais	0,9821	0,9968

Uma régua já vai longe (a física é forte). O ML corta o erro restante em ~10x. [análise complementar, pós-dissertação]


Sobreajuste?

Resultados na escala de +98% precisão/acurácia/F1 são frutos de Overfit? Tudo indica que não.




- Todas as métricas reportadas são de conjunto de teste
- A Regressão Logística também acerta: e ela não tem como decorar
- Ablação do tamanho do treino (80/20 $\rightarrow$ 65/35): -15% dos dados de treino, o F1 cai apenas $\sim 0,7$ pp (0,9906 $\rightarrow$ 0,9838)
- Validação cruzada 5-fold com desvio pequeno ($\sim 0,006$ – $0,010$ em F1)

Teste cego: Umbriel (seminário, 2025)



A única divergência do teste cego (18 curvas: 15 pos / 3 neg) foi esta curva, de rótulo discutível. Era mesmo negativa?

Recorte de Quaoar em detalhe



Anel fino real (esq.) vs. anel denso (dir.) probabilidades do XGBoost janela a janela.