


Projeto de Mestrado:

Pipeline para Detecção Automatizada de Ocultações Estelares em Curvas de Luz com Técnicas de Machine Learning

Uma nova abordagem para detectar e analisar ocultações estelares em larga escala usando o poder da inteligência artificial.

Aluno: Thiago Laidler Vidal Cunha

Orientador: Julio Ignacio Bueno de Camargo



Informações Curriculares



- Sem Bolsa.
- Aprovado no exame de proficiência em inglês oferecido pelo Observatório Nacional em 2024.
- Dissertação iniciada.
- Códigos publicados em: <https://github.com/TLaidler/Portfolio/tree/main/Astrofisica/Mestrado>
- Projeto em fase final.

Ano/Semestre	Disciplina	Conceito	Créditos
2024/1	Astronomia de Posição	A	4
2024/1	Evolução Estelar	A	4
2024/2	Astroestatística	A	4
2024/1	Astronomia Dinâmica	A	4
2024/2	Tópicos de E-Science	A	4
2024/2	Propriedades Físicas de Pequenos Corpos	A	4



A Ascensão dos Dados em Astronomia

- A astronomia moderna enfrenta um desafio crescente: o volume massivo de dados observacionais.
- Ocultações estelares, eventos onde um corpo celeste obscurece uma estrela, vem sendo cruciais para melhor compreensão desses objetos. No entanto, a análise manual de suas curvas de luz é cada vez mais inviável.
- Este projeto propõe uma pipeline automatizada para a detecção de ocultações estelares, otimizando o tempo dos pesquisadores e possibilitando a análise de dados em escalas anteriormente inviáveis.



Objetivos do Projeto

Banco de Dados Estruturado

Organizar e disponibilizar um banco de curvas de luz para futuras pesquisas em ocultações estelares.

Facilitando a revisitação de curvas duvidosas, e o acesso a novas curvas.

Ferramenta de Classificação Automatizada

Desenvolver um modelo de Machine Learning para identificar rapidamente curvas com ocultações reais, auxiliando astrônomos na triagem.

Este modelo visa acelerar a análise e detectar eventos sutis, superando limitações de ferramentas legadas que geram muitos falsos positivos.

Metodologia: Engenharia de Dados

A primeira fase do projeto focou na engenharia de dados, crucial para a aplicação de Machine Learning.

01

Coleta e Padronização

Curvas de luz de diversas fontes foram compiladas e integradas em um banco de dados relacional SQL.

02

Scripts de Pré-processamento


Desenvolvimento de scripts de consulta e pré-processamento para gerar datasets treináveis.

03


Enriquecimento de Atributos

Extração de estatísticas (média, desvio padrão, fluxo mínimo/máximo) para cada curva, auxiliando no treinamento de modelos supervisionados.

Fluxo de dados



Fluxo de dados



Organização BD

File - C:\Users\thiag\Documents\GitHub\Portfolio\Astro... *File - C:\Users\thiag\Documents\GitHub\Portfolio\As... *File - C:\Users\thiag\Documents\GitHub\Portfolio\As...

```
SELECT id, object_name, observation_date, source_portal, additional_metadata
FROM observations;
```

observations 1 x


SELECT id, object_name, observation_date, sou | Insira uma expressão SQL para filtrar os resultados (use Ctrl+Espaço)

	id	object_name	observation_date	source_portal	additional_metadata
18	18	2000SW106	2017-12-01	Manual Import	observer: Unknown, is_positive: True
19	19	2000TK17	2012-03-01	Manual Import	observer: Unknown, is_positive: True
20	20	2000WV132	2020-07-01	Manual Import	observer: Unknown, is_positive: True
21	21	2001HS35	2020-09-01	Manual Import	observer: Unknown, is_positive: True
22	22	2001HS35	2020-09-01	Manual Import	observer: PNosworthy, is_positive: True
23	23	2001US197	2020-10-01	Manual Import	observer: TimHaymes, is_positive: True
24	24	2002KX14	2018-09-01	Manual Import	observer: DHerald, is_positive: True
25	25	2002KX14	2018-09-01	Manual Import	observer: WHanna, is_positive: True
26	26	2002WC19	2018-12-01	Manual Import	observer: SKerr, is_positive: True
27	27	2003GG42	2019-02-01	Manual Import	observer: DeshmukhShishir, is_positive:
28	28	2003UP55	2020-12-01	Manual Import	observer: Unknown, is_positive: True
29	29	2005RM43	2019-02-01	Manual Import	observer: AGilmore, is_positive: True
30	30	2007JJ43	2020-05-01	Manual Import	observer: DeanHooper, is_positive: Tru
31	31	2014EZ51	2019-02-01	Manual Import	observer: Unknown, is_positive: True
32	32	Abundantia	2017-12-01	Manual Import	observer: BobDunford, is_positive: True
33	33	Abundantia	2017-12-01	Manual Import	observer: Unknown, is_positive: True
34	34	Abundantia	2017-12-01	Manual Import	observer: SMessner, is_positive: True
35	35	Abundantia	2017-11-01	Manual Import	observer: Unknown, is_positive: True
36	36	Academia	2020-11-01	Manual Import	observer: EricFrappa, is_positive: True
37	37	Academia	2016-10-01	Manual Import	observer: JerryBardecker, is_positive: Tr
38	38	Adelheid	2017-12-01	Manual Import	observer: Unknown, is_positive: True
39	39	Adelheid	2017-12-01	Manual Import	observer: TBarry, is_positive: True

Valor x

Abundantia

Organização BD



The screenshot shows a database management interface with a SQL query editor at the top and a results grid below. The query is: `SELECT id, observation_id, time, flux FROM light_curves;`. The results grid displays 19 rows of data with columns: id, observation_id, time, and flux. A sidebar on the left shows a tree view with 'light_curves 1' selected. A 'Valor' window is open on the right, showing the value '1'.

	id	observation_id	time	flux
1	1	1	0,0817362	5.787
2	2	1	0,122604	5.858
3	3	1	0,163472	6.285
4	4	1	0,204341	6.890
5	5	1	0,245209	6.368
6	6	1	0,286077	5.930
7	7	1	0,326945	6.629
8	8	1	0,367813	6.855
9	9	1	0,408681	6.665
10	10	1	0,449549	6.463
11	11	1	0,490417	7.365
12	12	1	0,531285	5.847
13	13	1	0,572154	7.068
14	14	1	0,613022	6.914
15	15	1	0,65389	6.155
16	16	1	0,694758	6.048
17	17	1	0,735626	6.380
18	18	1	0,776494	7.222
19	19	1	0,817362	7.709

Contexto e problemática

O projeto busca desenvolver um algoritmo de Machine Learning para detectar eventos em curvas de luz.

Um algoritmo bem treinado pode auxiliar astrônomos em situações adversas, como na identificação de eventos fracos ou na seleção de curvas mais promissoras para análise, destacando informações relevantes sobre o corpo estudado.





Figure 2. Detection of an occultation using the legacy method.

Devido à dificuldade de obter curvas de luz de eventos negativos, ou até mesmo positivos de difícil detecção (alto ruído e curto tempo de duração), a geração de dados sintéticos e o uso de técnicas de **data augmentation** são essenciais.


Curvas Artificiais: Construídas com base em parâmetros físicos do corpo ocultador (tamanho, composição), tempo de observação e localização Gomes-Ferrante and Braga-Ribas (2023).

Rebalanceamento: Utilização de trechos de curvas reais sem eventos para equilibrar a proporção entre eventos positivos e negativos.



Formando o dataset:

Cada curva de luz será reduzida a um vetor de parâmetros. Esses parâmetros serão as informações necessárias para o modelo



Amplitude do fluxo

Média do fluxo

$$\mu = \frac{1}{N} \sum_{i=1}^N F(t_i)$$


DP do fluxo

$$\sigma = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (F(t_i) - \mu)^2}$$

Fluxo mínimo/máximo

$$F_{\min} = \min_{1 \leq i \leq N} F(t_i), \quad F_{\max} = \max_{1 \leq i \leq N} F(t_i)$$

Resultado t-student de cada quartil da curva



Formando o dataset:

Cada curva de luz será reduzida a um vetor de parâmetros. Esses parâmetros serão as informações necessárias para o modelo






Figure 2. Detection of an occultation using the legacy method.

Área sob a curva (integral)/"energia da curva"

Estatística de Kolmogorov-Smirnov (comparação de distribuições de cada percentil)



Features pós tratamento Savitzky-Golay filter



Formando o dataset:

Cada curva de luz será reduzida a um vetor de parâmetros. Esses parâmetros serão as informações necessárias para o modelo





Figure 2. Detection of an occultation using the legacy method.

curve_name	Feature_Amp	Feature_mv_av_Max	Feature_mv_av_Min	Feature_Flux_std	Feature_Savgol_Max
Campania_2016-07-01_Unknown	1.697988	1.232740	0.038129	0.412072	1.473267
Notburga_2020-11-01_WHanna	1.233070	1.094221	0.326255	0.172823	1.233070
Iclea_2020-07-01_SKerr	0.965538	1.104563	0.644305	0.143659	1.143282
Hercynia_2019-12-01_PNosworthy	1.357207	1.134036	0.009393	0.335256	1.180208
Elfriede_2015-12-01_Unknown	0.927264	1.122290	0.560507	0.189191	1.202520

15 x 22 columns

Modelos de Machine Learning



O projeto está na etapa de rebalanceamento do dataset para treinamento e comparação de modelos de Machine Learning.



XGBoost


Reconhecido pela robustez em classificação e dados tabulares, oferecendo alta performance e interpretabilidade.



Random Forest

Amplamente utilizado por sua capacidade de generalização e resiliência a ruídos, ideal para variabilidade significativa.

Futuramente, exploraremos Redes Neurais Convolucionais (CNNs), dado seu sucesso em aplicações similares, como o modelo ODNet da Unistellar Network.



Dificuldades e Soluções



Dados restritos

Dados de curvas resultado de fotometria estão com pesquisadores. Poucos portais liberam publicamente.



Astroquery Collection

Utilização da lib astroquery para buscar dados do Vizier.

Criei scripts únicos com foco no banco de dados do projeto.




Fontes limitadas

Por enquanto apenas Drive do Grupo do Rio de curvas positivas do Vizier.



Geração de curvas sintéticas

Ajuda do prof Felipe e Welligton. Utilização do mesmo código-fonte para criação de novas curvas.



Dados mal distribuídos

90% das curvas buscadas são positivas. Aumenta ainda mais a importância de curvas sintéticas.



Data Augmentation

É possível também recortar eventos de curvas positivas para aumentar a quantidade de curvas negativas no dataset.


Métricas de Avaliação

Para avaliar o desempenho dos modelos de classificação, serão utilizadas métricas consagradas:

Acurácia	Proporção de classificações corretas (TP + TN) sobre o total.
Precisão	Proporção de verdadeiros positivos (TP) entre os preditos como positivos.
Recall (Sensibilidade)	Proporção de verdadeiros positivos (TP) entre todos os positivos reais.
F1-score	Média harmônica entre Precisão e Recall.
AUC	Área sob a Curva ROC, indica a capacidade de discriminação do modelo.


Resultado preliminar

- Para esse primeira teste utilizamos uma amostra pequena (95 curvas) e aplicamos o modelo **Random Forest**.
- Esse modelo é baseado no conceito de **Árvore de Decisão**.



Resultado preliminar

- Para esse primeira teste utilizamos uma amostra pequena (95 curvas) e aplicamos o modelo **Random Forest**.
- Esse modelo é baseado no conceito de **Árvore de Decisão**.
- Sua principal diferença com a simples árvore de decisão é a adição do conceito de **Bootstrap**, recriando várias árvores com amostragens diversas do data set original



Resultado preliminar

- Ao lado vemos o resultado do treinamento do modelo **Random Forest**.
- Utilizamos curvas negativas provenientes do recorte de curvas positivas. Ao total, ficamos com 60 curvas positivas e 35 curvas negativas.
- Resultado otimista, mas é preciso ter cautela!

Resultados no conjunto de teste:

Accuracy: 0.9767441860465116

Precision: 1.0

Recall: 0.9629629629629629

F1 Score: 0.9811320754716981

ROC-AUC: 1.0

Relatório de Classificação:

	precision	recall	f1-score	support
0	0.94	1.00	0.97	16
1	1.00	0.96	0.98	27
accuracy			0.98	43
macro avg	0.97	0.98	0.98	43
weighted avg	0.98	0.98	0.98	43

Matriz de Confusão:

```
[[16  0]
 [ 1 26]]
```

Resultado preliminar

- Ao lado vemos o resultado do treinamento do modelo **Random Forest**.
- Utilizamos curvas negativas provenientes do recorte de curvas positivas. Ao total, ficamos com 60 curvas positivas e 35 curvas negativas.
- Resultado otimista, mas é preciso ter cautela!

Resultados no conjunto de teste:

Accuracy: 0.9767441860465116

Precision: 1.0

Recall: 0.9629629629629629

F1 Score: 0.9811320754716981

ROC-AUC: 1.0

Relatório de Classificação:

	precision	recall	f1-score	support
0	0.94	1.00	0.97	16
1	1.00	0.96	0.98	27
accuracy			0.98	43
macro avg	0.97	0.98	0.98	43
weighted avg	0.98	0.98	0.98	43

Matriz de Confusão:

```
[[16  0]
 [ 1 26]]
```



Resultado preliminar

- Aplicação de um teste cego nos dados da Ocultação de Umbriel.
- Essa observação continha 18 curvas, sendo 15 positivas e 3 negativas.
- O único equívoco do modelo foi em uma das curvas negativas, observada por Norman Carlson.

blind_test.head()


Python

curve_name	Feature_Amp	Feature_mv_av_Max	Feature_mv_av_Min	Feature_Flux_std	Feature_Savgol_Max
Umbriel_2020-09-01_AndrewScheck	0.736684	1.158627	0.615188	0.149593	1.186564
Umbriel_2020-09-01_BartonBillard	1.233945	1.132440	0.046654	0.330404	1.246496
Umbriel_2020-09-01_BobDunford	3.123708	1.478305	-0.353303	0.527817	1.765084
Umbriel_2020-09-01_ChrisAnderson	2.045467	1.567099	0.001951	0.440340	1.673036
Umbriel_2020-09-01_ChrisKitting	1.733452	1.191617	0.085538	0.447372	1.285480



Resultado preliminar

- Aplicação de um teste cego nos dados da Ocultação de Umbriel.
- Essa observação continha 18 curvas, sendo 15 positivas e 3 negativas.
- O único equivoco do modelo foi em uma das curvas negativas, observada por Norman Carlson.
- Será que de fato era uma curva negativa?



curve_name	Feature_Amp	Feature_mv_av_Max	Feature_mv_av_Min	Feature_Flux_std	Feature_Savgol_Ma
Umbriel_2020-09-01_NormanCarlson	0.660739	1.147599	0.834618	0.112259	1.15301

Próximas Etapas e Resultados Esperados

1

Modelos Robusto e Confiáveis

Detectar ocultações em casos complexos (alto ruído, ocultações curtas) com alta acurácia.

2

Otimização com RAPIDS

Explorar o uso de GPUs via pacote RAPIDS para acelerar pré-processamento e treinamento.

3

Finalização do Pipeline

Concluir o pipeline automatizado de tratamento de dados pós-extração SQL.

4

Geração de Curvas Sintéticas

Finalizar a inclusão de curvas sintéticas negativas para balanceamento do dataset.

5

Banco de Dados Padronizado

Disponibilizar um banco de dados de curvas de luz estruturado para a comunidade astronômica.

Impacto e Futuro

Este projeto não só otimizará a análise de dados, mas também pavimentará o caminho para sistemas de detecção autônoma de eventos raros, como ocultações por objetos transnetunianos ou asteroides não catalogados.

Benefícios

- Redução da inspeção manual e risco de erro humano.
- Fornecimento de estimativas probabilísticas para eventos ambíguos.
- Ampliação da capacidade de descoberta da astronomia observacional.



Obrigado!