

Observatório Nacional

DISSERTAÇÃO DE MESTRADO

PIPELINE PARA DETECÇÃO AUTOMATIZADA DE OCULTAÇÕES ESTELARES EM CURVAS DE LUZ COM TÉCNICAS DE MACHINE LEARNING

THIAGO LAIDLER VIDAL CUNHA

RIO DE JANEIRO
2026

Agradecimentos

Gostaria de expressar minha sincera gratidão ao meu orientador, Dr. Julio Camargo, por acreditar neste projeto desde o início. Sua confiança em uma proposta ambiciosa, mesmo diante das limitações impostas pela minha rotina profissional, foi fundamental para que este trabalho se tornasse realidade.

Agradeço também aos integrantes do Grupo do Rio pela colaboração e disposição em ajudar ao longo desta pesquisa. Um agradecimento especial aos meus ex-orientadores, Dr. Marcelo Assafin e Dr. Sérgio Santos-Filho, cuja orientação durante a Iniciação Científica construiu a base sólida que tornou esta etapa muito mais leve.

Registro aqui minha gratidão ao Observatório Nacional por acolher meu projeto, mesmo em condições atípicas. Ser aceito como mestrando, ainda que sem vínculo de bolsa e conciliando atividades profissionais, foi uma oportunidade de ouro.

Aos meus amigos e à minha família, obrigado por estarem presentes durante toda essa jornada. Em especial, aos meus pais, Cesar Vidal Cunha e Adriana Vieira Laidler, e ao meu irmão, Matheus Laidler Vidal Cunha, por todo o amor, incentivo e apoio nos momentos mais difíceis. Agradeço também ao apoio da minha namorada, Daniela Ferreira de Monte Lima, que acompanhou meus devaneios sobre trabalhar com astrofísica desde a adolescência e esteve ao meu lado quando terminei esta dissertação.

Aos meus tios, Cláudio Vidal e Cláudia Lassance, agradeço pelo apoio constante e por terem me proporcionado, desde cedo, o aprendizado da língua inglesa, ferramenta indispensável na minha formação. Às minhas tias Alessandra Vieira Laidler e Christiane Vieira Laidler, pelo carinho e incentivo. Ao meu avô, capitão Oswaldo Laidler, agradeço pelo incentivo e inspiração ao longo de todos esses anos. Aos meus primos Yan Lassance e Raphael Lassance, agradeço muito por todo o apoio ao longo do caminho.

Este trabalho é dedicado a todos vocês.

"O primeiro princípio é que você não deve enganar a si mesmo — e você é a pessoa mais fácil de enganar."

— Richard Feynman

Thiago Laidler Vidal Cunha

PIPELINE PARA DETECÇÃO AUTOMATIZADA DE OCULTAÇÕES ESTELARES EM CURVAS DE LUZ COM TÉCNICAS DE MACHINE LEARNING

RESUMO

Entre as técnicas disponíveis para a caracterização física de asteroides, Centauros e objetos transnetunianos, as ocultações estelares destacam-se pela elevada precisão. Nesses eventos, um corpo do Sistema Solar bloqueia temporariamente a luz de uma estrela distante para um dado observador. A análise da curva de luz resultante permite inferir tamanho, forma projetada e, em casos favoráveis, atmosfera e anéis do corpo ocultante, com resolução espacial da ordem de quilômetros. O número crescente de curvas obtidas por redes de telescópios — impulsionado pela astrometria do catálogo Gaia, que permite prever esses eventos com mais precisão — tornou, no entanto, a triagem manual de todas as curvas um problema relevante e motivou o desenvolvimento de métodos automatizados de detecção. Esta dissertação apresenta uma cadeia de processamento (*pipeline*) completa para detecção automatizada de ocultações estelares em curvas de luz, baseada em técnicas de aprendizado de máquina. O problema é formulado como classificação binária: cada curva é descrita por um vetor de características numéricas (*features*) e classificada como positiva (ocultação presente) ou negativa (ausência de evento). Quatro classificadores foram treinados e comparados: Regressão Logística, Random Forest, XGBoost e CatBoost. O conjunto de dados reúne 1693 curvas (802 positivas e 891 negativas~~). Seis experimentos avaliaram o impacto da seleção de *features* e a generalização para dados exclusivamente reais. Os resultados demonstram desempenho elevado e consistente: ~~, das quais 702 simuladas). Cinco configurações de características foram comparadas por validação cruzada agrupada por evento, e o desempenho final foi estimado uma única vez em um conjunto de teste reservado. Os modelos da configuração escolhida, com 12 características, atingiram F1-score entre 0,~~978~~ 985 e 0,988 no teste (entre 0,985 e 0,994 somente nas curvas reais) e AUC-ROC ~~superior a~~ acima de 0,~~995 no conjunto de teste~~997, contra F1 de 0,90 de um critério trivial de limiar sobre a profundidade da queda; a taxa de falsos positivos nas negativas reais, estimada fora da amostra, ficou entre 2 e 4 %, conforme o modelo (189 negativas reais). Como, na triagem, o custo de perder um evento genuíno (falso negativo) supera o de revisar um alarme falso (falso positivo), a ~~*pipeline*~~ cadeia de processamento permite ajustar o limiar de decisão em pós-processamento e operar em regime de alta sensibilidade, sem necessidade de retreinamento. Como ~~validação~~ ilustração em dados reais ~~, utilizou-se a~~ externos ao conjunto de treinamento, a ferramenta foi aplicada a curvas da ocultação pelo objeto transnetuniano (50000) Quaoar, ~~não incluída no conjunto de treinamento. A aplicação da ferramenta permitiu avaliar a identificação~~

~~de ocultações em~~ uma curva de luz complexa. Embora os sinais produzidos pelos anéis finos ~~apresentem~~ recebam probabilidades absolutas baixas, no XGBoost estas são ~~cerca de duas ordens de grandeza superiores às atribuídas a trechos~~ de 100 a 190 vezes superiores à atribuída a um trecho de ruído ~~semelhantes. Como consequência, um ajuste simples do limiar é suficiente para recuperar~~ semelhante, e um limiar reduzido recupera esses eventos sutis~~sem introduzir falsos alarmes~~, ao custo de 3 a 6 % de alarmes falsos em janelas sem evento dessa curva (cerca de 10 % nas negativas reais do conjunto de desenvolvimento). Esses resultados indicam o potencial da ferramenta para revisitar curvas de luz complexas em busca de eventos mais sutis ainda não identificados numa primeira análise. Assim, este trabalho contribui com uma ferramenta reproduzível para a triagem e priorização de curvas de luz em estudos de ocultações estelares.

Thiago Laidler Vidal Cunha

AUTOMATED PIPELINE FOR DETECTING STELLAR OCCULTATIONS IN LIGHT CURVES USING MACHINE LEARNING

ABSTRACT

Among the techniques available for the physical characterization of asteroids, Centaurs and trans-Neptunian objects, stellar occultations stand out for their high precision. In such events, a Solar System body temporarily blocks the light of a distant star as seen by a given observer. Analysis of the resulting light curve allows one to infer the size, projected shape and, in favorable cases, the atmosphere and rings of the occulting body, with spatial resolution on the order of kilometers. The growing number of light curves obtained by telescope networks — driven by Gaia astrometry, which allows these events to be predicted more precisely — has, however, made the manual screening of all light curves a relevant problem and motivated the development of automated detection methods. This dissertation presents a complete pipeline for the automated detection of stellar occultations in light curves, based on machine learning techniques. The problem is cast as binary classification: each curve is described by a vector of numerical features and classified as positive (occultation present) or negative (no event). Four classifiers were trained and compared: Logistic Regression, Random Forest, XGBoost and CatBoost. The dataset comprises 1693 light curves (802 positive and 891 negative~~). Six experiments assessed the impact of feature selection and the generalization to exclusively real data. The results demonstrate high and consistent performance: ~~, 702 of which are simulated). Five feature configurations were compared by event-grouped cross-validation, and the final performance was estimated once on a held-out test set. The models of the chosen configuration, with 12 features, reached F1-scores between ~~0.978 and ~~0.985 and 0.988 on the test set (between 0.985 and 0.994 on real curves only) and AUC-ROC above ~~0.995 on the test set~~0.997, compared with an F1-score of 0.90 for a trivial threshold on the dip depth; the out-of-sample false-positive rate on real negatives was between 2 and 4%, depending on the model (189 real negatives). Since, in screening, the cost of missing a genuine event (false negative) outweighs that of reviewing a false alarm (false positive), the pipeline allows the decision threshold to be tuned as a post-processing step, operating in a high-recall regime without the need for retraining. As ~~a validation ~~an illustration on real data ~~, the ~~external to the training set, the tool was applied to light curves of the occultation by the trans-Neptunian object (50000) Quaoar, ~~not included in the training set, was used. Applying the tool made it possible to assess the identification of occultations in~~ a complex light curve. Although the signals produced by the thin rings ~~have ~~receive low absolute probabilities, with XGBoost these are 100 to 190 times higher than that assigned

to a similar noise segment, and a reduced threshold recovers these ~~are about two orders of magnitude higher than those assigned to similar noise segments. As a consequence, a simple threshold adjustment is enough to recover these~~ subtle events~~without introducing false alarms~~, at a cost of 3 to 6% false alarms in event-free windows of that curve (about 10% on the real negatives of the development set). These results indicate the potential of the tool to revisit complex light curves in search of subtler events that a first analysis leaves unidentified. This work thus contributes a reproducible tool for the screening and prioritization of light curves in stellar-occultation studies.

Lista de Figuras

2.1 Representação artística de uma ocultação estelar pelo Centauro (10199) Chariklo e seu sistema de anéis. A curva de luz esquemática (abaixo) mostra as quedas de fluxo correspondentes à passagem dos anéis e do corpo principal diante da estrela. Crédito: Lucie Maquet, 2014. 8

2.2 Exemplo completo do fluxo observacional: ocultação estelar por Umbriel (satélite de Urano), observada em 21 de setembro de ~~2020 (Assafin et al. , 2023). —~~2020. (a) Mapa de previsão da sombra sobre a superfície terrestre. (b) Detalhe do posicionamento dos observadores na costa leste dos EUA (Google Earth). (c) Quadros CCD de uma das estações, processados pelo PRAIA: imagem original (esquerda), modelo do halo de Urano (centro) e imagem após a subtração por coronagrafia digital (direita), que viabiliza a fotometria de Umbriel e da estrela. (d) Curva de luz de ocultação resultante: razão entre o fluxo da estrela somado ao de Umbriel e o fluxo de calibração (azul), e fundo de céu (verde). Fonte: adaptado de Assafin et al. (2023). 9

2.3 Componentes do modelo de curva de luz sintética utilizado pelo SORA (Gomes-Júnior et al. , 2022). Verde: modelo geométrico, o ponto de partida — corpo opaco de borda nítida ocultando uma estrela pontual, sem difração e com amostragem instantânea. Preto: o mesmo modelo incluindo a difração de Fresnel. Azul: incluindo também o diâmetro angular da estrela. Traços vermelhos: resposta instrumental, isto é, o valor que cada exposição registraria ao integrar a curva azul durante o tempo de exposição (a largura de cada traço). A curva sintética ajustada a dados reais combina todos esses efeitos (Figura 2.4a). 13

2.4 (a) Curva de luz de ocultação observada (preto) e curva sintética ajustada (vermelho) para uma das cordas da ocultação por Umbriel em 2020; os instantes de imersão e emersão encontram-se muito próximos dos pontos circulados nas bordas da queda~~(Assafin et al. , 2023)~~. (b) Perfil do limbo de Umbriel no plano do céu: cada linha azul é uma corda positiva projetada, com as incertezas dos extremos em vermelho~~(Assafin et al. , 2023)~~. Fonte: adaptado de Assafin et al. (2023). 14

3.1 Exemplo ilustrativo de regressão linear simples, com dados genéricos, não referentes a curvas de luz de ocultação. Fonte: Levada (2026). 21
3.2 Classificação binária (sim = 1, não = 0) em função do tamanho da queda de fluxo (marcadores). A linha tracejada indica o limiar de decisão; a linha contínua, o resultado da regressão linear aplicada aos dados (ver discussão no texto). Fonte: adaptado de Levada (2026). 22
3.3 Como na Figura 3.2, com a adição de um ponto discrepante (~~*outlier*~~valor atípico). Fonte: adaptado de Levada (2026). 23
3.4 Comparação entre as distribuições Gaussiana e de Laplace, que correspondem aos priors assumidos sobre os parâmetros na interpretação bayesiana das regularizações Ridge e Lasso, respectivamente. 26
3.5 Função sigmoide $\sigma(z) = 1/(1 + e^{-z})$. 27
3.6 Esquema simplificado do funcionamento de um Random Forest. 30
3.7 Exemplo ilustrativo: 25 árvores com acurácia individual em torno de 65% podem resultar em uma floresta com acurácia de aproximadamente 94%. . 30
3.8 Exemplos de curvas ROC 37
3.9 Exemplo de curvas de aprendizado 40
3.10 Esquema da validação cruzada com $q = 5$ dobras 41

4.1 Esquema da ~~*pipeline*~~cadeia de processamento: as curvas de luz são convertidas em vetores de características; o treinamento utiliza essas características, e não as séries temporais brutas. 44
4.2 Fluxograma da aquisição e organização dos dados externos e da integração na etapa de inserção no banco de dados. 47
4.3 Fluxograma da ~~*pipeline*~~ cadeia de processamento responsável pela consolidação do banco de dados. 49
4.4 Exemplos de curvas de luz do conjunto de dados, com o fluxo normalizado pela média dos dois quartis temporais mais altos: (a) positiva com queda profunda; (b) positiva com queda parcial e ruído alto; (c) negativa real (corda negativa da campanha de Umbriel), justamente a negativa real que o XGBoost classifica como positiva no conjunto de teste (Seção 5.6); (d) exemplo de negativa simulada gerado com o simulador, sem corpo ocultante (estrela de magnitude 13, exposição de 0,1 s, 40 s de registro); não é uma das 702 curvas do conjunto. Os rótulos de (a)–(c) indicam objeto, mês e ano de observação e observador. 53

5.1 Matriz de correlação de Spearman entre as 28 características (1692 curvas, inclusive as do conjunto de teste; análise descritiva, sem uso dos rótulos), com apenas o triângulo inferior, pois a matriz é simétrica. Os prefixos `Feature_` e `Occ_` foram omitidos dos rótulos. 69

5.2 Matrizes de confusão dos quatro modelos do Experimento 1.2b no conjunto de teste reservado (teste misto: 341 curvas, sendo 161 positivas e 180 negativas, das quais 146 simuladas), no limiar $\tau = 0{,}5$. 82
5.3 Curvas ROC dos quatro modelos do Experimento 1.2b no conjunto de teste reservado (teste misto, 341 curvas). Como 146 das 180 negativas são simuladas, a taxa de falsos positivos é dominada por elas. O quadro ampliado mostra a região de taxa de falsos positivos entre 0 e 0,1. 83
5.4 Curvas precisão-sensibilidade dos quatro modelos ~~no~~ do Experimento ~~5.~~ 1.2b, calculadas nas predições fora da dobra do conjunto de desenvolvimento. Cada posição ao longo de uma curva corresponde a um valor do limiar τ. ~~No gráfico~~O quadro ampliado mostra a região entre 0,~~"revocação" é sinônimo de sensibilidade (*recall*)~~95 e 1 nos dois eixos. 87
5.5 Precisão, sensibilidade, F1-score e F_2-score em função do limiar de decisão τ ~~(~~para os quatro modelos do Experimento ~~5).~~ 1.2b (~~a~~predições fora da dobra do desenvolvimento)~~ Random Forest e XGBoost; (b) CatBoost e Regressão Logística~~. A linha vertical pontilhada indica o limiar escolhido pelo critério de sensibilidade $\geqslant 99{,}5\,\%$. 88
5.6 Curva de luz da ocultação estelar por Quaoar utilizada no estudo de caso, com o tempo referenciado ao instante 2022-08-09 06:34:49,26 UTC. ~~O *dip*~~ A queda central (~~anotado~~ anotada como "Quaoar"), de duração ≈ 48 s e profundidade $\approx 100\%$, corresponde à ocultação pelo corpo principal. As estruturas secundárias rasas, isoladas nos quatro ~~quadros~~ painéis ampliados~~(*insets*)~~, são as assinaturas dos dois anéis, Q1R (Morgado et al. , 2023) e Q2R~~(Pereira et al. , 2023)~~, sendo Q1R observado em duas porções (parte contínua e parte densa) e Q2R em duas travessias antes e depois do corpo. A ~~linha~~ reta pontilhada ~~indica o *baseline*~~ marca a linha de base ($F_{\mathrm{norm}} = 1$). Fonte: adaptado de Pereira et al. (2023). 91
5.7 Recortes da curva Gemini-'Alopeke de Quaoar (canal ~~*Red*~~ vermelho, filtro z~~(visível-vermelho~~, no infravermelho próximo)~~de Quaoar~~, ~~com o veredito do XGBoost em cada janela colorida~~numerados como na Tabela 5.8. A legenda indica, por recorte, a probabilidade $\hat{p}$ atribuída pelo XGBoost do Experimento 1.2b e a classificação no limiar padrão ($\tau = 0{,}5$) e no limiar ~~ajustado~~ ilustrativo ($\tau = 0{,}03$). ~~Os anéis finos Q2R, negativos em $\tau = 0{,}5$, são recuperados em $\tau = 0{,}03$, enquanto o controle e o trecho de ruído permanecem corretamente negativos.~~ Tempo relativo a 2022-08-09 06:34:49,26 UTC. 94

5.8 ~~Comparação do F1-score entre os seis experimentos, por~~ As cinco características mais importantes de cada modelo ~~. Exp.~~final do Experimento ~~1~~1.2b: ~~28 *features*; Exp. 2: 11 *features*~~ Regressão Logística (~~ablação combinada~~módulo dos coeficientes padronizados)~~; Exp. 3: teste somente em curvas reais~~, Random Forest (~~198 curvas: 160 positivas~~MDI), XGBoost (*gain*) e ~~38 negativas; simuladas alocadas ao treino~~CatBoost (*PredictionValuesChange*)~~; Exp~~. ~~4: 14 *features*; Exp~~Cada painel usa a escala do próprio método, e os valores não são comparáveis entre painéis. ~~5: 13 *features*; Exp~~Os prefixos `Feature_` e `Occ_` foram omitidos dos rótulos.~~6: 12 *features* (sem `kmeans`).~~ 98

5.9 Distribuição da ~~*feature*~~ característica `kmeans_centroid_dist` ~~por classe (1–99 percentil). As curvas~~ nas positivas, nas negativas ~~concentram-se em valores baixos (regime único)~~ reais e ~~as positivas em valores altos~~ nas negativas simuladas (~~dois patamares~~entre os percentis 1 e 99), ~~evidenciando o poder discriminativo da variável~~nas 1692 curvas do conjunto. A figura é descritiva e inclui as curvas do conjunto de teste. 102

5.10 Curvas de aprendizado de (a) XGBoost e (b) CatBoost no Experimento 1.2b: perda logarítmica de treino e de validação em função das iterações de *boosting*, em uma dobra da validação cruzada do conjunto de desenvolvimento. 105

5.11 F1-score na validação em função do número de curvas de treino (Experimento 1.2b). As barras indicam ± 1 desvio padrão entre as 15 dobras (5 dobras $\times$ 3 repetições); os pontos dos quatro modelos foram ligeiramente deslocados na horizontal para não se sobreporem. 106

Lista de Tabelas

3.1 Dados do exemplo numérico da Regressão Logística (valores ilustrativos). . 24
3.2 Algoritmos de otimização e seu papel na etapa de treinamento em projetos de ML. 34

5.1 Conjunto completo de 28 ~~*features*~~ características extraídas pela ~~*pipeline*~~cadeia de processamento. A coluna "Família" indica o grupo funcional; a coluna "Definição" resume o cálculo. 68
5.2 Conjunto de 13 ~~*features*~~ características após a análise de redundância ~~. O conjunto de referência operacional~~ (Experimento ~~2~~1.1)~~remove~~. Os Experimentos 1.2a, 1.2b e 2 removem ainda `Feature_Savgol_Min`~~e~~, `kmeans_centroid_dist` ou ambas, ~~restando 11.~~respectivamente. 71
5.3 Comparação dos métodos de cálculo de importância de ~~*features*~~ características utilizados por cada modelo. A escala típica refere-se aos modelos finais do Experimento 1.2b. 73
5.4 Distribuição das amostras por fonte no ~~*dataset*~~ conjunto de dados utilizado nos experimentos. 74
5.5 ~~Métricas de desempenho~~ Validação cruzada estratificada e agrupada por evento (5 dobras × 5 repetições) no conjunto de ~~teste — Experimento 1. Conjunto completo~~ desenvolvimento: média ± desvio padrão do F1-score e da AUC-ROC, e taxa média de ~~28 *features*~~falsos positivos nas negativas reais (FP reais; média das taxas por dobra, ~~divisão 80%/20%~~cada uma calculada sobre 24 a 41 negativas reais), no limiar $\tau = 0{,}5$. Entre parênteses, o número de características de cada experimento. 76
5.6 Desempenho no conjunto de teste reservado (avaliação única), Experimento 1.2b, limiar $\tau = 0{,}5$. "Misto": 341 curvas (161 positivas, 34 negativas reais e 146 simuladas). "Só reais" (Análise 2.1): 195 curvas (161 positivas e 34 negativas reais). FP/FN: falsos positivos e falsos negativos. . 80

5.7 ~~Pontos operacionais selecionados na análise~~ Limiares escolhidos nas predições fora da dobra do conjunto de ~~limiar~~ desenvolvimento (Experimento~~5, 13 *features*~~ 1.2b) ~~. Para cada modelo: limiar padrão ($\tau = 0{,}5$), limiar sensível ou ótimo,~~ e ~~métricas associadas~~ desempenho resultante no conjunto de teste reservado (341 curvas; 161 positivas). FP ~~=~~ / FN: falsos positivos ~~, FN =~~ e falsos negativos~~)~~. 85

5.8 Probabilidade de ocultação $\hat{p}$ atribuída ~~por CatBoost e XGBoost (Exp.~~pelos quatro modelos finais do Experimento ~~2)~~ 1.2b à curva inteira ~~(*baseline*)~~ e a cada recorte da curva Gemini-'Alopeke ~~*Red*~~ no filtro z. Janelas em segundos relativos ao instante 2022-08-09 06:34:49,26 UTC. A última linha traz o limiar τ de cada modelo escolhido na validação cruzada (sensibilidade $\geqslant 99{,}5\,\%$). RL: Regressão Logística; RF: Random Forest. . . 92

5.9 Coeficientes da Regressão Logística do Experimento 1.2b (características padronizadas), ordenados pelo módulo, e razão de chances correspondente a um aumento de um desvio padrão na característica. Intercepto: $\theta_0 = 4{,}50$. 100

5.10 Teste de McNemar exato no conjunto de teste ($\tau = 0{,}5$, Experimento 1.2b): entre pares de modelos (~~Experimento 4~~parte superior) e entre o critério trivial de limiar em `Occ_depth` e cada modelo (parte inferior). b: ~~apenas~~ A erra e B acerta; c: ~~apenas B~~ A acerta e B erra. ~~$p < 0{,}05$ indicaria diferença significativa; nenhum par é significativo ($\alpha = 0{,}05$).~~ 104

5.11 F1-score médio $\pm$ desvio padrão na validação em função da fração dos grupos de treino utilizada (Experimento 1.2b; entre parênteses, o número médio de curvas de treino). 106

A.1 ~~Métricas de desempenho~~ Validação cruzada no conjunto de ~~teste — Experimento 5. 13 *features*~~ desenvolvimento: média $\pm$ desvio padrão sobre as 25 dobras. Entre parênteses, o número de características. As três últimas configurações são suplementares (~~sem `Feature_Savgol_Min`~~avaliadas depois da escolha)~~, divisão 80%/20%~~. 128

A.2 ~~Métricas~~ Melhor F1 médio de ~~desempenho no conjunto de teste — Experimento 6. 12 *features*~~ cada configuração (~~sem `kmeans_centroid_dist`~~e modelo correspondente) na validação cruzada com dois conjuntos de sementes, ~~divisão 80%/20%~~e limite da regra de um desvio padrão. 129

A.3 ~~Comparação do F1-score: com `kmeans` (Exp. 5), sem `kmeans` (Exp. 6)~~ Diferença pareada de F1 entre as configurações 1.2b e~~ablação combinada (Exp.~~ 2 nas 25 dobras da validação cruzada (positiva quando a 1.2b é melhor).~~Divisão 80%/20%.~~ 130

A.4 ~~Métricas de desempenho no conjunto de teste — variante do Experimento 3 com divisão 65%/35% (teste somente em curvas~~ Negativas reais ~~: 347 curvas, 281~~ classificadas como positivas~~e 66 negativas~~, fora da amostra (configuração 1.2b, $\tau = 0{,}5$). 131
A.5 ~~Importância~~ Métricas no conjunto de ~~variáveis por modelo — Experimento 4~~ teste (~~14 *features*~~ $\tau = 0{,}5$) de todas as configurações. ~~(a) Regressão Logística, (b) Random Forest, (c) XGBoost, (d) CatBoost~~"Misto": 341 curvas; "Só reais": 195 curvas. FP/FN no teste misto. 132

Sumário

Agradecimentos **3**

Lista de Figuras **11**

Lista de Tabelas **15**

1 Introdução **1**
1.1 Contexto e Relevância . . . 1
1.2 Problema de Pesquisa . . . 3

2 Ocultações Estelares e Processamento de Dados **7**
2.1 O que são Ocultações Estelares? . . . 7
2.2 Da observação às curvas de luz: coleta e armazenamento . . . 10
2.3 Caracterização das curvas de luz de ocultação . . . 11
2.4 Considerações finais do capítulo . . . 14

3 Modelos e ~~algoritmos para~~ Algoritmos de Aprendizado de Máquina **17**
3.1 Conceitos fundamentais de aprendizado de máquina . . . 17
3.1.1 Definição e papel do aprendizado de máquina . . . 17
3.1.2 Aprendizado supervisionado versus não supervisionado . . . 19
3.2 O problema da classificação supervisionada . . . 20
3.3 Modelos de classificação utilizados na cadeia de processamento . . . 22
3.3.1 Regressão Logística . . . 22
3.3.2 Árvores de decisão e critérios de impureza . . . 26
3.3.3 Random Forest (Floresta Aleatória) . . . 28
3.3.4 XGBoost (*eXtreme Gradient Boosting*) . . . 29
3.3.5 CatBoost . . . 31
3.4 Agrupamento não supervisionado: K-means . . . 32
3.5 Algoritmos de otimização no treinamento . . . 33
3.6 Engenharia de características e validação de modelos . . . 35
3.6.1 Engenharia de características . . . 35
3.6.2 Métricas de avaliação para classificação binária . . . 35

3.6.3 Sobreajuste, subajuste e o compromisso entre viés e variância 37
3.6.4 Curvas de aprendizado 39
3.6.5 Validação de modelos 39

4 Metodologia: Cadeia de Processamento para Detecção 43
4.1 Visão geral da cadeia de processamento 43
4.2 Aquisição e armazenamento dos dados 45
4.2.1 Fontes de dados 45
4.2.2 Estrutura do banco de dados 46
4.3 Acesso aos dados e normalização 48
4.3.1 Consulta e classificação 48
4.3.2 Normalização do fluxo 50
4.3.3 Remoção de ~~*outliers*~~valores atípicos 50
4.4 Construção do conjunto de dados para aprendizado de máquina 50
4.4.1 Tamanho e composição do conjunto de dados 51
4.4.2 Curvas positivas e negativas do banco 51
4.4.3 Recorte de segmentos negativos a partir de curvas positivas 51
4.4.4 Curvas negativas simuladas 52
4.5 Engenharia de características 54
4.5.1 Amplitude e desvio padrão do fluxo 54
4.5.2 Suavização (filtro de Savitzky-Golay) 54
4.5.3 Queda máxima acumulada~~(*max drawdown*)~~ 55
4.5.4 K-means no fluxo suavizado 55
4.5.5 Derivadas 56
4.5.6 Comparação entre quartis (testes estatísticos) 56
4.5.7 Métricas de profundidade, duração e ajuste de modelos 57
4.5.8 Resumo das ~~*features*~~características 59
4.6 Treinamento e avaliação dos modelos 60
4.6.1 Preparação dos dados e ~~divisão treino/teste~~protocolo de avaliação . 60
4.6.2 Modelos utilizados 61
4.6.3 Métricas de avaliação 62
4.6.4 Fluxo de treinamento e persistência 62

5 Resultados 65
5.1 Visão geral dos experimentos 65
5.2 Descrição das ~~*features*~~ características e análise de redundância 67
5.2.1 Conjunto completo de ~~*features*~~características 67
5.2.2 Análise de redundância 67
5.3 Importância das ~~*features*~~características: metodologia 71
5.3.1 Random Forest — *Mean Decrease in Impurity* (MDI) 71

5.3.2 XGBoost — ~~*Weight* *Gain* (contagem de *splits*~~redução média da perda) 72
5.3.3 CatBoost — *PredictionValuesChange* 72
5.3.4 Regressão Logística — valor absoluto dos coeficientes 73
5.3.5 Comparação entre os métodos 73
5.4 ~~Configuração~~ Protocolo experimental 73
5.5 ~~Resultados do Experimento 1 (linha de base, 28 *features*)~~ 75
5.5 Comparação das configurações por validação cruzada 75
5.6 ~~Redução do conjunto de *features*~~ 77
5.5.1 Importância não é sinônimo de insubstituibilidade 78
5.5.2 ~~Configuração enxuta: Experimento 2 (11 *features*)~~ 78
5.6 ~~Teste~~ Avaliação final no conjunto de ~~generalização: curvas exclusivamente reais~~teste 79
5.7 Minimização de falsos negativos 81
5.7.1 Motivação: assimetria de custo entre erros 81
5.7.2 Método: variação do limiar de classificação 84
5.7.3 Escolha do ponto operacional 84
5.7.4 Resultados 85
5.7.5 Implicações para uso operacional 86
5.8 Estudo de caso: aplicação a uma curva real de Quaoar 89
5.8.1 Motivação 89
5.8.2 Procedimento 90
5.8.3 Aplicação a recortes da curva: sondando os anéis 92
5.8.4 Interpretação 96
5.9 ~~Comparação entre os experimentos~~Importância das características na configuração escolhida 97
5.9.1 Interpretação dos coeficientes da Regressão Logística 99
5.9.2 ~~Análise de importância das *features*~~ 99
5.9.2 A distância entre centroides do K-means 101
5.10 ~~Validação cruzada estratificada~~Teste de McNemar entre modelos 101
5.10.1 ~~Teste de McNemar entre modelos~~ 103
5.11 Curvas de aprendizado~~dos modelos de *boosting*~~ 104
5.12 Discussão dos resultados 107
5.12.1 Desempenho e generalização 107
5.12.2 Análise de redundância e importância 108
5.12.3 ~~Interpretação da importância das *features*~~ 108
5.12.3 Custo assimétrico e ajuste de limiar 109

6 Conclusões **111**
6.1 Resumo dos achados 111

6.2 Resposta à hipótese de pesquisa . . . 113
6.3 Contribuições originais . . . 113
6.4 Limitações . . . 115
6.5 Trabalhos futuros . . . 117

Referências Bibliográficas **119**

A Resultados experimentais complementares **127**
A.1 ~~Experimento 4: subconjunto de 14 *features*~~Métricas completas da validação cruzada . . . 127
A.2 ~~Experimento 5: 13 *features* (sem `Feature_Savgol_Min`)~~ . . . 128
A.2 Robustez da regra de seleção . . . 129
A.3 ~~Experimento 6: ablação isolada do K-means~~ . . . 129
A.3 ~~Variante do Experimento 3 com divisão 65/35: ablação do tamanho do treino~~ 130
A.3 Falsos positivos nas negativas reais . . . 130
A.4 Métricas no conjunto de teste de todas as configurações . . . 131
A.5 ~~Curvas ROC dos experimentos complementares~~ . . . 131
A.5 ~~Importância das *features* nos Experimentos 4 e 5~~ . . . 132

B Hiperparâmetros dos classificadores **135**

C Ambiente de software e versões **137**

Capítulo 1

Introdução

1.1 Contexto e Relevância

O Sistema Solar não nasceu em seu estado atual, mas foi esculpido por interações gravitacionais a partir do colapso de um núcleo pré-estelar, formando um disco de gás e poeira regulado por campos magnéticos sob condições extremas de temperatura e pressão (Morbidelli et al. , 2024). Nesse sentido, o estudo da dinâmica de seus constituintes é o primeiro passo em direção a compreender como sistemas planetários se formam e evoluem com o tempo.

Ao longo da história, o mapeamento do Sistema Solar evoluiu de registros rudimentares do movimento dos astros para análises sofisticadas de sua dinâmica. Áreas como Astronomia Fundamental e Mecânica Celeste passaram a fornecer modelos matemáticos e simulações que revelam os caminhos que levaram à configuração planetária atual.

De forma geral, a metodologia científica é fundamentada em processos de decisão baseados em dados: hipóteses são confrontadas com observações, e a interpretação confiável exige métodos estatísticos que quantifiquem incertezas e permitam distinguir sinal de ruído (Wall & Jenkins , 2003). Nesse contexto, a combinação de observações, cada vez mais precisas, e modelos mais sofisticados possibilitou importantes avanços na descrição de Sistemas Planetários.

Nas últimas décadas, técnicas numéricas como a integração direta das equações de movimento permitiram esclarecer processos antes apenas sugeridos teoricamente -–entre eles, a migração dos planetas gigantes e a reorganização das regiões de ressonância, elementos do Modelo de Nice (Gomes , 2009). São esses avanços que ajudam a reconstituir um passado dinâmico e caótico que moldou o Sistema Solar tal como o observamos hoje.

Nesse contexto, o Sistema Solar exterior é a região menos processada pelo Sol desde a formação do sistema planetário e, portanto, um laboratório natural para estudar as condições e os mecanismos primordiais, cujos registros ali se preservam (Gomes , 2009; Morbidelli et al. , 2024). Nele se destacam os **Centauros** — pequenos corpos com órbitas

heliocêntricas instáveis entre Júpiter e Netuno — e os **Objetos Transnetunianos** (do inglês, *Trans-Neptunian Objects*, TNOs), com órbitas além da de Netuno. A caracterização física desses corpos — tamanho, forma, albedo, densidade e presença de atmosfera, anéis ou satélites — é essencial para compreender a origem e a evolução dinâmica do nosso sistema planetário (Ortiz et al. , 2020). Esses corpos têm tamanhos típicos da ordem de centenas de quilômetros e ~~distâncias de 15~~ encontram-se a ~~100 UA do Sol~~distâncias ao Sol que vão de cerca de 5 UA (Centauros mais internos) a dezenas ou centenas de UA (TNOs); a combinação de pequeno porte e grande distância resulta em baixo brilho aparente e dificulta medições precisas. Até recentemente, propriedades físicas fundamentais -–tamanho, forma, massa, atmosfera -–só podiam ser inferidas por métodos indiretos (fotometria, espectroscopia, telescópios espaciais, etc.). A determinação de diâmetros, em particular, dependia sobretudo de técnicas radiométricas baseadas em telescópios espaciais (Fornasier et al. , 2013). No entanto, um tipo de observação terrestre, de custo relativamente baixo e acessível a telescópios modestos, passou a constituir uma técnica bastante relevante para a determinação da forma e do tamanho de pequenos corpos do Sistema Solar: **as ocultações estelares**.

Ocultações estelares ocorrem quando um corpo do Sistema Solar passa diante de uma estrela distante, bloqueando temporariamente sua luz para um dado observador na Terra (Knieling et al. , 2024; Ortiz et al. , 2020). A análise da **curva de luz de ocultação** — a variação temporal do fluxo da estrela registrada durante o evento, que não deve ser confundida com as curvas de luz rotacionais usadas para determinar períodos de rotação — permite estimar a posição do objeto, inferir sua forma projetada e identificar estruturas periféricas, como satélites e anéis (Cazeneuve et al. , 2023); sua versatilidade vai de asteroides próximos a TNOs extremamente distantes (Fraser et al. , 2024). A técnica tornou-se uma das mais precisas para a determinação de dimensões e formas projetadas desses objetos, sendo superada nesse aspecto apenas por encontros diretos com sondas espaciais. Ocultações são ainda empregadas há décadas no estudo de atmosferas planetárias (Zhu et al. , 2022).

Esse sucesso tem um preço. O volume de dados gerados por campanhas observacionais cresceu muito, impulsionado (i) pela precisão astrométrica dos catálogos do satélite Gaia (Gaia Collaboration et al. , 2016, 2023), que tornou as previsões de ocultação muito mais confiáveis, e (ii) pelo barateamento de câmeras astronômicas rápidas e sensíveis, que popularizou esse tipo de observação entre astrônomos amadores e redes de ciência cidadã. Com isso, a identificação manual dos eventos tornou-se uma tarefa custosa, o que impulsiona a adoção de métodos computacionais, em particular de técnicas de **aprendizado de máquina** (do inglês, *Machine Learning*, ML). Neste contexto, ML refere-se a algoritmos que, a partir de dados de exemplo, ajustam internamente seus parâmetros para realizar uma tarefa (por exemplo, decidir se uma curva contém ou não uma ocultação), em vez de seguir regras fixas programadas à mão. No contexto das ocultações, o ML tem sido

usado para detecção confiável de eventos, mitigação de ruídos e caracterização de sinais (Cazeneuve et al. , 2023): redes neurais convolucionais (como a ODNet, Cazeneuve et al. , 2023) analisam séries temporais ou imagens da estrela alvo e de estrelas de referência, distinguindo ocultações reais de flutuações atmosféricas ou artefatos instrumentais; em buscas por TNOs em campos densos, redes residuais fazem triagem dos candidatos gerados por técnicas de empilhamento e deslocamento (*shift-and-stack*), reduzindo detecções espúrias (Fraser et al. , 2024). Além disso, processos gaussianos têm sido explorados para modelar curvas de luz e extrair parâmetros temporais com estimativa nativa de incertezas (Deisenroth et al. , 2019; Knieling et al. , 2024).

1.2 Problema de Pesquisa

O avanço instrumental e a multiplicação de redes de observação (incluindo ciência cidadã) expandiram fortemente o volume de dados de ocultações. Em muitas campanhas, cada participante registra milhares de imagens, embora a ocultação ocupe apenas uma pequena fração desse conjunto (Cazeneuve et al. , 2023). O desafio central é identificar rapidamente, nesse volume massivo, quais curvas de luz exibem um evento positivo e, portanto, requerem atenção imediata.

É preciso, porém, distinguir dois níveis de exigência sobre essa triagem. Detectar a queda de fluxo profunda associada à detecção do **corpo principal** é o requisito mínimo: trata-se de um sinal de alta amplitude que qualquer ferramenta de detecção deve recuperar sem falhas. O objetivo de maior valor científico, contudo, é não deixar escapar os **sinais sutis** — assinaturas rasas de anéis, atmosferas tênues ou estruturas secundárias — que costumam passar despercebidos em uma primeira inspeção. O exemplo emblemático são os anéis do objeto transnetuniano (50000) Quaoar. O primeiro anel (Q1R), denso e situado muito além do limite de Roche, foi identificado a partir de uma **revisita** a dados de ocultações anteriores, motivada por uma observação nova (Morgado et al. , 2023); o segundo anel (Q2R), mais tênue, é descrito por Pereira et al. (2023). Casos como esse evidenciam que uma ferramenta capaz de chamar a atenção do analista para os trechos potencialmente relevantes de uma curva — mesmo quando o sinal é fraco — pode ser decisiva para que uma descoberta inédita não seja perdida. Esta dissertação ~~demonstra, entre seus resultados, justamente essa capacidadeaplicada a~~ ilustra essa capacidade, de forma exploratória, em uma curva real de Quaoar (Seção 5.8).

A tarefa é complexa. Ruídos observacionais e variabilidades atmosféricas (nuvens, *seeing* — o borramento da imagem estelar causado pela turbulência atmosférica —, etc.) podem produzir quedas ou picos espúrios que imitam uma ocultação (Cazeneuve et al. , 2023; Knieling et al. , 2024). Além disso, as observações frequentemente operam no limite instrumental, o que exige definições cuidadosas de detecção e critérios estatísticos para não confundir excursões de ruído com sinal; em buscas por TNOs em regiões densas,

sinais podem ainda ser artefatos da subtração de estrelas fixas (Fraser et al. , 2024).

A detecção rápida, precisa e escalável tornou-se, assim, um gargalo no fluxo de trabalho científico. Métodos que dispensam ML, como janelas de suavização, podem ser limitados em determinados regimes: a suavização tende a mascarar eventos muito rápidos (com tempos de ingresso e egresso menores que a janela escolhida), e o desempenho em estrelas com baixa relação sinal-ruído (do inglês, *Signal-to-Noise Ratio*, SNR) depende fortemente da experiência do analista. Nesses casos, o sinal pode ser facilmente confundido com flutuações de ruído. Técnicas de ML surgem como alternativa: redes neurais e modelos de regressão modernos (como os processos gaussianos) já são usados para filtrar candidatos, reconstruir dados e apoiar levantamentos (Deisenroth et al. , 2019; Fraser et al. , 2024; Carleo et al. , 2019), e apresentam-se como caminho natural para os desafios de escalabilidade e precisão na era do grande volume de dados (*big data*) em astronomia (Cazeneuve et al. , 2023).

O objetivo principal desta dissertação é desenvolver e validar uma abordagem automatizada, baseada em técnicas fundamentais de ML, para detectar de forma robusta e eficiente eventos de ocultação estelar em dados fotométricos. Os objetivos específicos são: (a) implementar uma~~fluxo cadeia~~ **de** ~~**trabalho em etapas**~~**processamento** (*pipeline*) em etapas: aquisição dos dados, pré-processamento e extração de **características numéricas** (*features*) a partir de cada curva de luz -~~–~~por exemplo, amplitude do fluxo, mínimo da série suavizada, distância entre ~~centróides~~ centroides de um agrupamento (*clustering*) em dois níveis, etc.; (b) **treinar** e comparar **classificadores** de ML (Regressão Logística, Random Forest, XGBoost e CatBoost), isto é, algoritmos que recebem um vetor de características e respondem "positivo" ou "negativo" (ou uma probabilidade de evento), ajustando seus parâmetros a partir de curvas cuja classificação verdadeira é conhecida; (c) avaliar o desempenho com métricas de classificação binária (acurácia, precisão, sensibilidade, F1-score, área sob a curva ROC) em dados reais e simulados, permitindo interpretar a capacidade de generalização e a importância de cada variável.

Neste trabalho optou-se por classificadores baseados em árvores de decisão e em vetores de características extraídos de forma explícita a partir das curvas, em vez de redes convolucionais que operam diretamente sobre as séries temporais brutas (como o ODNet). As razões são três: a **interpretabilidade** — é possível verificar quais ~~grandezas (*features*)~~ características mais influenciam a decisão do modelo, o que é valioso para a análise científica —, a **reprodutibilidade** com volumes de dados moderados e a **facilidade** de integração a ~~*pipelines*~~ ~~de~~ cadeias de processamento de análise já existentes. A metodologia explora a capacidade desses modelos em identificar padrões típicos de ocultação e distingui-los de ruídos instrumentais, atmosféricos ou intrínsecos, com perspectiva de incorporar também redes neurais em trabalhos futuros.

A ~~*pipeline*~~ cadeia de processamento desenvolvida atua como ferramenta de organização, priorização e triagem em grandes bases observacionais: (1) indica quais curvas de

luz merecem atenção prioritária e (2) estima a probabilidade de evento em curvas ruidosas, visando superar limitações atuais de precisão e velocidade e, no futuro, permitir implementações em tempo real a bordo de telescópios.

A hipótese de pesquisa que norteia o trabalho é a de que ~~é possível obter desempenho superior ou comparável ao de abordagens manuais ou baseadas em redes convolucionais usando uma *pipeline* baseada em~~ características clássicas extraídas das curvas (estatísticas do fluxo, derivadas, testes entre quartis, distância entre ~~centróides~~ centroides do K-means, etc.)~~e em~~, combinadas a ~~***ensembles***~~**comitês** (*ensembles*) de árvores (combinações de muitos modelos de árvore de decisão), ~~aproveitando as~~ permitem separar com alto desempenho as curvas com e sem ocultação, superando com folga um critério de limiar simples aplicado a uma única grandeza, e oferecem as vantagens de interpretabilidade, velocidade de processamento, organização dos dados e controle sobre cada etapa. A comparação direta com redes convolucionais e com a inspeção humana, sobre os mesmos dados, fica como perspectiva.

A dissertação está organizada da seguinte forma. O **Capítulo 2** apresenta a fenomenologia das ocultações estelares e o processamento dos dados astronômicos que originam as curvas de luz. O **Capítulo 3** expõe os fundamentos dos modelos de ML utilizados, em linguagem acessível a leitores com formação em física ou astronomia: classificação **supervisionada** (aprendizado a partir de exemplos com rótulo conhecido), agrupamento (K-means) e os conceitos de validação e generalização. O **Capítulo 4** descreve a metodologia completa da ~~*pipeline*~~cadeia de processamento: aquisição e armazenamento dos dados, pré-processamento, extração de características e treinamento e avaliação dos classificadores. O **Capítulo 5** apresenta os resultados dos experimentos e a discussão, retomando os objetivos específicos e as métricas de avaliação. O **Capítulo 6** apresenta as conclusões do trabalho, com contribuições e limitações de forma explícita.

Capítulo 2

Ocultações Estelares e Processamento de Dados

2.1 O que são Ocultações Estelares?

Uma **ocultação estelar** ocorre quando um objeto celeste (planeta, satélite natural, asteroide ou objeto transnetuniano) passa na frente de uma estrela distante, bloqueando temporariamente parte ou toda a sua luz. Esse evento se manifesta como uma queda característica no fluxo luminoso registrado por um observador na Terra. Como a estrela ocultada está a distâncias muito maiores que a do corpo do Sistema Solar à Terra (a estrela a anos-luz; o corpo a minutos ou horas-luz), os raios luminosos da estrela que chegam ao corpo são essencialmente paralelos entre si. Por isso, no plano perpendicular à direção da estrela — o plano do céu —, a sombra reproduz o perfil do corpo em escala 1:1. Essa correspondência deixa de ser fiel quando o tamanho do corpo se torna comparável à escala de Fresnel ou ao diâmetro aparente da estrela projetado à distância do corpo (Seção 2.3); sobre o solo, a sombra aparece ainda alongada pela inclinação da superfície terrestre em relação aos raios. Essa projeção, combinada à alta resolução temporal das observações, permite determinar tamanho, forma projetada no plano do céu e, em casos favoráveis, atmosfera, anéis ou satélites do corpo ocultante, com precisão comparável à de sondas espaciais (Knieling et al. , 2024; Sicardy et al. , 2011). A Figura 2.1 ilustra esquematicamente o fenômeno para o Centauro (10199) Chariklo e seu sistema de anéis: a curva de luz de ocultação (painel inferior) registra as quedas de fluxo estelar produzidas pela passagem dos anéis e do corpo principal diante da estrela, tal como medidas por um observador na superfície da Terra. Chariklo serve aqui apenas como ilustração do fenômeno. Nas demais figuras deste capítulo adota-se como exemplo a ocultação por Umbriel, satélite de Urano, de 21 de setembro de 2020 (Assafin et al. , 2023): além de ser um caso bem documentado, as curvas de luz dessa campanha fazem parte do banco de dados utilizado nesta dissertação (Capítulo 4).

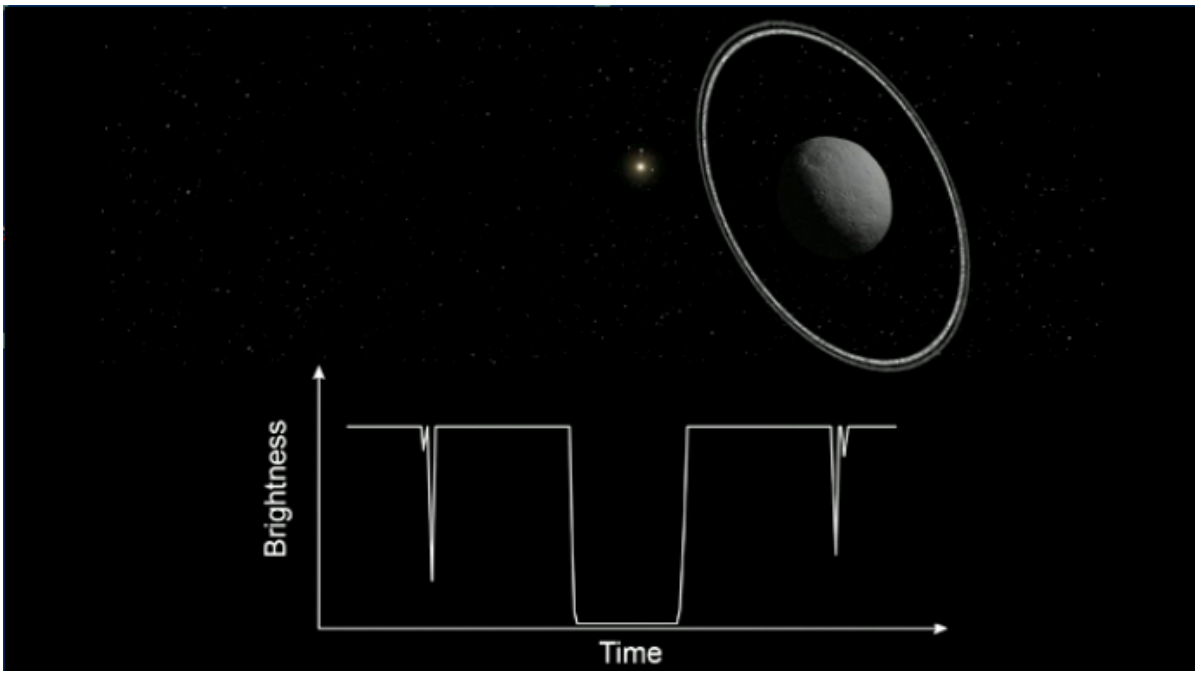
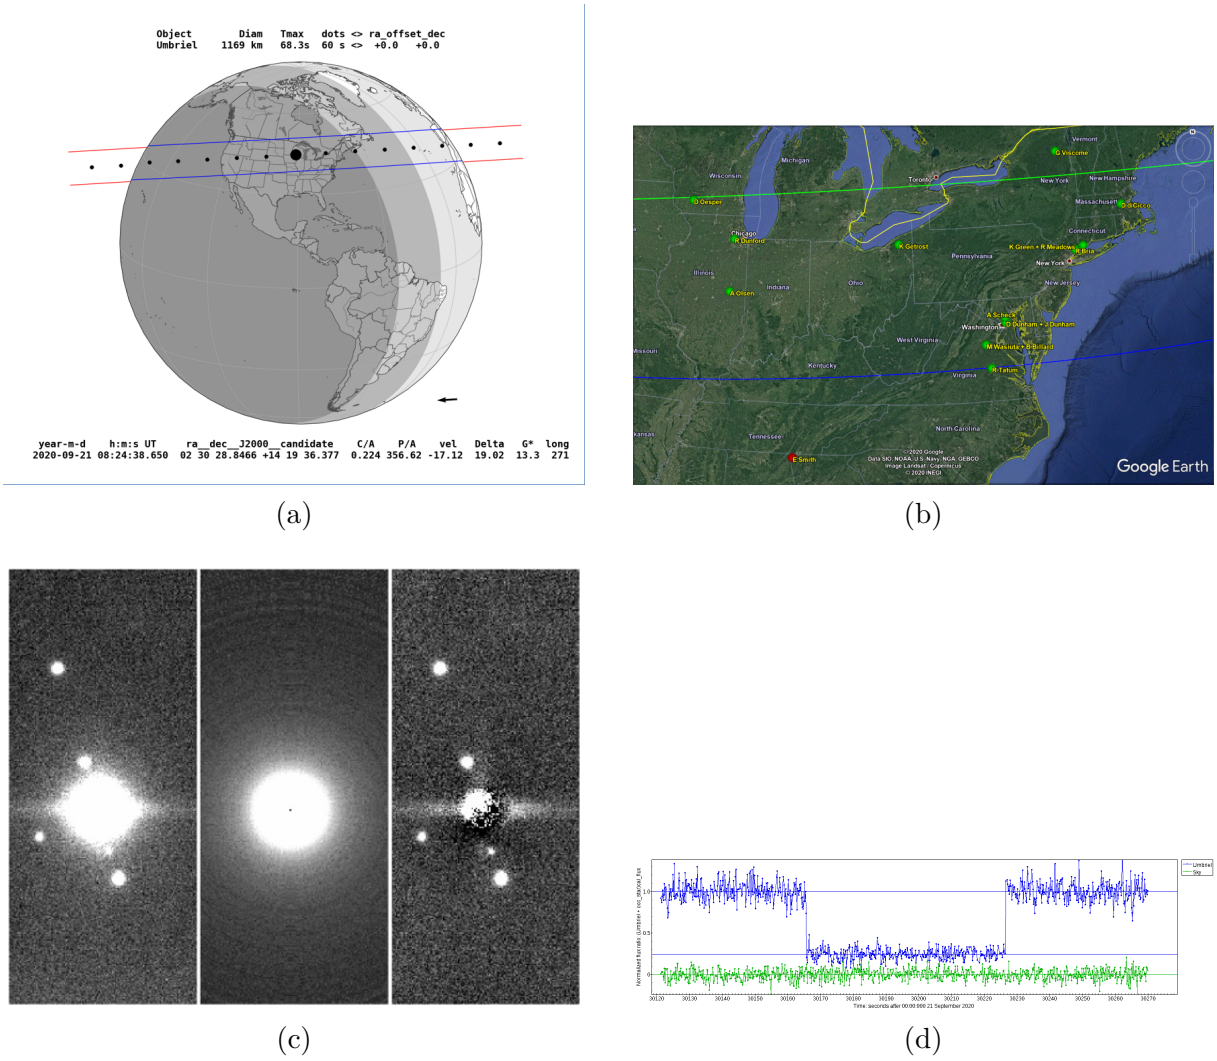


Figura 2.1: Representação artística de uma ocultação estelar pelo Centauro (10199) Chariklo e seu sistema de anéis. A curva de luz esquemática (abaixo) mostra as quedas de fluxo correspondentes à passagem dos anéis e do corpo principal diante da estrela. Crédito: Lucie Maquet, 2014.

A sombra do corpo ocultante projeta-se na superfície terrestre e move-se sobre ela com velocidade V_S — de alguns a algumas dezenas de $\mathrm{km\,s^{-1}}$ —, que é a velocidade do corpo *relativa ao observador*, projetada no plano do céu. Ela combina o movimento orbital do corpo, o movimento orbital da Terra (termo dominante para Centauros e TNOs, que se deslocam a poucos $\mathrm{km\,s^{-1}}$) e, em menor grau, a rotação da Terra ($\lesssim 0{,}46\,\mathrm{km\,s^{-1}}$). Na ocultação por Umbriel de 2020, por exemplo, $V_S \approx 17\,\mathrm{km\,s^{-1}}$ (Figura 2.2a). Cada observador dentro do caminho da sombra registra o intervalo de tempo durante o qual a estrela permanece oculta — uma **corda** positiva —; os instantes de imersão e emersão, projetados no plano do céu, fornecem dois pontos do limbo do objeto. Observadores fora do caminho registram cordas negativas, que limitam até onde o limbo pode se estender. A duração e o instante central da corda dependem da posição do observador em relação ao trajeto da sombra. Vários observadores em locais diferentes produzem várias cordas; a combinação dessas cordas permite reconstruir a forma e o tamanho do corpo no plano do céu com precisão quilométrica (Assafin et al. , 2023; Ortiz et al. , 2020). No entanto, a previsão de ocultações depende criticamente da precisão das posições estelares e das efemérides do corpo; a melhoria contínua desses ingredientes tem ampliado o número de eventos previstos e observados com sucesso, inserindo a técnica na era do grande volume de dados ~~*(big data)*~~ em astronomia (Knieling et al. , 2024; Gomes-Júnior et al. , 2022). Graças à precisão astrométrica do catálogo Gaia (Gaia Collaboration et al. , 2016, 2023), o gargalo atual para a previsão de ocultações está na qualidade das efemérides

dos pequenos corpos do Sistema Solar. Na análise publicada da ocultação por Umbriel, a posição da estrela foi tomada do Gaia DR3, e o seu diâmetro angular aparente, do Gaia DR2 (Assafin et al. , 2023). A Figura 2.2 percorre, para essa ocultação por Umbriel, o fluxo observacional completo — do mapa de previsão da sombra e do posicionamento dos observadores aos quadros (*frames*) CCD e à curva de luz de ocultação reduzida.



(a) (b)

(c) (d)

Figura 2.2: Exemplo completo do fluxo observacional: ocultação estelar por Umbriel (satélite de Urano), observada em 21 de setembro de ~~2020 (Assafin et al. , 2023).~~ 2020. (a) Mapa de previsão da sombra sobre a superfície terrestre. (b) Detalhe do posicionamento dos observadores na costa leste dos EUA (Google Earth). (c) Quadros CCD de uma das estações, processados pelo PRAIA: imagem original (esquerda), modelo do halo de Urano (centro) e imagem após a subtração por coronagrafia digital (direita), que viabiliza a fotometria de Umbriel e da estrela. (d) Curva de luz de ocultação resultante: razão entre o fluxo da estrela somado ao de Umbriel e o fluxo de calibração (azul), e fundo de céu (verde). Fonte: adaptado de Assafin et al. (2023).

A observação é tipicamente feita por telescópios amadores e profissionais, com detectores CCD ou câmeras de vídeo. A análise das imagens serve-se de **fotometria diferencial de abertura**, em que se mede o fluxo da estrela-alvo em relação ao de estrelas

de referência no mesmo campo. Como a luz de todas atravessa praticamente a mesma coluna atmosférica no mesmo instante, cancelam-se efeitos sistemáticos comuns, como extinção atmosférica, variações de transparência etc. Essa fotometria é usualmente feita com pacotes dedicados, como o PRAIA (*Platform for Reduction of Astronomical Images Automatically*) (Assafin et al. , 2011), que também implementa a **coronagrafia digital**: a subtração, imagem a imagem, de um modelo do halo de um objeto muito brilhante próximo ao alvo — como Urano, no caso de Umbriel (Assafin , 2023). A **curva de luz de ocultação** é a razão entre o fluxo medido na abertura da estrela-alvo e o fluxo das estrelas de referência da mesma imagem, em função do tempo. Em geral, o corpo ocultante não é resolvido da estrela: a abertura contém a soma estrela + corpo, e a luz do corpo continua presente durante a ocultação (Seção 2.3). Em uma detecção **positiva**, a curva exibe um trecho de fluxo aproximadamente constante (estrela ainda não ocultada), uma queda relativamente abrupta (a imersão: o corpo passa diante da estrela e o observador entra na sombra), um patamar de baixo fluxo e o retorno ao nível inicial (a emersão). Em uma detecção **negativa**, não há queda significativa; a curva permanece estável (ou com flutuações de ruído), e essa informação é igualmente útil: uma corda negativa delimita até onde o limbo do corpo pode se estender naquela direção. O ajuste de uma curva sintética — que considera o diâmetro aparente da estrela projetado à distância do corpo, a difração de Fresnel e o tempo de exposição usado na observação — permite obter os instantes de imersão e emersão com precisão da ordem de frações de segundo e, projetando esses instantes no plano do céu, as dimensões e a forma bidimensional do objeto (Gomes-Júnior et al. , 2022; Ortiz et al. , 2020).

2.2 Da observação às curvas de luz: coleta e armazenamento

As curvas de luz utilizadas em campanhas de ocultações provêm de redes de telescópios (profissionais e amadores) que registram o fluxo da estrela alvo em cadência rápida (exposições de fração de segundo a poucos segundos, com o mínimo possível de intervalo entre imagens sucessivas — o chamado tempo morto) para maximizar a resolução temporal e, portanto, espacial ao longo da corda. O volume de dados gerado é grande: cada observação pode produzir milhares de quadros e da ordem de gigabytes por evento (Cazeneuve et al. , 2023). A redução fotométrica (extração do fluxo em cada quadro) é feita com o PRAIA, que automatiza a fotometria de abertura e a construção da curva de luz a partir das imagens (Assafin , 2023). O *Stellar Occultation Reduction and Analysis* (SORA, Gomes-Júnior et al. , 2022) é utilizado na etapa de análise e redução pós-fotometria para ajuste de modelos às curvas e extração de parâmetros físicos; sua saída pode alimentar bancos de dados e catálogos (como os do Grupo do Rio, grupo de pesquisa em ocultações

estelares formado por pesquisadores do Observatório Nacional e de instituições colaboradoras). Após a redução, as curvas são armazenadas em bancos de dados ou catálogos (por exemplo, VizieR, bancos de grupos de pesquisa), em formato tabular: cada registro associa uma observação a uma série de pontos (tempo, fluxo), além de metadados (objeto ocultante, data, observador, classificação positiva/negativa quando disponível, etc.).

Nesta dissertação, a ~~*pipeline* de~~ cadeia de processamento de detecção (Capítulo 4) parte de curvas **já reduzidas** (pós-PRAIA/pós-SORA ou equivalentes), obtidas de fontes externas (Grupo do Rio, VizieR) e inseridas em um banco de dados relacional. Ou seja, o fluxo aqui descrito começa após a etapa de redução fotométrica e análise; a estrutura do banco, o fluxo de aquisição e a normalização do fluxo são detalhados no Capítulo 4. Aqui basta destacar que as curvas de luz são o insumo central para a etapa de classificação por ML: cada curva será convertida em um vetor de características e classificada como positiva ou negativa pelos modelos descritos no Capítulo 3.

2.3 Caracterização das curvas de luz de ocultação

Do ponto de vista observacional, uma curva de luz de ocultação é uma série temporal de fluxo, normalizada de modo que o nível fora da ocultação (estrela + corpo) valha 1. Sua **morfologia** depende de fatores físicos — razão de brilho entre o corpo e a estrela, diâmetro aparente da estrela, difração de Fresnel, velocidade da sombra e presença de atmosfera, anéis ou satélites — e de fatores instrumentais e atmosféricos — tempo de exposição e tempo morto, cintilação, nuvens e qualidade da fotometria.

Detecção positiva e negativa. Em uma detecção positiva, a curva exibe uma queda de fluxo durante o intervalo de tempo em que o ~~trânsito ocorre~~observador está dentro da sombra. Para um corpo sem atmosfera, muito maior que a estrela projetada e que a escala de Fresnel, qualquer corda que cruze o disco bloqueia toda a luz da estrela, seja ela central ou não: a posição da corda determina a *duração* da queda, e não a sua profundidade. A profundidade depende da razão entre os brilhos do corpo e da estrela, porque a luz do próprio corpo continua a ser registrada na abertura. O patamar normalizado vale

$$F_{\mathrm{oc}} = \frac{F_{\mathrm{c}}}{F_{\star} + F_{\mathrm{c}}} = \frac{1}{1 + 10^{\,0{,}4\,(m_{\mathrm{c}} - m_{\star})}},$$

em que F e m são o fluxo e a magnitude do corpo (c) e da estrela ($\star$). Na ocultação por Umbriel (Figura 2.2d), o patamar $\approx 0{,}24$ corresponde a $m_{\mathrm{c}} - m_{\star} \approx 1{,}2$ mag; para TNOs, em geral muito mais fracos que a estrela ocultada, o patamar fica próximo de zero. Em uma detecção negativa, o observador está fora da sombra; a curva não apresenta queda significativa, apenas flutuações típicas de ruído fotométrico, atmosférico e instrumental. Tanto positivas quanto negativas são úteis: as primeiras fornecem cordas para o ajuste de forma e tamanho; as últimas ajudam a delimitar a borda da sombra e a descartar falsos

positivos (Gomes-Júnior et al. , 2022).

Fatores que afetam a forma da curva. O perfil da queda (ingresso e egresso) é influenciado pelo **diâmetro aparente da estrela** à distância do corpo ocultante: estrelas cujo diâmetro angular não é desprezível nessa escala produzem, em combinação com o ciclo de integração do detector, uma transição suave entre os níveis de fluxo desocultado e ocultado da estrela. A **difração de Fresnel** nas bordas do corpo suaviza adicionalmente as regiões de ingresso e egresso; a escala típica é da ordem de $L_{\mathrm{F}} = \sqrt{D\lambda/2}$, onde D é a distância entre o observador e o corpo ocultante ~~(ou, em convenções equivalentes, a distância estrela–corpo)~~ e λ o comprimento de onda (Roques et al. , 1987); a distância da estrela não entra na expressão, pois ela está, para todos os efeitos, no infinito. Essa suavização faz com que os instantes de "meia-luz" não coincidam exatamente com o contato geométrico do limbo; exposições longas ou baixa resolução temporal podem mascarar os detalhes da difração e reduzir a precisão da extração dos tempos de imersão e emersão (Gomes-Júnior et al. , 2022). O **tempo de exposição** converte-se em resolução espacial ao longo da corda por meio da relação $r_t = V_S \times t_{\mathrm{exp}}$, onde r_t é a resolução espacial efetiva, V_S é a velocidade da sombra projetada na superfície terrestre e t_{exp} é o tempo de exposição. Desse modo, exposições longas suavizam ou mascaram os detalhes da difração. A rigor, a amostragem ao longo da corda é determinada pelo **ciclo completo** entre quadros sucessivos — o tempo de exposição somado ao tempo morto: enquanto t_{exp} borra cada ponto ao longo de um intervalo $V_S\, t_{\mathrm{exp}}$, o tempo morto abre lacunas entre medidas sucessivas, de modo que um tempo morto elevado degrada a resolução efetiva mesmo com exposições curtas — daí a busca por minimizá-lo na aquisição (Seção 2.2). A Figura 2.3 mostra como essas componentes — difração de Fresnel, tamanho angular da estrela e ciclo de integração do detector — se combinam no modelo de curva de luz utilizado pelo SORA (Gomes-Júnior et al. , 2022). Em corpos com atmosfera, refração e absorção modificam o perfil da curva e permitem inferir composição e estrutura da atmosfera, como perfis de temperatura e densidade em função da altitude (Sicardy et al. , 2016); anéis ou satélites podem produzir quedas adicionais ou assimetrias (Braga-Ribas et al. , 2014). Para a detecção automatizada por ML, o que importa é que curvas com ocultação exibem uma queda sustentada e característica no fluxo, ao passo que curvas negativas ou com apenas ruído não exibem esse padrão; flutuações atmosféricas ou instrumentais podem, no entanto, imitar quedas pontuais, o que torna a tarefa de classificação não trivial e motiva o uso de modelos treinados e de características bem escolhidas (Capítulos 3 e 4).

Exemplo numérico: escala de Fresnel. Para um objeto transnetuniano (TNO) a uma distância típica de $D = 40\,\mathrm{UA} \approx 6{,}0 \times 10^{12}\,\mathrm{m}$, observado no visível ($\lambda = 500\,\mathrm{nm}$), a escala de Fresnel é

$$L_{\mathrm{F}} = \sqrt{\frac{D\lambda}{2}} \approx \sqrt{\frac{6{,}0 \times 10^{12} \times 5{,}0 \times 10^{-7}}{2}} \approx 1{,}2\ \mathrm{km}.$$

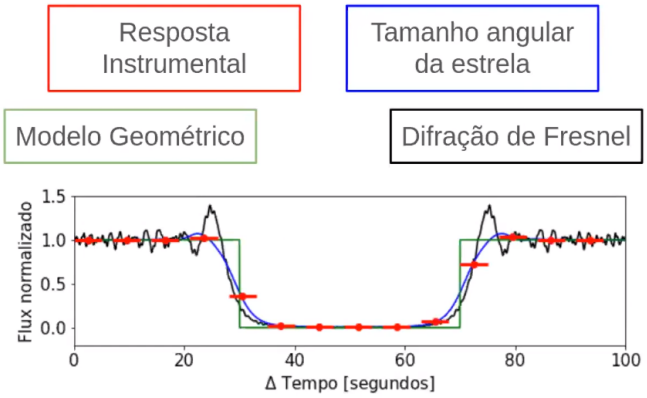
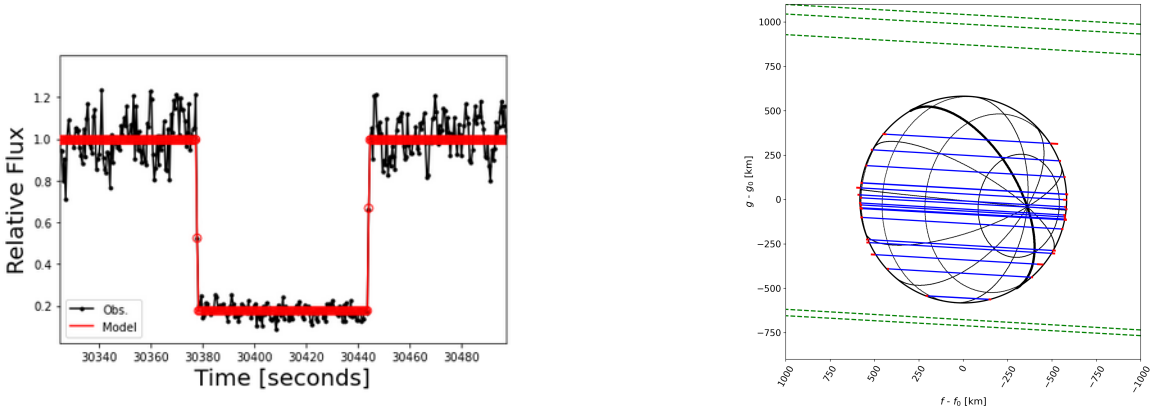


Figura 2.3: Componentes do modelo de curva de luz sintética utilizado pelo SORA (Gomes-Júnior et al. , 2022). Verde: modelo geométrico, o ponto de partida — corpo opaco de borda nítida ocultando uma estrela pontual, sem difração e com amostragem instantânea. Preto: o mesmo modelo incluindo a difração de Fresnel. Azul: incluindo também o diâmetro angular da estrela. Traços vermelhos: resposta instrumental, isto é, o valor que cada exposição registraria ao integrar a curva azul durante o tempo de exposição (a largura de cada traço). A curva sintética ajustada a dados reais combina todos esses efeitos (Figura 2.4a).

~~Essa escala define~~ A difração limita a resolução ~~espacial efetiva~~ *ao longo da corda*, isto é, na direção ~~perpendicular à corda~~do movimento da sombra através do limbo: detalhes menores que L_{F} nessa direção são suavizados~~pela difração.~~ ; na direção perpendicular às cordas, a resolução é dada pelo espaçamento entre os observadores. Na prática, a resolução efetiva ao longo da corda é o maior entre três comprimentos: L_{F}, o diâmetro aparente da estrela projetado à distância do corpo e o deslocamento da sombra durante um ciclo de aquisição. Trata-se de uma resolução da ordem do quilômetro na observação de objetos a dezenas de unidades astronômicas de distância — superior à de qualquer telescópio óptico terrestre operando por imageamento direto. É essa capacidade de resolução que torna as ocultações estelares uma ferramenta única para a caracterização de pequenos corpos do Sistema Solar.

Relação sinal-ruído e qualidade. A confiabilidade da detecção e da extração de parâmetros físicos depende da relação sinal-ruído (SNR) da curva. Em astronomia, muitas medições são feitas no limite da detectabilidade instrumental, onde o ruído pode produzir excursões que imitam fontes tênues; definições operacionais claras de detecção e critérios estatísticos são essenciais para interpretar os dados de forma confiável (Wall & Jenkins , 2003). SNR alto favorece a identificação clara da queda e a precisão dos instantes de imersão e emersão; curvas com SNR baixo são mais difíceis de classificar e mais suscetíveis a falsos positivos e negativos. Na ~~*pipeline*~~ cadeia de processamento desta dissertação, as características extraídas de cada curva (estatísticas de fluxo, derivadas, métricas de forma, etc.) são escolhidas de forma a capturar padrões discriminativos entre curvas com e sem ocultação, mesmo na presença de ruído; o conjunto preciso de ~~*features*~~ características e

o protocolo de treinamento são apresentados no Capítulo 4. A Figura 2.4 ilustra, para a ocultação por Umbriel (2020), o ajuste de uma curva sintética a uma das curvas de luz de ocultação observadas nessa campanha — com os instantes de imersão e emersão indicados — e o perfil do limbo reconstruído a partir do conjunto de cordas (Assafin et al. , 2023).



(a) (b)

Figura 2.4: (a) Curva de luz de ocultação observada (preto) e curva sintética ajustada (vermelho) para uma das cordas da ocultação por Umbriel em 2020; os instantes de imersão e emersão encontram-se muito próximos dos pontos circulados nas bordas da queda~~(Assafin et al. , 2023)~~. (b) Perfil do limbo de Umbriel no plano do céu: cada linha azul é uma corda positiva projetada, com as incertezas dos extremos em vermelho~~(Assafin et al. , 2023)~~. Fonte: adaptado de Assafin et al. (2023).

2.4 Considerações finais do capítulo

Este capítulo situou as ocultações estelares como fenômeno astronômico e as curvas de luz de ocultação como produto observacional central. Vimos que a sombra do corpo, projetada em escala 1:1 no plano do céu, é amostrada pelas cordas dos observadores, e que é a combinação de cordas positivas e negativas que permite reconstruir forma e tamanho. Vimos também que a astrometria estelar do Gaia, ao tornar mais precisa a previsão de onde a sombra passará, aumentou o número de eventos observados com sucesso. A coleta e o armazenamento dos dados foram descritos em linhas gerais, e foram resumidas as características observacionais das curvas. A combinação de previsões mais precisas, da popularização de câmeras rápidas e de baixo custo e das redes de observadores multiplicou o número de curvas de luz de ocultação a analisar e tornou penosa a triagem manual de todas elas. Essa escala motiva o desenvolvimento de métodos automatizados de detecção baseados em aprendizado de máquina, cujos fundamentos são apresentados no Capítulo 3 e cuja implementação é detalhada no Capítulo 4. Interessa-nos, em particular, que sejam apontados eventos tênues que passaram despercebidos num primeiro tratamento

das curvas — como ocorreu com os anéis de Quaoar: o primeiro (Q1R) foi revelado pela revisita de dados antigos motivada por uma observação nova (Morgado et al. , 2023), e o segundo (Q2R) foi descrito por Pereira et al. (2023). Um alerta confiável nesses casos é suporte para campanhas observacionais e descobertas importantes.

Capítulo 3

Modelos e ~~algoritmos para~~ Algoritmos de Aprendizado de Máquina

O Capítulo 2 mostrou que as campanhas de ocultação estelar podem produzir diversas curvas de luz, sendo número suficiente para que haja dificuldade na análise completa e minuciosa. Cada curva pode ser resumida por um conjunto de características como profundidade da queda, estatísticas de ruído, entre outros. A questão é: *a partir dessa descrição numérica de uma curva, é possível decidir automaticamente se ela contém ou não uma ocultação?* Trata-se de um problema de **classificação binária**, e os métodos de ~~*Machine Learning*~~ aprendizado de máquina são as ferramentas naturais para resolvê-lo. Com isso, os objetivos deste capítulo são: definir e situar os modelos de ~~*Machine Learning*~~ aprendizado de máquina como ferramentas de descobertas e classificações no contexto científico; formalizar o problema de classificação (espaço de atributos, rótulos, regiões de decisão); apresentar os principais modelos utilizados na ~~*pipeline*~~cadeia de processamento; e, por fim, discutir algoritmos de otimização, engenharia de características (*feature engineering*), validação de modelos e os riscos de falsos resultados.

3.1 Conceitos fundamentais de aprendizado de máquina

3.1.1 Definição e papel do aprendizado de máquina

O ~~*Machine Learning* (ML), ou~~ aprendizado de máquina ~~,~~ é uma área na qual os sistemas "aprendem" a partir de dados, sem serem explicitamente programados para cada tarefa (Geron , 2019). Em vez de regras fixas codificadas à mão, um algoritmo de ML é alimentado com informações e **ajusta seus próprios parâmetros** (por exemplo,

coeficientes de uma combinação linear) para capturar padrões ou relações nos dados. Esse processo de ajuste é o que se chama de **treinamento**; ao final, o modelo está "treinado" e pode ser aplicado a novas informações. O objetivo é permitir que o sistema melhore seu desempenho à medida que mais dados ou mais iterações estejam disponíveis, especialmente em problemas sem solução analítica ~~fechada~~ ou com grandes volumes de dados.

No contexto científico, o ML costuma ser visto como uma "caixa-preta" que produz previsões sem explicação. Essa visão reflete usos industriais em que a precisão preditiva prevalece sobre a interpretabilidade. Em ciência, porém, o ML pode ir além: atuando como ferramenta de descoberta, revelando padrões que podem ser incorporados a uma teoria formal de causa e efeito. O papel do ML não é substituir a teoria, mas auxiliar na sua formulação, identificando os padrões que a teoria buscará explicar. Segundo López (2020), por exemplo, o uso do ML na ciência pode ser agrupado em algumas funções típicas:

(i) **Sugerir a existência de algo novo:** ML pode encontrar padrões não previstos, indicando a existência de relações ainda não descobertas. Em matemática, algoritmos já auxiliaram a conjecturar teoremas que depois foram demonstrados formalmente (Gryak et al. , 2018).

(ii) **Descobrir o grau de importância das variáveis:** técnicas como a *Mean Decrease Accuracy* (MDA, a queda média da acurácia) permitem avaliar o impacto de cada variável (~~***feature*, ou**~~ **característica** numérica de entrada) sobre a saída do modelo de ML para exemplos novos — aqui, "predição" é a resposta do classificador, e não a previsão de uma ocultação a partir de efemérides. A ideia é treinar o modelo, medir o desempenho (por exemplo, via acurácia), embaralhar uma variável por vez e verificar se o desempenho cai; se cair, a variável é importante (Liu , 2004). Assim, o ML identifica quais variáveis devem compor explicações teóricas, mesmo sem revelar o mecanismo causal.

(iii) **Explorar relações de causa e efeito:** um modelo pode ser ajustado com dados nos quais um determinado efeito está ausente. Depois, quando esse efeito passa a atuar, o modelo continua produzindo previsões baseadas no cenário anterior. Se as observações reais passarem a divergir das previsões, essa diferença pode ser um indício de que o efeito alterou o sistema, sugerindo possíveis relações causais.

(iv) **Redução e simplificação:** em dados multidimensionais, técnicas de redução de dimensionalidade — por exemplo, a Análise de Componentes Principais (PCA) — projetam os dados em um espaço de menor dimensão, tornando mais evidentes padrões, agrupamentos e relações entre observações, o que favorece a interpretação dos resultados.

(v) **Encontrar padrões desconhecidos:** o ML pode atuar na detecção de eventos raros ou de anomalias em grandes volumes de dados — por exemplo, na triagem automática de curvas de luz de ocultação obtidas em campanhas dedicadas e por redes de observadores, como as reunidas no catálogo `B/occ/asteroid` do VizieR. A maioria dos levantamentos de imageamento de grande campo não tem tempos de exposição e cadência compatíveis com a duração de uma ocultação. O ML indica onde vale a pena investigar, mesmo sem explicar o mecanismo.

Neste trabalho, o ML atua sobretudo na ~~função de **encontrar padrões desconhecidos** e~~ **detecção de eventos** em grandes volumes de dados (triagem) e na função de **descobrir o grau de importância das variáveis** (importância das ~~*features* nos *ensembles*~~ características nos comitês de árvores), em apoio à decisão do pesquisador sobre quais curvas merecem análise detalhada.

3.1.2 Aprendizado supervisionado versus não supervisionado

A ~~taxonomia~~ classificação usual divide o ML em dois cenários, conforme a natureza dos dados:

- **Supervisionado:** cada exemplo possui um rótulo (classe ou valor numérico). Tarefas típicas: classificação (rótulo discreto) e regressão (rótulo contínuo). Exemplos: filtro de *spam*, previsão de preços ~~, etc~~e, na astronomia, classificação morfológica de galáxias e estimativa fotométrica do desvio para o vermelho (*redshift* fotométrico).
- **Não supervisionado:** os dados não possuem rótulos. Tarefas típicas: agrupamento~~ (*clustering*)~~, detecção de anomalias, redução de dimensionalidade. Exemplos: segmentação de clientes, identificação de ~~*outliers* (anomalias), etc~~anomalias ou valores atípicos (*outliers*) e, na astronomia, agrupamento de asteroides em famílias dinâmicas ou em classes espectrais e busca de objetos anômalos em grandes levantamentos (Ivezić et al. , 2014).

Neste trabalho, o foco é o **paradigma supervisionado**, em particular a **classificação binária**. No aprendizado supervisionado, o objetivo é encontrar uma função f que mapeie cada entrada $\vec{x}$ (por exemplo, o vetor de características de uma curva de luz) a um rótulo y (por exemplo, "ocultação presente" ou "ausente"). Os rótulos usados no treinamento vêm da classificação já conhecida dos dados (a chamada **verdade de campo**, ou *ground truth* -–por exemplo, a análise prévia de um especialista ou o catálogo). O objetivo é que f **generalize** bem, ou seja, que erre pouco em dados novos que não foram usados no ajuste. A detecção de ocultações estelares é formulada exatamente assim: a curva de luz contém um evento de ocultação (classe positiva, $y = 1$) ou não (classe negativa, $y = 0$). Os classificadores (Regressão Logística, Random Forest, XGBoost, CatBoost)

recebem vetores de características extraídos das curvas e produzem uma classe ou uma probabilidade de classe, permitindo triagem e priorização automáticas no fluxo da ~~*pipeline*~~ cadeia de processamento (Capítulo 4). Neste trabalho, os classificadores foram usados por meio de bibliotecas Python de código aberto, cujas documentações pedem a citação dos trabalhos originais: *scikit-learn* (Pedregosa et al. , 2011), para a Regressão Logística e o Random Forest (Breiman , 2001); XGBoost (Chen & Guestrin , 2016); e CatBoost (Prokhorenkova et al. , 2018).

3.2 O problema da classificação supervisionada

Em notação matemática, uma amostra rotulada é representada pelo par ordenado (ou **tupla**, isto é, uma sequência ordenada e finita de elementos) $Z = (X, Y)$. Aqui $X = \{\vec{x}_1, \vec{x}_2, \ldots, \vec{x}_n\}$ é o conjunto de **vetores de características**: cada $\vec{x}_i \in \mathbb{R}^d$ é um vetor com d números que resumem, no caso deste trabalho, uma curva de luz de ocultação (por exemplo, a amplitude e o mínimo do fluxo suavizado). O número d é a "dimensionalidade" do problema (neste trabalho, entre 11 e 28 ~~*features*~~características, conforme o experimento; Capítulo 5). ~~O conjunto $Y = \{y_1, y_2, \ldots, y_n\}$~~ Dispostos como linhas, esses n vetores formam a **matriz de dados X**, de dimensão $n \times d$. O conjunto $Y = \{y_1, y_2, \ldots, y_n\}$ contém os **rótulos**: a classificação verdadeira de cada exemplo, com $y_i \in \{0, 1\}$ no caso binário (0 = sem ocultação, 1 = com ocultação).

Um **classificador** é uma função $f\colon \mathbb{R}^d \longrightarrow \{0, 1\}$ (ou, em geral, $\{1, \ldots, c\}$ para c classes) que, dado um vetor $\vec{x}$, prediz um rótulo y. Em muitos modelos, f produz primeiro uma **probabilidade** de a classe ser positiva; a decisão final é então "positivo" se essa probabilidade for maior ou igual a 50 %, e "negativo" caso contrário. O uso do valor 0,5 é intuitivo, mas é arbitrário e depende do objetivo do modelo. Esse valor de corte é chamado de **limiar** de decisão (em inglês, *threshold*) e será denotado por τ; seu ajuste é discutido na Seção 5.7.

A função f divide o espaço $\mathbb{R}^d$ em **regiões de decisão**: $R_k = \{\vec{x} \in \mathbb{R}^d \mid f(\vec{x}) = k\}$. Cada região corresponde a uma classe. O objetivo do treinamento é estimar f a partir dos dados (X, Y) de modo que f generalize bem para novos exemplos, não vistos durante o treinamento.

Antes de apresentar os modelos de classificação, convém fixar a ideia de treinamento como minimização de uma função de custo. O exemplo mais natural de ser explorado é a **regressão linear**. O modelo $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$ descreve o comportamento médio de uma variável resposta y dado x, com erro ϵ_i (Figura 3.1).

Os parâmetros ~~são~~ podem ser estimados pelo método dos **mínimos quadrados**, que constitui o primeiro exemplo de algoritmo de otimização nesta dissertação. No caso mais

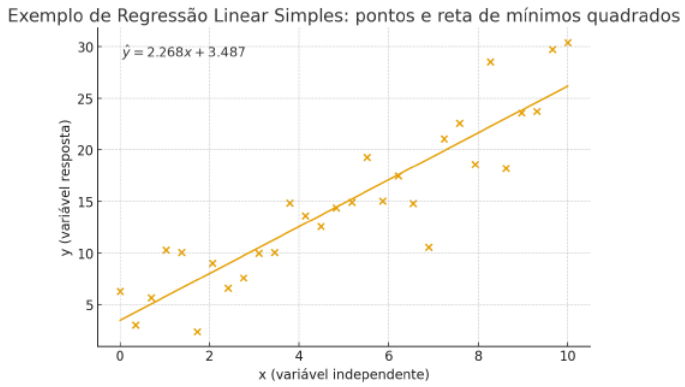


Figura 3.1: Exemplo ilustrativo de regressão linear simples, com dados genéricos, não referentes a curvas de luz de ocultação. Fonte: Levada (2026).

simples ($\mathbb{R}^2$), o modelo é $y = \alpha + \beta x$ e a função de custo é

$$J(\alpha, \beta) = \sum_{i=1}^{n} (y_i - \alpha - \beta x_i)^2,$$

minimizada pela condição $\partial J/\partial\alpha = 0$, $\partial J/\partial\beta = 0$. A generalização para múltiplas variáveis (d dimensões) segue naturalmente em notação vetorial. O modelo prediz ~~$\hat{\vec{y}} = X\vec{\theta}$,~~ ~~com X~~ $\hat{\vec{y}} = \mathbf{X}\vec{\theta}$, com $\mathbf{X}$ a matriz de dados (cada linha é um exemplo, cada coluna uma variável) e $\vec{\theta}$ o vetor de parâmetros. A função de custo torna-se

$$J(\vec{\theta}) = (\vec{y} - \cancel{X}\mathbf{X}\vec{\theta})^\top (\vec{y} - \cancel{X}\mathbf{X}\vec{\theta}) = \sum_{i=1}^{n} \left(y_i - \vec{\theta}^\top \vec{x}_i\right)^2.$$

A condição de mínimo, $\nabla_{\vec{\theta}} J = \vec{0}$, fornece a **equação normal**:

$$\cancel{X}\mathbf{X}^\top(\cancel{X}\mathbf{X}\vec{\theta} - \vec{y}) = \vec{0} \quad \Longrightarrow \quad \vec{\theta}^* = (\cancel{X}\mathbf{X}^\top\cancel{X}\mathbf{X})^{-1}\cancel{X}\mathbf{X}^\top\vec{y}.$$

Após estimar $\vec{\theta}^*$, o modelo pode predizer $\vec{y}$ para novos dados de entrada (Geron , 2019; Levada , 2026).

Apesar dos problemas de regressão servirem de excelente passo inicial para se compreender as métricas e interpretações básicas dos modelos de ML, para problemas de classificação, não usamos regressão linear diretamente -~~–~~a solução completa desses problemas pode ser acompanhada no Capítulo 2 de Levada (2026). A **Regressão Logística** mantém a combinação linear, mas mapeia a saída ao intervalo $(0, 1)$ por uma **função sigmoide**, $\sigma(z) = 1/(1 + e^{-z})$ — uma curva em forma de "S" que leva qualquer número real a um valor entre 0 e 1 (Figura 3.5) — e utiliza o custo de entropia cruzada, para o qual **não existe solução ~~fechada~~analítica** (o treinamento é feito por algoritmos iterativos~~-~~; Seção 3.5).

3.3 Modelos de classificação utilizados na cadeia de processamento

3.3.1 Regressão Logística

A Regressão Logística é um classificador probabilístico. Similarmente à Regressão Linear, este modelo calcula uma soma ponderada das características de entrada, mas, em vez de gerar o resultado diretamente, gera a *logística* (função sigmoide) desse resultado (Geron , 2019). Em outras palavras, ele transforma combinações lineares de características em probabilidades válidas.

Suponha um problema de classificação no qual se deseja identificar uma ocultação em uma curva de luz a partir de uma única informação: o **tamanho da queda máxima do fluxo**. Curvas com maiores quedas possuem maior probabilidade de conter a ocultação. A Figura 3.2 ilustra a aplicação da regressão linear a oito exemplos ilustrativos — quatro com grandes quedas de fluxo e quatro com quedas pequenas: nesse caso simples, o limiar 0,5 sobre a reta separa perfeitamente as duas classes, embora a reta produza valores fora do intervalo $[0, 1]$.

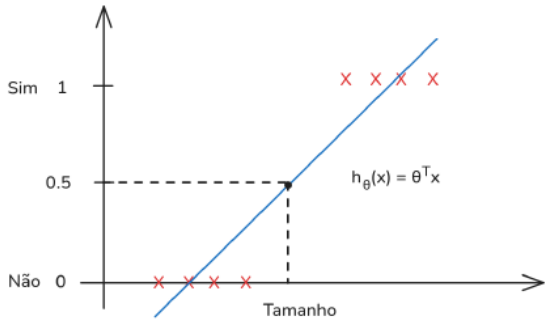


Figura 3.2: Classificação binária (sim = 1, não = 0) em função do tamanho da queda de fluxo (marcadores). A linha tracejada indica o limiar de decisão; a linha contínua, o resultado da regressão linear aplicada aos dados (ver discussão no texto). Fonte: adaptado de Levada (2026).

Nesse caso, teríamos infinitos valores sob uma reta para a variável de saída. ~~Notadamente, a~~ A solução mais intuitiva seria considerar um limiar simples na metade da reta. No entanto, suponha que, no mesmo conjunto de dados (*dataset*), tivéssemos um ~~elemento *outlier*~~valor atípico, uma anomalia. A Figura 3.3 ilustra a situação: a curva discrepante tem amplitude muito diferente das demais (por exemplo, por falta de normalização), a reta se desloca e o limiar que antes funcionava deixa de ser útil, pois agora a metade da reta passa a considerar um ponto positivo como negativo ao mesmo tempo que vários pontos positivos ficam próximos do limiar de decisão (e apenas o ~~*outlier*~~ valor atípico se encontra confortavelmente longe das curvas consideradas negativas),

gerando dúvida para o analista que estuda os dados.

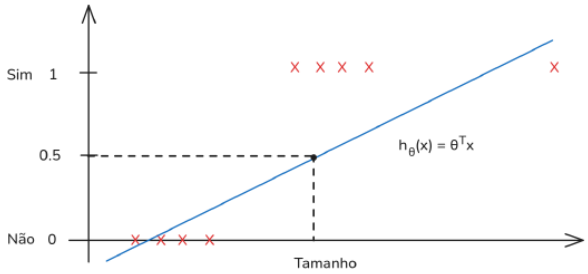


Figura 3.3: Como na Figura 3.2, com a adição de um ponto discrepante (~~*outlier*~~valor atípico). Fonte: adaptado de Levada (2026).

~~O que podemos ver é que~~ Observa-se que a reta de regressão pode sofrer alterações significativas com a inclusão de novos pontos, evidenciando sua sensibilidade aos dados observados. Além disso, a regressão linear pode gerar valores fora do intervalo [0,1], incompatíveis com a interpretação probabilística. Dessa forma, sua sensibilidade a ~~*outliers*~~ valores atípicos e a ausência de uma saída naturalmente probabilística fazem da regressão linear uma abordagem inadequada para as tarefas de classificação necessárias a este trabalho.

Mais adequada a esse fim, a regressão logística funciona de forma similar aos modelos lineares (saída contínua), mas é adaptada ao nosso problema. O primeiro ponto de adaptação é a interpretação probabilística: a combinação linear $\vec{\theta}^\top \vec{x}$ será mapeada pela logística ao intervalo $(0, 1)$, permitindo a interpretação como a probabilidade da classe ser positiva (Levada , 2026).

Em notação vetorial, seja $\vec{\theta}$ o vetor de parâmetros e $\vec{x}$ o vetor de atributos; a probabilidade predita é

$$\hat{p} = h_{\vec{\theta}}(\vec{x}) = \sigma(\vec{\theta}^\top \vec{x}) = \frac{1}{1 + e^{-\vec{\theta}^\top \vec{x}}}.$$

A decisão é: classe 1 se $\hat{p} \geqslant 0{,}5$, caso contrário classe 0. Isso porque a saída continua sendo contínua, mas agora limitada ao intervalo $(0, 1)$. ~~Vale lembrar, também,~~ Ressalte-se que o valor de 0,5 pode ser alterado a depender da calibração do modelo, como discutido no início do capítulo.

O segundo ponto ~~a ser adaptado será quanto ao treinamento. Nesse sentido,~~ de adaptação refere-se ao treinamento: passa-se a utilizar outra função de custo ~~ao invés dos mínimo quadrados:~~ em vez dos mínimos quadrados, a **entropia cruzada** (ou perda logarítmica, *log loss*). Essa medida penaliza predições distantes do rótulo real. Por exemplo, se temos uma curva positiva (ocultação presente), e o modelo prediz uma probabilidade baixa de haver ocultação, o custo deverá ser alto.

$$loss = -[y \log p + (1 - y) \log (1 - p)]$$

onde p é a probabilidade prevista pelo modelo e a perda ~~(loss)~~ deverá ser aplicada a um único ponto. Ou seja, para um conjunto de n exemplos, com rótulos $y^{(i)} \in \{0, 1\}$ e probabilidades preditas $\hat{p}^{(i)}$, a função é

$$J(\vec{\theta}) = -\frac{1}{n}\sum_{i=1}^{n}\left[y^{(i)}\log(\hat{p}^{(i)}) + (1-y^{(i)})\log(1-\hat{p}^{(i)})\right]. \tag{3.1}$$

A minimização de $J(\vec{\theta})$ é equivalente à maximização da log-verossimilhança (MLE), de modo que os parâmetros estimados são estatisticamente ótimos sob o modelo probabilístico assumido (Geron , 2019; Levada , 2026). O ajuste é ~~realizado por gradiente descendente(veremos mais detalhes sobre os algoritmos de otimização na~~ iterativo. O mecanismo é ilustrado a seguir com o gradiente descendente, por ser o esquema mais intuitivo; a implementação usada neste trabalho (*scikit-learn*), porém, emprega o método quasi-Newton L-BFGS (Seção 3.5). O gradiente de J em relação a $\vec{\theta}$ pode ser escrito na forma vetorial

$$\nabla_{\vec{\theta}} J(\vec{\theta}) = \frac{1}{n}\mathbf{X}^{\top}\big(\sigma(\mathbf{X}\vec{\theta}) - \vec{y}\big),$$

onde ~~X~~ $\mathbf{X}$ é a matriz de dados e $\vec{y}$ o vetor de rótulos. A atualização dos parâmetros em cada iteração segue a **direção oposta ao gradiente** (direção de maior descida do custo), com passo controlado pela **taxa de aprendizado** η (análogo ao passo de um método numérico de minimização). Trata-se, portanto, de uma medida sobre o quão distante da realidade estão as previsões do modelo.

Exemplo numérico: uma iteração do gradiente descendente. Para tornar o mecanismo concreto, considere $n = 4$ curvas com uma única ~~*feature*~~ característica x (amplitude da queda de fluxo, normalizada entre 0 e 1) e rótulos y (0 = sem ocultação, 1 = com ocultação):

Curva	x	y	$\hat{p}$ (inicial)
1	0,2	0	0,50
2	0,4	0	0,50
3	0,7	1	0,50
4	0,9	1	0,50

Tabela 3.1: Dados do exemplo numérico da Regressão Logística (valores ilustrativos).

Inicializamos $\theta_0 = 0$ e $\theta_1 = 0$. Como $\sigma(0) = 0{,}5$, todas as curvas recebem probabilidade $\hat{p} = 0{,}5$ e o custo inicial é $J = -\log(0{,}5) \approx 0{,}693$. Os gradientes são $\partial J/\partial\theta_0 = \frac{1}{4}\sum_i(\hat{p}_i - y_i) = 0$ e $\partial J/\partial\theta_1 = \frac{1}{4}\sum_i(\hat{p}_i - y_i)\,x_i = \frac{1}{4}(0{,}1 + 0{,}2 - 0{,}35 - 0{,}45) = -0{,}125$. Com taxa de aprendizado $\eta = 1{,}0$, a atualização dá $\theta_1 \leftarrow 0 - 1{,}0 \times (-0{,}125) = 0{,}125$. Recalculando as probabilidades com o novo θ_1, obtemos $\hat{p}_1 = \sigma(0{,}025) \approx 0{,}506$, $\hat{p}_2 \approx 0{,}512$, $\hat{p}_3 \approx 0{,}522$ e $\hat{p}_4 \approx 0{,}528$. O custo cai para $J \approx 0{,}678$. Uma única iteração já empurrou as probabilidades na direção correta: as curvas com maior amplitude (3 e 4, positivas)

receberam $\hat{p}$ ligeiramente maior que as negativas. Após centenas de iterações, a separação se consolida e o custo diminui continuamente. Como esses quatro pontos são linearmente separáveis (todo $x \leqslant 0{,}4$ é negativo e todo $x \geqslant 0{,}7$ é positivo), sem regularização o custo só tende a zero no limite $|\theta_1| \to \infty$: não existe mínimo finito. Essa é uma das motivações para a regularização apresentada a seguir.

Sem nenhuma restrição, a Regressão Logística é livre para atribuir pesos enormes a qualquer ~~*feature*~~ característica — inclusive ao ruído. Se uma curva de treino por acaso tem um pico espúrio que coincide com a classe positiva, o modelo pode atribuir peso grande a essa flutuação; na hora de classificar curvas novas, esse peso exagerado prejudica a predição. Esse é o problema do **sobreajuste** (*overfitting*, discutido em detalhe na Seção 3.6.3): o modelo "decorou" particularidades do treino em vez de aprender o padrão geral.

A solução é a **regularização**: impor um custo adicional aos pesos grandes, forçando o modelo a manter coeficientes moderados e a distribuir a "explicação" entre múltiplas ~~*features*~~ características em vez de apostar tudo em uma (Geron , 2019; Levada , 2026). As três formas principais são:

- **Ridge (ℓ_2):** adiciona ao custo o termo $\frac{\alpha}{2}\sum_j \theta_j^2$. Os coeficientes são *encolhidos* em direção a zero, mas raramente se anulam -–todos os atributos permanecem no modelo. Funciona bem com ~~*features*~~ características correlacionadas, reduzindo o sobreajuste sem descartar ~~características~~nenhuma delas.

- **Lasso (ℓ_1):** adiciona $\alpha\sum_j |\theta_j|$. Tende a **zerar** coeficientes de atributos irrelevantes, atuando como seleção automática de variáveis. Em contrapartida, pode comportar-se de forma errática com muitas variáveis correlacionadas (tendendo a escolher apenas uma) ou quando o número de variáveis supera o de instâncias. A função de custo não é diferenciável em $\theta_j = 0$ (algoritmos de otimização não sabem a direção do próximo passo), exigindo subgradientes na otimização.

- **Elastic Net:** combina as penalidades Ridge e Lasso com uma taxa de mistura, unindo os benefícios de ambas. É recomendado quando há muitas variáveis correlacionadas.

Existe uma interpretação elegante dessas penalidades do ponto de vista bayesiano (Estimativa MAP — *Maximum A Posteriori*). Regularizar equivale a assumir uma crença prévia (*prior*) sobre os valores dos coeficientes do modelo *antes* de ver os dados. No Ridge, essa crença é uma **distribuição Gaussiana** centrada em zero: acredita-se que os pesos são provavelmente pequenos, mas não necessariamente nulos — as caudas suaves da Gaussiana permitem valores moderados (Figura 3.4). No Lasso, a crença é uma **distribuição de Laplace**, que tem um pico afiado em zero: acredita-se que muitos pesos

são zero, e apenas alguns poucos são relevantes — daí o efeito de seleção automática de variáveis (Geron , 2019; Levada , 2026).

O hiperparâmetro α (ou $C = 1/\alpha$) controla a força da penalização: α grande significa uma crença prévia forte de que os pesos devem ser pequenos; α pequeno deixa o modelo mais livre. ~~A~~ Em geral, a escolha de α é feita por **validação cruzada**: treina-se o modelo com diferentes valores de α e seleciona-se aquele de melhor desempenho médio nas partições de validação (Geron , 2019), as chamadas *dobras* (*folds*), definidas na Seção 3.6.5.

É essencial **escalonar** as ~~*features*~~ características (por exemplo, com o `StandardScaler` do *scikit-learn*) antes de aplicar Ridge ou Lasso, pois ambas as penalidades são sensíveis à escala dos dados. Por exemplo, um atributo medido em quilômetros terá coeficiente numericamente muito diferente do mesmo atributo medido em metros, e a penalização tratará ambos de forma desigual. Nesta dissertação, utiliza-se ~~Ridge ou Lasso na Regressão Logística, conforme documentado no~~ apenas a penalidade Ridge (ℓ_2), com $C = 1$ (valor padrão do *scikit-learn*, sem busca de hiperparâmetros), conforme o Apêndice B.

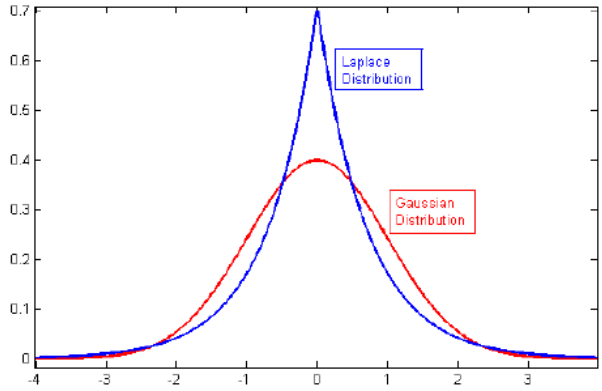


Figura 3.4: Comparação entre as distribuições Gaussiana e de Laplace, que correspondem aos priors assumidos sobre os parâmetros na interpretação bayesiana das regularizações Ridge e Lasso, respectivamente.

A Regressão Logística serve de base conceitual para entender classificadores probabilísticos e foi também treinada e avaliada na ~~*pipeline*~~ cadeia de processamento desta dissertação, junto com os demais modelos (Random Forest, XGBoost, CatBoost), que tipicamente oferecem melhor desempenho em dados tabulares e fornecem importância de variáveis. A função sigmoide $\sigma(z) = 1/(1 + e^{-z})$ está ilustrada na Figura 3.5.

3.3.2 Árvores de decisão e critérios de impureza

Os modelos Random Forest, XGBoost e CatBoost são baseados em **árvores de decisão**. Uma árvore de decisão é um classificador que funciona como um fluxograma: em cada "nó" pergunta-se o valor de uma das características (por exemplo, "o mínimo do fluxo suavizado é menor que 0,85?"); conforme a resposta, segue-se por um dos dois ramos até

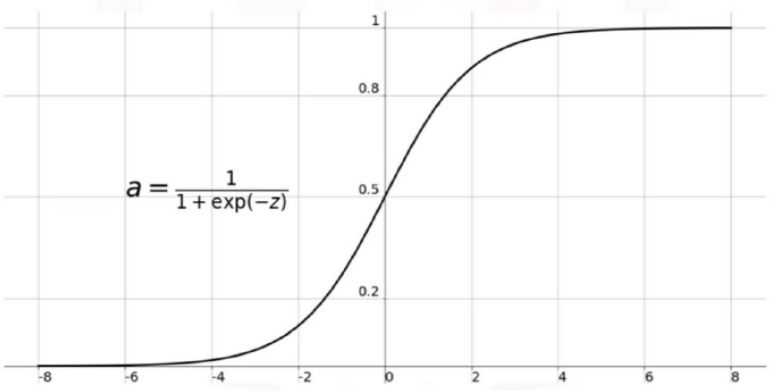


Figura 3.5: Função sigmoide $\sigma(z) = 1/(1 + e^{-z})$.

um novo nó ou até uma "folha", que devolve a classe predita. O espaço de entradas (vetores de características) fica assim particionado em regiões (chamadas de hiper-retângulos), cada uma associada a uma classe (Levada , 2026). Uma das maiores vantagens desses modelos é a **interpretabilidade**: as regras podem ser lidas e aplicadas manualmente, em contraste com modelos opacos como redes neurais. A biblioteca Python *scikit-learn* (Pedregosa et al. , 2011), usada neste trabalho na Regressão Logística, no Random Forest, no K-means, na imputação, na padronização e no cálculo das métricas, utiliza o algoritmo **CART** (*Classification and Regression Trees*), que produz árvores binárias e escolhe, em cada nó, a divisão (*split*) que maximiza a pureza dos nós filhos (Geron , 2019). Os dois critérios de impureza mais usados para classificação são o **coeficiente de Gini** e a **entropia**. Para um nó i com proporções $p_{i,k}$ de exemplos na classe k (com $k = 1, \ldots, c$ classes):

$$G_i = 1 - \sum_{k=1}^{c} p_{i,k}^2, \qquad H_i = -\sum_{k=1}^{c} p_{i,k} \log_2(p_{i,k}) \quad \text{(convenção } 0 \log 0 = 0\text{)}. \tag{3.2}$$

Nessas expressões, G_i é o coeficiente de Gini e H_i é a **entropia** do nó i: ambos medem a impureza, ou seja, o quanto as classes estão misturadas naquele nó. Os dois valem zero quando o nó é puro (todos os exemplos pertencem a uma única classe) e crescem à medida que as classes ficam mais equilibradas entre si.

O Gini tende a isolar a classe mais frequente; a entropia tende a produzir árvores mais equilibradas. A divisão é feita de modo a maximizar a redução da impureza (ganho de informação). Árvores de decisão são instáveis e sensíveis a pequenas variações nos dados; sem restrições, tendem ao sobreajuste. Para regularizar, utilizam-se critérios de parada como a profundidade máxima e o número mínimo de amostras por nó ou por folha (Geron , 2019) — no *scikit-learn*, os hiperparâmetros `max_depth` e `min_samples_leaf`. A **poda** (*pruning*) pode ser aplicada após o crescimento completo, removendo ramos que não contribuem significativamente para a capacidade preditiva (Levada , 2026).

Exemplo numérico: redução de impureza de Gini em uma divisão. Considere um nó contendo 8 curvas de luz de treino, sendo 4 positivas (com ocultação) e 4 negativas. Como as classes estão perfeitamente misturadas, a impureza é máxima para o caso binário:

$$G_{\text{nó}} = 1 - \left[\left(\tfrac{4}{8}\right)^2 + \left(\tfrac{4}{8}\right)^2\right] = 1 - 0{,}5 = 0{,}5.$$

A árvore testa então uma divisão candidata — por exemplo, "profundidade da queda $> 0{,}5$?" — que separa as 8 curvas em dois nós-filhos:

- **Filho da esquerda** (3 curvas, todas positivas): $G_{\text{esq}} = 1 - [1^2 + 0^2] = 0$ (nó *puro*).
- **Filho da direita** (5 curvas, 1 positiva e 4 negativas): $G_{\text{dir}} = 1 - \left[\left(\tfrac{1}{5}\right)^2 + \left(\tfrac{4}{5}\right)^2\right] = 1 - 0{,}68 = 0{,}32$.

A impureza após a divisão é a média **ponderada** pelo número de exemplos em cada filho:

$$G_{\text{div}} = \frac{3}{8} \times 0 + \frac{5}{8} \times 0{,}32 = 0{,}20,$$

e o **ganho** (redução de impureza) é $\Delta G = G_{\text{nó}} - G_{\text{div}} = 0{,}50 - 0{,}20 = 0{,}30$. A divisão deixou os nós mais "puros" (o da esquerda já decide com certeza pela classe positiva). O algoritmo CART avalia todos os cortes candidatos de todas as ~~*features*~~ características e escolhe aquele que produz o *maior* ganho; o processo se repete em cada nó-filho até atingir um critério de parada.

3.3.3 Random Forest (Floresta Aleatória)

Random Forest (Breiman , 2001) é um método de ~~***ensemble***~~**comitê**: em vez de uma única árvore, treina-se um grande número de árvores de decisão (por exemplo, centenas), cada uma em uma **amostra aleatória** dos dados (amostragem com reposição, ou *bootstrap*) e usando, em cada divisão de nó, apenas um subconjunto aleatório das características (Geron , 2019; Levada , 2026). A predição final é obtida por **votação majoritária**: cada árvore "vota" em uma classe e escolhe-se a classe que recebeu mais votos. A força da floresta está na **descorrelação** entre as árvores. Aqui, ***bagging*** (de *bootstrap aggregating*) é a técnica de treinar cada árvore em uma amostra distinta dos dados, sorteada com reposição, e depois agregar as predições por votação: como cada árvore vê um conjunto ligeiramente diferente, elas erram em casos diferentes. O *bagging* e a escolha aleatória de atributos em cada nó garantem essa diversidade; ao agregar centenas de árvores, o modelo mantém o baixo viés das árvores individuais e reduz drasticamente a **variância**. Uma vantagem colateral é a estimativa ~~***out-of-bag***~~**fora da bolsa** (*out-of-bag*, OOB): como cada árvore é treinada em aproximadamente 63% dos dados (amostragem com reposição), cerca de 37% das instâncias ficam "fora da bolsa" para cada árvore e podem ser

usadas como conjunto de validação interno, permitindo estimar o erro de generalização sem um conjunto de teste separado (Geron , 2019). Uma variante ainda mais aleatória são as **Extra-Trees** (*Extremely Randomized Trees*): em vez de procurar o melhor ponto de corte em cada atributo, sorteiam limiares ao acaso e ficam com o melhor entre os sorteados. Isso acelera o treinamento e pode reduzir ainda mais a variância, ao custo de um viés ligeiramente maior (Geron , 2019).

A aleatoriedade em dois níveis — nos dados e nos atributos — reduz a correlação entre as árvores e diminui a **variância** do ~~*ensemble*~~comitê: ao agregar predições de árvores pouco correlacionadas, o erro global tende a ser menor que o de uma única árvore (Geron , 2019). O **Teorema do Júri de Condorcet**[1] ilustra a ideia: se cada "votante" (árvore) tem probabilidade maior que 50% de acertar, a decisão por maioria tende a melhorar com o número de votantes. Por exemplo, várias árvores com acurácia individual em torno de 65% podem produzir um ~~*ensemble*~~ comitê com acurácia bem maior (da ordem de 90% ou mais), desde que os erros não sejam idênticos. O ganho depende da **diversidade** entre os modelos: se todos errarem nos mesmos casos, a votação não corrige.

Além da predição, Random Forest fornece uma estimativa natural da **importância das variáveis** (por exemplo, pela queda média na impureza ou na acurácia quando a variável é permutada), o que é útil para análise exploratória e seleção de ~~*features*~~ características (Capítulo 4). Nesta dissertação, a importância das variáveis ~~nos modelos baseados em árvores (~~é obtida pela métrica padrão de cada biblioteca: no Random Forest, ~~XGBoost, CatBoost) é obtida~~ pela **queda média na impureza** (Gini) ~~em cada divisão em~~ nas divisões em que a variável participa ~~; para a~~ (MDI, do inglês *Mean Decrease in Impurity*); no XGBoost, pelo **ganho médio** (*gain*) das divisões que utilizam a variável; no CatBoost, pelo ***PredictionValuesChange*** (descrito adiante); e, na Regressão Logística, ~~utilizam-se os coeficientes estimados (em valor absoluto ou normalizado)~~ pelo módulo dos coeficientes padronizados. O critério adotado na ~~*pipeline*~~ cadeia de processamento é detalhado no Capítulo 4, e os resultados ~~(ranking —~~ ordenação (*ranking*) e magnitude das importâncias ~~)~~ — são apresentados no Capítulo 5.

3.3.4 XGBoost (*eXtreme Gradient Boosting*)

O ***boosting*** é uma família de métodos em que os modelos são treinados **um após o outro**: cada novo modelo (por exemplo, uma árvore) é ajustado para corrigir os erros do modelo anterior, de modo que a combinação de todos forme um preditor forte a partir de vários preditores "fracos" (Geron , 2019; Levada , 2026). O ***gradient boosting*** utiliza

[1] Formulado por Condorcet (1785): se n votantes independentes acertam, cada um, com probabilidade $p > 1/2$, a probabilidade de a maioria acertar é $P_n = \sum_{k>n/2} \binom{n}{k} p^k (1-p)^{n-k}$, que cresce com n e tende a 1. Para $n = 25$ e $p = 0{,}65$, obtém-se $P_{25} \approx 0{,}94$ (Figura 3.7). Como as árvores de uma floresta não são independentes, o ganho real é menor; ver Geron (2019).

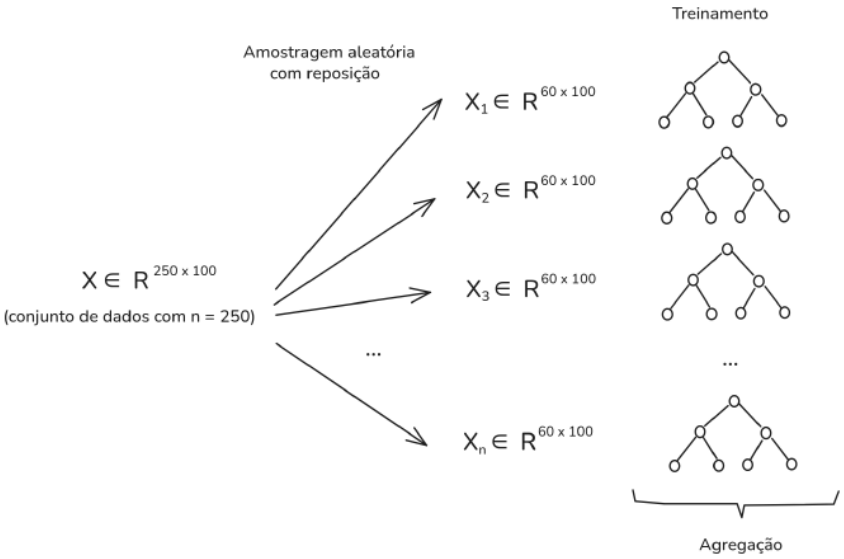


Figura 3.6: Esquema simplificado do funcionamento de um Random Forest.

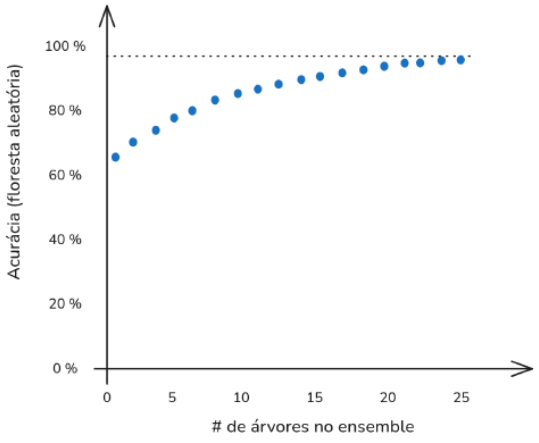


Figura 3.7: Exemplo ilustrativo: 25 árvores com acurácia individual em torno de 65% podem resultar em uma floresta com acurácia de aproximadamente 94%.

um modelo aditivo: na iteração m,

$$\hat{f}_m(\vec{x}) = \hat{f}_{m-1}(\vec{x}) + \eta\, h_m(\vec{x}), \tag{3.3}$$

onde h_m é um novo aprendiz fraco (por exemplo, uma árvore rasa) ajustado ao **gradiente negativo** da função de perda em relação à predição atual $\hat{f}_{m-1}$ — ou seja, aos "resíduos" no espaço da perda (Geron , 2019). A taxa de aprendizado η controla a contribuição de cada árvore (encolhimento, *shrinkage*), reduzindo o risco de ~~*overfitting*~~sobreajuste. O XGBoost (*eXtreme Gradient Boosting*) (Chen & Guestrin , 2016) aprimora esse esquema de duas maneiras. Primeiro, adiciona à função de custo termos de regularização explícitos, que penalizam o número de folhas e os pesos das folhas. Segundo, usa uma expansão de Taylor de segunda ordem da perda para calcular a atualização de cada árvore. O resultado é uma implementação eficiente e de alto desempenho (Geron , 2019).

O XGBoost tornou-se muito popular em competições de ciência de dados (como as da plataforma Kaggle) e em aplicações práticas, por sua precisão e velocidade. Em contraste com o Random Forest (que treina árvores em paralelo), o *boosting* é inerentemente sequencial, o que pode limitar o paralelismo em certas fases, mas o ganho de desempenho preditivo costuma compensar.

3.3.5 CatBoost

CatBoost (*Categorical Boosting*) é um algoritmo de *gradient boosting* baseado em árvores, desenvolvido pela Yandex, empresa russa de tecnologia conhecida por seu mecanismo de busca (Prokhorenkova et al. , 2018), que incorpora inovações voltadas à robustez e à eficiência do treinamento.

Assim como o XGBoost, o CatBoost constrói árvores sequencialmente, minimizando uma função de perda por gradiente. Entretanto, sua arquitetura difere em dois aspectos relevantes:

- ***Ordered Boosting*:** para calcular os resíduos de cada exemplo, o CatBoost utiliza apenas os modelos treinados com exemplos anteriores a ele (em uma permutação aleatória do conjunto), combatendo o ~~*target leakage*~~ (vazamento de rótulo (*target leakage*) — situação em que a predição de um exemplo é influenciada pelo próprio rótulo durante o treinamento. Esse procedimento reduz o viés otimista na estimativa dos resíduos, especialmente em conjuntos pequenos ou moderados.

- ***Oblivious Decision Trees*:** cada nível da árvore aplica a **mesma condição de divisão** a todos os nós daquele nível. Essa restrição produz árvores simétricas (ou *oblivious*), que são mais rápidas de avaliar e atuam como regularização estrutural, reduzindo o risco de ~~*overfitting*~~sobreajuste.

O CatBoost também possui tratamento nativo de variáveis categóricas — codificando-as internamente sem necessidade de ~~*one-hot encoding* (~~codificação *one-hot* (que substitui uma variável categórica com c valores possíveis por c colunas binárias, uma por categoria) — e opções para lidar com desbalanceamento de classes, como o parâmetro `auto_class_weights='Balanced'`, que ajusta automaticamente os pesos das classes de forma inversamente proporcional à sua frequência. Neste trabalho, todas as ~~*features*~~ características são numéricas, de modo que o tratamento de variáveis categóricas não é utilizado.

A métrica de importância de variáveis padrão do CatBoost é o ***PredictionValuesChange***: para cada ~~*feature*~~característica, mede-se a mudança média nas predições do modelo ao longo de ~~todos os *splits*~~ todas as divisões que a utilizam. Os valores são normalizados para que a soma seja igual a 100. Neste trabalho, CatBoost é utilizado junto com Regressão Logística, Random Forest e XGBoost para comparação de desempenho e robustez na classificação de curvas de luz (Capítulo 4).

3.4 Agrupamento não supervisionado: K-means

O **K-means**, proposto originalmente por MacQueen (1967), é um algoritmo de **agrupamento** ~~(*clustering*)~~ não supervisionado: não usa rótulos; apenas particiona os dados em K grupos de modo a minimizar a soma dos quadrados das distâncias de cada ponto ao ~~centróide~~ centroide do seu grupo (Geron , 2019; Levada , 2026). A função objetivo, conhecida como ~~*Within-Cluster Sum of Squares* (~~soma dos quadrados intragrupo (*Within-Cluster Sum of Squares*, WCSS) ou inércia, é

$$J = \sum_{i=1}^{K} \sum_{\vec{x} \in S_i} \|\vec{x} - \vec{\mu}_i\|^2, \tag{3.4}$$

onde S_i é o conjunto de pontos atribuídos ao grupo (*cluster*) i e $\vec{\mu}_i$ é o ~~centróide desse *cluster*~~centroide desse grupo. O algoritmo alterna dois passos: (1) **atribuição** — cada ponto é atribuído ao ~~centróide~~ centroide mais próximo; (2) **atualização** — cada ~~centróide~~ centroide é recalculado como a média aritmética dos pontos a ele atribuídos. O custo J não aumenta a cada iteração, de modo que o processo converge para um mínimo local (Geron , 2019; Levada , 2026). Em aplicações em que K não é fixo, a inércia (WCSS) é frequentemente usada no **método do cotovelo** (gráfico de WCSS em função de K) para sugerir o número de ~~*clusters*~~grupos; índices como o de ~~**Caliski–Harabasz**~~**Caliński–Harabasz**[2] medem a razão entre ~~dispersão inter e intra-*cluster*~~as dispersões intergrupos e intragrupo, indicando quão bem separados estão os grupos. Para mais detalhes sobre o

[2]Índice proposto por Caliński & Harabasz (1974): $CH(K) = \dfrac{\mathrm{tr}(B_K)/(K-1)}{\mathrm{tr}(W_K)/(n-K)}$, em que B_K e W_K são as matrizes de dispersão entre os grupos e dentro dos grupos, e n é o número de pontos. Valores maiores indicam grupos mais compactos e mais bem separados.

funcionamento ~~deste algoritmo, fica como recomendação o paper original :~~ do algoritmo, recomenda-se o artigo original de MacQueen (1967).

Como mencionado na Seção 3.1, os classificadores utilizados neste trabalho são supervisionados; o uso do K-means limita-se à etapa de extração de características numéricas das curvas de luz de ocultação. Assim, nesta dissertação, o K-means **não** é usado como classificador de curvas, e sim como ferramenta para **extrair uma característica numérica**: aplica-se K-means com $K = 2$ aos valores do fluxo (ou do fluxo suavizado) de cada curva. Como não há rótulos, o algoritmo apenas descobre dois "níveis" típicos nos dados (Levada , 2026). Os dois ~~centróides~~ centroides representam, grosso modo, o nível "fora da ocultação" e o nível "dentro da ocultação". A **distância entre os ~~centróides~~ centroides** é então usada como mais uma ~~entrada (*feature*)~~ característica de entrada para o classificador: curvas com ocultação bem definida tendem a ter distância maior; curvas apenas ruidosas tendem a ter distância menor. ~~O detalhe está~~ Os detalhes estão no Capítulo 4. No uso aqui, $K = 2$ e a variável é unidimensional (fluxo), o que simplifica a interpretação.

3.5 Algoritmos de otimização no treinamento

Em um projeto de ML supervisionado, a etapa de **treinamento** corresponde, como explicado anteriormente, a ajustar os parâmetros do modelo de modo a minimizar uma função de custo (ou perda) nos dados. Nas seções anteriores foram apresentados os modelos e suas funções de custo; aqui unificamos os **algoritmos** usados para obter o minimizador. A minimização pode ser feita por **solução analítica~~fechada~~**, quando existe fórmula explícita (como na regressão linear, Seção 3.2), ou por **algoritmos iterativos**, quando não há ~~forma fechada~~solução analítica. Os três esquemas mais recorrentes são resumidos a seguir; a Tabela 3.2 indica em que contexto cada um aparece.

1. Mínimos quadrados (solução ~~fechada~~analítica). Conforme visto na regressão linear (Seção 3.2), modelos lineares com custo quadrático possuem minimizador analítico dado pela equação normal ~~$\vec{\theta}^* = (X^\top X)^{-1} X^\top \vec{y}$~~ $\vec{\theta}^* = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \vec{y}$. Na Regressão Logística e em modelos não lineares, recorre-se a métodos iterativos.

2. Gradiente descendente (método de primeira ordem). O **gradiente** da função de custo indica a direção de maior crescimento do custo; para minimizar, atualiza-se os parâmetros na **direção oposta**, com passo controlado pela taxa de aprendizado η:

$$\vec{\theta}_{t+1} = \vec{\theta}_t - \eta \, \nabla_{\vec{\theta}} J(\vec{\theta}_t).$$

As variantes principais distinguem-se pela quantidade de dados usada em cada atualização (Geron , 2019): ***~~Batch~~* ~~GD~~gradiente descendente em lote** (*Batch GD*) utiliza todo o conjunto de treino (preciso, mas lento em grandes volumes); ***~~Stochastic~~* ~~GD~~gradiente**

descendente estocástico (*Stochastic GD*, SGD) utiliza uma única instância aleatória por passo (rápido e capaz de escapar de mínimos locais, mas com trajetória errática); ~~***Mini-batch* GD~~**gradiente descendente em minilotes** (*Mini-batch GD*) processa pequenos subconjuntos aleatórios, equilibrando estabilidade e eficiência. A convergência depende crucialmente de η: se muito alta, o algoritmo pode divergir; se muito baixa, o treinamento torna-se excessivamente lento. ~~Como vimos na Seção 3.3, a~~ A Regressão Logística ~~é~~ pode ser ajustada por gradiente descendente (Seção 3.3), embora a implementação usada neste trabalho empregue o L-BFGS; o mesmo esquema é usado em redes neurais e no *gradient boosting* (cada árvore é ajustada ao gradiente da perda).

3. Métodos de segunda ordem (Newton e variantes). O **método de Newton** utiliza o gradiente e a **Hessiana**[3] da função de custo:

$$\vec{\theta}_{t+1} = \vec{\theta}_t - H^{-1}(\vec{\theta}_t)\,\nabla_{\vec{\theta}} J(\vec{\theta}_t).$$

Isso permite passos mais informados e convergência mais rápida perto do mínimo, às custas de calcular e inverter H a cada iteração (custo $O(p^3)$ por passo). Variantes **quasi-Newton**, como o BFGS[4], aproximam a Hessiana sem calculá-la explicitamente. O XGBoost utiliza uma **expansão de Taylor de segunda ordem** da perda para determinar a atualização ótima de cada árvore no *gradient boosting* (Geron , 2019).

Tabela 3.2: Algoritmos de otimização e seu papel na etapa de treinamento em projetos de ML.

Família	**Exemplo**	**Onde aparece**
Solução analítica	Mínimos quadrados (equação normal)	Regressão linear (Seção 3.2)
Primeira ordem (iterativo)	Gradiente descendente (em lote, SGD, em minilotes)	Exposição didática da Regressão Logística, redes neurais, *gradient boosting*
Segunda ordem (iterativo)	Newton, quasi-Newton (BFGS, L-BFGS), Taylor	Regressão Logística desta dissertação (L-BFGS); XGBoost (Taylor da perda); otimização convexa em geral

[3]Matriz das derivadas parciais de segunda ordem da função de custo, $H_{ij} = \partial^2 J/\partial\theta_i\,\partial\theta_j$, que descreve a curvatura local de J (Nocedal & Wright , 2006).

[4]Sigla de Broyden–Fletcher–Goldfarb–Shanno: o método atualiza, a cada iteração, uma aproximação de H^{-1} usando apenas as variações sucessivas dos parâmetros e do gradiente (Nocedal & Wright , 2006, cap. 6). Sua versão de memória limitada (L-BFGS) é o algoritmo de otimização (*solver*) padrão da Regressão Logística do *scikit-learn*, usado neste trabalho.

3.6 Engenharia de características e validação de modelos

3.6.1 Engenharia de características

A criação e a seleção de **características numéricas** (atributos) a partir dos dados brutos são fundamentais para o sucesso do ML (Geron , 2019), uma vez que essas variáveis representam a informação que será efetivamente utilizada pelos algoritmos para identificar padrões e realizar previsões.

Essa etapa inclui: (i) escolher ou construir variáveis que capturem informação útil para a tarefa (por exemplo, estatísticas da curva de luz, derivadas, comparações entre segmentos); (ii) combinar ou transformar variáveis existentes (médias móveis, suavização, testes estatísticos entre quartis, etc.). No Capítulo 4, descreve-se em detalhe o conjunto de ~~*features*~~ características extraídas de cada curva de luz (amplitude, desvio padrão, queda máxima acumulada (*max drawdown*), distância entre ~~centróides~~ centroides do K-means no fluxo, estatísticas de derivadas, p-valores entre quartis, entre outras). Essas grandezas formam o vetor $\vec{x}$ de entrada dos classificadores.

3.6.2 Métricas de avaliação para classificação binária

A avaliação de um classificador binário parte da **matriz de confusão**, que contabiliza os acertos e erros do modelo em relação aos rótulos verdadeiros. Sejam $y_i \in \{0, 1\}$ os rótulos reais e $\hat{y}_i$ as predições; definem-se quatro contagens:

- **Verdadeiro Positivo (TP, do inglês *True Positive*):** $\hat{y}_i = 1$ e $y_i = 1$ (acerto na classe positiva).
- **Verdadeiro Negativo (TN, *True Negative*):** $\hat{y}_i = 0$ e $y_i = 0$ (acerto na classe negativa).
- **Falso Positivo (FP, *False Positive*):** $\hat{y}_i = 1$ e $y_i = 0$ (alarme falso).
- **Falso Negativo (FN, *False Negative*):** $\hat{y}_i = 0$ e $y_i = 1$ (evento perdido).

A partir dessas contagens, as métricas mais utilizadas em classificação binária são:
Acurácia — fração de predições corretas sobre o total:

$$\text{Acurácia} = \frac{TP + TN}{TP + TN + FP + FN}. \tag{3.5}$$

A acurácia é intuitiva, mas pode ser enganosa em conjuntos desbalanceados.

Exemplo numérico: considere 100 curvas de luz, das quais 10 contêm ocultação (positivas) e 90 não (negativas). Um classificador que **sempre** prediz "negativo" acerta 90 das

100 curvas — acurácia de 90% — mas não detecta *nenhuma* ocultação (sensibilidade = 0). Esse paradoxo evidencia que, em cenários desbalanceados, a acurácia sozinha é insuficiente para avaliar o modelo.

Precisão (*Precision*) — entre os exemplos classificados como positivos, qual fração é realmente positiva:

$$\text{Precisão} = \frac{TP}{TP + FP}. \tag{3.6}$$

Sensibilidade (*Recall*~~, ou sensibilidade~~) — entre os exemplos verdadeiramente positivos, qual fração foi corretamente detectada:

$$\text{Sensibilidade} = \frac{TP}{TP + FN}. \tag{3.7}$$

F1-score — média harmônica de precisão e sensibilidade, oferecendo um compromisso entre ambas:

$$F_1 = 2 \cdot \frac{\text{Precisão} \cdot \text{Sensibilidade}}{\text{Precisão} + \text{Sensibilidade}} = \frac{2\,TP}{2\,TP + FP + FN}. \tag{3.8}$$

F$_\beta$-score — generalização do F1-score que permite atribuir peso diferente à sensibilidade:

$$F_\beta = (1 + \beta^2) \cdot \frac{\text{Precisão} \cdot \text{Sensibilidade}}{\beta^2 \cdot \text{Precisão} + \text{Sensibilidade}}. \tag{3.9}$$

Para $\beta > 1$, o F_β penaliza mais os falsos negativos (favorecendo a sensibilidade); para $\beta < 1$, penaliza mais os falsos positivos. Em aplicações de triagem científica, como a detecção de ocultações estelares, $\beta = 2$ é uma escolha natural, pois o custo de perder um evento genuíno é maior que o de investigar um alarme falso, isto é, o custo de um FN supera o de um FP.

AUC-ROC (*Area Under the Receiver Operating Characteristic Curve*) — mede a capacidade discriminativa do modelo ao longo de todos os limiares de decisão possíveis. A curva ROC plota a **taxa de verdadeiros positivos** (sensibilidade) contra a **taxa de falsos positivos** ($FP/(FP+TN)$) para cada limiar τ. A área sob essa curva (AUC) varia de 0,5 (classificador aleatório) a 1,0 (classificador perfeito), como mostrado na Figura 3.8: quanto mais a curva se aproxima do canto superior esquerdo, melhor a capacidade discriminativa do modelo. Um exemplo intuitivo é um teste médico: a taxa de verdadeiros positivos é a fração de doentes corretamente identificados, a taxa de falsos positivos é a fração de saudáveis apontados como doentes, e variar o limiar move o teste ao longo da curva, negociando a detecção de mais doentes contra um número maior de alarmes falsos. A AUC-ROC é útil por ser invariante ao limiar escolhido, mas pode ser otimista em conjuntos desbalanceados (Saito & Rehmsmeier , 2015).

Curva Precisão-Sensibilidade (*Precision-Recall*) — alternativa à curva ROC, recomendada quando a classe positiva é rara ou quando o custo dos erros é assimétrico

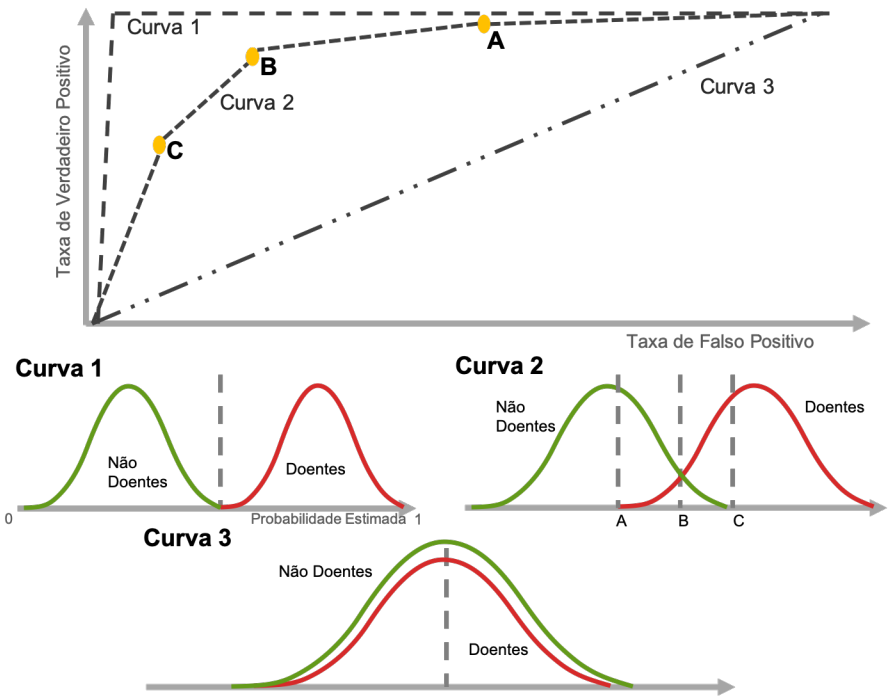


Figura 3.8: Exemplos de curvas ROC para classificadores de diferentes qualidades; a diagonal corresponde a um classificador aleatório (AUC = 0,5). Fonte: adaptado de Ciência e Negócios. Disponível em: `https://cienciaenegocios.com/curva-roc-e-auc-em-machine-learning`. Acesso em: 6 abr. 2026.

(Saito & Rehmsmeier , 2015). Plota a precisão contra a sensibilidade para cada limiar τ. A área sob a curva PR (AUC-PR) é mais informativa que a AUC-ROC em cenários desbalanceados, pois não é inflada por verdadeiros negativos abundantes.

Nesta dissertação, os modelos são avaliados por acurácia, precisão, sensibilidade, F1-score e AUC-ROC no conjunto de teste (Capítulo 5). Para a análise de ajuste de limiar, utilizam-se também o F_2-score e a curva ~~*precision-recall*~~precisão-sensibilidade.

3.6.3 ~~Sobreajuste, subajuste~~ e o compromisso entre viés e variância

A identificação de **sobreajuste** ~~(*overfitting*)~~ e **subajuste** (*underfitting*) baseia-se na comparação do desempenho do modelo nos dados usados no treinamento versus nos dados reservados para teste ou validação (Geron , 2019). Em termos intuitivos: **sobreajuste** ocorre quando o modelo "decora" os dados de treino (incluindo o ruído) e deixa de generalizar — o erro no treino fica muito baixo, mas o erro em dados novos permanece alto. **Subajuste** ocorre quando o modelo é simples demais e não captura o padrão verdadeiro dos dados — tanto o erro de treino quanto o de validação ficam altos.

O erro de generalização pode ser decomposto em **viés**, **variância** e **ruído irredutível**

(Levada , 2026; Deisenroth et al. , 2019). Formalmente, seja $f^\star(\vec{x})$ a relação verdadeira (desconhecida) entre entrada e saída e $\hat{f}$ o modelo — a função f da Seção 3.2 — estimado a partir de diferentes amostras de treino do mesmo processo gerador; o erro quadrático médio esperado em um ponto $\vec{x}$ é:

$$\mathbb{E}\Big[(y - \hat{f}(\vec{x}))^2\Big] = \text{Viés}^2[\hat{f}(\vec{x})] + \text{Var}[\hat{f}(\vec{x})] + \sigma^2, \tag{3.10}$$

onde $\text{Viés}^2[\hat{f}] = \Big(\mathbb{E}[\hat{f}(\vec{x})] - f^\star(\vec{x})\Big)^2$ mede o erro sistemático do modelo (quão longe a predição média está do valor verdadeiro), $\text{Var}[\hat{f}]$ mede a sensibilidade do modelo a flutuações nos dados de treino, e σ^2 é a variância do ruído intrínseco aos dados (irredutível por qualquer modelo). Modelos muito simples tendem a alto viés (subajuste); modelos muito flexíveis tendem a alta variância (sobreajuste). O objetivo prático é encontrar um equilíbrio que minimize o erro total.

Diagnóstico. O sinal mais claro de sobreajuste é um erro muito baixo no treino e um erro alto no teste ou validação (não generalizou). Esse diagnóstico é feito graficamente pelas **curvas de aprendizado** (Seção 3.6.4): o sobreajuste aparece como uma~~gap~~**lacuna** (*gap*) entre a curva de treino e a de validação, enquanto o subajuste mantém ambas próximas e em um **platô alto** de erro.

A **validação cruzada** — detalhada na Seção 3.6.5 — complementa esse diagnóstico ao fornecer uma estimativa robusta do erro de generalização (média e desvio padrão sobre várias divisões dos dados), facilitando perceber quando o modelo começou a sobreajustar (Geron , 2019).

Em resumo: **sobreajuste** ~~(*overfitting*)~~ significa que o modelo se ajustou demais aos dados de treino (incluindo o ruído) e perde capacidade de generalizar; soluções típicas são obter mais dados, simplificar o modelo ou usar regularização (penalizar parâmetros grandes). **Subajuste** ~~(*underfitting*)~~ significa que o modelo é simples demais e não captura o padrão dos dados; as soluções envolvem aumentar a complexidade do modelo ou enriquecer as características de entrada. Os **hiperparâmetros** (por exemplo, força da regularização, profundidade máxima das árvores) controlam esse equilíbrio e podem ser escolhidos via validação cruzada.

A **regularização** restringe a liberdade do modelo (por exemplo, penalidade ℓ_2 na Regressão Logística ou limites de profundidade e número de folhas nas árvores), sendo controlada por hiperparâmetros que podem ser ajustados via validação cruzada (Geron , 2019). Outras formas incluem a **parada antecipada**: interromper o treinamento quando o erro no conjunto de validação deixa de melhorar, evitando que o modelo "decore" o ruído do treino. Nesta dissertação, o foco está na penalização ~~de pesos em modelos lineares (Ridge/Lasso) e nos critérios de parada e poda~~ ℓ_2 da Regressão Logística e nos limites de profundidade e de número mínimo de amostras por nó e por folha nas árvores (não se aplica poda). A regularização ℓ_1 e ℓ_2 é **sensível à escala** das variáveis de entrada: atributos em

escalas maiores tendem a receber pesos menores pela penalização. Em geral, recomenda-se **padronizar** as variáveis (subtrair a média e dividir pelo desvio padrão) antes de aplicar Ridge ou Lasso. No entanto, nesta dissertação a padronização é aplicada apenas à Regressão Logística; os modelos baseados em árvores recebem as ~~*features*~~ características na escala original, pois são insensíveis a transformações monotônicas de cada variável (Capítulo 4).

3.6.4 Curvas de aprendizado

As **curvas de aprendizado** mostram o desempenho do modelo (acurácia ou erro) em função do tamanho do conjunto de treino (ou do número de épocas); são a ferramenta gráfica que torna visível o equilíbrio viés–variância discutido acima e auxiliam na decisão de coletar mais dados ou alterar a complexidade do modelo.

A Figura 3.9 ilustra o conceito com curvas de aprendizado de seis classificadores — (A) XGBoost, (B) Random Forest, (C) árvore de decisão, (D) *Extra Trees*, (E) *Naive Bayes* gaussiano e (F) Regressão Logística — aplicados a um problema de classificação em medicina (Zhong et al. , 2023). Em cada painel, a curva superior é o desempenho no **treino** e a inferior o desempenho em **validação cruzada**, ambos em função do número de amostras de treino. Dois padrões didáticos aparecem: (i) a curva de validação **sobe** à medida que mais dados ficam disponíveis e tende a um **platô**, ponto a partir do qual coletar mais exemplos pouco acrescenta; (ii) ~~o~~ a ~~**intervalo**~~**lacuna** ~~(*gap*)~~ entre a curva de treino (quase perfeita) e a de validação mede o **sobreajuste** — quanto maior ~~o vão~~a lacuna, mais o modelo decorou o treino em vez de generalizar. Um modelo bem ajustado é aquele cujas duas curvas convergem para um patamar alto com ~~vão pequeno~~lacuna pequena; na figura, é o caso do XGBoost (painel A), cujas curvas convergem para $\approx 0{,}96$. Os painéis E e F ilustram o subajuste: as curvas se encontram, mas num patamar baixo ($\approx 0{,}67$ e $\approx 0{,}74$). Com poucos exemplos de treino, todos os modelos mostram ~~o vão largo típico~~ a lacuna larga típica do sobreajuste.

3.6.5 Validação de modelos

Para estimar o desempenho em dados não vistos e evitar otimismo, é essencial separar os dados usados no treino daqueles usados na avaliação (Geron , 2019). ~~Imagine que treinamos o modelo usando~~ Suponha que o modelo seja treinado com todas as curvas de luz disponíveis e depois ~~o avaliamos~~ avaliado nessas mesmas curvas. O resultado seria enganosamente bom. Para estimar honestamente o desempenho, é preciso reservar dados que o modelo nunca viu. A **validação cruzada** sistematiza esse processo: em vez de uma única divisão treino/teste (~~que pode ser sortuda ou azarada), roda-se~~ cujo resultado pode ser favorável ou desfavorável por acaso), repete-se o experimento q vezes, cada vez deixando uma fatia diferente de fora (Figura 3.10). A média dos q resultados é uma

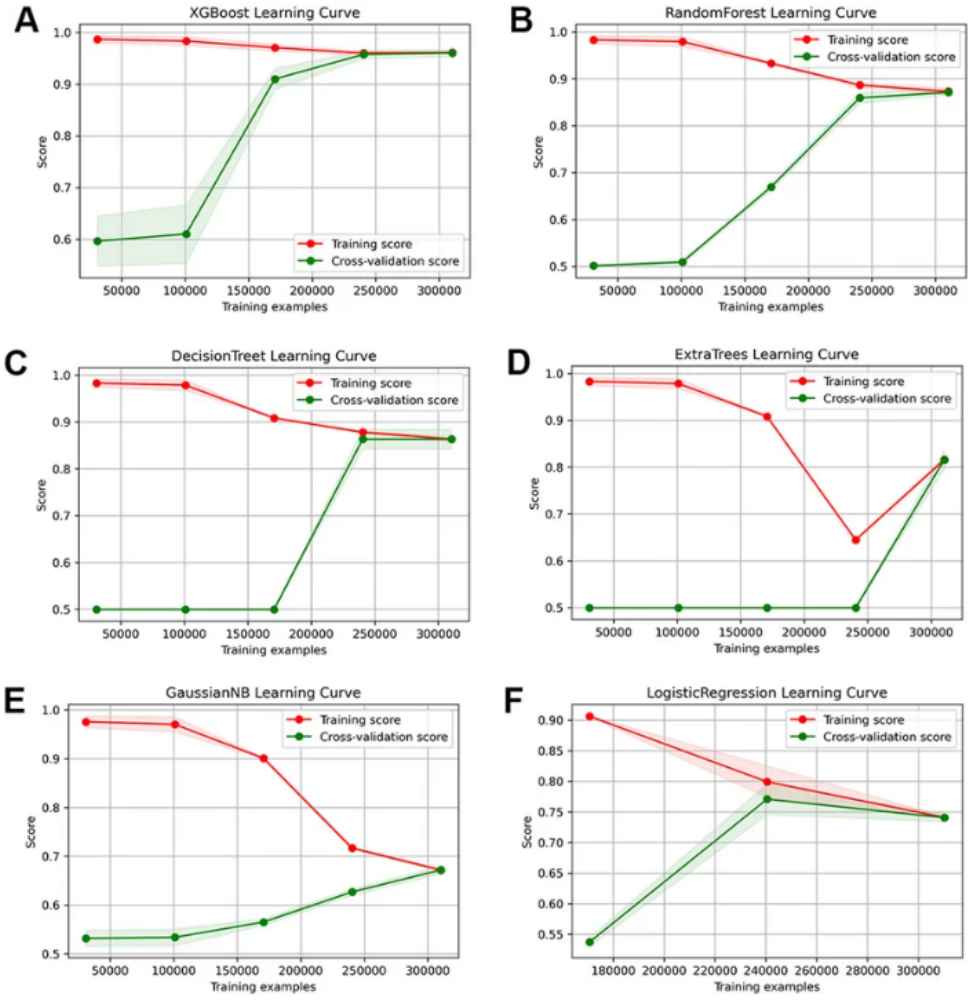


Figura 3.9: Exemplo de curvas de aprendizado (dados genéricos, não referentes a curvas de luz de ocultação) para seis classificadores: (A) XGBoost, (B) Random Forest, (C) árvore de decisão, (D) *Extra Trees*, (E) *Naive Bayes* gaussiano e (F) Regressão Logística. Em cada painel, compara-se o desempenho no conjunto de treino com o obtido em validação cruzada, em função do número de amostras de treino. Fonte: Zhong et al. (2023).

estimativa muito mais robusta do erro de generalização.

As estratégias mais comuns são:

- **Conjunto de teste:** uma fração dos dados é reservada e nunca usada no treino; o desempenho nesse conjunto fornece uma estimativa do erro de generalização.
- **Validação cruzada em q dobras** (em inglês, *k-fold cross-validation*): os dados são divididos em q partes (dobras); em cada rodada, $q-1$ dobras são usadas para treino e uma para validação; a métrica final é a média sobre as q rodadas. Isso dá uma estimativa mais estável do desempenho e é útil para comparar modelos ou escolher hiperparâmetros (parâmetros do algoritmo que não são ajustados pelo treinamento, como a força da regularização).

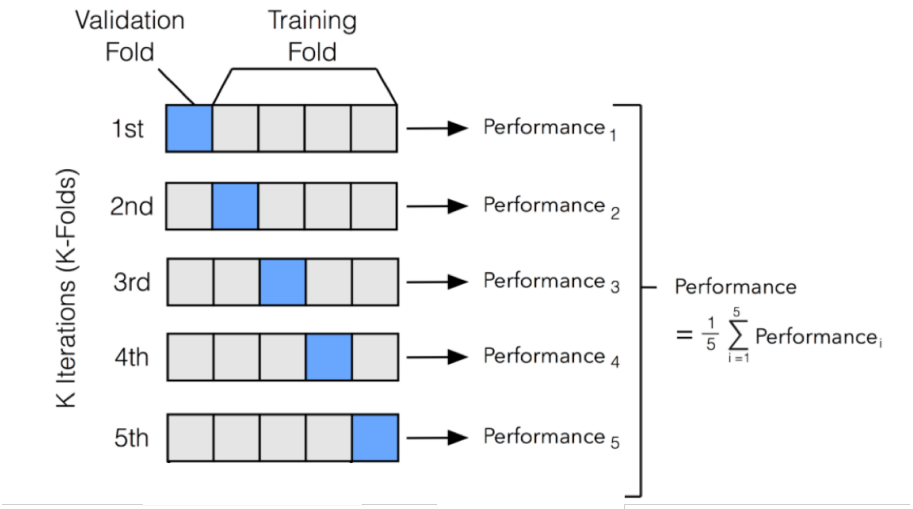


Figura 3.10: Esquema da validação cruzada com $q = 5$ dobras: em cada rodada, uma fatia diferente (em destaque) é usada como conjunto de validação, e as demais como treino. Fonte: adaptado de Nishad (2023). Disponível em: `https://medium.com/@nishad009adi/k-fold-cross-validation-with-simple-example-e023bb2e2d43`. Acesso em: 6 abr. 2026.

- **Validação cruzada estratificada:** quando as classes são desbalanceadas (por exemplo, poucas curvas com ocultação e muitas sem), a divisão aleatória simples pode produzir dobras em que uma das classes está sub ou sobrerrepresentada. A validação **estratificada** preserva a proporção de cada classe em cada dobra, tornando a estimativa mais confiável (Geron , 2019). Na detecção de ocultações, o uso de divisão estratificada é recomendado.

- **Busca em grade:** para escolher hiperparâmetros, avalia-se um conjunto de combinações (a "grade") e escolhe-se a que maximiza a métrica de validação.

Na ~~*pipeline*~~ cadeia de processamento desta dissertação (~~Capítulo~~ Capítulos 4 ~~), a divisão treino/~~e 5), adota-se o seguinte protocolo: (i) um conjunto de teste é ~~feita de forma estratificada (mantendo a proporção de positivas e negativas em cada parte) ou por seleção manual de curvas para o~~ reservado antes de qualquer escolha de modelagem, com divisão estratificada e **agrupada por evento** (todas as curvas de um mesmo evento de ocultação — cordas de observadores diferentes e os recortes derivados delas — ficam do mesmo lado da divisão); (ii) todas as escolhas (a configuração de características e o limiar de decisão de cada modelo) são feitas por validação cruzada estratificada e agrupada no restante dos dados; (iii) o conjunto de teste é usado uma única vez, ao final, para estimar o desempenho dos modelos escolhidos. As métricas finais (acurácia, precisão, sensibilidade, F1-score, AUC-ROC) são, portanto, calculadas no **conjunto de teste** — dados que ~~o modelo nunca viu durante o treinamento~~ não foram usados no treinamento

nem nas escolhas de configuração, modelo e limiar.

Em resumo, ~~o leitor dispõe de uma referência clara sobre o significado das "contas" envolvidas~~ este capítulo percorreu os procedimentos de cálculo envolvidos no treinamento de modelos de aprendizado de máquina. Inicialmente, apresentamos um modelo simples de Regressão Linear ajustado por meio do método dos mínimos quadrados e discutimos suas limitações. Em seguida, introduzimos a Regressão Logística (Seção 3.3) como ~~um exemplo direto~~ exemplo de otimização ~~por gradiente descendente~~iterativa (gradiente descendente, na exposição; L-BFGS, na implementação). Depois, abordamos os ~~*ensembles*~~ comitês de árvores, que utilizam critérios de divisão para o aprendizado; no caso do XGBoost, o processo de otimização incorpora informações de segunda ordem da função de perda, resultando em atualizações mais eficientes (Geron , 2019). Por fim, esta seção reuniu as métricas de avaliação e os procedimentos de validação. Com isso, o capítulo fornece a base conceitual necessária para interpretar a metodologia e os resultados descritos nos Capítulos 4 e 5.

Capítulo 4

Metodologia: Cadeia de Processamento para Detecção

Este capítulo descreve a metodologia adotada para desenvolver ~~o~~ a ~~fluxo~~ cadeia **de** ~~trabalho em etapas~~**processamento** ~~(*pipeline*)~~ de detecção automatizada de ocultações estelares em curvas de luz. A exposição está organizada em etapas sucessivas: desde a aquisição e o armazenamento dos dados até o **treinamento** (ajuste dos parâmetros dos classificadores) e a **avaliação** (medida do desempenho em dados não usados no ajuste).

Os objetivos deste capítulo são: (1) descrever a arquitetura completa da ~~*pipeline*~~ cadeia de processamento, da coleta dos dados ao modelo treinado; (2) detalhar o pré-processamento das curvas de luz, incluindo fontes de dados, armazenamento em banco relacional, normalização e critérios de classificação; (3) explicar a construção do conjunto de dados utilizado no treinamento, incluindo o recorte de segmentos negativos a partir de curvas positivas e a incorporação de curvas simuladas; (4) formalizar a engenharia de características ~~(*feature engineering*)~~ aplicada às curvas; e (5) especificar o protocolo de treinamento e avaliação dos classificadores, com as métricas e a divisão treino/teste adotadas. Ao final, o leitor terá uma visão clara de como os dados brutos são transformados em um conjunto de atributos e como os modelos são treinados e avaliados, preparando o terreno para a discussão dos resultados no Capítulo 5.

4.1 Visão geral da cadeia de processamento

A metodologia está organizada em uma ~~*pipeline*~~ cadeia de processamento em etapas, na qual a saída de um bloco alimenta o seguinte. Essa estrutura facilita a manutenção, a reprodução e a extensão do trabalho. A Figura 4.1 ilustra o fluxo desde as fontes de dados até os modelos treinados.

Etapa 1 — Aquisição e armazenamento: curvas de luz são obtidas a partir de portais externos (VizieR, banco do Grupo do Rio) e inseridas em um banco de dados

relacional SQLite, com duas tabelas principais: `observations` (metadados da observação) e `light_curves` (pontos tempo–fluxo).

Etapa 2 — Acesso e normalização: um módulo de acesso aos dados consulta o banco, filtra curvas por objeto, data e tipo (positiva ou negativa), aplica normalização do fluxo pela linha de base (*baseline*, o nível de fluxo fora da ocultação), estimada por quartis, e remove ~~*outliers*~~ valores atípicos quando necessário.

Etapa 3 — Construção do conjunto de dados: as curvas disponíveis são reunidas; segmentos sem ocultação são recortados de curvas positivas (com revisão manual) para ampliar a classe negativa; curvas negativas simuladas são incorporadas. Em seguida, cada curva é convertida em um vetor de características (lista de números que a descrevem), formando uma tabela em que cada linha é uma curva e cada coluna é uma dessas grandezas.

Etapa 4 — Extração de características: para cada curva (série tempo–fluxo), calculam-se grandezas numéricas que a resumem — estatísticas do fluxo, da série suavizada e de suas derivadas numéricas, e comparações estatísticas entre quartis temporais —, gerando a tabela de vetores da etapa 3. O Capítulo 3 já introduziu a ideia de ~~*features*~~ características; aqui detalhamos quais grandezas são extraídas.

Etapa 5 — Treinamento e avaliação: ~~o conjunto de dados final~~ um **conjunto de teste** é ~~dividido em **treino** (usado para ajustar os parâmetros dos classificadores) e **teste** (reservado para medir o desempenho). Os quatro classificadores~~ reservado antes de qualquer escolha de modelagem; no restante dos dados (**conjunto de desenvolvimento**), a configuração de características e o limiar de decisão de cada modelo são ~~treinados na parte de treino; o desempenho é avaliado na parte de~~ escolhidos por validação cruzada, e os modelos escolhidos são avaliados uma única vez no teste (acurácia, precisão, sensibilidade, F1-score, AUC-ROC). Os modelos ajustados e os resultados são salvos em disco para análise posterior.

As seções seguintes detalham cada uma dessas etapas.

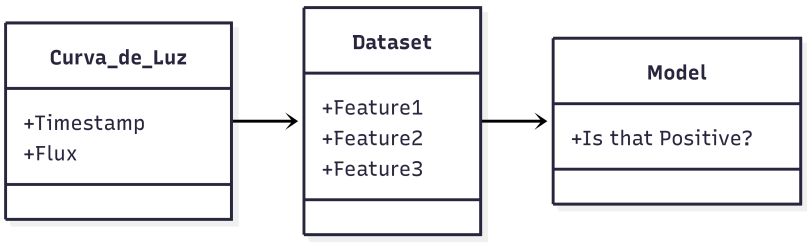


Figura 4.1: Esquema da ~~*pipeline*~~cadeia de processamento: as curvas de luz são convertidas em vetores de características; o treinamento utiliza essas características, e não as séries temporais brutas.

4.2 Aquisição e armazenamento dos dados

4.2.1 Fontes de dados

As curvas de luz utilizadas neste trabalho provêm de duas origens principais.

Grupo do Rio: parte do conjunto foi obtida a partir do banco de dados em nuvem do Grupo do Rio, referente a campanhas de ocultações já analisadas na literatura: a ocultação por Umbriel (satélite de Urano) ~~, observada em~~ de 21 de setembro de 2020~~e~~, analisada por Assafin et al. (2023), e a ocultação por Chiron ~~, observada em~~ de 10 de setembro de 2023~~e analisada por Ortiz et al. (2023)~~, analisada por Pereira et al. (2025) . Esses dados já possuem classificação (positiva ou negativa)~~e metadados consistentes.~~. Das 24 cordas publicadas para Umbriel (19 positivas e 5 negativas), o repositório continha 18 (15 positivas e 3 negativas). A curva de Chiron, por sua vez, não chegou ao banco de dados: o arquivo está em formato CSV (valores separados por vírgula, com linha de cabeçalho), diferente do formato em colunas separadas por espaço esperado na importação, e a leitura falhou depois de a observação ter sido registrada, de modo que o banco contém a observação de Chiron sem nenhum ponto de curva de luz. Essa observação é ignorada na construção do conjunto de dados; na prática, a contribuição do Grupo do Rio restringe-se às 18 cordas de Umbriel.

VizieR: a maior parte das curvas foi adquirida no portal VizieR (*cdsarc.cds.unistra.fr*), catálogo `B/occ/asteroid` (Herald et al. , 2016), ~~totalizando centenas de~~ do qual foram obtidas 923 curvas em formato `.dat` (912 delas inseridas no banco), contendo séries temporais de tempo e fluxo. Para cada entrada do catálogo, os pontos da curva são baixados via serviço `vizgraph` e armazenados localmente. Convém esclarecer uma possível confusão de escalas: os milhares de registros mencionados na Introdução referem-se às **imagens (quadros)** que cada observação produz, das quais se extrai *uma* curva de luz por fotometria. O conjunto de dados deste trabalho é contado em **curvas**, não em quadros — são centenas de curvas, que, somadas às curvas negativas (cuja obtenção é descrita na Seção 4.4), totalizam as 1693 amostras detalhadas na Seção 5.4 (Capítulo 5).

O processamento e a integração dos dados foram realizados com as bibliotecas `Astropy` (Astropy Collaboration et al. , 2022) e `Astroquery` (Ginsburg et al. , 2019) (leitura e consulta a catálogos astronômicos), `asyncio` (biblioteca padrão do Python) e `aiohttp` (coleta assíncrona, reduzindo o tempo total de aquisição), e `Pandas` (McKinney , 2010) (manipulação tabular). As rotinas numéricas de suavização e de testes estatísticos (Seção 4.5) usam a biblioteca SciPy (Virtanen et al. , 2020). Programas (~~*Scripts*~~*scripts*) em Python foram desenvolvidos para automatizar a busca, ~~o~~ a obtenção (*download*) e a organização dos arquivos.

Vale observar nos fluxogramas (Figuras 4.2 e 4.3) um detalhe do procedimento: as curvas do VizieR foram baixadas e **triadas localmente** — com pré-visualizações (*previews*) em `.png` e arquivos `.dat` organizados em pastas — antes de um ~~*script*~~ programa de

importação inseri-las no banco. Essa triagem prévia agilizou a inspeção de centenas de curvas que poderiam não ser positivas, estar em formato divergente ou sequer ser curvas de luz (por exemplo, curvas de rotação). Como efeito colateral, ~~essas curvas~~ todas as observações, inclusive as do VizieR, foram registradas com ~~origem *local*~~ a origem `Manual Import`, de modo que nenhuma ~~observação~~ consta explicitamente como `VizieR` no campo de origem — um detalhe de proveniência corrigível por uma simples consulta SQL e sem efeito sobre os rótulos positivo/negativo. Registra-se, ainda, que ~~as curvas marcadas como defeituosas no *download* foram descartadas sem caracterização do defeito nem tentativa de reaproveitamento (decisão de escopo e tempo~~ o conjunto obtido cobre apenas parte do catálogo: a consulta ao `B/occ/asteroid` retornou 6765 entradas, das quais 923 resultaram em arquivos gravados. O programa de aquisição não repete as transferências que falham (resposta HTTP diferente de 200 ou erro de conexão), que não geram arquivo nem registro, e nomeia cada arquivo pelo objeto, pelo observador e pelo mês da observação, de modo que curvas com esses três elementos em comum se sobrescrevem; a parcela de cada causa não pode ser recuperada a partir dos artefatos. Na importação para o banco, 11 das 923 curvas foram ainda descartadas como duplicatas aparentes: nomes de observador com pontos ou hífens (por exemplo, `D.Gault`) são registrados como `Unknown`, e duas curvas do mesmo objeto e do mesmo mês com observador `Unknown` passam a ter a mesma chave. Nenhuma dessas perdas decorre de defeito nas curvas, e nenhuma foi recuperada, o que constitui uma fragilidade reconhecida da metodologia~~)~~.

4.2.2 Estrutura do banco de dados

O banco de dados relacional foi implementado em SQLite (`.db`) e estruturado em duas tabelas principais, garantindo integridade referencial e consultas eficientes.

Tabela `observations`: armazena informações gerais de cada observação: identificador único, nome do objeto ocultador, data da observação, portal de origem, nome do observador e metadados adicionais (incluindo a classificação do evento como ocultação positiva ou negativa, quando disponível).

Tabela `light_curves`: contém os pontos individuais de cada curva de luz (tempo e fluxo), vinculados à observação correspondente por uma chave estrangeira (`observation_id`). Assim, uma mesma observação pode possuir muitos pontos, mantendo a normalização do esquema.

Durante a inserção, ~~buscou-se preservar ao máximo os valores originais, realizando apenas ajustes mínimos de consistência: uniformização de unidades quando necessário, checagem~~ os pares de tempo e fluxo foram armazenados exatamente como fornecidos pelas fontes, sem conversão de unidades nem reordenação, e a coluna de incerteza fotométrica, quando presente, foi descartada. Não houve checagem automática do alinhamento temporal~~e validação de metadados, sem alterar~~: os pontos de cada curva são recuperados

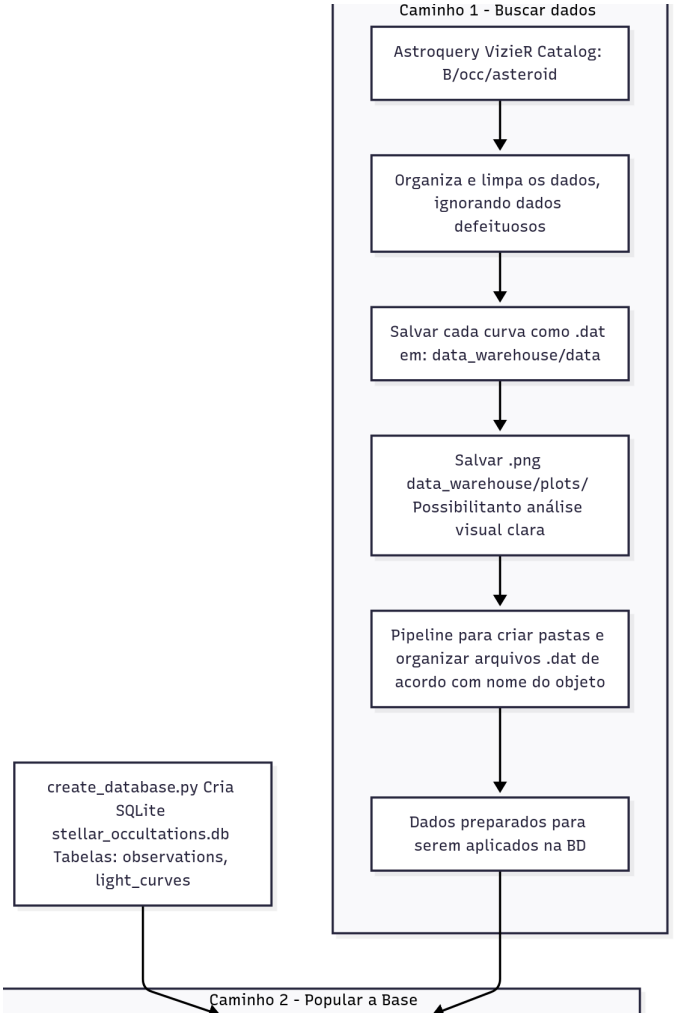


Figura 4.2: Fluxograma da aquisição e organização dos dados externos e da integração na etapa de inserção no banco de dados.

do banco em ordem crescente de tempo no momento da extração das características, o que corrige a única curva gravada em ordem decrescente, e a sincronização absoluta dos instantes não é necessária, pois cada curva é analisada isoladamente. Os tempos ficaram, assim, na unidade fornecida por cada fonte: segundos, em tempo relativo ao início do registro, nas curvas do VizieR, e dias julianos nas 18 cordas de Umbriel. Entre as características ~~intrínsecas das curvas~~utilizadas, apenas a duração do evento depende da unidade de tempo; nessas cordas e nos recortes derivados delas, ela foi convertida para segundos antes do treinamento (Capítulo 5). As datas das observações foram registradas com resolução de mês, a partir do nome das pastas. A Figura 4.3 resume o fluxo de consolidação do banco.

4.3 Acesso aos dados e normalização

Após a consolidação no banco, um módulo dedicado de acesso aos dados (*data access*) é responsável por consultar as curvas, filtrá-las por critérios (objeto, data, tipo positivo/negativo) e prepará-las para as etapas seguintes.

4.3.1 Consulta e classificação

As curvas são identificadas como **positivas** (com evento de ocultação) ou **negativas** (sem evento) com base em metadados armazenados na tabela `observations` (campo de metadados adicionais). Essa classificação pode provir de análises prévias (como no caso do Grupo do Rio) ou de anotações inseridas durante a organização dos dados. No Grupo do Rio, os rótulos decorrem ~~das análises publicadas nas campanhas citadas (Umbriel, Chiron), realizadas~~ da análise publicada da campanha de Umbriel, realizada por especialistas do grupo; no VizieR, ~~a classificação positiva/negativa provém dos curadores do~~ o rótulo não é lido do catálogo `B/occ/asteroid`: o programa de aquisição atribui o rótulo positivo a todas as curvas obtidas, e nenhuma curva do VizieR consta como negativa no banco. O rótulo positivo dessas curvas é, portanto, uma suposição sobre o conteúdo do catálogo, conferida apenas pela triagem visual das pré-visualizações descrita acima. Não há estudo formal de concordância entre anotadores neste trabalho; as métricas de desempenho reportadas no Capítulo 5 são, portanto, relativas a ~~esse *ground truth*~~ essa verdade de campo e devem ser lidas com a ressalva de que erros ou inconsistências de rotulagem nos catálogos podem afetar tanto o treinamento quanto a avaliação dos modelos. Durante a organização dos dados não foram identificados casos confirmados de rótulo invertido (positiva rotulada como negativa ou vice-versa); contudo, como não se realizou uma reanálise independente de cada curva, não é possível descartar a existência de inconsistências pontuais herdadas dos catálogos de origem. O módulo de acesso permite listar objetos disponíveis, datas de observação por objeto e, para cada par objeto–data, recuperar as

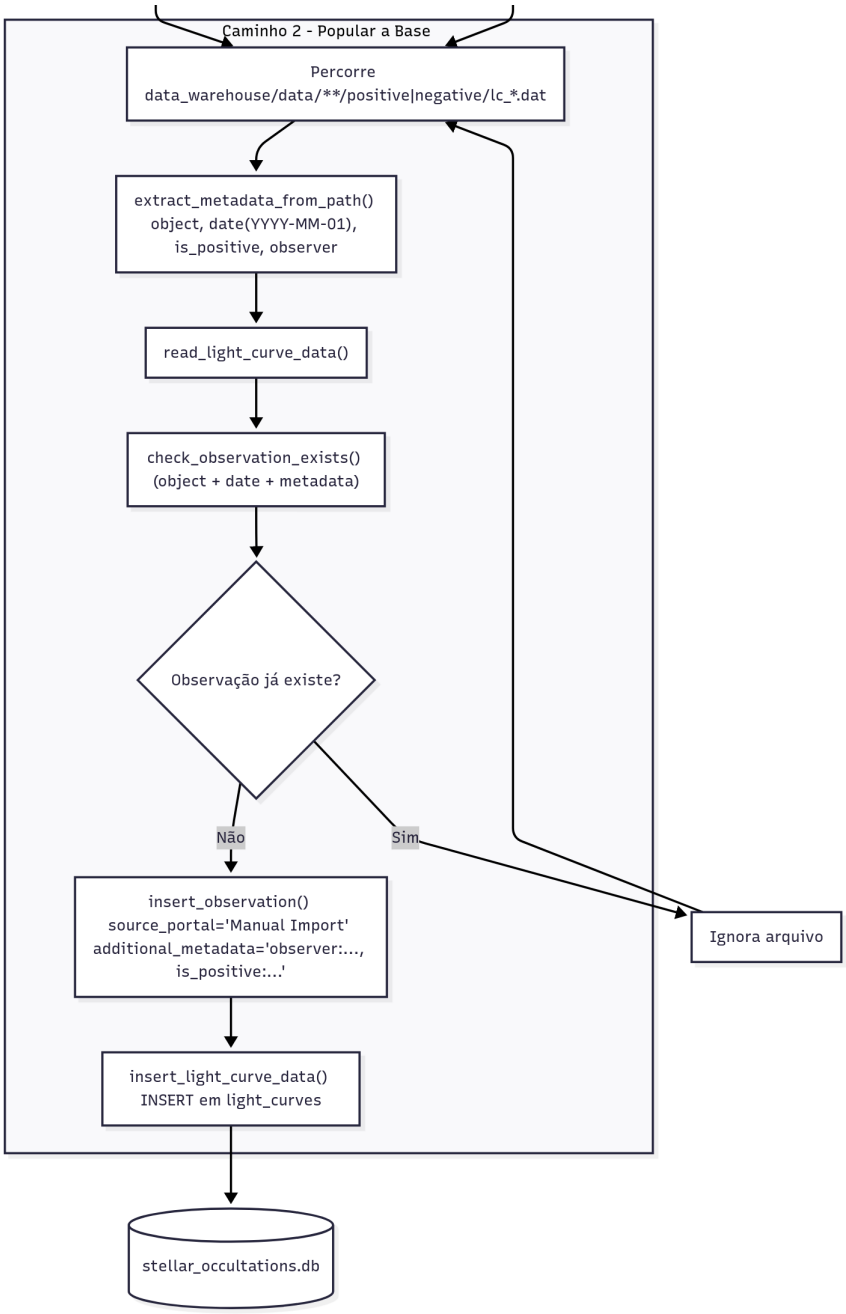


Figura 4.3: Fluxograma da ~~*pipeline*~~ cadeia de processamento responsável pela consolidação do banco de dados.

curvas com seus rótulos.

4.3.2 Normalização do fluxo

O fluxo fotométrico bruto varia em escala entre observações (diferentes telescópios, condições de céu, etc.). Para colocar todas as curvas em uma base comparável, aplica-se uma normalização que estima ~~um *baseline*~~ uma linha de base (nível de fluxo fora da ocultação) e divide-se a série pelo valor ~~desse *baseline*~~dessa linha de base.

A estratégia adotada é a seguinte: a série temporal do fluxo é dividida em quatro segmentos contíguos (quartis em ordem temporal). Calcula-se a média de cada segmento; os dois segmentos com maior média são considerados representativos do nível fora da ocultação. ~~O *baseline*~~ A linha de base é ~~definido~~ definida como a média dessas duas médias. O fluxo inteiro é então dividido por ~~esse *baseline*~~essa linha de base, de modo que, em curvas sem ocultação ou nos trechos externos à ocultação, o valor normalizado fique próximo de 1. Em curvas com ocultação, a região de queda aparece com valores inferiores a 1. Em casos degenerados (poucos pontos ou ~~*baseline*~~ ~~inválido~~linha de base inválida), recorre-se à média global do fluxo como alternativa. A normalização coloca todas as curvas em uma escala comparável, facilitando a convergência dos algoritmos e a interpretação de resíduos; em modelos de regressão, a análise de resíduos é um diagnóstico fundamental para verificar a aderência do modelo aos dados (Morettin & Bussab , 2010). Esse procedimento é análogo a uma normalização "pós-fotometria", em que o nível de continuum já foi tratado.

4.3.3 Remoção de ~~*outliers*~~valores atípicos

Quando necessário, pontos extremos do fluxo podem ser removidos com base em um critério de z-score: para um limiar z_{lim} (por exemplo, 3), pontos cujo fluxo se afasta da média da série por mais de z_{lim} desvios padrão são descartados. Isso reduz o impacto de picos ou quedas espúrias pontuais (defeitos de leitura, raios cósmicos, etc.) sem alterar a estrutura geral da curva.

4.4 Construção do conjunto de dados para aprendizado de máquina

O **conjunto de dados** ~~(*dataset*)~~ é a tabela de exemplos (curvas de luz convertidas em vetores de características) com sua classificação verdadeira (positiva ou negativa), usada para treinar e avaliar os classificadores. Devido à escassez de curvas negativas nos catálogos disponíveis, adotaram-se duas estratégias complementares: recorte de segmentos sem ocultação a partir de curvas positivas e geração de curvas negativas simuladas com o

simulador de curvas de luz de ocultação de Gomes-Ferrante & Braga-Ribas (2023). Os detalhes de cada estratégia são descritos nas subseções seguintes.

4.4.1 Tamanho e composição do conjunto de dados

Para interpretar sobreajuste, significância das métricas e generalização no Capítulo 5, é essencial conhecer o tamanho e a composição do conjunto utilizado. A composição final (quantidade de curvas positivas, negativas do banco, negativos por recorte manual, curvas simuladas, total de amostras e proporção treino/teste) é apresentada na Seção 5.4 (~~Configuração~~ Protocolo experimental), onde os números dos experimentos são detalhados junto com a distribuição por fonte.

4.4.2 Curvas positivas e negativas do banco

As curvas classificadas como positivas são obtidas do banco via consultas que filtram observações com rótulo correspondente. As curvas negativas são obtidas da mesma forma. O número de curvas negativas "nativas" (observações realmente sem ocultação) costuma ser menor que o de positivas no catálogo utilizado neste trabalho. Além disso, o catálogo obtido via VizieR, que constitui a principal fonte de dados deste trabalho, contém exclusivamente curvas positivas.

4.4.3 Recorte de segmentos negativos a partir de curvas positivas

Uma estratégia para obter exemplos negativos de alta qualidade consiste em extrair, das próprias curvas positivas, os trechos localizados **fora** da região de ocultação (isto é, anteriores à imersão e posteriores à emersão). Esses segmentos representam observações do mesmo sinal na ausência do evento e, portanto, constituem candidatos adequados para compor a classe negativa (denominados **negativos por recorte**). Contudo, por serem derivados da mesma curva de luz de ocultação, os recortes compartilham com ela a mesma estrela (brilho, cor e diâmetro aparente), o mesmo instrumento e as mesmas condições de imagem daquela noite (PSF, *seeing*, cadência, cintilação e transparência).

O procedimento adotado foi o seguinte: em cada curva positiva de uma amostra aleatória, a região de ocultação é delimitada automaticamente pelo primeiro e pelo último ponto com fluxo normalizado inferior a 0,78, após a remoção de ~~*outliers*~~ valores atípicos a 3σ; os segmentos anterior e posterior a essa região, com pelo menos 20 pontos cada, são exibidos e aceitos ou rejeitados manualmente. Se ao menos um segmento é aceito, a curva positiva original é excluída do conjunto de positivas, para que a mesma observação não apareça como positiva e como negativa (vazamento de informação, ou *data leakage*). Pelo mesmo motivo, nas partições de treino, validação e teste (Capítulo 5), os recortes de uma

mesma curva e as demais cordas do mesmo evento formam um único grupo, que nunca é dividido entre os dois lados de uma partição. Quedas rasas que não cruzam o limiar de 0,78 — como as de anéis, atmosferas ou ocultações rasantes — não são detectadas por esse critério e, se presentes fora do evento principal, permanecem nos segmentos rotulados como negativos; a inspeção visual é a única salvaguarda.

4.4.4 Curvas negativas simuladas

Para diversificar ainda mais a classe negativa e cobrir condições variadas de ruído e amostragem, foram incorporadas **curvas de luz simuladas** geradas por um simulador físico (Gomes-Ferrante & Braga-Ribas , 2023). O simulador combina: (i) a geometria do evento — o instante de cada exposição é convertido na posição do observador ao longo da corda, $x(t) = V_S\,(t - t_0)$, medida no plano do céu a partir do centro do evento; o corpo é representado por uma faixa opaca de largura igual ao seu diâmetro, o que equivale a uma corda central; (ii) a difração de Fresnel nas bordas de imersão e emersão, o diâmetro aparente da estrela e a integração durante a exposição; (iii) um modelo de ruído branco (Poisson da estrela e do céu, ruído de leitura gaussiano e cintilação multiplicativa lognormal); (iv) a normalização pós-fotometria. Para a classe negativa, o diâmetro é nulo: a geometria e a difração não intervêm, e cada curva simulada consiste apenas na base de tempo (20 a 60 s de duração, com exposições de 0,05 a 0,25 s) e no ruído, com parâmetros sorteados uniformemente (estrela de magnitude 11 a 14,5; *seeing* de 0,8″ a 1,6″). Não foram incluídos ruído correlacionado, variações de transparência nem nuvens. As curvas simuladas são exportadas em formato `.dat` e carregadas pelo módulo de construção do ~~*dataset*~~conjunto de dados, sendo tratadas como negativas. Essa etapa permite aumentar o tamanho e a variedade do conjunto de treino~~e melhorar a generalização do modelo em condições diversas~~. Por construção, porém, o ruído simulado é em geral menor que o das curvas observadas: a mediana do desvio padrão fora do evento (`Occ_baseline_std`) é 0,021 nas negativas simuladas, contra 0,058 nos negativos por recorte e 0,104 nas positivas. Por isso o desempenho é avaliado também somente em curvas reais (Capítulo 5).

O conjunto final reúne, portanto: positivas do banco (excluindo as usadas para recorte), negativas do banco, negativos por recorte (segmentos recortados e aprovados) e curvas negativas simuladas. Cabe destacar que o catálogo `B/occ/asteroid` do VizieR, principal fonte das curvas positivas, é um agregador público de campanhas independentes envolvendo diferentes corpos, observadores, telescópios, datas e localizações geográficas; a diversidade observacional do conjunto positivo é, portanto, ~~intrínseca à natureza do catálogo, e não há fonte observacional única que possa enviesar essa classe~~considerável, embora alguns eventos e observadores contribuam com várias curvas (por exemplo, 11 cordas positivas de Umbriel). Os pontos onde existe acoplamento entre amostras são explicitamente assumidos e mitigados: (i) os negativos por recorte herdam telescópio, estrela

e noite da curva positiva da qual foram recortados, motivo pelo qual a positiva original é excluída do conjunto ~~de treino~~ todas as curvas de um mesmo evento são mantidas juntas nas partições; (ii) as curvas simuladas, geradas por simulador físico, ~~podem apresentar~~ apresentam características de ruído distintas das observações reais, limitação ~~retomada e quantificada no Experimento 3 (~~avaliada pela taxa de falsos positivos nas negativas reais e pela avaliação restrita a curvas reais (Análise 2.1, Capítulo 5). A Figura 4.4 mostra exemplos de cada tipo de curva do conjunto. Todas as curvas passam pela mesma etapa de extração de características, descrita na próxima seção.

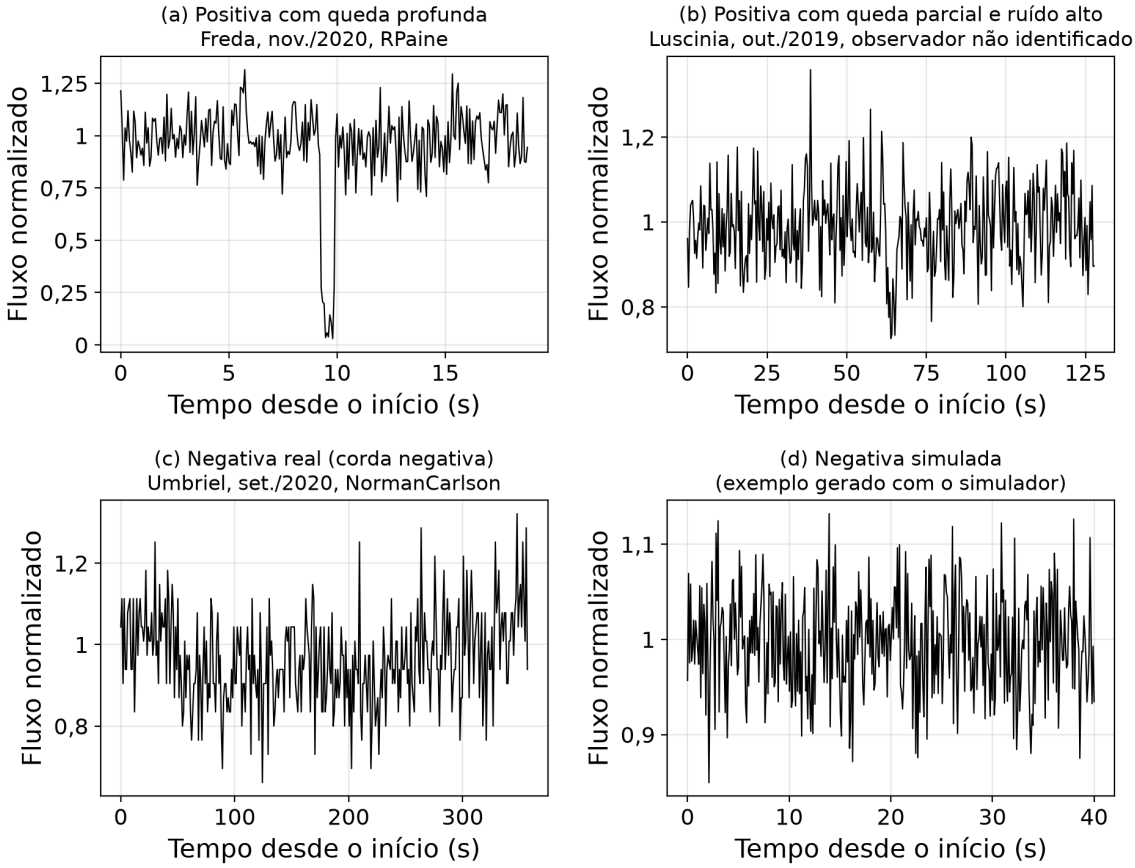


Figura 4.4: Exemplos de curvas de luz do conjunto de dados, com o fluxo normalizado pela média dos dois quartis temporais mais altos: (a) positiva com queda profunda; (b) positiva com queda parcial e ruído alto; (c) negativa real (corda negativa da campanha de Umbriel), justamente a negativa real que o XGBoost classifica como positiva no conjunto de teste (Seção 5.6); (d) exemplo de negativa simulada gerado com o simulador, sem corpo ocultante (estrela de magnitude 13, exposição de 0,1 s, 40 s de registro); não é uma das 702 curvas do conjunto. Os rótulos de (a)–(c) indicam objeto, mês e ano de observação e observador.

4.5 Engenharia de características

Os modelos de classificação utilizados neste trabalho (Regressão Logística, Random Forest, XGBoost, CatBoost) recebem **vetores numéricos**, e não as séries brutas; por isso, cada curva é convertida no vetor de características descrito nesta seção. As características foram padronizadas (média zero, desvio unitário) **apenas para a Regressão Logística**, via `StandardScaler` — o transformador da biblioteca `scikit-learn` (Pedregosa et al. , 2011) que, para cada variável, subtrai a média e divide pelo desvio padrão do conjunto de treino —, uma vez que a regularização ℓ_2 é sensível à escala das variáveis (Geron , 2019). Os modelos baseados em árvores (Random Forest, XGBoost, CatBoost) recebem as ~~*features*~~ características em escala original, pois são insensíveis a transformações monotônicas de cada variável.

~~Adiante veremos que algumas~~ Algumas das características extraídas ~~carregarão informações redundantes . Isto~~ são redundantes entre si. Isso é proposital ~~, pois motivará uma demonstração sobre~~ e permite avaliar, no Capítulo 5, o efeito da redução ~~de dimensionalidade nos modelosfinais~~do conjunto de variáveis sobre o desempenho dos modelos.

4.5.1 Amplitude e desvio padrão do fluxo

Seja $F(t)$ a série de fluxo (preferencialmente normalizado) com N pontos. Definem-se:

$$\mu\hat{\mu} = \frac{1}{N}\sum_{i=1}^{N} F(t_i), \qquad \sigma\hat{\sigma} = \sqrt{\frac{1}{N-1}\sum_{i=1}^{N}(F(t_i)-\mu)^2}\sqrt{\frac{1}{N-1}\sum_{i=1}^{N}(F(t_i)-\hat{\mu})^2}, \tag{4.1}$$

$$F_{\min} = \min_{1\leqslant i\leqslant N} F(t_i), \qquad F_{\max} = \max_{1\leqslant i\leqslant N} F(t_i). \tag{4.2}$$

A amplitude da curva é $\mathrm{Amp} = F_{\max} - F_{\min}$. Em curvas com ocultação, a amplitude tende a ser maior (queda pronunciada); em curvas negativas, o desvio padrão (σ $\hat{\sigma}$) e a amplitude tendem a ser menores. Os acentos circunflexos indicam que $\hat{\mu}$ e $\hat{\sigma}$ são estimativas, calculadas a partir dos N pontos da curva, da média e do desvio padrão do fluxo. O desvio padrão ~~σ~~ $\hat{\sigma}$ e a amplitude são portanto candidatos naturais a ~~*features*~~ características discriminativas.

4.5.2 Suavização (filtro de Savitzky-Golay)

Para reduzir o ruído de alta frequência sem perder a forma geral da curva, aplica-se uma suavização. Ela atua como um filtro passa-baixa — um filtro que deixa passar as variações lentas (baixas frequências) e atenua as rápidas (altas frequências): as flutuações

ponto a ponto, dominadas pelo ruído, são atenuadas, enquanto as variações lentas, que descrevem a forma da ocultação, são preservadas. Utiliza-se o filtro de Savitzky-Golay (Savitzky & Golay , 1964), implementado na função `savgol_filter` da biblioteca SciPy (Virtanen et al. , 2020): em cada janela móvel de w pontos ajusta-se, por mínimos quadrados, um polinômio de grau 2, e o ponto central é substituído pelo valor do polinômio. Por isso o filtro preserva melhor a profundidade de picos e vales do que uma média móvel simples. A largura da janela depende do número N de pontos da série: $w = \max(3, \lfloor N/3 \rfloor)$ para $N < 40$ e $w = \max(3, \lfloor N/40 \rfloor)$ para $N \geqslant 40$, somando-se 1 quando o resultado é par (o filtro simétrico exige w ímpar). O valor mínimo de 3 refere-se à janela, e não à série; curvas com menos de 5 pontos são descartadas da extração de características. Do fluxo suavizado extraem-se máximo, mínimo e desvio padrão. A suavização é especialmente importante para as derivadas (subseção seguinte): a diferenciação numérica amplifica as componentes de alta frequência, nas quais domina o ruído, de modo que derivadas da série bruta refletiriam sobretudo o ruído, e não a forma da queda.

Essas medidas resumem o comportamento "suave" da curva e são menos sensíveis a flutuações pontuais.

4.5.3 Queda máxima acumulada ~~(*max drawdown*)~~

~~O *max drawdown*, termo~~ A queda máxima acumulada, conceito emprestado da análise de séries financeiras, é a maior queda do fluxo em relação ao máximo atingido *anteriormente* na série:

$$\text{drawdown}(i) = F(t_i) - \max_{1 \leqslant j \leqslant i} F(t_j), \qquad \text{Max_Drawdown} = \min_i \text{drawdown}(i). \tag{4.3}$$

A motivação é física: em uma ocultação, a queda ocorre a partir de um patamar alto (a estrela ainda visível). Ao contrário da amplitude, ~~o *max drawdown*~~ a queda máxima acumulada respeita a ordem temporal — só contam quedas que vêm depois de um máximo, como uma imersão. Em curvas com ocultação, ~~o *max drawdown* tende a ser mais negativo; em~~ a queda máxima acumulada assume valores mais negativos, próximos de menos a profundidade da queda. Em curvas sem evento, ~~permanece próximo de zero (apenas flutuações)~~ela é menor em módulo, mas não nula: um pico de ruído seguido de uma flutuação para baixo já produz um valor de algumas vezes o desvio padrão do ruído.

4.5.4 K-means no fluxo suavizado

Conforme definido na Seção 3.4 (Capítulo 3), o K-means é um algoritmo de agrupamento não supervisionado; nesta etapa, ele é empregado não como classificador, mas como **extrator de característica**. Aplica-se o K-means com $K = 2$ aos valores do fluxo

suavizado (Savitzky-Golay), tratando cada ponto como um vetor unidimensional. A escolha de $K = 2$ é motivada pela física do problema: espera-se que uma curva com ocultação apresente dois regimes de fluxo (o nível fora do evento, ou ~~*baseline*~~linha de base, e o nível de fluxo menor durante o evento). A **distância entre os dois ~~centróides~~centroides** resultantes é então usada como ~~*feature*~~característica: curvas com ocultação bem definida tendem a apresentar distâncias maiores, enquanto curvas negativas, cujas variações de fluxo se devem apenas ao ruído, apresentam distâncias menores. É importante notar que o K-means sempre encontra dois grupos, mesmo em ruído puro: para uma série gaussiana de desvio padrão σ_s (o da série suavizada), os ~~centróides~~ centroides ficam em $\pm\sigma_s\sqrt{2/\pi}$ em torno da média, e a distância entre eles vale $\approx 1{,}6\,\sigma_s$. A característica só discrimina, portanto, quando a queda é algumas vezes maior que o ruído da série suavizada. Em quedas tênues, com profundidade comparável a $1{,}6\,\sigma_s$, a distância de uma curva positiva pode coincidir com a de uma negativa ruidosa; verificar se, mesmo assim, a característica contribui para a classificação é o objetivo desta extração.

4.5.5 Derivadas

A partir do fluxo suavizado, calculam-se a primeira e a segunda derivada (numericamente, e.g. via `np.gradient`). Uma ocultação típica produz picos negativos na primeira derivada (queda) e inflexões na segunda. São extraídas estatísticas dessas derivadas: mínimo, máximo, média, desvio padrão, assimetria (*skewness*, que mede o quanto a distribuição se afasta da simetria em torno da média) e curtose (*kurtosis*, que mede o peso das caudas da distribuição em relação ao da gaussiana; a implementação usa o excesso de curtose, nulo para uma gaussiana) da primeira derivada; mínimo, máximo e desvio padrão da segunda derivada. Essas ~~*features*~~ características capturam a "forma" da transição de fluxo e ajudam a distinguir quedas reais de quedas espúrias ou ruidosas.

4.5.6 Comparação entre quartis (testes estatísticos)

A série é dividida em quatro quartis temporais. Para cada par de quartis, aplicam-se o teste t de Welch (Welch , 1947), que compara as médias sem supor variâncias iguais, e o teste de Kolmogorov-Smirnov (K-S) para duas amostras (Kolmogorov , 1933; Smirnov , 1948), que compara as funções de distribuição acumulada; ambos estão implementados no SciPy (`ttest_ind` e `ks_2samp`) (Virtanen et al. , 2020) e fornecem um p-valor sob a hipótese de que as duas amostras vêm da mesma população (Wall & Jenkins , 2003; Morettin & Bussab , 2010). Em curvas com ocultação, pelo menos um quartil (o que contém a queda) tende a diferir dos demais; os p-valores dos testes tendem a ser pequenos. Define-se então a ~~*feature*~~ característica como o menor p-valor entre todos os pares, em escala logarítmica: $-\log_{10}(p_{\min} + \epsilon)$, para evitar $\log(0)$. Valores altos indicam ~~forte evidência de diferença entre segmentos,~~ que pelo menos um trecho da curva difere dos

demais, o que é compatível com a presença de um evento.

Essas duas grandezas são usadas como **medidas de heterogeneidade entre segmentos** da curva, e não como testes de hipótese no sentido estrito, por três razões. Primeiro, os testes supõem amostras independentes e estacionárias, condição que as curvas de luz não satisfazem: pontos vizinhos têm ruído correlacionado (cintilação, variações de transparência), e o quartil que contém a queda mistura dois regimes de fluxo, de modo que sua média não representa uma população única. Segundo, o p-valor depende não apenas da diferença entre os segmentos, mas também do número de pontos: duas ocultações idênticas recebem valores diferentes se forem registradas com cadências diferentes. Terceiro, não há correção para as seis comparações múltiplas. Os p-valores obtidos não são, portanto, interpretados como probabilidades. Como características para o classificador, as duas grandezas separam as classes, mas são redundantes com as demais: sua remoção não altera o desempenho dos modelos (Seção 5.5.1). Uma alternativa estatisticamente mais adequada para a mesma ideia seria usar o tamanho do efeito, isto é, a maior diferença entre as médias dos quartis dividida pelo desvio padrão combinado, que não depende do número de pontos.

4.5.7 Métricas de profundidade, duração e ajuste de modelos

Além das ~~*features*~~ características descritas até aqui, a ~~*pipeline*~~ cadeia de processamento incorpora um conjunto de métricas inspiradas em critérios observacionais discutidos em fóruns entre astrônomos amadores para análise de curvas difíceis de ocultação. Não há documento oficial que defina essas grandezas como critério definitivo para classificar uma curva como positiva; no texto referimo-nos a elas simplesmente como **métricas de profundidade, duração e ajuste de modelos**, isto é, grandezas adotadas neste trabalho e inspiradas em critérios práticos de análise. A implementação concreta segue o módulo de engenharia de características do projeto (arquivo `occ_features.py`), cujas fórmulas são resumidas abaixo.

~~***Baseline***~~**Linha de base.** O nível de fluxo fora da ocultação é estimado pela mediana da série: baseline = mediana(F). Em implementações alternativas pode-se usar a média dos pontos com fluxo acima da mediana. A mediana é robusta a ~~*outliers* — valores~~ valores atípicos — pontos extremos isolados, como quedas ou picos pontuais causados por raios cósmicos ou defeitos de leitura —, que pouco a deslocam, ao contrário do que ocorreria com a média.

Profundidade da queda (*dip*). A queda do fluxo em relação ~~ao *baseline*~~ à linha de base é

$$\text{depth} = \max\big(0,\ \text{baseline} - \min_i F(t_i)\big). \tag{4.4}$$

~~Em~~ Mesmo em curvas sem ocultação, ~~depth ≈ 0; em~~ depth não é nulo: o mínimo de N pontos de ruído fica, em média, cerca de 3 desvios padrão abaixo da mediana para

$N \sim 10^3$. Em curvas com evento, depth reflete a magnitude da queda.

Desvio ~~do *baseline*~~da linha de base. O desvio padrão σ_{baseline} é calculado apenas sobre os pontos com fluxo $\geqslant$ baseline (fora ~~do *dip*~~da queda). Essa grandeza estima o **ruído fotométrico fora do evento**: a dispersão natural do fluxo medido quando não há ocultação, decorrente das incertezas de medição (ruído de fótons, de leitura e de cintilação atmosférica). Usá-la como referência evita contaminar a medida de ruído com a própria queda. Se houver poucos pontos acima ~~do *baseline*~~da linha de base, usa-se o desvio padrão de toda a série.

SNR ~~do *dip*~~da queda. Neste trabalho, define-se a razão sinal-ruído da queda como o quociente entre a profundidade ~~do *dip*~~ da queda e o ruído estimado fora do evento:

$$\text{SNR_dip} = \frac{\text{depth}}{\sigma_{\text{baseline}}}. \tag{4.5}$$

Valores altos indicam queda ~~significativa~~ grande em relação ao ruído, compatível com evento real. Essa grandeza é um indicador, e não uma razão sinal-ruído no sentido usual: como σ_{baseline} é calculado apenas sobre a metade superior da distribuição (para ruído gaussiano, $\sigma_{\text{baseline}} \approx 0{,}60\,\sigma$) e o numerador é um valor extremo, o indicador vale cerca de 5 em ruído puro com $N = 1000$ pontos. Além disso, quando a ocultação ocupa mais da metade da curva, a mediana passa a pertencer ao patamar da queda e o indicador diminui.

Sequências abaixo ~~do *baseline*~~da linha de base. Uma *sequência* (*run*) é um bloco consecutivo de índices em que $F(t_i) <$ baseline. Ocultações típicas produzem uma sequência longa; ruído tende a sequências curtas ou isoladas. Define-se o **número de ~~*frames*~~ quadros na maior sequência** como a quantidade de pontos do maior bloco consecutivo abaixo ~~do *baseline*~~da linha de base.

Duração em segundos. A duração da maior sequência é ~~$\Delta t = t_{\text{fim}} - t_{\text{início}}$, onde $t_{\text{início}}$~~ $\Delta t = t_{\text{fim}} - t_{\text{início}}$, onde $t_{\text{início}}$ e t_{fim} são os instantes do primeiro e do último ponto dessa sequência. Essa grandeza está ligada à geometria do evento (tamanho do objeto, velocidade da sombra, posição da corda, etc.).

Fluxo mínimo e razão. Sejam $F_{\min} = \min_i F(t_i)$ e a razão $F_{\min}/\text{baseline}$ (quando baseline > 0). Em curvas normalizadas com ocultação, a razão tende a ser menor que 1.

Chiš do modelo constante. O modelo "sem evento" assume fluxo constante igual ~~ao *baseline*~~à linha de base. Define-se

$$\chi^2_{\text{const}} = \sum_i \frac{(F_i - \mu)^2}{s^2_{\text{MAD}}}, \tag{4.6}$$

com $\mu =$ baseline e s_{MAD} uma escala robusta dos resíduos (por exemplo, MAD — mediana do valor absoluto dos desvios em relação à mediana).

Chiš do modelo ~~"square well"~~de poço retangular (*square well*). O modelo

com ~~*dip*~~ queda assume nível constante fora da janela da maior sequência e nível constante (média do fluxo) dentro da janela, em formato de "poço retangular". Esse modelo é a versão mais simples do modelo geométrico da Figura 2.3 (curva verde): bordas nítidas, sem difração nem integração temporal; difere dele por ajustar o nível interno (a média dos pontos da janela) em vez de fixá-lo, o que acomoda a luz residual do corpo ocultante. No modelo de poço retangular, o valor previsto para cada ponto, $\hat{F}_i$, é igual ~~ao *baseline*~~ à linha de base fora da janela e à média dos fluxos dentro dela. Define-se

$$\chi^2_{\mathrm{sw}} = \sum_i \frac{(F_i - \hat{F}_i)^2}{s^2_{\mathrm{MAD}}}. \tag{4.7}$$

Razão chiš. A grandeza

$$\chi^2_{\mathrm{ratio}} = \frac{\chi^2_{\mathrm{const}}}{\chi^2_{\mathrm{sw}}} \tag{4.8}$$

mede o ganho de ajuste ao incluir ~~o *dip*~~a queda: valores $\chi^2_{\mathrm{ratio}} > 1$ indicam que o modelo com ~~*dip*~~ queda explica melhor os dados. Na implementação, a razão é limitada ao intervalo [0,1, 10] para evitar valores extremos. Curvas sem ~~*dip*~~ queda tendem a $\chi^2_{\mathrm{ratio}} \approx 1$.

No ~~*dataset* gerado pela *pipeline*~~conjunto de dados gerado pela cadeia de processamento, essas grandezas aparecem em colunas cujos nomes no código possuem o prefixo `Occ_` (de *occultation*), por exemplo `Occ_depth`, `Occ_duration_s`. No texto, tratamos todas elas como métricas de profundidade, duração e ajuste de modelos.

4.5.8 Resumo das ~~*features*~~características

O vetor final de ~~*features*~~ características inclui: amplitude e desvio padrão do fluxo; máximo, mínimo e desvio padrão do fluxo suavizado por Savitzky-Golay; ~~*max drawdown*~~ queda máxima acumulada; distância entre ~~centróides~~ centroides do K-means no fluxo; mínimos $-\log_{10}(p)$ dos testes t e K-S entre quartis; as estatísticas das derivadas primeira e segunda listadas acima; e as métricas de profundidade, duração e ajuste de modelos (profundidade ~~do *dip*, SNR do *dip*~~da queda, SNR da queda, duração em segundos da maior sequência abaixo ~~do *baseline*~~da linha de base, número de ~~*frames*~~ quadros na maior sequência, desvio padrão ~~do *baseline*~~da linha de base, fluxo mínimo, razão fluxo mínimo/~~*baseline*~~ linha de base, χ^2 do modelo constante, χ^2 do modelo ~~square well~~de poço retangular, razão $\chi^2_{\mathrm{const}}/\chi^2_{\mathrm{sw}}$). Todas as colunas de ~~*features*~~ características são numéricas; metadados como identificador da curva e rótulo (positivo/negativo) são mantidos em colunas separadas e não são usados como entrada do classificador. O resultado da etapa de engenharia de características é um arquivo tabular (por exemplo, `dataset_final.csv`) em que cada linha é uma curva e as colunas são as ~~*features*~~ características mais o rótulo e o identificador.

4.6 Treinamento e avaliação dos modelos

4.6.1 Preparação dos dados e ~~divisão treino/testeprotocolo de avaliação~~

O ~~*dataset*~~ conjunto de dados final é carregado a partir do arquivo gerado na etapa anterior. As colunas de metadados (identificador da curva, fonte, rótulo) são separadas das colunas de *features*. ~~Valores faltantes (NaN) são preenchidos pela~~ **mediana** ~~calculada no conjunto de treino (`SimpleImputer` com `strategy='median'`), estratégia robusta a outliers. O~~ características, e o rótulo binário (ocultação presente = 1, ausente = 0) é definido como variável alvo.

~~A divisão entre treino e teste pode ser feita de duas formas:~~

~~**Divisão estratificada:** os dados são divididos aleatoriamente em~~ A única curva com valor ausente em uma característica é descartada; um imputador (*imputer*) pela **mediana** do conjunto de treino ~~e conjunto de teste (por exemplo, 80% treino e 20% teste) , mantendo a proporção das classes em cada parte (~~(`SimpleImputer` com `strategy='median'`) permanece acoplado a cada modelo (objeto `Pipeline` do ~~*stratified split*~~*scikit-learn*) ~~. Uma semente fixa (*random state*) é utilizada na divisão para garantir reprodutibilidade; a mesma semente (ou sementes documentadas) é empregada no treinamento de cada modelo (Regressão Logística, Random Forest, XGBoost, CatBoost), de modo que os experimentos sejam reproduzíveis.~~ como salvaguarda para curvas novas.

O protocolo de avaliação, detalhado na Seção 5.4, separa as escolhas da estimativa final de desempenho:

1. ~~**Seleção manual**~~ **Conjunto de teste reservado**:~~**um subconjunto de curvas**~~ antes de qualquer escolha de modelagem, um quinto dos grupos de curvas (341 curvas) é ~~fixado como conjunto de teste (por exemplo,~~ separado, com estratificação por classe e **agrupamento por evento**: todas as curvas de um ~~objeto ou data específicos) . O restante compõe o treino. Essa opção~~ mesmo evento de ocultação (mesmo objeto e mesmo mês de observação) — cordas de observadores diferentes e os recortes "antes" e "depois" extraídos de uma mesma curva — ficam do mesmo lado da divisão. Uma semente aleatória fixa garante a reprodutibilidade.

2. **Validação cruzada no conjunto de desenvolvimento:** nas curvas restantes, cada combinação de configuração de características e modelo é ~~útil para avaliar a generalização para cenários de interesse conhecido.~~

   ~~As métricas de desempenho (acurácia, precisão, sensibilidade, F1-score, AUC-ROC) são calculadas no conjunto de teste e reportadas no Capítulo 5. Quando a escolha de hiperparâmetros for feita~~ avaliada por validação cruzada ~~, pode-se reportar também a média e o~~ estratificada e agrupada por evento (5 dobras, repetidas com 5 sementes).

A configuração de características e o limiar de decisão de cada modelo são escolhidos com base nessas estimativas, reportadas como média ± desvio padrão~~da métrica nas dobras de validação, para dar noção da variabilidade;~~ .

3. **Avaliação final:** os modelos escolhidos são retreinados em todo o conjunto de desenvolvimento e avaliados uma única vez no conjunto de teste~~, as métricas são reportadas como valor único, condicionado à divisão treino/teste adotada~~.

Dessa forma, nenhuma escolha de configuração, modelo ou limiar usa o conjunto de teste. As configurações candidatas, porém, foram definidas em análises anteriores, que tinham acesso a todas as curvas (Seção 5.4); por isso, o desempenho no teste é uma estimativa possivelmente um pouco otimista.

4.6.2 Modelos utilizados

Foram utilizados quatro algoritmos de classificação supervisionada, descritos no Capítulo 3:

- **Regressão Logística:** classificador linear probabilístico com regularização ℓ_2 (Ridge)~~ou ℓ_1 (Lasso); hiperparâmetro de~~ , com força de regularização ~~(C ou α)escolhido via validação cruzada~~fixa no valor padrão do *scikit-learn* ($C = 1$), algoritmo de otimização L-BFGS e peso das classes balanceado.

- **Random Forest:** ~~*ensemble*~~ comitê de árvores de decisão com *bagging*; hiperparâmetros típicos incluem número de árvores (`n_estimators`), profundidade máxima (`max_depth`) e peso das classes (`class_weight='balanced'`) para lidar com desbalanceamento.

- **XGBoost:** *gradient boosting* com árvores; controle de profundidade, taxa de aprendizado (`learning_rate`), subamostragem de linhas e colunas; treinado sem ponderação de classes, pois o conjunto é aproximadamente equilibrado.

- **CatBoost:** outro algoritmo de *boosting*, com opção de ponderação automática das classes (`auto_class_weights='Balanced'`).

Os valores concretos dos hiperparâmetros~~utilizados nos experimentos (e eventual busca em grade ou validação cruzada)~~ , fixos e iguais em todos os experimentos, estão documentados no Apêndice B. A escolha desses modelos deve-se ao seu bom desempenho em problemas de classificação com dados tabulares, à interpretabilidade (importância de variáveis) e à disponibilidade em bibliotecas estáveis (scikit-learn, XGBoost, CatBoost). Para quantificar a interpretabilidade, a **importância das variáveis** é calculada ~~da seguinte forma: nos *ensembles* baseados em árvores~~ (pela métrica padrão de cada biblioteca: queda média na impureza (MDI) no Random Forest, ~~XGBoost, CatBoost), utiliza-se~~

~~a importância por **queda média na impureza** (Gini) em cada divisão em que a variável participa, conforme fornecido pelas respectivas bibliotecas~~redução média da perda (*gain*) no XGBoost e *PredictionValuesChange* no CatBoost; na Regressão Logística, utilizam-se os coeficientes estimados ~~(em valor absoluto). Os rankings~~ sobre as características padronizadas. Os métodos, as ordenações e as magnitudes das importâncias são apresentados e discutidos no Capítulo 5.

4.6.3 Métricas de avaliação

As definições formais das métricas de classificação binária utilizadas neste trabalho — acurácia, precisão, sensibilidade, F1-score, F_β-score, AUC-ROC e curva ~~*precision-recall*~~ precisão-sensibilidade — foram apresentadas na Seção 3.6.2 (Capítulo 3). Aqui, discutem-se as escolhas específicas adotadas na ~~*pipeline*~~ cadeia de processamento à luz do problema de detecção de ocultações.

Em problemas de detecção de eventos, a matriz de confusão e as métricas dela derivadas permitem avaliar a capacidade do modelo de tomar decisões confiáveis (Cazeneuve et al. , 2023). A **curva ROC** visualiza o compromisso (*trade-off*) entre a taxa de verdadeiros positivos (sensibilidade) e a taxa de falsos positivos à medida que o limiar de decisão varia; a **área sob a curva** (AUC-ROC) resume a capacidade de ordenação do modelo de forma independente do limiar escolhido (Sudjianto & Liu , 2025). Em problemas com **classe positiva rara** — isto é, quando os exemplos de interesse (positivos) são minoria expressiva frente aos negativos —, a **curva ~~*precision-recall*~~precisão-sensibilidade** pode ser mais informativa, pois não é inflada pelo grande número de verdadeiros negativos.

No ~~contexto~~ conjunto de dados desta dissertação ~~, em que os dados são desbalanceados (muitas~~ as classes estão aproximadamente equilibradas (47 % de positivas), mas em campanhas reais as curvas sem ocultação ~~)~~podem ser maioria; nesse cenário, a **acurácia** sozinha pode ser enganosa, conforme ilustrado pelo exemplo numérico do Capítulo 3. Para detecção de ocultações estelares, a **sensibilidade** tem prioridade, pois não perder eventos raros é essencial; a **precisão** evita excesso de falsos positivos que sobrecarregariam a triagem humana. O **F1-score** equilibra precisão e sensibilidade e é adequado para comparar os quatro modelos em cenário desbalanceado. A **AUC-ROC** avalia a capacidade de separação das classes de forma global.

4.6.4 Fluxo de treinamento e persistência

O fluxo de treinamento é: (1) carregar o conjunto de dados; (2) separar as colunas de características das colunas de rótulo (positivo/negativo); (3) ~~dividir em treino e teste(por exemplo, 80% treino, 20% teste)~~reservar o conjunto de teste, agrupado por evento; (4) ~~treinar cada um dos quatro modelos~~ avaliar cada configuração e cada modelo por validação cruzada no conjunto de ~~treino~~desenvolvimento e escolher configuração e li-

miar; (5) ~~avaliar cada modelo~~ retreinar os modelos escolhidos em todo o desenvolvimento e avaliá-los uma única vez no conjunto de teste~~, calculando as métricas acima~~; (6) gerar visualizações (curvas ROC, matrizes de confusão, importância de cada variável); (7) salvar os modelos ajustados e um resumo das métricas em disco. Esse fluxo está implementado nos programas `train_model.py` e `reanalise_banca.py`, no diretório `pipeline/model_training` do repositório do projeto. Os modelos salvos podem ser carregados depois para classificar novas curvas ou para comparação com outras configurações. Os resultados numéricos e as figuras são a base da discussão do Capítulo 5. O ambiente de software (versões do Python e das bibliotecas) necessário para reproduzir esse fluxo está documentado no Apêndice C.

Este capítulo apresentou a metodologia completa da ~~*pipeline* de~~ cadeia de processamento de detecção de ocultações estelares em curvas de luz: desde a aquisição e o armazenamento em banco relacional até o treinamento e a avaliação de classificadores. A arquitetura em etapas (aquisição → acesso e normalização → construção do ~~*dataset*~~ conjunto de dados → engenharia de características → treinamento) permite reproduzir o fluxo e estendê-lo com novas fontes de dados, novas ~~*features*~~ características ou novos modelos. A combinação de dados reais (VizieR, Grupo do Rio), negativos por recorte (~~obtidos manualmente~~com inspeção visual) e curvas ~~simuladas visa~~ negativas simuladas produz um conjunto de treino ~~equilibrado e representativo.~~ com classes aproximadamente equilibradas (47 % de positivas). Essa composição não reproduz a das campanhas observacionais reais: nelas, a proporção entre cordas positivas e negativas varia de evento para evento e as negativas têm ruído real, ao passo que 79 % das negativas deste conjunto são simuladas, com ruído em geral menor que o das curvas observadas. As implicações dessa diferença são discutidas no Capítulo 5. A extração de características baseada em estatísticas, suavização, derivadas e testes entre quartis fornece uma representação vetorial adequada aos modelos de árvore e à Regressão Logística utilizados. No próximo capítulo, são apresentados os resultados obtidos com os quatro modelos treinados (Regressão Logística, Random Forest, XGBoost, CatBoost), incluindo comparação de desempenho, análise de importância das variáveis e discussão sobre generalização e possível ~~*overfitting*~~ sobreajuste.

Capítulo 5

Resultados

5.1 Visão geral dos experimentos

Este capítulo apresenta os resultados obtidos com a ~~*pipeline* de~~ cadeia de processamento de detecção automatizada de ocultações estelares em curvas de luz, descrita no Capítulo 4. O problema é formulado como **classificação binária**~~em que~~ , e foram treinados e avaliados quatro classificadores — Regressão Logística, Random Forest, XGBoost e CatBoost~~— cujo desempenho foi medido exclusivamente no~~ . Todas as escolhas (a configuração de características e o limiar de decisão de cada modelo) foram feitas por **validação cruzada** em um conjunto de desenvolvimento; um **conjunto de teste**, ~~isto é, em dados que não participaram do treinamento~~reservado antes de qualquer escolha, foi usado uma única vez, ao final, para estimar o desempenho dos modelos escolhidos (Seção 5.4).

As métricas adotadas são: **acurácia** (fração de acertos no total), **precisão** (entre as curvas classificadas como positivas, quantas eram realmente positivas), **sensibilidade** ~~ou *recall*~~ (entre todas as curvas realmente positivas, quantas foram detectadas), **F1-score** (média harmônica entre precisão e sensibilidade) e **área sob a curva ROC** (AUC-ROC), que resume a capacidade do modelo de separar as duas classes para diversos limiares de decisão. Como as curvas negativas simuladas são, em geral, mais fáceis de reconhecer que as reais, reporta-se também a **taxa de falsos positivos nas negativas reais**, isto é, a fração dos negativos por recorte e das negativas nativas classificada como positiva. As **matrizes de confusão** mostram ~~quantos verdadeiros positivos (TP), verdadeiros negativos (TN), falsos positivos (FP) e falsos negativos (FN) cada modelo produziu~~as contagens de TP, TN, FP e FN (Seção 3.6.2) de cada modelo.

A montagem de um conjunto de dados equilibrado foi a primeira grande dificuldade do projeto: nos catálogos disponíveis (VizieR, Grupo do Rio), o número de curvas negativas é muito inferior ao de positivas — o banco dispunha de ~~802~~ 927 curvas positivas e apenas 3 negativas. Para contornar esse desbalanceamento, adotaram-se duas estra-

tégias complementares, descritas no Capítulo 4: recorte de segmentos sem ocultação a partir ~~das~~ de curvas positivas (com revisão manual), gerando 186 negativos por recorte ~~,~~ a partir de 125 curvas positivas, que foram por isso excluídas do conjunto, e incorporação de 702 curvas negativas simuladas geradas pelo simulador físico de Gomes-Ferrante & Braga-Ribas (2023). O ~~*dataset*~~ conjunto de dados final reúne **1693 amostras** (802 positivas e 891 negativas)~~, com divisão treino/teste estratificada por curva (80%/20%)~~; uma curva positiva com valor ausente em uma das características foi descartada, de modo que as análises usam 1692 curvas. Entre as positivas, um par corresponde à mesma série de fluxo registrada sob dois nomes de observador (Euphrosyne, fev./2018); como as duas pertencem ao mesmo evento, ficam sempre do mesmo lado das partições e não causam vazamento.

~~Ao todo, foram realizados **seis experimentos**, que variam o conjunto de *features* (de 28 a 11 variáveis) e a composição do conjunto de teste (misto ou exclusivamente real). Como o desempenho se mostrou notavelmente estável entre eles, este capítulo apresenta **em detalhe os três experimentos mais informativos**, que sintetizam a progressão lógica do trabalho~~Foram avaliadas cinco configurações de características, nomeadas de modo a refletir a ordem em que o conjunto é reduzido, e duas análises complementares:

- **Experimento 1:** conjunto completo de 28 ~~*features*~~ características (Tabela 5.1)~~, divisão 80%/20%. É a~~ .
- ~~**linha de base**~~**Experimento 1.1:** ~~de desempenho, com todas as~~ 13 características, após a remoção das 15 variáveis ~~disponíveis~~redundantes identificadas na Seção 5.2 (Tabela 5.2).
- ~~**Experimento 2**~~**Experimentos 1.2a e 1.2b:** ~~11 *features* (sem~~ 12 características, removendo do Experimento 1.1, respectivamente, `Feature_Savgol_Min` e ~~sem~~ `kmeans_centroid_dist`~~), divisão 80%/20%. É a **configuração enxuta** adotada como referência operacional — a mais simples sem perda de desempenho, e a usada no estudo de caso de Quaoar~~, duas das variáveis de maior importância nos modelos de árvore da configuração 1.1.
- **Experimento ~~32~~:** 11 ~~features, porém com teste somente em curvas reais (as simuladas permanecem no treino). É o teste de generalização mais próximo do uso real.~~características, removendo ambas.
- **Análise 2.1:** desempenho no conjunto de teste restrito às curvas reais (161 positivas e 34 negativas reais), excluindo da avaliação as 146 negativas simuladas, para avaliar o desempenho em uma situação mais próxima do uso em campanhas observacionais.
- **Análise 2.2:** desempenho em função do tamanho do conjunto de treino.

~~Os demais três experimentos — a redução intermediária de features para 14 (Experimento 4) e 13 variáveis (Experimento 5) e a ablação isolada da feature kmeans_centroid_dist (Experimento 6) — conduzem às mesmas conclusões e estão documentados em detalhe no Apêndice, que reúne ainda uma variante do Experimento 3 com divisão 65%/35%, usada como ablação do tamanho do conjunto de treino. Suas métricas são consolidadas, ao lado das dos três experimentos-destaque, na Tabela ?? (Seção 5.5).~~

~~Em todos os experimentos, o mesmo protocolo foi aplicado: divisão treino/teste estratificada, preenchimento de valores faltantes pela mediana calculada no treino, e padronização das características (média zero, desvio unitário) apenas para a Regressão Logística, conforme detalhado no Capítulo 4.~~

Além ~~dos experimentos de~~ da classificação, ~~este~~ o capítulo apresenta ~~um~~a análise de **ajuste do limiar de decisão** (Seção 5.7), que investiga como reduzir o limiar ~~de classificação~~ para minimizar falsos negativos — uma demanda natural em ~~cenários de~~ triagem científica, ~~onde~~ em que perder uma ocultação real é mais custoso do que revisar um falso alarme ~~. Por fim,~~ — e um **estudo de caso** (Seção 5.8) ~~aplica a *pipeline* a curvas reais~~ com curvas de uma ocultação estelar pelo objeto transnetuniano (50000) Quaoar (Pereira et al. , 2023; Morgado et al. , 2023) ~~— dados externos~~ , externas ao banco de treino e morfologicamente ~~complexos~~ complexas (corpo principal e estruturas de anel) ~~— como teste de generalização operacional e como demonstração da capacidade de revisitar curvas em busca de eventos sutis~~.

5.2 Descrição das ~~*features*~~ características e análise de redundância

5.2.1 Conjunto completo de ~~*features*~~características

A ~~*pipeline* de~~ cadeia de processamento de extração de características produz 28 variáveis numéricas a partir de cada curva de luz normalizada. Essas variáveis podem ser agrupadas em cinco famílias, descritas na Tabela 5.1.

Nas definições acima, F denota o vetor de fluxo normalizado (como no Capítulo 4), $\tilde{F}$ o fluxo suavizado por filtro Savitzky-Golay (polinômio de grau 2, janela adaptativa), F' e F'' a primeira e segunda derivadas numéricas de $\tilde{F}$, e ~~*baseline* a~~ baseline a linha de base, isto é, a mediana de F.

5.2.2 Análise de redundância

A presença de variáveis redundantes — altamente correlacionadas ou conceitualmente equivalentes — pode inflar a dimensionalidade sem acrescentar informação discriminativa,

Tabela 5.1: Conjunto completo de 28 ~~*features*~~ características extraídas pela ~~*pipeline*~~cadeia de processamento. A coluna "Família" indica o grupo funcional; a coluna "Definição" resume o cálculo.

Família	**Característica**	**Definição**
Fluxo bruto	`Feature_Amp`	$\max(F) - \min(F)$ (amplitude total do fluxo)
	`Feature_Flux_std`	$\sigma(F)$ (desvio padrão do fluxo)
	`Max_Drawdown`	$\min(F_i - \max_{j \leqslant i} F_j)$ (maior queda acumulada)
Savitzky-Golay	`Feature_Savgol_Max`	$\max(\tilde{F})$ (máximo do fluxo suavizado)
	`Feature_Savgol_Min`	$\min(\tilde{F})$ (mínimo do fluxo suavizado)
	`Feature_Savgol_std`	$\sigma(\tilde{F})$ (desvio padrão do fluxo suavizado)
K-means	`kmeans_centroid_dist`	Distância entre os 2 centroides do K-means aplicado a $\tilde{F}$
Testes de quartis	`MinLogP_Ttest`	$-\log_{10}(\min p_{\text{t-test}})$ entre pares de quartis
	`MinLogP_KS`	$-\log_{10}(\min p_{\text{KS}})$ entre pares de quartis
Derivadas	`Deriv_Min`	$\min(F')$
	`Deriv_Max`	$\max(F')$
	`Deriv_Mean`	$\bar{F}'$
	`Deriv_Std`	$\sigma(F')$
	`Deriv_Skew`	Assimetria de F'
	`Deriv_Kurtosis`	Curtose de F'
	`SecondDeriv_Min`	$\min(F'')$
	`SecondDeriv_Max`	$\max(F'')$
	`SecondDeriv_Std`	$\sigma(F'')$
Observacionais	`Occ_depth`	$\text{baseline} - \min(F)$ (profundidade da queda)
	`Occ_SNR_dip`	$\text{depth}/\sigma_{\text{baseline}}$ (razão sinal-ruído da queda)
	`Occ_duration_s`	Duração do maior bloco abaixo da linha de base (em segundos)
	`Occ_n_frames_below_baseline`	Maior nž de quadros consecutivos abaixo da linha de base
	`Occ_baseline_std`	$\sigma(F \mid F \geqslant \text{baseline})$ (ruído fora da queda)
	`Occ_flux_min`	$\min(F)$
	`Occ_flux_min_over_baseline`	$\min(F)/\text{baseline}$
	`Occ_chi2_constant`	χ^2 do modelo constante (sem evento)
	`Occ_chi2_square_well`	χ^2 do modelo de poço retangular
	`Occ_chi2_ratio`	$\chi^2_{\text{const}}/\chi^2_{\text{sw}}$ (razão de ajuste)

aumentar o risco de ~~*overfitting*~~ sobreajuste e dificultar a interpretação da importância das ~~*features*~~características. Para identificar pares redundantes, foram analisadas tanto as definições matemáticas quanto as correlações empíricas entre as 28 variáveis. A Figura 5.1 mostra a matriz de correlação de Spearman: os blocos de correlação alta (em módulo) correspondem a grupos de variáveis que medem o mesmo aspecto da curva, como as estatísticas de derivadas entre si ($|\rho| \approx 0{,}97$–$0{,}98$), a amplitude e a queda máxima acumulada ($\rho = -0{,}99$) ou o fluxo mínimo e sua razão pela linha de base ($\rho = 0{,}99$). Os pares identificados e a variável mantida em cada caso são ~~apresentados~~ listados a seguir.

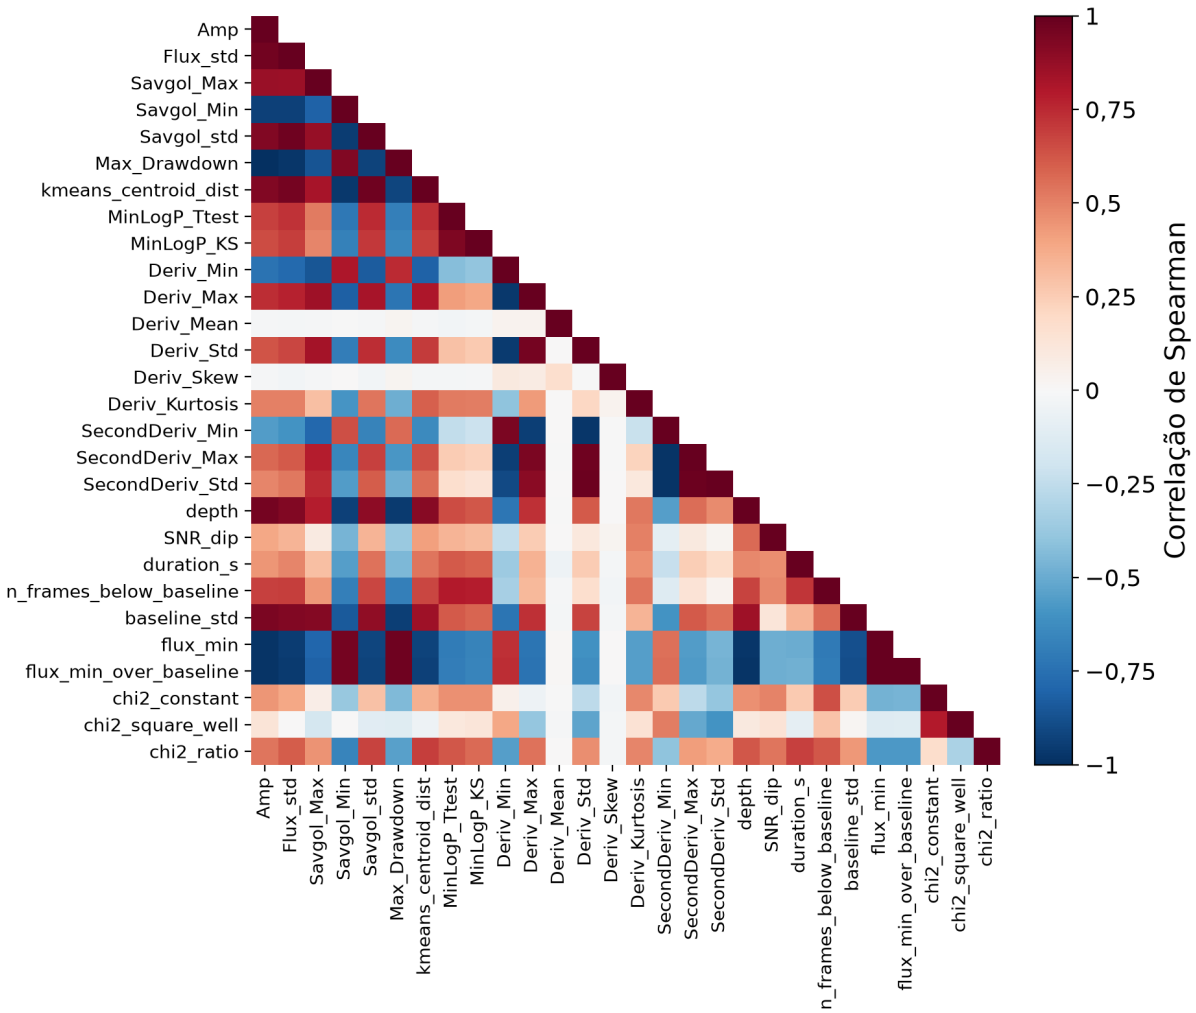


Figura 5.1: Matriz de correlação de Spearman entre as 28 características (1692 curvas, inclusive as do conjunto de teste; análise descritiva, sem uso dos rótulos), com apenas o triângulo inferior, pois a matriz é simétrica. Os prefixos `Feature_` e `Occ_` foram omitidos dos rótulos.

1. **`Feature_Amp` vs. `Occ_depth`.** A amplitude é definida como $\max(F) - \min(F)$, enquanto a profundidade observacional é baseline $-$ $\min(F)$, com baseline $=$ mediana(F). Para curvas de fluxo normalizado próximo de 1, o máximo tende a coincidir com a mediana, tornando as duas métricas praticamente idênticas.

Removida: `Feature_Amp`. **Mantida:** `Occ_depth`, por possuir motivação física direta na caracterização de ocultações.

2. **`Feature_Flux_std` vs. `Occ_baseline_std`.** O desvio padrão do fluxo total ($\sigma(F)$) inclui os pontos dentro ~~do *dip*~~da queda, inflando a medida de ruído quando há ocultação. O desvio padrão ~~do *baseline*~~ da linha de base ($\sigma(F \mid F \geqslant \text{mediana})$) estima o ruído fotométrico fora do evento, sendo mais adequado fisicamente. **Removida:** `Feature_Flux_std`. **Mantida:** `Occ_baseline_std`.

3. **`Occ_flux_min` vs. `Feature_Savgol_Min`.** O mínimo do fluxo bruto e o mínimo do fluxo suavizado por Savitzky-Golay são altamente correlacionados, pois o filtro preserva a posição dos mínimos. A versão suavizada é mais robusta a ruído pontual. **Removida:** `Occ_flux_min`. **Mantida:** `Feature_Savgol_Min`.

4. **`Occ_flux_min_over_baseline`.** Esta razão (min(F)/baseline) é algebricamente derivável de `Occ_depth` e do valor ~~do *baseline*~~da linha de base, não acrescentando informação independente. **Removida.**

5. **`Occ_n_frames_below_baseline` vs. `Occ_duration_s`.** Para observações com cadência uniforme, a duração em segundos é proporcional ao número de ~~*frames*~~ quadros ($\Delta t_{\text{dur}} \approx n_{\text{frames}} \times \delta t$). A duração em unidade física (segundos) é mais interpretável e invariante a mudanças de cadência. ~~**Removido**~~**Removida:** `Occ_n_frames_below_baseline`. **Mantida:** `Occ_duration_s`.

6. **`Feature_Savgol_Max`.** Para fluxo normalizado, o máximo do sinal suavizado ~~é~~ fica próximo de 1 ~~,0 em quase todas as curvas , resultando em variância muito baixa e poder discriminativo desprezível~~na maior parte das curvas e acrescenta pouca informação sobre a queda. **Removida.**

7. **Nove ~~*features*~~ características de derivadas (`Deriv_*` e `SecondDeriv_*`).** ~~No Experimento 4, a remoção das nove *features* de derivadas não causou perda de desempenho (F1 mantido em 0~~As derivadas são fortemente correlacionadas entre si (Figura 5.1), ~~99). Além disso, e~~ as métricas observacionais de profundidade, duração e razão χ^2 já capturam as variações abruptas do fluxo que ~~as derivadas~~ elas buscam codificar, caracterizando redundância conceitual. **Removidas** todas as nove variáveis de derivadas.

Após a remoção, o conjunto ~~final utilizado no treinamento~~ contém **13 ~~*features*~~características**, listadas na Tabela 5.2 (Experimento 1.1).

É importante ressaltar que as 15 variáveis removidas **continuam sendo calculadas e armazenadas** no arquivo CSV do ~~*dataset*~~conjunto de dados. A exclusão ocorre apenas

Tabela 5.2: Conjunto de 13 ~~*features*~~ características após a análise de redundância ~~. O conjunto de referência operacional~~ (Experimento ~~21~~.1)~~remove~~. Os Experimentos 1.2a, 1.2b e 2 removem ainda `Feature_Savgol_Min`~~e~~, `kmeans_centroid_dist` ou ambas, ~~restando 11.~~respectivamente.

Família	**Características**
Savitzky-Golay	`Feature_Savgol_Min`, `Feature_Savgol_std`
Fluxo bruto	`Max_Drawdown`
K-means	`kmeans_centroid_dist`
Testes de quartis	`MinLogP_Ttest`, `MinLogP_KS`
Observacionais	`Occ_depth`, `Occ_SNR_dip`, `Occ_duration_s`, `Occ_baseline_std`, `Occ_chi2_constant`, `Occ_chi2_square_well`, `Occ_chi2_ratio`

no momento do treinamento, por meio de uma lista configurável no código (`EXCLUDED_FEATURES`). Essa decisão de projeto permite re-incluir qualquer variável em estudos futuros de ablação sem necessidade de reprocessar as curvas de luz.

5.3 Importância das ~~*features*~~características: metodologia

Uma das vantagens de modelos baseados em árvores e de modelos lineares é a possibilidade de quantificar a contribuição individual de cada variável para a decisão do classificador. Entretanto, cada família de modelos emprega uma definição distinta de "importância", e valores obtidos por métodos diferentes **não devem ser comparados diretamente em escala absoluta**. Esta seção descreve o cálculo adotado ~~internamente~~ por cada um dos quatro classificadores utilizados neste trabalho.

5.3.1 Random Forest — *Mean Decrease in Impurity* (MDI)

No caso do Random Forest, cada nó de cada árvore realiza uma divisão ~~(*split*)~~ em uma variável, e essa divisão reduz a impureza (medida pelo índice de Gini) dos subconjuntos resultantes. Para uma ~~*feature*~~ característica x_j, a importância MDI é definida como a **média**, sobre todas as árvores e todos os nós, da redução de impureza atribuída a x_j:

$$\mathrm{MDI}(x_j) \;=\; \frac{1}{T}\sum_{t=1}^{T}\sum_{n\in\mathcal{N}_t(x_j)} \Delta I(n),$$

onde T é o número de árvores, $\mathcal{N}_t(x_j)$ é o conjunto de nós da árvore t que utilizam x_j para ~~o *split*~~ divisão, e $\Delta I(n)$ é a redução ponderada de impureza no nó n.

Na implementação do `scikit-learn`, os valores de MDI são **normalizados para que a soma seja igual a 1**. ~~Consequentemente, com 13 *features*, nenhuma variável individual~~

~~ultrapassa tipicamente valores de importância em torno de 0,20–0,30, e o eixo horizontal dos gráficos de importância varia de 0 a ≈0,25.~~

Uma limitação conhecida do MDI é o viés em favor de variáveis contínuas ou com muitas categorias, que oferecem mais pontos de corte candidatos, e de variáveis correlacionadas (Strobl et al. , 2007).

5.3.2 XGBoost — ~~*Weight Gain* (contagem de *splits*~~redução média da perda~~)~~

O XGBoost constrói árvores de forma sequencial por *gradient boosting*. ~~Na interface do `scikit-learn` (`XGBClassifier`), o atributo `feature_importances_` retorna, por padrão, a métrica ***weight***: para cada *feature*~~ Neste trabalho, a importância de cada característica x_j ~~, conta-se o número total de vezes em que~~ é medida pelo ***gain***: a redução média da função de perda obtida nas divisões que usam x_j ~~foi selecionada como variável de *split* em todas as árvores do *ensemble*. Os valores são então normalizados para somar~~, normalizada para que a soma sobre as variáveis seja 1.

~~A métrica~~ O *weightgain* ~~mede a **frequência de uso** da variável, não a magnitude da melhoria que cada *split* proporciona~~é a métrica padrão do atributo `feature_importances_` do `XGBClassifier` para modelos de árvore. Alternativas disponíveis ~~no XGBoost incluem~~ são o ~~*gain*~~*weight* (~~melhoria média de perda) e~~ número de vezes em que a variável é usada em uma divisão) e o *cover* (número médio de amostras afetadas ~~). Neste trabalho, utilizou-se o *weight* padrão.~~ pelas divisões).

5.3.3 CatBoost — *PredictionValuesChange*

O CatBoost, assim como o XGBoost, é um algoritmo de *gradient boosting*. ~~Porém, a~~ A métrica de importância padrão ~~retornada por `feature_importances_`~~ é o ***PredictionValuesChange***: para cada ~~*feature*~~ característica x_j, ~~calcula-se a mudança~~ mede-se o quanto, em média~~no valor de~~, a predição do modelo ~~quando os valores de~~ muda quando o valor de x_j ~~são permutados aleatoriamente. Essa abordagem~~ muda, ponderando as diferenças entre os valores das folhas das árvores pelo número de exemplos em cada folha. O cálculo é ~~conceitualmente próxima da **importância por permutação**, sendo mais fidedigna à contribuição preditiva real da variável do que métricas baseadas em contagem de *splits*.~~

~~Os valores de *PredictionValuesChange*~~ feito a partir da estrutura das árvores, sem permutação dos dados. Os valores são normalizados para somar ~~100 na implementação do CatBoost, de modo que a escala dos gráficos difere da adotada pelo Random Forest e XGBoost.~~ 100.

5.3.4 Regressão Logística — valor absoluto dos coeficientes

Na Regressão Logística, cada ~~*feature*~~ característica x_j possui um coeficiente θ_j no modelo log-linear (a mesma notação do Capítulo 3):

$$\log \frac{P(y=1)}{P(y=0)} = \theta_0 + \sum_{j=1}^{p^d} \theta_j \, x_j.$$

Como as ~~*features*~~ características são previamente padronizadas (média zero, desvio unitário) pelo `StandardScaler`, os coeficientes estão em escalas comparáveis. A importância de x_j é então estimada como $|\theta_j|$: quanto maior o módulo do coeficiente, maior a influência da variável na probabilidade de ocultação.

O sinal de θ_j indica o sentido do efeito e é discutido na Seção 5.9. Ao contrário dos modelos baseados em árvores, esses valores **não são normalizados para somar 1 ou 100**~~, e por isso a escala do gráfico pode variar de 0 a valores como 3 ou 4, dependendo do problema~~.

5.3.5 Comparação entre os métodos

A Tabela 5.3 sintetiza as diferenças entre os quatro métodos.

Tabela 5.3: Comparação dos métodos de cálculo de importância de ~~*features*~~ características utilizados por cada modelo. A escala típica refere-se aos modelos finais do Experimento 1.2b.

Modelo	Métrica	Normalização	Escala típica
Random Forest	MDI (Gini)	$\sum = 1$	0 a ≈0,3
XGBoost	*Gain* (redução média da perda)	$\sum = 1$	0 a ≈0,5
CatBoost	*PredictionValuesChange*	$\sum = 100$	0 a ≈50
Regressão Logística	$\lvert\theta_j\rvert$ (coeficientes padronizados)	Sem normalização	0 a ≈4,5

É fundamental notar que **a mesma ~~*feature*~~ característica pode ter importância relativa diferente entre modelos**, sem que isso represente contradição: cada algoritmo captura padrões distintos nos dados, e a métrica de importância reflete a forma como cada modelo utiliza internamente a variável. A análise de importância, portanto, deve ser interpretada dentro de cada modelo, e não como ~~um *ranking* absoluto~~uma ordenação absoluta.

5.4 ~~Configuração~~ Protocolo experimental

~~Para os experimentos foram processadas **802 curvas positivas** do~~ A Tabela 5.4 resume a composição do conjunto de dados: 802 curvas positivas do banco de dados (VizieR e Grupo do Rio)~~; a partir delas, foram obtidos **186 negativos por recorte manual de segmentos sem ocultação. Além disso, foram utilizadas 3 curvas negativas** ,

186 negativos por recorte, 3 curvas negativas do próprio banco e ~~**702 curvas negativas simuladas**~~ 702 curvas negativas simuladas geradas pelo simulador de Gomes-Ferrante & Braga-Ribas (2023). ~~A Tabela 5.4 resume a composição do *dataset*.~~

Tabela 5.4: Distribuição das amostras por fonte no ~~*dataset*~~ conjunto de dados utilizado nos experimentos.

Fonte	**Quantidade**
Curvas positivas do banco (db_positive)	802
Curvas negativas simuladas (`synthetic`)	702
Negativos por recorte (manual)	186
Curvas negativas do banco (db_negative)	3
Total	1693

~~A divisão entre treino e teste foi feita de forma **estratificada por curva** (80% treino,~~ Antes do treinamento, corrigiu-se a unidade de tempo das 18 cordas de Umbriel (set./2020) obtidas do Grupo do Rio, cujo tempo estava registrado em dias julianos, e não em segundos. No conjunto de dados, elas correspondem a 20 ~~% teste): cada curva aparece integralmente em treino ou em teste, nunca nos dois, evitando vazamento de informação. O conjunto de teste contém 339 curvas (aproximadamente 178–179 negativas~~curvas: 11 positivas, as 3 cordas negativas e 6 negativos por recorte extraídos de outras 4 cordas. Como `Occ_duration_s` é a única característica que depende da escala de tempo, bastou convertê-la para segundos. O protocolo adotado tem quatro etapas.

1. **Agrupamento por evento.** Todas as curvas de um mesmo evento de ocultação — cordas registradas por observadores diferentes e os recortes "antes" e "depois" de uma mesma curva (que, por sua vez, não entra no conjunto) — formam um grupo, que fica sempre inteiro de um mesmo lado de qualquer partição. Como as datas do banco têm resolução mensal, o evento é identificado pelo objeto e pelo mês de observação, critério conservador que pode reunir em um só grupo eventos distintos do mesmo objeto. Cada curva simulada é um grupo próprio. O agrupamento impede que o modelo seja avaliado em uma curva cuja estrela, noite e instrumento já viu no treino, o que inflaria a estimativa de desempenho. São 1466 grupos.

2. **Conjunto de teste reservado.** Um quinto dos grupos foi separado, com estratificação por classe e semente fixa (42), antes de qualquer escolha: 341 curvas (161 positivas e 180 negativas, das quais 34 reais e 146 simuladas). As 1351 curvas restantes (640 positivas e ~~160–161 positivas).~~ 711 negativas) formam o **conjunto de desenvolvimento**. A estratificação é feita apenas pela classe, de modo que a proporção de negativas reais no teste não foi controlada. O evento de Umbriel (set./2020) caiu inteiro no teste, e com ele as 3 cordas negativas do banco: as 34 negativas reais do teste são 31 negativos por recorte e essas 3 cordas, e o conjunto de desenvolvimento não contém nenhuma corda negativa real.

3. **Validação cruzada no desenvolvimento.** Cada combinação de configuração de características e modelo foi avaliada por validação cruzada estratificada e agrupada por evento, com 5 dobras repetidas com 5 sementes diferentes (25 estimativas por combinação). As métricas são reportadas como média ± desvio padrão sobre as 25 dobras. A configuração final foi escolhida pela **regra de um desvio padrão**: a configuração mais simples (com menos características) cujo melhor F1 médio fica a menos de um desvio padrão do melhor resultado entre todas. O limiar de decisão de cada modelo foi escolhido nas predições fora da dobra (*out-of-fold*) da primeira repetição, isto é, em modelos treinados com quatro quintos do desenvolvimento, e depois aplicado aos modelos finais, treinados com o desenvolvimento inteiro.

4. **Avaliação final.** Os quatro modelos da configuração escolhida foram retreinados em todo o conjunto de desenvolvimento e avaliados **uma única vez** no conjunto de teste, no limiar padrão e nos limiares escolhidos na etapa anterior.

Os hiperparâmetros (número de árvores, profundidade máxima, regularização, etc.) foram fixados conforme o Apêndice B e não foram ajustados. Utilizou-se ponderação das classes ~~nos quatro algoritmos para lidar com o desbalanceamento residual.~~ na Regressão Logística, no Random Forest e no CatBoost; o XGBoost foi treinado sem ponderação, pois o conjunto é aproximadamente equilibrado (47% de positivas). Como referência, avaliou-se também um classificador trivial: um único limiar sobre `Occ_depth`, escolhido no treino de cada dobra. A análise está implementada no programa `pipeline/model_training/reanalise_banca.py`.

O protocolo tem uma limitação que deve ser declarada: as configurações candidatas não foram concebidas às cegas. A ~~semente aleatória foi fixada em 42 para reprodutibilidade. Todas as métricas referem-se exclusivamente ao **conjunto de teste**.~~ remoção das 15 variáveis redundantes e as ablações de `Feature_Savgol_Min` e `kmeans_centroid_dist` foram definidas em análises exploratórias anteriores à separação do conjunto de teste, que usavam também as curvas depois reservadas para ele (por exemplo, a remoção das derivadas foi motivada em parte pelo desempenho observado naquelas análises). Nenhuma escolha deste protocolo usa o conjunto de teste, mas a estimativa final pode ser levemente otimista.

5.5 ~~Resultados do Experimento 1 (linha de base, 28 *features*)~~

5.5 Comparação das configurações por validação cruzada

No Experimento 1 foram utilizadas as 28 *features* descritas na Tabela 5.1 (conjunto completo). A Tabela ?? resume as métricas de desempenho no conjunto de teste. 5.5 apresenta o F1-score, a AUC-ROC e a taxa de falsos positivos nas negativas reais de cada configuração e modelo na validação cruzada do conjunto de desenvolvimento. As demais métricas (acurácia, precisão e sensibilidade) estão no Apêndice A.

Tabela 5.5: Métricas de desempenho Validação cruzada estratificada e agrupada por evento (5 dobras × 5 repetições) no conjunto de teste — Experimento 1. Conjunto completo desenvolvimento: média ± desvio padrão do F1-score e da AUC-ROC, e taxa média de 28 *features*falsos positivos nas negativas reais (FP reais; média das taxas por dobra, divisão 80%/20%cada uma calculada sobre 24 a 41 negativas reais), no limiar $\tau = 0{,}5$. Entre parênteses, o número de características de cada experimento.

Experimento	Modelo	F1-score	AUC-ROC	FP reais
1 (28)	Regressão Log.	$0{,}9872 \pm 0{,}0062$	$0{,}9993 \pm 0{,}0006$	0,8 %
	Random Forest	$0{,}9890 \pm 0{,}0068$	$0{,}9997 \pm 0{,}0003$	1,9 %
	XGBoost	$0{,}9906 \pm 0{,}0061$	$0{,}9997 \pm 0{,}0003$	1,7 %
	CatBoost	$0{,}9901 \pm 0{,}0061$	$0{,}9997 \pm 0{,}0002$	1,6 %
1.1 (13)	Regressão Log.	$0{,}9839 \pm 0{,}0071$	$0{,}9988 \pm 0{,}0010$	2,0 %
	Random Forest	$0{,}9886 \pm 0{,}0058$	$0{,}9996 \pm 0{,}0003$	2,8 %
	XGBoost	$0{,}9889 \pm 0{,}0063$	$0{,}9997 \pm 0{,}0002$	2,8 %
	CatBoost	$0{,}9882 \pm 0{,}0070$	$0{,}9996 \pm 0{,}0003$	2,3 %
1.2a (12)	Regressão Log.	$0{,}9798 \pm 0{,}0090$	$0{,}9983 \pm 0{,}0012$	4,1 %
	Random Forest	$0{,}9821 \pm 0{,}0067$	$0{,}9991 \pm 0{,}0007$	8,4 %
	XGBoost	$0{,}9833 \pm 0{,}0065$	$0{,}9993 \pm 0{,}0005$	6,0 %
	CatBoost	$0{,}9825 \pm 0{,}0077$	$0{,}9992 \pm 0{,}0005$	5,9 %
1.2b (12)	Regressão Log.	$0{,}9844 \pm 0{,}0061$	$0{,}9989 \pm 0{,}0009$	2,0 %
	Random Forest	$0{,}9899 \pm 0{,}0069$	$0{,}9997 \pm 0{,}0003$	3,2 %
	XGBoost	$0{,}9883 \pm 0{,}0067$	$0{,}9997 \pm 0{,}0003$	3,1 %
	CatBoost	$0{,}9892 \pm 0{,}0062$	$0{,}9996 \pm 0{,}0003$	1,9 %
2 (11)	Regressão Log.	$0{,}9797 \pm 0{,}0079$	$0{,}9982 \pm 0{,}0012$	4,1 %
	Random Forest	$0{,}9829 \pm 0{,}0088$	$0{,}9992 \pm 0{,}0006$	8,0 %
	XGBoost	$0{,}9836 \pm 0{,}0075$	$0{,}9993 \pm 0{,}0005$	6,2 %
	CatBoost	$0{,}9834 \pm 0{,}0079$	$0{,}9992 \pm 0{,}0005$	5,6 %
Referência (1)	Limiar em `Occ_depth`	$0{,}9024 \pm 0{,}0182$	$0{,}9071 \pm 0{,}0173$	7,8 %

O melhor desempenho em F1-score e acurácia foi obtido pelo Quatro observações emergem da tabela:

1. **O aprendizado de máquina supera com folga um critério trivial.** Um único limiar em `Occ_depth` já atinge F1 ≈ 0,90 — a maior parte das ocultações do conjunto é profunda e fácil de reconhecer —, mas os classificadores reduzem a fração de erros de ≈ 10 % para 1–2 %.

2. **Random Forest(As 15 variáveis redundantes podem ser removidas.** Do Experimento 1 (28 características) para o 1.1 (13), o melhor F1 = passa de 0,9937; acurácia = 9906 para 0,9941) 9889, diferença bem menor que um desvio padrão. A sensibilidade de 98, 75% indica que a grande maioria das curvas com ocultação foi corretamente identificada; a precisão de 100% indica ausência de falsos positivos nesse modelo. A

3. **A distância entre centroides do K-means é dispensável; o mínimo do fluxo suavizado, não.** Remover `kmeans_centroid_dist` (1.1 → 1.2b) não altera o desempenho. Remover `Feature_Savgol_Min` (1.1 → 1.2a, ou 1.2b → 2) reduz o F1 em 0,4–0,7 ponto percentual (pp) e aumenta a taxa de falsos positivos nas negativas reais, que passa de 2–3 % para 4–8 %, conforme o modelo.

4. **Os quatro modelos têm desempenho semelhante dentro de cada configuração.** As diferenças entre os F1 médios de uma mesma configuração (até 0,006) são da ordem de um desvio padrão; a Regressão Logística ~~também alcança precisão de 100% fica~~ cerca de 0,002 a 0,006 abaixo dos modelos de árvore. ~~A AUC-ROC muito alta ($\geqslant$ 0,9997) confirma excelente capacidade de separação das classes.~~

~~A Figura ?? apresenta as matrizes de confusão dos quatro modelos no Experimento 1. Em cada matriz, as linhas indicam aclasse real e as colunas a classe predita. A diagonal principal contém os acertos: verdadeiros negativos no canto superior esquerdo e verdadeiros positivos no canto inferior direito. Fora da diagonal ficam os erros: falsos positivos (superior direito) e falsos negativos (inferior esquerdo). Por exemplo,o Random Forest classifica corretamente as 179 curvas negativas e158 das 160 positivas, com 2 falsos negativos e nenhum falso positivo.~~

~~Matrizes de confusão dos quatro modelos no Experimento 1 (28 *features*). Eixos: real (vertical) e predito (horizontal). Classes: Negativa (0) e Positiva (1).~~

5.6 ~~Redução do conjunto de *features*~~

~~Partindo das 28 *features* do Experimento 1,o conjunto de variáveis foi progressivamente reduzido,removendo aquelas identificadas como redundantes ou pouco discriminativas (Seção 5.2). O Experimento 4 (14 *features*) elimina amplitude, desvio~~ Pela regra de um desvio padrão ~~do fluxo bruto, máximo do Savitzky-Golay e as derivadas; o Experimento 5 (13 *features*) remove adicionalmente~~ (limite: $0{,}9906 - 0{,}0061 = 0{,}9845$), as configurações 2 e 1.2a, cujo melhor F1 fica abaixo do limite, são descartadas, e a configuração escolhida é a **1.2b (12 características)**, a mais simples que preserva o desempenho do conjunto completo. A margem, porém, é pequena: o melhor F1 da configuração 2 (0,9836) fica apenas 0,0009 abaixo do limite, e, repetindo a validação cruzada com outras cinco sementes (2000 a 2004), a mesma regra passa a indicar a configuração 2 (melhor F1 de 0,9849, para um limite de 0,9835; Apêndice A). A escolha exata entre 1.2b e 2 depende, portanto, da semente. O que se mantém é a contribuição de `Feature_Savgol_Min`~~; eo Experimento 6 (12 *features*) ablaciona a `kmeans_centroid_dist`. Em todos eles, o melhor F1-score permanece em torno~~ : comparando, dobra a dobra, as configurações 1.2b e 2 nas mesmas partições, a primeira tem F1 maior em 18 a 19 das 25 dobras, conforme o modelo, com ganho médio de 0,~~99 — ou seja,**a remoção dessas variáveis não degrada o**~~

desempenho. Os resultados completos desses três experimentos (tabelas e matrizes de confusão) estão no Apêndice A; a Tabela ?? (Seção 5.5) consolida os valores. 005 a 0,007, e a taxa de falsos positivos nas negativas reais é menor em todos os modelos. Por isso a configuração 1.2b foi mantida.

Um achado merece destaque por ser, à primeira vista, contraintuitivo. A `kmeans_centroid_dist` — distância entre os dois centróides obtidos pela aplicação de K-means ($K = 2$) ao fluxo suavizado — figura consistentemente entre as

5.5.1 Importância não é sinônimo de insubstituibilidade

As duas variáveis *mais importantes* removidas nos Experimentos 1.2a e 1.2b estão entre as mais importantes nos modelos de árvore , chegando a concentrar boa parte e são fortemente correlacionadas entre si ($\rho = -0{,}97$, Figura 5.1), mas a validação cruzada mostra que seus papéis são diferentes. A `kmeans_centroid_dist` recebe parcela relevante da importância no XGBoost. Ainda assim, removê-la (Experimento 6)**não piora o desempenho**quando está presente (cerca de 12 a 15 % no Random Forest e no XGBoost da configuração 1.1), e ainda assim sua remoção não altera o desempenho: a capacidade preditiva é simplesmente redistribuída para as variáveis colineares, sobretudo `Feature_Savgol_std`– que captura o mesmo fenômeno físico, a dispersão do fluxo causada pelos dois patamares dentro e fora do *dip*`Min` e `Feature_Savgol_std`. A lição é importante: que **a importância atribuída por um algoritmo de árvore não é sinônimo de insubstituibilidade**;: uma variável pode concentrar importância apenas por oferecer um ponto de corte conveniente, enquanto outras compensam sua ausência. Na prática, isso permite simplificar a *pipeline* eliminando eliminar o passo de K-means da cadeia de processamento sem custo de desempenho.

5.5.2 Configuração enxuta: Experimento 2 (11 *features*)

O Experimento 2 leva essa simplificação ao limite, removendo *simultaneamente* O mesmo não vale para `Feature_Savgol_Min`e `kmeans_centroid_dist` e restando **11 *features***, com divisão 80%/20%. É esta a **configuração enxuta** adotada como referência operacional do trabalho . Sem ela, nenhuma das variáveis restantes compensa sua ausência nas negativas reais, e a taxa de falsos positivos nessas curvas aumenta. Uma interpretação física plausível é que o mínimo do fluxo suavizado distingue uma queda sustentada (a ocultação) de flutuações pontuais de ruído, enquanto o desvio padrão do fluxo suavizado, que permanece no Experimento 2, cresce também com ruído correlacionado sem evento — a mais simples que preserva o desempenho da linha de base — e a empregada no estudo de caso de Quaoar (Seção 5.8). A Tabela ?? apresenta as métricasum efeito que as negativas reais exibem e as simuladas não.

Métricas de desempenho no conjunto de teste — Experimento 2. 11 *features* (sem `Feature_Savgol_Min` e sem `kmeans_centroid_dist`), divisão 80%/20%.

XGBoost e CatBoost mantêm F1 ⩾ 0,990, confirmando que a ablação combinada

A mesma abordagem foi aplicada às duas características de testes entre quartis (`MinLogP_Ttest` e `MinLogP_KS`; Seção 4.5.6): removê-las do Experimento 1.2b não degrada o desempenho mesmo com menos de metade das variáveis originais. A matriz de confusão dos quatro modelos nesta configuração (Figura **??**), assim como as dos demais experimentos,encontra-se no altera o desempenho (F1 de 0,9883 para 0,9912 no XGBoost, dentro de um desvio padrão; Apêndice A). As duas são, portanto, redundantes com as demais. Essas configurações suplementares foram avaliadas depois da escolha e não participaram da regra de seleção: promovê-las a configuração final com base nesses números seria uma escolha *a posteriori*.

5.6 Teste Avaliação final no conjunto de generalização: curvas exclusivamente reaisteste

No *dataset* utilizado, cerca de 78% das curvas negativas são **simuladas** (geradas pelo simulador de Gomes-Ferrante & Braga-Ribas , 2023). Assim, A Tabela 5.6 apresenta o desempenho dos quatro modelos da configuração escolhida (Experimento 1.2b), retreinados em todo o conjunto de teste padrão mistura curvas reais e simuladas. Para avaliar se o desempenho se mantém em cenários onde apenas curvas **reais** são classificadas — situação típica de uso em campanhas observacionais — foi realizado o Experimento 3: os modelos são treinados com 11 *features* e a desenvolvimento, no conjunto de teste reservado. A parte inferior da tabela restringe a avaliação é feita **somente em curvas reais**. A divisão adotada é a mesma dos demais experimentos (80%/20%, estratificada por curva), de modo que os resultados sejam diretamente comparáveis; a fração aplica-se às curvas elegíveis para o teste (positivas reais, negativos por recorte e negativas nativas), enquanto as curvas simuladassão alocadas integralmente ao treino. O conjunto de teste resultante contém 198 curvas reais (160 positivas e 38 negativas). Uma variante com divisão 65%/35%, que amplia o número de curvas reais avaliadas ao custo de reduzir o treino, é analisada no Apêndice A como ablação do tamanho do conjunto de treino. Os resultados estão na Tabela 5.6, que apresenta as métricas no conjunto de teste restrito a curvas reais195 curvas reais do teste (161 positivas e 34 negativas reais; Análise 2.1), excluindo as negativas simuladas.

O desempenho em teste exclusivamente real é **essencialmente preservado**: o melhor

No teste misto, os quatro modelos atingem F1 (XGBoost entre 0,0,9906) coincide com o obtido no testemisto do Experimento 2, e a 985 e 0,988 e AUC-ROC permanece ⩾ 0,9965

Métricas de desempenho no conjunto de teste — Experimento 3. Teste somente em curvas reais (11 *features*, divisão 80%/20%; teste com 198 curvas: 160 positivas e 38 negativas).

Tabela 5.6: Desempenho no conjunto de teste reservado (avaliação única), Experimento 1.2b, limiar $\tau = 0{,}5$. "Misto": 341 curvas (161 positivas, 34 negativas reais e 146 simuladas). "Só reais" (Análise 2.1): 195 curvas (161 positivas e 34 negativas reais). FP/FN: falsos positivos e falsos negativos.

Teste	Modelo	Acurácia	Precisão	Sensib.	F1	AUC-ROC	FP / FN
Misto	Regressão Log.	0,9853	0,9815	0,9876	0,9845	0,9976	3 / 2
	Random Forest	0,9853	0,9815	0,9876	0,9845	0,9993	3 / 2
	XGBoost	0,9883	0,9816	0,9938	0,9877	0,9997	3 / 1
	CatBoost	0,9883	0,9876	0,9876	0,9876	0,9992	2 / 2
	Limiar em `Occ_depth`	0,9032	0,8721	0,9317	0,9009	0,9047	22 / 11
Só reais	Regressão Log.	0,9744	0,9815	0,9876	0,9845	0,9885	3 / 2
	Random Forest	0,9795	0,9876	0,9876	0,9876	0,9980	2 / 2
	XGBoost	0,9897	0,9938	0,9938	0,9938	0,9991	1 / 1
	CatBoost	0,9846	0,9938	0,9876	0,9907	0,9976	1 / 2
	Limiar em `Occ_depth`	0,9231	0,9740	0,9317	0,9524	0,9070	4 / 11

em todos os modelos. Isso indica que as *features* capturam sinal discriminativo real e não apenas artefatos da distribuição simulada.Na variante 65%/35% do Experimento 3 acima de 0,997, em concordância com a validação cruzada (Tabela 5.5); o critério trivial fica em F1 = 0,90. Restrito às curvas reais (Apêndice A), Análise 2.1), o melhor F1 passa de 0,9906 para 0,9838, uma diferença de fica entre 0,7 ponto percentual (pp). Como essa variante altera ao mesmo tempo o treino (−19 % das curvas reais de treino,ou −10 % do treino total)e o conjunto de teste (198 → 347 curvas) 985 e 0,não 994. Como 161 das 195 curvas reais do teste são positivas, esse valor é possível atribuir a diferença à redução do treino: trata-se de uma hipótese, dominado pela sensibilidade; para as negativas reais, o indicador informativo é a taxa de falsos positivos, discutida a seguir. As curvas reais do teste, contudo, vêm das mesmas fontes que as do desenvolvimento, de modo que esse resultado não de um resultado. A diferença tem, de todo modo, a mesma ordem da flutuação entre partições (desvio padrão do F1 na substitui uma validação cruzada em campanhas independentes.

O XGBoost erra 1 das 34 negativas reais do teste, uma taxa de falsos positivos de 2,9 %, cujo intervalo de confiança de 0, 006 a 95 % (Clopper–Pearson) vai de 0,010; Tabela **??**) . Como ressalva, o teste desta configuração contém 1 % a 15,3 %: com apenas 38 curvas negativas reais, de modo que as métricas ligadas a falsos positivos possuem maior incerteza amostral. O Experimento 34 negativas reais no teste, das quais só 3 reforça que a *pipeline* são cordas negativas, todas do mesmo evento, as métricas ligadas a falsos positivos têm incerteza amostral grande. A curva errada é adequada para triagem em dados observacionais reaisjustamente uma dessas cordas (Umbriel, set./2020, Figura 4.4c), à qual o modelo atribui $\hat{p} = 0{,}97$. Uma estimativa mais estável soma as predições fora da amostra das 155 negativas reais do desenvolvimento (predições fora da dobra) e das 34 do teste: o XGBoost

classifica como positivas 6 das 189 (3,2 %; intervalo de confiança de 95 % de 1,2 % a 6,8 %), o Random Forest também 6 (3,2 %), o CatBoost 4 (2,1 %; 0,6 % a 5,3 %) e a Regressão Logística 7 (3,7 %; 1,5 % a 7,5 %), contra 16 (8,5 %) do critério trivial (Apêndice A).

As métricas no teste das demais configurações (misto e somente reais) estão no Apêndice A, apenas para registro. Nele, a configuração 2 aparece ligeiramente à frente (por exemplo, F1 = 0,997 no XGBoost, com 1 erro, contra 4 da configuração 1.2b), mas a diferença corresponde a poucas curvas e não altera a escolha feita na validação cruzada: usar o conjunto de teste para escolher entre configurações reintroduziria o viés que este protocolo procura evitar.

A Figura 5.2 apresenta as matrizes de confusão dos quatro modelos no teste misto. Em cada matriz, as linhas indicam a classe verdadeira e as colunas a classe predita. A diagonal principal contém os acertos: verdadeiros negativos no canto superior esquerdo e verdadeiros positivos no canto inferior direito. Fora da diagonal ficam os erros: falsos positivos (superior direito) e falsos negativos (inferior esquerdo). Por exemplo, o XGBoost classifica corretamente 177 das 180 curvas negativas e 160 das 161 positivas, com 3 falsos positivos e 1 falso negativo. A Figura 5.3 apresenta as curvas ROC correspondentes.

5.7 Minimização de falsos negativos

5.7.1 Motivação: assimetria de custo entre erros

~~Nos experimentos~~ Nas seções anteriores, todos os modelos utilizam o limiar de decisão padrão $\tau = 0{,}5$: uma curva é classificada como positiva se a probabilidade estimada $\hat{p} = P(y = 1 \mid \mathbf{x})$ for $\geqslant 0{,}5$. Esse limiar implica que falsos positivos e falsos negativos possuem o mesmo custo — hipótese que raramente se verifica em aplicações reais.

No contexto de triagem de curvas de luz para análise de ocultações estelares, os custos são **assimétricos**:

- **Falso negativo** (ocultação real classificada como negativa): a curva deixa de ser prioridade para análise mais detalhada. O dado não é perdido — desde que não seja descartado, a informação continua disponível —, mas o evento pode demorar a ser "redescoberto", com risco de o grupo perder a oportunidade de um resultado inédito (como ilustra a história do primeiro anel de Quaoar, revelado numa revisita de dados antigos (Morgado et al. , 2023)).
- **Falso positivo** (curva sem evento classificada como positiva): a curva recebe prioridade indevida e será examinada por um analista humano, que rapidamente descartará o falso alarme. O custo é apenas tempo de análise.

Essa assimetria é análoga à de sistemas de triagem médica (*screening*), nos quais se prefere aceitar mais falsos alarmes a perder diagnósticos reais. Formalmente, o obje-

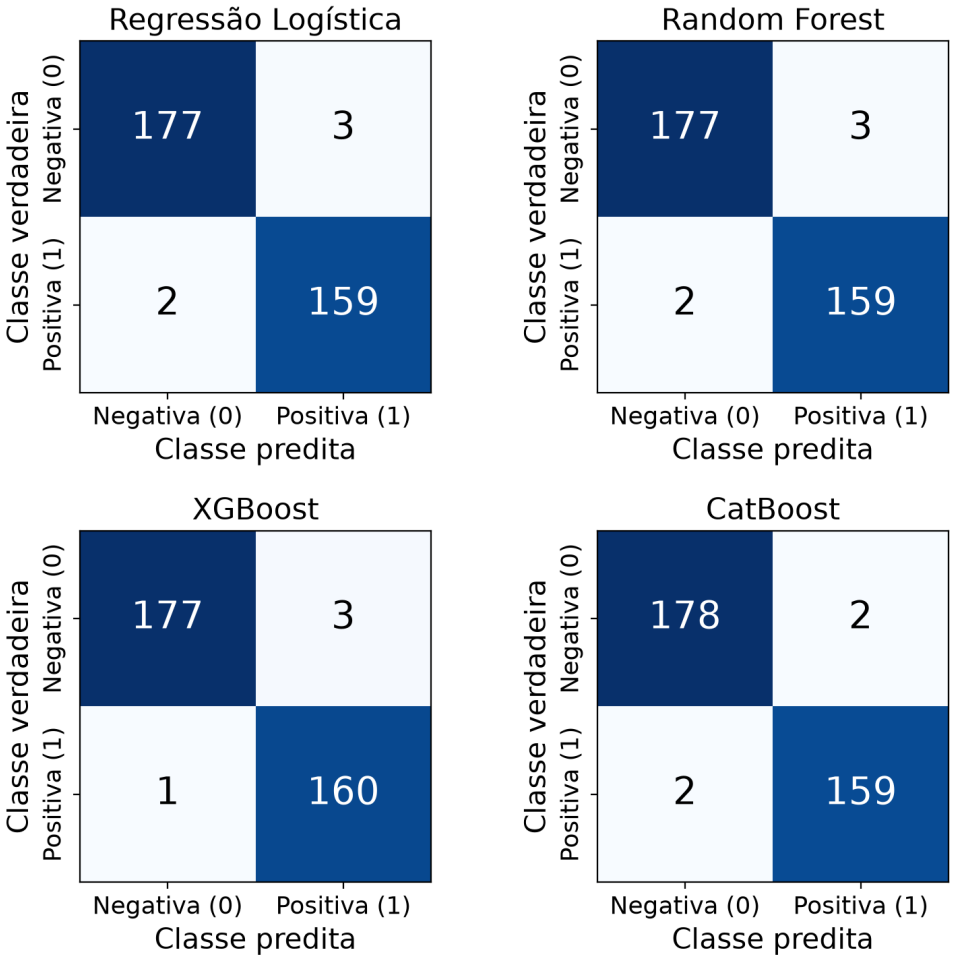


Figura 5.2: Matrizes de confusão dos quatro modelos do Experimento 1.2b no conjunto de teste reservado (teste misto: 341 curvas, sendo 161 positivas e 180 negativas, das quais 146 simuladas), no limiar $\tau = 0{,}5$.

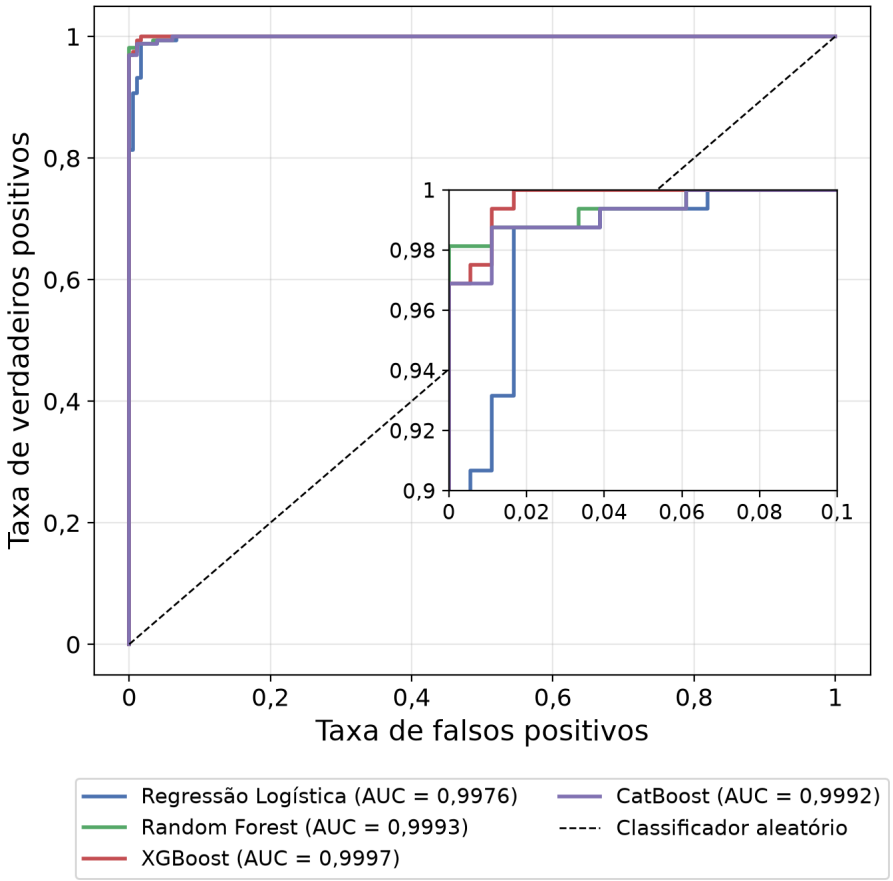


Figura 5.3: Curvas ROC dos quatro modelos do Experimento 1.2b no conjunto de teste reservado (teste misto, 341 curvas). Como 146 das 180 negativas são simuladas, a taxa de falsos positivos é dominada por elas. O quadro ampliado mostra a região de taxa de falsos positivos entre 0 e 0,1.

tivo é **maximizar a sensibilidade** (minimizar falsos negativos), aceitando uma redução controlada da precisão (aumento de falsos positivos).

5.7.2 Método: variação do limiar de classificação

Todos os quatro classificadores utilizados neste trabalho produzem, além do rótulo binário, uma **probabilidade estimada** $\hat{p} = P(y = 1 \mid \mathbf{x}) \in [0, 1]$ de a curva conter uma ocultação. Essa saída contínua é obtida pelo método `predict_proba` das bibliotecas `scikit-learn`, XGBoost e CatBoost, que converte a pontuação interna de cada modelo em uma probabilidade. A classificação binária é, então, obtida pela aplicação de um limiar τ sobre $\hat{p}$:

$$\hat{y} = \begin{cases} 1 & \text{se } \hat{p} \geqslant \tau, \\ 0 & \text{caso contrário.} \end{cases}$$

Ao **reduzir** τ abaixo de 0,5, o modelo torna-se mais "sensível": classifica como positiva qualquer curva com probabilidade moderada de conter uma ocultação. Isso tem dois efeitos simultâneos:

1. A **sensibilidade aumenta**: curvas com evento que estavam na zona de incerteza passam a ser corretamente classificadas como positivas.

2. A **precisão diminui**: algumas curvas sem evento cuja probabilidade estimada está entre τ e 0,5 passam a ser classificadas como positivas (falsos positivos adicionais).

O compromisso entre precisão e sensibilidade pode ser visualizado por meio da **curva precisão-sensibilidade**~~(*precision-recall curve*)~~, que é parametrizada por τ. Diferentemente da curva ROC — que compara a taxa de verdadeiros positivos (TPR~~) com~~ , do inglês *true positive rate*) com a taxa de falsos positivos (FPR, *false positive rate*) — , a curva precisão-sensibilidade é mais informativa ~~para conjuntos de dados com leve desbalanceamento e~~ quando o objetivo é minimizar falsos negativos (Saito & Rehmsmeier , 2015).

~~Adicionalmente, para~~ Para cada valor de τ, podem-se ~~recalcular todas as~~ também recalcular as demais métricas~~de classificação (acurácia, precisão, sensibilidade, F1-score),~~ , gerando **curvas de métrica em função do limiar** que permitem escolher o ponto operacional mais adequado ao cenário de uso.

5.7.3 Escolha do ponto operacional

A seleção do limiar ótimo depende do critério adotado. Três abordagens comuns são:

1. **Sensibilidade mínima~~garantida~~:** fixar um patamar desejado de sensibilidade (ex.: $\geqslant 99{,}5\%$) e identificar o maior τ que o satisfaz. Esse é o critério mais natural para triagem científica.

2. **Maximização do F_β-score:** utilizar uma versão ponderada do F1 que atribui peso β^2 à sensibilidade:

$$F_\beta = (1+\beta^2)\cdot\frac{\text{precisão}\cdot\text{sensibilidade}}{\beta^2\cdot\text{precisão}+\text{sensibilidade}}.$$

   Com $\beta = 2$, a sensibilidade vale quatro vezes mais que a precisão; o limiar ótimo é aquele que maximiza F_2.

3. **Análise de custo:** atribuir um custo c_{FN} a cada falso negativo (evento perdido) e um custo c_{FP} a cada falso positivo (alarme a ser revisado) e escolher τ que minimize o custo total $C(\tau) = c_{\mathrm{FN}}\,\mathrm{FN}(\tau) + c_{\mathrm{FP}}\,\mathrm{FP}(\tau)$. Se as probabilidades forem bem calibradas, o limiar ótimo é $\tau^\star = c_{\mathrm{FP}}/(c_{\mathrm{FP}}+c_{\mathrm{FN}})$; por exemplo, $c_{\mathrm{FN}} = 9\,c_{\mathrm{FP}}$ dá $\tau^\star = 0{,}1$. Quando $c_{\mathrm{FN}} \gg c_{\mathrm{FP}}$, o limiar ótimo desloca-se para baixo.

Neste trabalho, ~~adota-se o critério de **sensibilidade mínima garantida**, por ser o mais transparente e o mais fácil de comunicar: "o modelo detecta pelo menos X% das ocultações reais, ao custo de Y falsos alarmes adicionais"~~os limiares foram escolhidos pelos critérios 1 (sensibilidade $\geqslant 99{,}5\,\%$) e 2 (F_2 máximo) nas predições fora da dobra do conjunto de desenvolvimento, sem consultar o conjunto de teste, e depois aplicados uma única vez ao teste.

5.7.4 Resultados

~~O ajuste de limiar foi aplicado aos quatro modelos do Experimento 5 (13 *features*, divisão 80%/20%; detalhado no Apêndice A). Para cada modelo , foram calculadas as métricas em função do limiar $\tau \in [0{,}01,\ 0{,}99]$. A Tabela 5.7 resume pontos operacionais representativos~~A Tabela 5.7 apresenta, para cada modelo do Experimento 1.2b, os limiares escolhidos na validação cruzada e o desempenho correspondente no conjunto de teste.

Tabela 5.7: ~~Pontos operacionais selecionados na análise~~ Limiares escolhidos nas predições fora da dobra do conjunto de ~~limiar~~ desenvolvimento (Experimento~~5, 13 *features* 1.2b) . Para cada modelo: limiar padrão ($\tau = 0{,}5$), limiar sensível ou ótimo,~~ e ~~métricas associadas~~ desempenho resultante no conjunto de teste reservado (341 curvas; 161 positivas). FP ~~=~~ / FN: falsos positivos ~~, FN =~~ e falsos negativos~~)~~.

Modelo	Critério	τ	Precisão	Sensib.	F1	F_2	FP / FN
Regressão Log.	sens. $\geqslant 99{,}5\,\%$	0,10	0,8895	1,0000	0,9415	0,9758	20 / 0
	máx. F_2	0,25	0,9636	0,9876	0,9755	0,9827	6 / 2
Random Forest	sens. $\geqslant 99{,}5\,\%$	0,40	0,9815	0,9876	0,9845	0,9864	3 / 2
	máx. F_2	0,35	0,9581	0,9938	0,9756	0,9864	7 / 1
XGBoost	sens. $\geqslant 99{,}5\,\%$	0,18	0,9758	1,0000	0,9877	0,9951	4 / 0
	máx. F_2	0,16	0,9758	1,0000	0,9877	0,9951	4 / 0
CatBoost	sens. $\geqslant 99{,}5\,\%$	0,15	0,9357	0,9938	0,9639	0,9816	11 / 1
	máx. F_2	0,32	0,9695	0,9876	0,9785	0,9839	5 / 2

~~**Destaque:** A~~ O XGBoost com $\tau = 0{,}18$ detecta todas as 161 ocultações do teste ao custo de 4 falsos positivos (3 a mais que no limiar padrão). Com 161 positivas, uma sensibilidade observada de 100 % corresponde a um intervalo de confiança de 95 % de [97,7 %; 100 %]. Nos demais modelos, o limiar escolhido na validação cruzada transfere-se pior: a Regressão Logística ~~com $\tau = 0{,}16$ atinge~~ e o CatBoost alcançam sensibilidade de 100~~% com apenas 1 falso positivo — ponto operacional ideal para triagem em que minimizar falsos negativos~~ % e 99,4 % com 20 e 11 falsos positivos, e o Random Forest, com $\tau = 0{,}40$, ainda deixa escapar 2 ocultações. O resultado indica que o limiar deve ser escolhido por validação cruzada e acompanhado em uso, pois a sensibilidade alcançada no desenvolvimento não é ~~prioritário.~~ garantida em dados novos. O próprio valor de τ é aproximado: o patamar de 99,5 % foi fixado antes da análise, mas o maior limiar que o satisfaz depende da partição em dobras usada para estimá-lo e deve ser lido como uma ordem de grandeza, e não como um valor exato.

~~As Figuras 5.4 e 5.5 ilustram~~ A Figura 5.4 mostra as curvas precisão-sensibilidade e a Figura 5.5, as métricas em função do limiar~~(Experimento 5)~~, ambas calculadas nas predições fora da dobra do desenvolvimento. Variando τ de 1 a 0, percorre-se cada curva precisão-sensibilidade da esquerda (alta precisão, baixa sensibilidade) para a direita (alta sensibilidade, menor precisão); quanto mais a curva se aproxima do canto superior direito, melhor o modelo. Como todos os modelos operam em valores muito altos, a região de interesse concentra-se acima de ~~0,9~~ 0,95 em ambos os eixos, destacada no quadro ampliado.

5.7.5 Implicações para uso operacional

O ajuste de limiar é uma operação de **pós-processamento**: não requer retreinamento dos modelos, não altera os pesos aprendidos e pode ser realizado instantaneamente. Na prática, isso significa que a ~~*pipeline*~~ cadeia de processamento pode operar em **dois modos**:

- **Modo balanceado** ($\tau = 0{,}5$): otimiza o equilíbrio entre precisão e sensibilidade. Adequado para relatórios de desempenho geral e comparação entre modelos.
- **Modo triagem** ($\tau < 0{,}5$): maximiza a detecção de ocultações reais, aceitando falsos alarmes adicionais que serão descartados na etapa de análise manual. Adequado para o cenário operacional de priorização de curvas.

A escolha do limiar pode, inclusive, ser adaptada por campanha observacional: em campanhas com poucas curvas (dezenas), um limiar mais baixo é aceitável porque o custo de revisar falsos positivos é pequeno; em campanhas com milhares de curvas, pode-se optar por um limiar intermediário que limite o volume de falsos alarmes a um nível gerenciável pela equipe de análise.

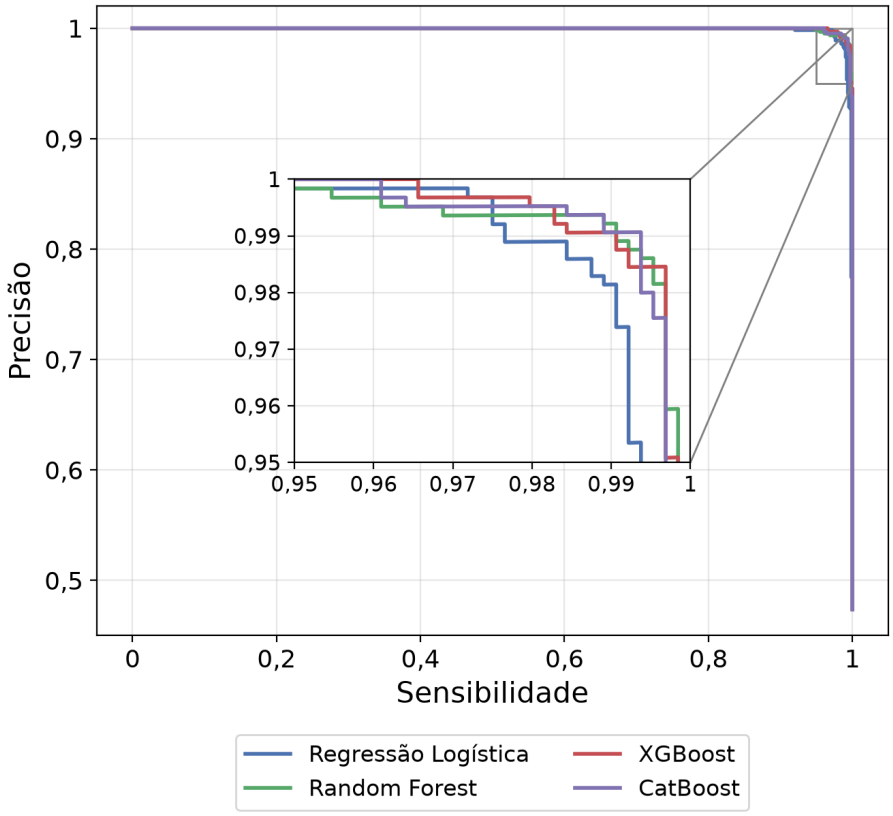


Figura 5.4: Curvas precisão-sensibilidade dos quatro modelos ~~no~~ do Experimento ~~5.~~1.2b, calculadas nas predições fora da dobra do conjunto de desenvolvimento. Cada posição ao longo de uma curva corresponde a um valor do limiar τ. ~~No gráfico~~O quadro ampliado mostra a região entre 0,~~"revocação" é sinônimo de sensibilidade (*recall*)~~95 e 1 nos dois eixos.

~~(a) Random Forest e XGBoost (b) CatBoost e Regressão Logística~~

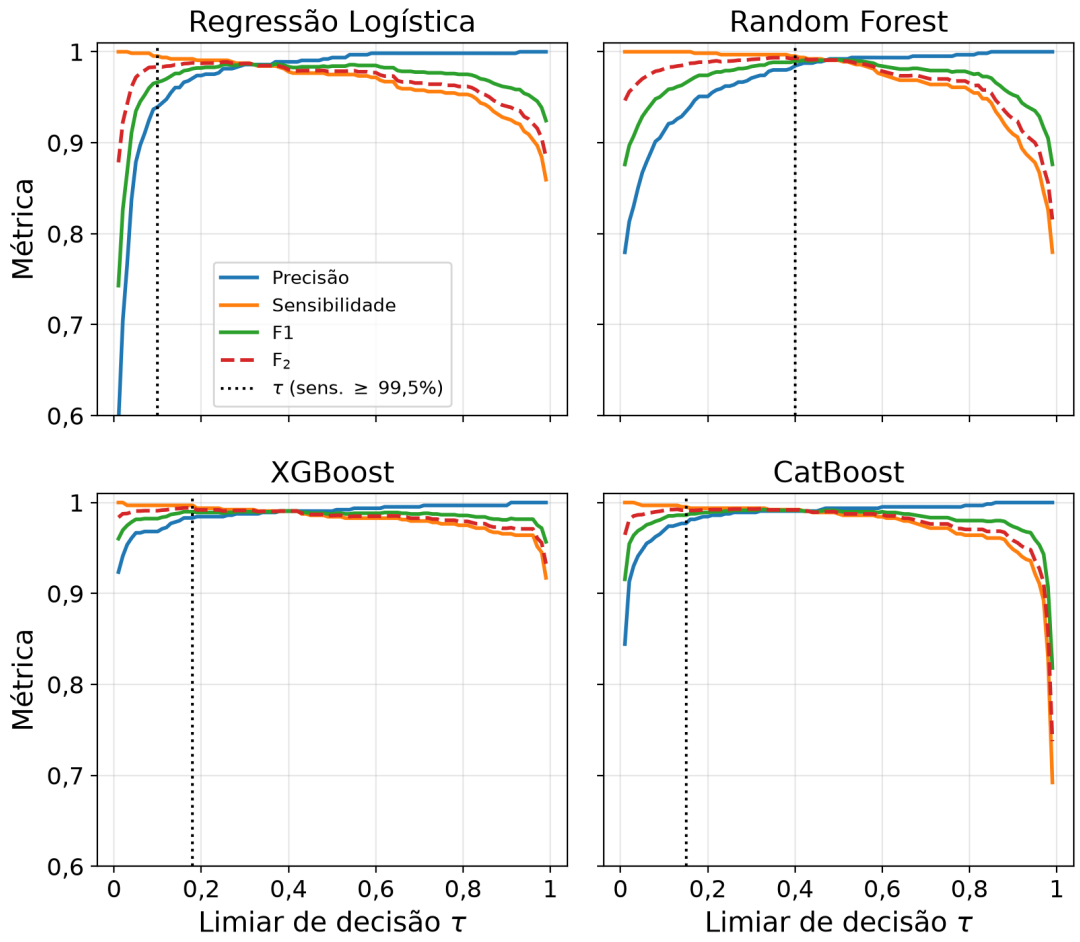


Figura 5.5: Precisão, sensibilidade, F1-score e F_2-score em função do limiar de decisão τ ~~(~~para os quatro modelos do Experimento ~~5).~~ 1.2b (~~a~~predições fora da dobra do desenvolvimento) ~~Random Forest e XGBoost; (b) CatBoost e Regressão Logística~~. A linha vertical pontilhada indica o limiar escolhido pelo critério de sensibilidade $\geqslant 99{,}5\,\%$.

5.8 Estudo de caso: aplicação a uma curva real de Quaoar

5.8.1 Motivação

~~Os seis experimentos descritos nas~~ As seções anteriores avaliam a ~~*pipeline*~~ cadeia de processamento sobre curvas oriundas do banco de dados de treinamento (catálogo `B/occ/asteroid` do VizieR e Grupo do Rio)~~, respeitando a partição treino/teste~~. Para complementar essa avaliação, apresenta-se nesta seção um **estudo de caso** no qual a ~~*pipeline*~~ cadeia de processamento é aplicada a um conjunto de curvas **externas ao banco**: registros de uma ocultação estelar pelo objeto transnetuniano **(50000) Quaoar**, que não estavam ~~armazenadas~~ armazenados no VizieR nem no ~~*drive*~~ repositório em nuvem do Grupo do Rio. O evento é especialmente interessante porque, além da queda profunda associada ao corpo principal, apresenta assinaturas adicionais atribuídas aos dois anéis recentemente descobertos em torno de Quaoar (Pereira et al. , 2023; Morgado et al. , 2023), configurando uma curva complexa com múltiplas assinaturas físicas (corpo principal, anéis e o limite para a existência de uma possível atmosfera) em uma única série temporal. Foram analisadas três curvas do mesmo evento: CFHT/WIRCam (banda K_s) e Gemini-Norte/'Alopeke, nos canais azul (filtro r) e vermelho (filtro z).

Este estudo de caso tem três objetivos:

1. Verificar se ~~o modelo CatBoost~~ os quatro modelos finais do Experimento ~~2 (11 *features*; na análise de recortes, também o XGBoost do mesmo experimento) generaliza~~ 1.2b generalizam para curvas reais **nunca vistas** — isto é, fora do conjunto de teste e fora da distribuição dos catálogos de origem.

2. Avaliar o comportamento da ~~*pipeline*~~ cadeia de processamento em uma curva **morfologicamente complexa**, com componentes não típicos da maioria das curvas de treino (anéis e estruturas secundárias).

3. Demonstrar o uso da ~~*pipeline*~~ cadeia de processamento como ferramenta de **recorte~~interativo~~**, permitindo isolar segmentos específicos da curva (anel, atmosfera, corpo ocultante) e reaplicar o classificador a cada janela, e estimar, por uma varredura cega, a taxa de alarmes falsos desse uso.

Os dados de Quaoar foram **gentilmente cedidos pelo autor principal** de Pereira et al. (2023), no qual a redução fotométrica completa do evento e a caracterização dos dois anéis Q1R e Q2R são apresentadas. ~~Reforçando o que já se mencionou, a~~ A curva de Quaoar não figura no banco SQLite usado para treinar os modelos, ~~garantindo~~ de modo que o teste é, de fato, sobre dados externos à distribuição de treino.

5.8.2 Procedimento

A aplicação da ~~*pipeline*~~ cadeia de processamento ao caso Quaoar foi implementada ~~em um *script* dedicado (~~no programa `pipeline/model_in_practice/~~test_~~quaoar_reanalise.py~~)~~, escrito em estilo linear~~(*top-down*)~~, de cima para baixo (*top-down*), para facilitar a inspeção passo a passo~~ — inclusive a colocação interativa de pontos de parada no VS Code. O fluxo é~~. As etapas são:

1. **Leitura das curvas:** cada arquivo `.dat` é lido com `np.genfromtxt`, extraindo apenas a coluna de tempo (segundos do dia, em UTC) e a de fluxo normalizado. Pontos ~~marcados com *flag*~~ sinalizados pelo PRAIA como de baixa qualidade ~~pelo PRAIA~~ (valores extremos como 99,999) são descartados por um filtro de validade física: mantêm-se apenas os pontos com fluxo normalizado no intervalo $[-2,\ 5]$, preservando ocultações profundas reais (fluxo $\rightarrow 0$) sem cortar ~~o *dip* verdadeiro~~a queda verdadeira.

2. **Recorte ~~opcional~~ por janela temporal:~~um dicionário `CUT_RANGES`, preenchido manualmente pelo autor a partir da inspeção visual da curva, permite restringir cada curva a um intervalo~~ ~~($t_{\text{início}}$, t_{fim})~~ cada janela é um intervalo ($t_{\text{início}}$, t_{fim}), em segundos contados a partir de 00:00:00 UTC de 2022-08-09 (segundos do dia), definido a partir da inspeção visual da curva. O recorte é aplicado antes ~~do plot e~~ da extração de ~~*features*~~características, permitindo isolar separadamente ~~o *dip* principal~~ a queda do corpo, ~~possíveis~~ as estruturas de anel ~~à esquerda/direita~~ antes e depois do evento principal ou eventuais assinaturas atmosféricas nas bordas ~~do *dip.*~~ da queda. A operação é uma única linha (`cut(t, f, t_ini, t_fim)`) e pode ser repetida interativamente sobre qualquer janela, sem retreinar o modelo nem reescrever a cadeia de processamento.

3. **Extração de ~~*features*~~características:** as mesmas funções utilizadas no treinamento (`extract_features` e `compute_occ_features`, no pacote `model_training`) são reaproveitadas, garantindo coerência exata com o pré-processamento aprendido pelos modelos.

4. **Inferência:** ~~o modelo **CatBoost** treinado no Experimento 2 (11 *features*, sem `Feature_Savgol_Min` e sem `kmeans_centroid_dist`)é carregado a partir do diretório~~ os quatro modelos finais do Experimento 1.2b (12 características), retreinados em todo o conjunto de desenvolvimento (Seção 5.7.4), são carregados do arquivo `outputs/~~resultado5~~reanalise_banca/modelos/modelos_config_1.2b.joblib~~; o *imputer*~~`. Cada modelo é salvo junto com o imputador ajustado no treino — objeto `SimpleImputer` do *scikit-learn*, ~~ajustado no treino,~~ que substitui valores ausentes de uma ~~*feature*~~ característica pela mediana do conjunto

de treino — é recuperado, com recurso alternativo à mediana local caso ocorra incompatibilidade de versão do `scikit-learn`. , de modo que a curva nova passa exatamente pelo mesmo pré-processamento.

A escolha do CatBoost-Exp. 2 é deliberada: trata-se da configuração mais enxuta da *pipeline* (menor número de *features*, sem o passo de K-means), reforçando que o desempenho elevado não depende das variáveis identificadas como dispensáveis pelo estudo de ablação (Seção 5.5.1).

A Figura 5.6 apresenta a curva analisada após o pré-processamento, com o *dip* a queda central do corpo principal e as estruturas rasas dos anéis. A detecção das**curva inteira****curvas inteiras** como ocultação é trivial esperada — corpo central mais dois anéis fornecem um sinal forte — e serve apenas como *baseline* (referência: as três curvas recebem $\hat{p} \geqslant 0{,}985$ dos quatro modelos (1,000 na Regressão Logística e no Random Forest, 0,9997 no XGBoost e entre 0,986 e 0,988 no CatBoost; primeira linha da Tabela 5.8 , $\hat{p} \approx 0{,}995$ no CatBoostpara a curva no filtro z). O interesse real está em **sondar os anéis por recortes**, isolando cada assinatura física.

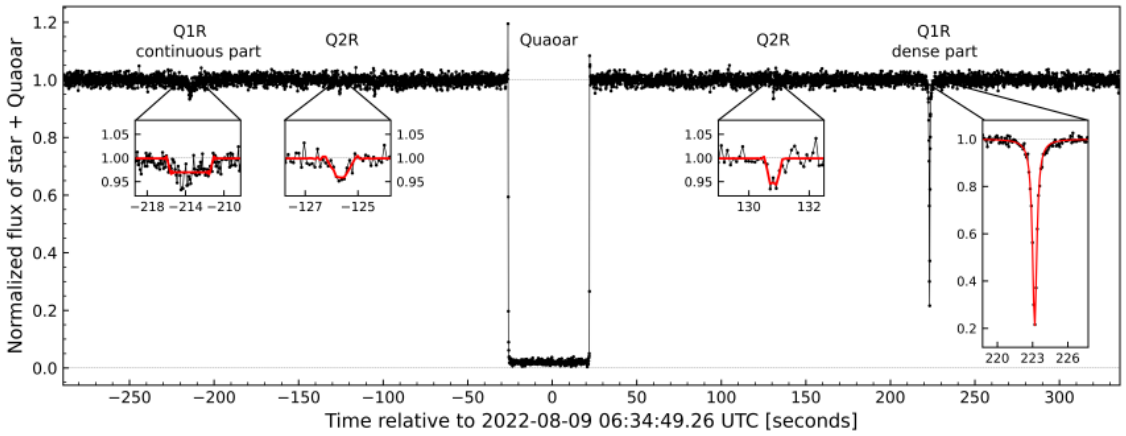


Figura 5.6: Curva de luz da ocultação estelar por Quaoar utilizada no estudo de caso, com o tempo referenciado ao instante 2022-08-09 06:34:49,26 UTC. O *dip* A queda central (anotado anotada como "Quaoar"), de duração $\approx$ 48 s e profundidade $\approx$ 100%, corresponde à ocultação pelo corpo principal. As estruturas secundárias rasas, isoladas nos quatro quadros painéis ampliados(*insets*), são as assinaturas dos dois anéis, Q1R (Morgado et al. , 2023) e Q2R(Pereira et al. , 2023), sendo Q1R observado em duas porções (parte contínua e parte densa) e Q2R em duas travessias antes e depois do corpo. A linha reta pontilhada indica o *baseline* marca a linha de base ($F_{\text{norm}} = 1$). Fonte: adaptado de Pereira et al. (2023).

5.8.3 Aplicação a recortes da curva: sondando os anéis

A ~~demonstração mais interessante~~ aplicação mais relevante deste estudo de caso explora ~~justamente~~ a ideia anunciada na Introdução: usar a ~~*pipeline*~~ cadeia de processamento para **(re)visitar uma curva complexa por recortes**, isolando trechos específicos e perguntando ao modelo, janela a janela, se há indício de evento. ~~O dicionário `CUT_RANGES` do *script* permite reexecutar a inferência sobre uma janela temporal arbitrária — a operação é uma única linha (`cut_curve(time, flux, t_ini, t_fim)`) e pode ser feita interativamente no *Debug Console* do VS Code, sem retreinar o modelo nem reescrever a *pipeline*.~~

Tomando a curva Gemini-'Alopeke ~~*Red*~~ no filtro z — a de maior SNR —, definiram-se **seis janelas** que cobrem assinaturas físicas distintas: um trecho de ~~*baseline*~~ linha de base sem evento (controle negativo), as duas porções do anel Q1R (contínua e densa), as duas travessias do anel fino Q2R (antes e depois do corpo) e um trecho curto de ruído que se assemelha visualmente a uma ocultação, adjacente ao Q2R (janelas ~~destacadas~~ numeradas na Figura 5.7). As janelas foram definidas sabendo onde estão os anéis, a partir das posições publicadas, e são as mesmas da versão anterior deste estudo. A inferência foi aplicada a cada janela com os ~~modelos CatBoost (o modelo de referência da Seção 5.8) e XGBoost do Experimento 2; o Random Forest e a Regressão Logística não foram avaliados nos recortes~~quatro modelos. A Tabela 5.8 reúne as probabilidades atribuídas e, na última linha, o limiar de cada modelo escolhido na validação cruzada pelo critério de sensibilidade $\geqslant 99{,}5\,\%$ (Tabela 5.7).

Tabela 5.8: Probabilidade de ocultação $\hat{p}$ atribuída ~~por CatBoost e XGBoost (Exp.~~pelos quatro modelos finais do Experimento ~~2)~~ 1.2b à curva inteira ~~(*baseline*)~~ e a cada recorte da curva Gemini-'Alopeke ~~*Red*~~ no filtro z. Janelas em segundos relativos ao instante 2022-08-09 06:34:49,26 UTC. A última linha traz o limiar τ de cada modelo escolhido na validação cruzada (sensibilidade $\geqslant 99{,}5\,\%$). RL: Regressão Logística; RF: Random Forest.

Recorte (janela, s)	Assinatura física	RL	RF	XGBoost	CatBoost
Curva inteira	corpo central + 2 anéis	1,0000	1,0000	0,9997	0,9859
(1) −290 a −250	linha de base (controle negativo)	0,0039	0,0000	0,0004	0,0020
(2) −225 a −200	Q1R — parte contínua	0,0540	0,5828	0,9154	0,3703
(3) −129 a −114	Q2R — anel fino (real)	0,0116	0,1895	0,0963	0,0352
(4) −109 a −099	ruído parecido com anel	0,0052	0,0000	0,0005	0,0036
(5) +121 a +146	Q2R — anel fino (real)	0,0122	0,0770	0,0526	0,0169
(6) +191 a +251	Q1R — parte densa	1,0000	0,9900	0,9991	0,9740
Limiar da validação cruzada (τ)		0,10	0,40	0,18	0,15

A leitura da tabela revela três regimes. **(i) Anéis fortes (Q1R):** ~~tanto a parte~~ a parte densa é detectada pelos quatro modelos ($\hat{p} \geqslant 0{,}97$). A parte contínua ~~quanto a densa são detectadas com folga ($\hat{p} = 0{,}96$ e $0{,}999$ no XGBoost) — o sinal~~ é ~~profundo ou longo o bastante para o modelo~~detectada no limiar padrão pelo XGBoost ($\hat{p} = 0{,}92$) e pelo Random Forest (0,58), e pelo CatBoost (0,37) apenas no limiar da validação cruzada; a

Regressão Logística (0,054) não a detecta em nenhum dos dois limiares. **(ii) Controle e ruído:** ~~o *baseline* sem evento~~ a janela de linha de base e o trecho de ruído recebem probabilidades ~~ínfimas ($\hat{p} \approx 6 \times 10^{-4}$ e 5×10^{-4} no XGBoost), confirmando que o classificador não tem viés pró-positivo~~muito baixas em todos os modelos ($\hat{p} < 0{,}01$). **(iii) Anéis finos (Q2R):** ~~aqui está o ponto sutil. Ambos os anéis~~ as duas travessias do Q2R recebem veredito *negativo* em todos os modelos, tanto no limiar padrão $\tau = 0{,}5$ ~~($\hat{p} = 0{,}043$ e $0{,}081$ no XGBoost).~~ quanto no limiar escolhido na validação cruzada. Nos pontos operacionais da Seção 5.7.4, portanto, nenhuma das duas travessias seria sinalizada.

~~À primeira vista, isso pareceria uma falha. Mas o que importa~~ Esse resultado não constitui, por si só, uma falha: para a revisita de curvas~~não~~, o relevante é ~~o valor absoluto da probabilidade, e sim~~ a ~~separação entre eventos e não-eventos. O anel fino real (Q2R, $\hat{p} = 0{,}043$~~**ordenação** das janelas, e não o valor absoluto da probabilidade. No XGBoost, a primeira travessia do Q2R ($\hat{p} = 0{,}096$) recebe probabilidade cerca de **~~86~~ 190 vezes maior** do que o trecho de ruído adjacente, de duração comparável ($\hat{p} = 0{,}0005$)~~— quase duas ordens de grandeza de diferença. Em outras palavras, mesmo "errando" a~~, e cerca de 250 vezes maior do que o controle de linha de base; a segunda travessia ($\hat{p} = 0{,}053$) recebe cerca de 100 vezes a probabilidade do ruído. No CatBoost, as razões correspondentes à primeira travessia são de cerca de 10 e 18 vezes; o Random Forest atribui probabilidade nula ao controle e ao ruído e 0,19 e 0,08 às travessias; e a Regressão Logística separa pouco as janelas (razões de 2 a 3). Ainda que a classificação binária ~~, o modelo *ordena corretamente* as janelas : atribui~~ seja negativa, os modelos de árvore ordenam as janelas no sentido correto: atribuem ao anel verdadeiro uma probabilidade pequena em termos absolutos~~(4–8%), mas enorme frente à do ruído que mais se parece com uma ocultação (0,05%). É exatamente esse contraste que um analista revisitando a curva precisa enxergar~~ porém maior que a das janelas sem evento.

Essa separação ~~é o que torna o~~ permite ilustrar o **ajuste de limiar** (Seção 5.7) ~~tão eficaz~~ neste caso. ~~Baixando o limiar para~~ Com o limiar do XGBoost reduzido a $\tau = 0{,}03$ — ~~um valor~~ o mesmo valor ilustrativo da versão anterior deste estudo, situado entre as duas escalas de probabilidade e escolhido depois de observar as probabilidades das seis janelas —, ~~os dois anéis~~ as duas travessias do Q2R passam a ser ~~corretamente classificados~~ classificadas como ocultações, ~~*sem*~~ sem que o controle (~~6×10^{-4}~~4×10^{-4}) ou o ruído (5×10^{-4}) cruzem o novo limiar. ~~A sensibilidade sobre os quatro eventos físicos da curva (Q1R contínuo, Q1R denso, $Q2R_1$ e $Q2R_2$) sobe de 50% para 100%, sem nenhum falso alarme nos dois recortes-controle. Esta é a manifestação prática, em dados reais externos ao treino, do mecanismo de *threshold tuning* apresentado na Seção 5.7~~Esse ganho tem um custo que as duas janelas de controle não revelam: nas predições fora da dobra do conjunto de desenvolvimento, o XGBoost com $\tau = 0{,}03$ classifica como positivas 16 das 155 negativas reais (10 %). A Figura 5.7 ilustra os seis recortes ~~coloridos~~ sobre a curva, com a probabilidade atribuída pelo XGBoost e o veredito em $\tau = 0{,}5$ e em $\tau = 0{,}03$.

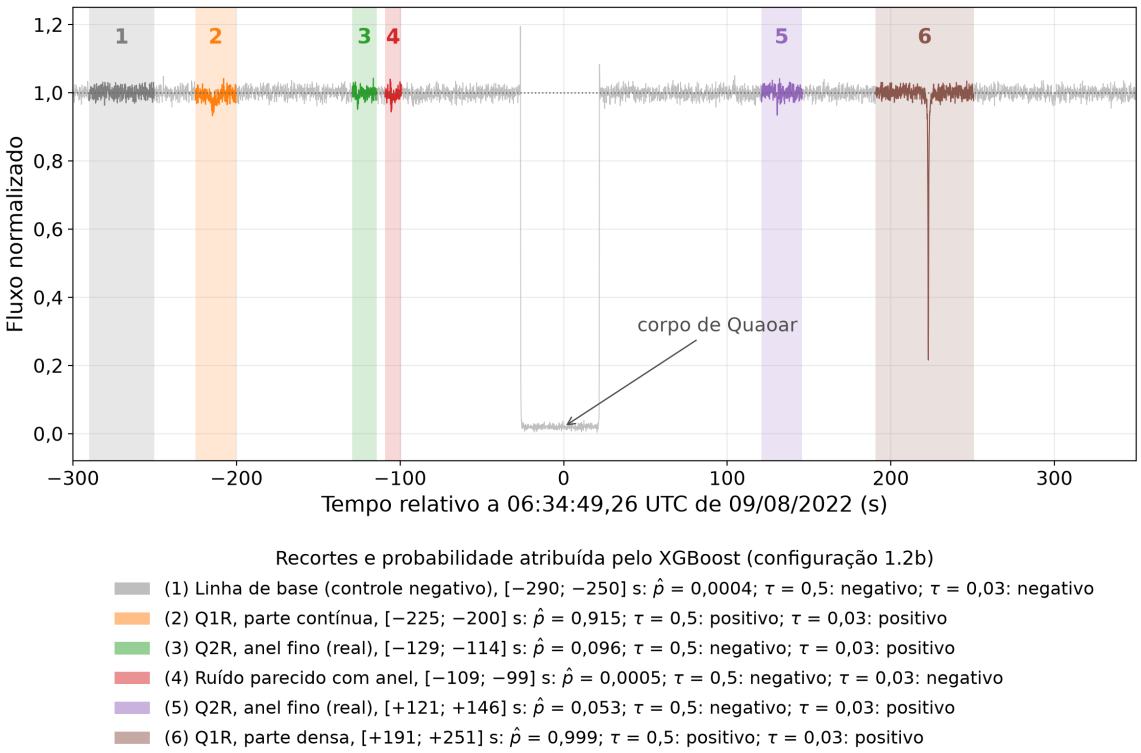


Figura 5.7: Recortes da curva Gemini-'Alopeke de Quaoar (canal ~~*Red* –~~ vermelho, filtro z~~(visível-vermelho~~, no infravermelho próximo)~~de Quaoar~~, ~~com o veredito do XGBoost em cada janela coloridas~~numerados como na Tabela 5.8. A legenda indica, por recorte, a probabilidade $\hat{p}$ atribuída pelo XGBoost do Experimento 1.2b e a classificação no limiar padrão ($\tau = 0{,}5$) e no limiar ~~ajustado~~ ilustrativo ($\tau = 0{,}03$). ~~Os anéis finos Q2R, negativos em $\tau = 0{,}5$, são recuperados em $\tau = 0{,}03$, enquanto o controle e o trecho de ruído permanecem corretamente negativos.~~ Tempo relativo a 2022-08-09 06:34:49,26 UTC.

~~A janela curta~~ Varredura cega. As janelas da Tabela 5.8 foram escolhidas conhecendo a posição dos anéis. Para estimar a taxa de alarmes falsos sem essa informação, a curva no filtro z foi percorrida por janelas de mesma duração — 15 s e 25 s, as durações dos recortes do Q2R —, deslocadas de meia janela, e cada janela foi classificada independentemente. Das 160 janelas de 15 s, 123 não tocam nenhum evento conhecido (corpo e anéis, com margem de 3 s); das 96 janelas de 25 s, 70. Com $\tau = 0{,}03$, o XGBoost classificou como positivas 4 das 123 (3 %) e 4 das 70 (6 %) janelas sem evento; com o limiar da validação cruzada ($\tau = 0{,}18$), nenhuma das 123 e 2 das 70. Essas taxas são menores que os 10 % estimados nas negativas reais do desenvolvimento, o que é esperado em uma curva de SNR alto, e não devem ser generalizadas a curvas mais ruidosas. Quanto à ordenação, a janela escolhida sobre a primeira travessia do Q2R recebe probabilidade maior que todas as 123 janelas sem evento de mesma duração, e a da segunda travessia, maior que 66 das 70. Na varredura, porém, as janelas não estão alinhadas aos anéis: a melhor janela sobre cada travessia recebeu $\hat{p} = 0{,}044$ e 0,13 (15 s) ou 0,21 e 0,15 (25 s). Em três desses quatro casos, uma ou duas janelas sem evento receberam probabilidade maior; a exceção é a segunda travessia com janelas de 15 s, cuja melhor janela supera todas as 123 janelas sem evento (máximo de 0,093). As janelas sem evento de maior probabilidade cobrem o mesmo trecho no fim da série (de +589 a ~~causa.~~+627 s), em que há uma flutuação rasa do fluxo (cerca de 1,5 %, por alguns segundos) sem evento conhecido.

O tamanho da janela não explica as baixas probabilidades dos anéis finos. Uma hipótese natural para a baixa probabilidade ~~dos~~ atribuída aos anéis finos seria que as janelas correspondentes (10–25 s) são curtas demais ~~, prejudicando~~ para a extração de ~~*features*~~características. Essa hipótese foi testada ~~e **refutada**: ao ampliar~~ ampliando as janelas dos recortes do Q2R por um fator ~ 3 (para -160 a -110 s e +80 a +170 s). No XGBoost, a probabilidade ~~atribuída pelo XGBoost ao anel real $\mathrm{Q2R}_1$ *caiu* de 0,043 para~~ da primeira travessia passou de 0,096 para 0,027, e a da segunda, de 0,053 para 0,025. No CatBoost, as probabilidades aumentaram (de 0,035 ~~, e a do $\mathrm{Q2R}_2$ caiu de 0,081 para 0,029 — ou seja, ampliar a janela tornou o veredito negativo ainda mais forte. A~~ para 0,051 e de 0,017 para 0,048), e no Random Forest a da segunda travessia aumentou de 0,077 para 0,19; em nenhum modelo, contudo, a ampliação levou um anel fino ao limiar escolhido na validação cruzada. Uma explicação plausível é estrutural: o conjunto de ~~*features*~~ características é dominado por **estatísticas globais** da janela (~~mínimo do Savitzky-Golay, *Max Drawdown*~~desvio padrão do fluxo suavizado, queda máxima acumulada, profundidade, SNR ~~do *dip*). Um *dip*~~ da queda), e uma queda de poucos segundos ~~diluído~~ diluída em dezenas de segundos de ~~*baseline* limpo torna-se um *outlier* estatisticamente desprezível, e o modelo responde com *mais* confiança que se trata de *baseline* puro. A fronteira de detecção~~ linha de base pesa pouco nessas estatísticas. Outra explicação concorrente é ~~, portanto, regida pela razão entre a duração do *dip* e a duração da janela — não pelo~~

~~tamanho absoluto da janela. Esse diagnóstico motiva diretamente~~ que a janela de suavização cresce com o número de pontos da série (Seção 4.5.2) e passa a atenuar a própria queda. As duas explicações motivam as direções de trabalho futuro discutidas no Capítulo 6 (janela deslizante e ~~*features*~~ características locais).

Por que XGBoost. A análise de recortes destaca o XGBoost porque suas probabilidades são mais **polarizadas**: a razão entre a probabilidade do anel real e a do ruído ~~no~~ na primeira travessia do Q2R ~~1~~ é de ~~$\sim 86\times$~~ $\sim 190\times$ no XGBoost, contra ~~$\sim 12\times$~~ $\sim 10\times$ no CatBoost (Tabela 5.8). ~~Os dois modelos~~ O Random Forest também separa as janelas, atribuindo probabilidade nula ao controle e ao ruído; como a razão fica indefinida nesse caso, a comparação com ele se faz pela varredura cega, na qual 2 das 123 janelas sem evento de 15 s recebem probabilidade maior que a da primeira travessia do Q2R, contra nenhuma no XGBoost. Os modelos de árvore concordam qualitativamente — ~~ambos~~ detectam o corpo e ~~os anéis fortes~~ a parte densa do Q1R e rejeitam controle e ruído —, mas a maior separação do XGBoost torna o ajuste de limiar mais robusto. ~~Isso é coerente com a leve vantagem do XGBoost no teste em curvas exclusivamente reais (Experimento 3). A subseção anterior, sobre a curva completa, usou o CatBoost-Exp. 2; aqui, ambos classificam o corpo principal com $\hat{p} > 0{,}99$, e o XGBoost é preferido apenas para a discussão dos eventos sutis~~Essa escolha foi feita depois de observar as probabilidades dos recortes, o que reforça o caráter ilustrativo do estudo de caso.

5.8.4 Interpretação

O estudo de caso ~~reforça~~ilustra, na prática, quatro ~~conclusões dos experimentos formais~~ aspectos da ferramenta:

1. **Generalização para dados externos:** mesmo ~~treinado em curvas predominantemente simuladas e~~ treinados com negativas majoritariamente simuladas e curvas oriundas dos catálogos VizieR/Grupo do Rio, ~~o modelo do Experimento 2 classifica~~ os quatro modelos classificam corretamente registros de uma campanha observacional distinta, em três bandas espectrais e dois telescópios diferentes.

2. **Robustez a complexidade morfológica:** a presença de estruturas secundárias na curva (anéis) não confunde ~~o classificador, que mantém probabilidades $> 0{,}99$ para o evento principal~~os classificadores, que mantêm probabilidades $\geqslant 0{,}985$ para as curvas inteiras.

3. ~~**Capacidade**~~ **Ordenação de** ~~**triagem de**~~ **eventos sutis por recorte:** ainda que os anéis finos do Q2R fiquem abaixo ~~do limiar padrão, o modelo~~ dos limiares escolhidos na validação cruzada, o XGBoost lhes atribui probabilidade ~~até $\sim 86\times$ de~~ 100 a 250 vezes maior do que ~~a um trecho de~~ às duas janelas sem evento examinadas

(controle e ruídosemelhante. Essa separação — e não o valor absoluto —) e maior do que a de todas, ou quase todas, as janelas sem evento de mesma duração na curva. Essa ordenação é o que permite recuperá-los com um simples ajuste de limiar, validando a *pipeline* como ferramenta para revisitar curvas em busca de descobertastornaria possível priorizá-los numa revisita, ao custo de alarmes falsos quando o limiar é reduzido a $\tau = 0{,}03$: 3 a 6 % das janelas sem evento nesta curva e cerca de 10 % das negativas reais do desenvolvimento.

4. **Utilidade operacional:** o procedimento — leitura do `.dat`, limpeza, recorte opcional e inferência — é executado em segundos e pode ser incorporado a campanhas reais com modificação mínima.

Como limitação, vale registrar que se trata trata-se de um n pequeno (três curvas, todas do mesmo evento)e que , as janelas dos recortes foram escolhidas sabendo onde estão os anéis, e os modelos atuais não estão otimizados para detectar separadamente os eventos de anel: o . A varredura cega reduz o primeiro viés, mas foi feita em uma única curva, de SNR alto, e com janelas não alinhadas aos anéis a ordenação favorável deixa de ser garantida. O ajuste de limiar resolve ilustra o caso prático, mas não substitui uma avaliação sistemática em muitas curvas nem melhorias estruturais como janela deslizante, *features* características locais ou classificação multi-classe. Uma avaliação sistemática nesse regime — inclusive incorporando dados de campanhas similares no banco de treino — é uma das multiclasse, direções recomendadas discutidas no Capítulo 6.

5.9 Comparação entre os experimentosImportância das características na configuração escolhida

A Tabela ?? permite uma visão comparativa do F1-score por modelo nos seis experimentos realizados. Figura 5.8 apresenta as cinco características mais importantes de cada um dos quatro modelos finais do Experimento 1.2b. A interpretação dos valores deve considerar as diferenças metodológicas discutidas na Seção 5.3: as escalas horizontais não são diretamente comparáveis entre os painéis.

Cinco observações principais emergem da análise conjunta:

Estabilidade entre conjuntos de *features*. A redução de 28 (Experimento 1) para 14 *features* (Experimento 4) preserva o desempenho, com F1 entre Nos três modelos de árvore, a variável dominante é `Feature_Savgol_Min` (0,98 e 028 no Random Forest, 99.

Impacto da remoção de `Feature_Savgol_Min`. No Experimento 5 (13 *features*), o Random Forestlidera com F1 = 0,9905; a remoção dessa *feature* não causa degradação acentuada.

Dispensabilidade do K-means. Nos Experimentos 6 e 2, a remoção de 50 no XGBoost e 46 no CatBoost), seguida de `kmeansFeature_centroidSavgol_diststd` (e , no

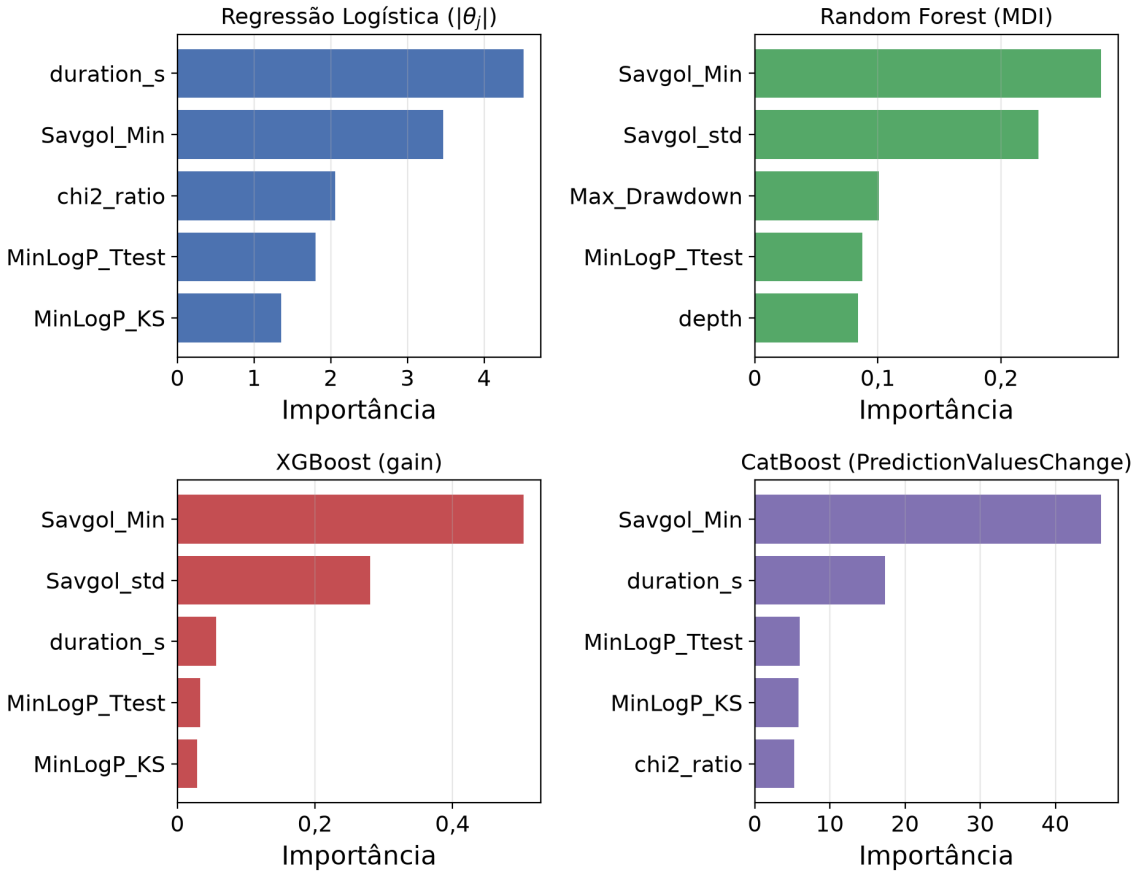


Figura 5.8: ~~Comparação do F1-score entre os seis experimentos, por~~ As cinco características mais importantes de cada modelo ~~. Exp.~~final do Experimento ~~1~~1.2b: ~~28 *features*; Exp. 2: 11 *features*~~ Regressão Logística (~~ablação combinada~~módulo dos coeficientes padronizados)~~; Exp. 3: teste somente em curvas reais~~ , Random Forest (~~198 curvas: 160 positivas~~ MDI), XGBoost (*gain*) e ~~38 negativas; simuladas alocadas ao treino~~CatBoost (*PredictionValuesChange*)~~; Exp~~. ~~4: 14 *features*; Exp~~Cada painel usa a escala do próprio método, e os valores não são comparáveis entre painéis. ~~5: 13 *features*; Exp~~Os prefixos `Feature_` e `Occ_` foram omitidos dos rótulos.~~ 6: 12 *features* (sem `kmeans`).~~

Exp. 2, também no Random Forest e no XGBoost e de `Feature_Savgol_Min`) não degrada o desempenho: XGBoost e CatBoost mantêm F1 $\geqslant$ 0,990. A colinearidade funcional com `Feature_Savgol_std` explica essa redundância`Occ_duration_s` no CatBoost.

Generalização em curvas reais. O Experimento 3 (teste somente em curvas reais) preserva o melhor F1 do teste misto (XGBoost, 0,9906)e mantém AUC-ROC $\geqslant$ 0,9965, indicando que as *features* capturam sinal real e não apenas artefatos da distribuição simulada. A queda de 0,7 pp na variante 65/35 (Apêndice A) Esse ordenamento é compatível com a flutuação entre partições; atribuí-la à redução do treino coerente com o resultado da validação cruzada: `Feature_Savgol_Min` é uma hipótese, pois a variante também altera o conjunto de teste.

AUC-ROC. Em todos os experimentos com teste misto (todos exceto o Experimento 3), a AUC-ROC permanece $\geqslant$ 0,9995; no Experimento 3, $\geqslant$ 0,9965justamente a variável cuja remoção prejudica o desempenho nas negativas reais (Seção 5.5.1).

A Figura 5.3 apresenta as curvas ROC da linha de base em dados mistos (Experimento 1), com separação quase perfeita entre as classes. As curvas ROC dos demais experimentos — incluindo a variante 65/35 do Experimento 3 (Figura ??) — estão reunidas no Apêndice AOs testes entre quartis (`MinLogP_Ttest` e `MinLogP_KS`) aparecem entre as cinco primeiras em todos os modelos (no Random Forest, apenas o teste t); nos de árvore, com importância baixa, coerente com sua redundância. A variável mais importante depende do método: `Feature_Savgol_Min` nos modelos de árvore e `Occ_duration_s` na Regressão Logística.

Curvas ROC — Experimento 1 (28 *features*).

5.9.1 Interpretação dos coeficientes da Regressão Logística

5.9.2 Análise de importância das *features*

A Figura 5.8 apresenta os gráficos de importância de variáveis para os quatro modelos no Experimento 2 (configuração enxuta, 11 *features* úteis após a remoção das redundantes); concentramos a análise nesta configuração porque são justamente essas variáveis que permanecem em uso na *pipeline* final. As figuras análogas das demais configurações estão no Apêndice A. A interpretação dos valores deve considerar as diferenças metodológicas discutidas na Seção 5.3: cada modelo emprega uma métrica própria — MDI normalizado para soma 1 (Random Forest), *weight* normalizado (XGBoost), *PredictionValuesChange* normalizado para soma 100 (CatBoost) e $|\theta_j|$ sem normalização (Por ser um modelo linear nas características padronizadas, a Regressão Logística) —, de modo que as escalas horizontais não são diretamente comparáveis entre os painéisLogística permite ler o sentido e a intensidade de cada efeito. A Tabela 5.9 apresenta os coeficientes θ_j do modelo final do Experimento 1.2b e a razão de chances (*odds ratio*) e^{θ_j}, que indica por quanto se multiplica a chance $P(y = 1)/P(y = 0)$ de a

curva conter uma ocultação quando a característica aumenta um desvio padrão, mantidas as demais constantes.

Experimento 2 (11 *features* úteis). (a) Regressão Log. (b)Random Forest (c) XGBoost (d) CatBoost Importância de variáveis por modelo — Experimento 2 (configuração enxuta, 11 *features*). (a) Regressão Logística, (b) Random Forest, (c) XGBoost, (d) CatBoost.

Tabela 5.9: Coeficientes da Regressão Logística do Experimento 1.2b (características padronizadas), ordenados pelo módulo, e razão de chances correspondente a um aumento de um desvio padrão na característica. Intercepto: $\theta_0 = 4{,}50$.

Característica	θ_j	**Razão de chances** e^{θ_j}
`Occ_duration_s`	4,51	91,30
`Feature_Savgol_Min`	−3,47	0,03
`Occ_chi2_ratio`	2,06	7,86
`MinLogP_Ttest`	1,80	6,04
`MinLogP_KS`	1,35	3,88
`Max_Drawdown`	−1,20	0,30
`Occ_chi2_square_well`	1,01	2,75
`Feature_Savgol_std`	1,01	2,74
`Occ_chi2_constant`	0,79	2,20
`Occ_baseline_std`	−0,54	0,58
`Occ_depth`	0,49	1,63
`Occ_SNR_dip`	0,20	1,22

Nos modelos de árvore (Random Forest e XGBoost), as variáveis mais relevantes Os sinais são consistentemente:

`Feature_Savgol_std`: a *feature* dominante em ambos os modelos — isolada, responde por ≈0coerentes com a física do problema. Aumentam a chance de ocultação: uma sequência longa de pontos abaixo da linha de base (`Occ_duration_s`), um melhor ajuste do modelo de poço retangular em relação ao modelo constante (`Occ_chi2_ratio`), diferenças marcadas entre os quartis da série (`MinLogP_Ttest`, 57 da importância no XGBoost. Mede a `MinLogP_KS`) e maior dispersão do fluxo suavizado , que cresce quando coexistem dois patamares (dentro e fora do *dip*). Com a remoção de `kmeans_centroid_dist` (Experimento 2), ela absorve o papel discriminativo antes atribuído àquela (`Feature_Savgol_std`). Diminuem a chance: um mínimo do fluxo suavizado mais alto (`Feature_Savgol_Min`; quanto mais fundo o mínimo, maior a chance de ocultação), uma queda máxima acumulada de menor módulo e um ruído maior fora do evento (`Occ_baseline_std`), que torna menos convincente uma queda de mesma profundidade.

Três cuidados são necessários na leitura. Primeiro, os coeficientes são **condicionais**: medem o efeito de uma variável colinear, como antecipado pelo estudo de ablação. `Max_Drawdown`: captura diretamente a magnitude da maior queda acumulada de fluxo, assinatura primária de uma ocultação. mantidas as demais fixas, e variáveis correlacionadas dividem entre si o efeito. Isso explica por que `Occ_depth`e , fisicamente central, tem coeficiente pequeno: seu efeito é absorvido por `Feature_Savgol_Min` e `Max_Drawdown`, com as quais tem correlação alta. Segundo, a razão de chances de `Occ_duration_s` ÷

~~quantificam a profundidade~~ (91 por desvio padrão) pode refletir também a diferença de comprimento entre as curvas (hipótese não testada neste trabalho): os negativos por recorte são trechos curtos de curvas positivas, e a duração ~~do evento segundo critérios observacionais. `MinLogP_Ttest` (e, em menor grau, `Occ_chi2_ratio` e `MinLogP_KS`): os testes estatísticos entre quartis detectam a heterogeneidade no fluxo esperada em curvascom ocultação.~~

~~As figuras análogas das configurações com conjuntos maiores de *features* (Experimentos 4 e 5), que permitem acompanhar como a importância relativa das variáveis se redistribui à medida que o conjunto~~ da maior sequência abaixo da linha de base tende a crescer com o comprimento do registro. Além disso, a distribuição dessa variável é ~~reduzido, estão reunidas no Apêndice A~~muito assimétrica (a maioria das curvas tem durações de poucos segundos, e algumas passam de cem segundos), de modo que "um desvio padrão" representa uma variação grande para a maioria das curvas; o valor 91 indica o sentido e a relevância do efeito, não sua magnitude exata. Terceiro, a Regressão Logística tem desempenho ligeiramente inferior ao dos modelos de árvore (Tabela 5.5), de modo que sua leitura serve como interpretação aproximada, e não como modelo causal.

~~Naquelas configurações, a *feature*~~

5.9.2 A distância entre centroides do K-means

Mesmo dispensável, a `kmeans_centroid_dist` ~~figura entre as mais importantes, e isso não é~~~~um artefato dos modelos: a análise exploratória dos dados confirma que ela é~~, por si só, discriminativa. A Figura 5.9 mostra que as curvas negativas se concentram em valores baixos de distância entre ~~centróides~~ centroides — coerente com um fluxo de regime único, em que o K-means não encontra dois agrupamentos distintos —, enquanto as curvas positivas se espalham por valores altos, refletindo a coexistência dos dois patamares (dentro e fora ~~do *dip*).~~ da queda). As negativas reais, porém, ficam acima das simuladas (entre cerca de 0,05 e 0,25) e se sobrepõem à cauda inferior das positivas, mais uma indicação de que as negativas simuladas são mais fáceis de separar que as reais. É justamente por parecer tão promissora que o resultado ~~do estudo de~~ da ablação (sua remoção não ~~degrada~~ altera o desempenho, ~~pois `Feature_Savgol_std` é colinear e a substitui Seção ??~~porque as variáveis colineares a substituem) se torna um achado relevante, e não uma simplificação trivial.

5.10 ~~Validação cruzada estratificada~~Teste de McNemar entre modelos

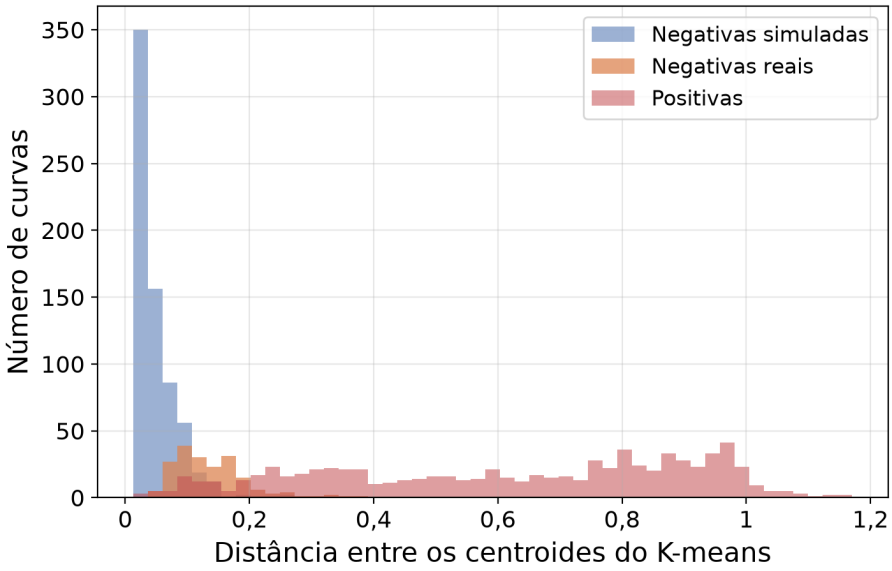


Figura 5.9: Distribuição da *feature* característica `kmeans_centroid_dist` por classe (1–99 percentil). As curvas nas positivas, nas negativas concentram-se em valores baixos (regime único) reais e as positivas em valores altos nas negativas simuladas (dois patamaresentre os percentis 1 e 99), evidenciando o poder discriminativo da variávelnas 1692 curvas do conjunto. A figura é descritiva e inclui as curvas do conjunto de teste.

Os resultados das seções anteriores baseiam-se em uma única divisão treino/teste por experimento. Isso é útil para comparar modelos sob as mesmas condições, mas não diz o quanto o desempenho *varia* se mudarmos a divisão dos dados. Para medir essa variabilidade, repetimos a avaliação cinco vezes, com partições diferentes — procedimento conhecido como **validação cruzada com $q = 5$ dobras** (*k-fold*).

O procedimento é simples. Primeiro, embaralha-se o conjunto e divide-se em 5 partes (as "dobras") de tamanho parecido. Em seguida, faz-se cinco rodadas: em cada uma, quatro dobras servem de treino e a quinta de teste, alternando qual dobra é a de teste, de modo que toda curva é avaliada exatamente uma vez. As partições são **estratificadas** (cada dobra mantém a mesma proporção entre as duas classes, positiva e negativa — continua sendo um problema binário) e respeitam o **agrupamento por curva** (todos os segmentos recortados de uma mesma curva ficam na mesma dobra, para que o modelo nunca seja testado em um pedaço de uma curva que viu no treino, o que inflaria artificialmente o desempenho). Em cada rodada, os quatro modelos são treinados e avaliados de forma independente, registrando-se F1-score, precisão, sensibilidade e AUC-ROC. O resultado final é a **média ± desvio padrão** dessas métricas sobre as cinco dobras: a média estima o desempenho típico e o desvio padrão, a sua variabilidade.

A Tabela **??** apresenta a média e o desvio padrão das métricas na validação cruzada estratificada *5-fold* (Experimento 5, 13 *features*; detalhado no Apêndice A).

~~Validação cruzada estratificada ($q = 5$): média ± desvio padrão das métricas por modelo (Experimento 5).~~

~~A validação cruzada cumpre dois objetivos: (1) confirmar que o desempenho elevado observado nos experimentos anteriores não é artefato de uma partição favorável dos dados; e (2) fornecer desvios padrão que permitam avaliar se as diferenças entre modelos são significativas ou estão dentro da flutuação estatística. O desvio padrão do F1 entre as dobras vai de 0,0062 (XGBoost) a 0,0104 (Regressão Logística) (Tabela ??). As diferenças entre as médias dos quatro modelos (no máximo 0,0037) são menores que um desvio padrão; a validação cruzada, portanto, não distingue os classificadores, o que é coerente com o teste de McNemar (Seção 5.10.1).~~

5.10.1 ~~Teste de McNemar entre modelos~~

Para ~~determinar~~ verificar se as diferenças de desempenho entre pares de modelos no conjunto de teste são **estatisticamente significativas** — e não meras flutuações amostrais —, aplicou-se o **teste de McNemar** (McNemar , 1947), cujo uso ~~adequado~~ em comparação de classificadores é discutido por Smith e Ruxton (2020). ~~Esse teste é apropriado para comparar~~ O teste compara dois classificadores avaliados no mesmo conjunto~~de teste~~: constrói-se uma tabela 2×2 de concordância ~~/~~e discordância entre as predições dos dois modelos ~~,~~e testa-se se os padrões de discordância são simétricos.

Sejam b o número de exemplos que o modelo A erra e o modelo B acerta, e c o número de exemplos que o modelo A acerta e o modelo B erra. ~~A estatística de McNemar (com correção de continuidade) é:~~

$$\chi^2 = \frac{(|b-c|-1)^2}{b+c},$$

~~que segue uma distribuição χ^2 com 1 grau de liberdade sob~~ Sob a hipótese nula ~~$H_0 : b = c$ (os~~ de que os dois modelos têm a mesma taxa de erro~~). Se $p < 0{,}05$, rejeita-se H_0 e conclui-se que a diferença~~, b segue uma distribuição binomial com $n = b + c$ tentativas e probabilidade 1/2. A aproximação usual pela distribuição χ^2 com um grau de liberdade só é ~~significativa.~~

~~A Tabela 5.10 apresenta os resultados do teste de McNemar entre pares de modelos (Experimento 4, 14 *features*; detalhado no Apêndice A)~~adequada quando $b + c$ é grande (tipicamente $\geqslant 25$); como nas comparações entre os quatro modelos $b + c \leqslant 5$, utilizou-se em todas as comparações o **teste exato**, com p-valor bilateral binomial (Smith e Ruxton , 2020).

~~**Conclusão:**~~ Nenhum par de modelos apresenta diferença ~~estatisticamente significativa; os quatro classificadores podem ser considerados equivalentes no conjunto de teste deste experimento.~~

~~Em cenários de alto desempenho (F1 > 0,97),~~ significativa. Com tão poucos erros discordantes, porém, o teste não tem poder: com $b + c \leqslant 5$, o menor p-valor possível é

Tabela 5.10: Teste de McNemar exato no conjunto de teste ($\tau = 0{,}5$, Experimento 1.2b): entre pares de modelos (~~Experimento 4~~parte superior) e entre o critério trivial de limiar em `Occ_depth` e cada modelo (parte inferior). b: ~~apenas~~ A erra e B acerta; c: ~~apenas B~~ A acerta e B erra.~~$p < 0{,}05$ indicaria diferença significativa; nenhum par é significativo ($\alpha = 0{,}05$).~~

Modelo A	**Modelo B**	b	c	p (exato)
Regressão Log.	Random Forest	2	2	1,00
Regressão Log.	XGBoost	3	2	1,00
Regressão Log.	CatBoost	2	1	1,00
Random Forest	XGBoost	2	1	1,00
Random Forest	CatBoost	1	0	1,00
XGBoost	CatBoost	1	1	1,00
Limiar em `Occ_depth`	Regressão Log.	31	3	8×10^{-7}
Limiar em `Occ_depth`	Random Forest	31	3	8×10^{-7}
Limiar em `Occ_depth`	XGBoost	31	2	1×10^{-7}
Limiar em `Occ_depth`	CatBoost	31	2	1×10^{-7}

~~comum que os valores de b~~ $2 \times 0{,}5^5 = 0{,}0625$, de modo que o teste não poderia rejeitar a hipótese nula ao nível de 5 % em nenhum desses pares. A ausência de significância indica apenas que os dados *não permitem distinguir* os modelos, e ~~c sejam pequenos, o que pode tornar o teste pouco potente. Se o McNemar indicar que as~~ não que eles sejam equivalentes. Na comparação com o critério trivial, ao contrário, as discordâncias são numerosas (o limiar em `Occ_depth` erra 31 curvas que cada modelo acerta, contra 2 ou 3 no sentido oposto), e a superioridade dos quatro modelos é significativa ($p < 10^{-6}$). Essa leitura é coerente com a validação cruzada, na qual as diferenças **~~não~~** entre modelos de uma mesma configuração são ~~significativas para a maioria dos pares, isso sugere que os modelos são equivalentes no contexto deste *dataset* e que a~~ da ordem de um desvio padrão. A escolha entre eles pode, portanto, ser guiada por critérios secundários (interpretabilidade, velocidade de inferência, facilidade de implantação, etc.).

5.11 Curvas de aprendizado~~dos modelos de *boosting*~~

A Seção 3.6.4 (Capítulo 3) apresentou as curvas de aprendizado como ferramenta gráfica para diagnosticar sobreajuste: acompanha-se o erro em treino e em validação em função do número de iterações ou do tamanho do conjunto de treino~~ou do número de épocas. Aplicamos aqui a segunda variante aos dois modelos de *boosting* da *pipeline*, registrando a~~. Ambas as variantes foram aplicadas ao Experimento 1.2b, sempre com dados de validação do conjunto de desenvolvimento, e não com o conjunto de teste.

Perda em função das iterações. A Figura 5.10 mostra a perda logarítmica (~~*logloss*~~, isto é, a entropia cruzada da Seção 3.3) de treino e de ~~teste~~ validação a cada iteração ~~,~~

na configuração enxuta do Experimento 2 (11 *features*, divisão 80%/20% por curva). A Figura 5.10 apresenta os resultados.

Curvas de aprendizado de (a) XGBoost e (b) CatBoost na configuração do Experimento 2: *logloss* de treino (azul) e de teste (vermelho) em função das iterações de *boosting*.

Dois padrões merecem registro. Primeiro, a perda de teste acompanha a de treino do início ao fim e estabiliza por volta da dos dois modelos de *boosting*, em uma das dobras da validação cruzada. A perda de validação diminui até o fim das 100 iterações (o mínimo ocorre na iteração 50 60, sem em nenhum momento inverter a tendência e 91 no XGBoost e na 100 no CatBoost), sem voltar a crescer. Essa ; essa inversão seria a assinatura clássica de sobreajuste em *boosting*; sua ausência indica que as 100 iterações adotadas param antes da região de risco. Segundo, os *gaps* finais entre teste e treino são pequenos: . A diferença final entre validação e treino é de 0,0215 037 no XGBoost (treino 0,0052; teste 004; validação 0,0267) e 042) e de 0,0125 030 no CatBoost (treino 0,0192; teste 014; validação 0,0317). O CatBoostencerra com o menor *gap*, comportamento coerente com sua regularização estrutural (*ordered boosting* e árvores *oblivious*044). Os níveis dos dois painéis não devem ser comparados entre si: no CatBoost, Capítulo a perda é calculada com os pesos de classe usados no treino, e no XGBoost, sem eles. A figura corresponde a uma única dobra e serve como ilustração qualitativa.

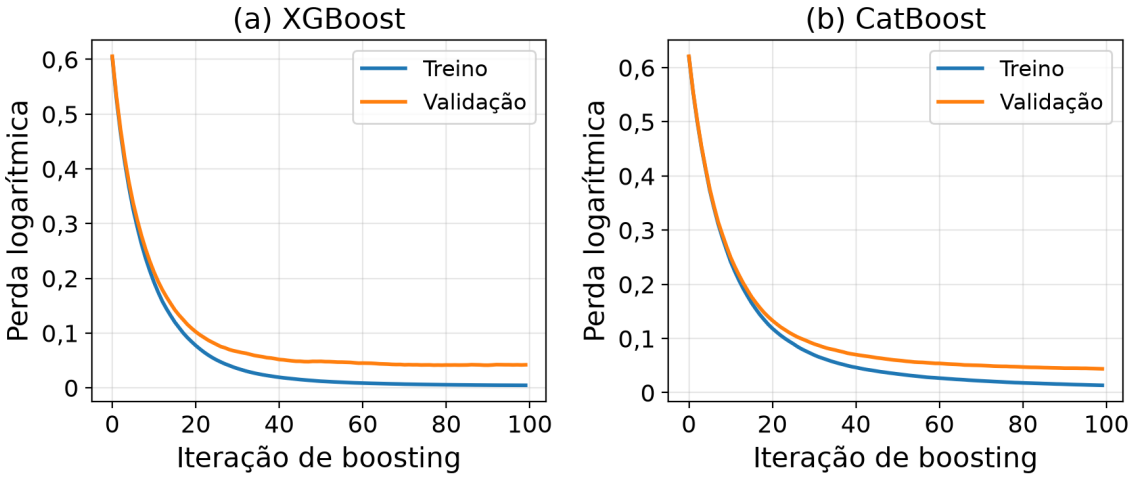


Figura 5.10: Curvas de aprendizado de (a) XGBoost e (b) CatBoost no Experimento 1.2b: perda logarítmica de treino e de validação em função das iterações de *boosting*, em uma dobra da validação cruzada do conjunto de desenvolvimento.

Desempenho em função do tamanho do treino (Análise 2.2). Para medir quanto o desempenho depende da quantidade de dados, a validação cruzada foi repetida treinando cada modelo com 25 %, 50 %, 75 % e 100 % dos grupos de treino de cada dobra, sorteados ao acaso, e avaliando sempre na dobra de validação completa (5 dobras × 3), enquanto

~~o XGBoost desce a perda~~ repetições). A Tabela 5.11 e a Figura 5.11 apresentam os resultados.

Tabela 5.11: F1-score médio ± desvio padrão na validação em função da fração dos grupos de treino utilizada (Experimento 1.2b; entre parênteses, o número médio de curvas de treino).

Fração do treino	Regressão Log.	Random Forest	XGBoost	CatBoost
25 % (272)	0,9764 ± 0,0128	0,9813 ± 0,0135	0,9816 ± 0,0122	0,9823 ± 0,0107
50 % (543)	0,9812 ± 0,0100	0,9874 ± 0,0103	0,9880 ± 0,0087	0,9879 ± 0,0107
75 % (811)	0,9842 ± 0,0092	0,9890 ± 0,0082	0,9901 ± 0,0083	0,9879 ± 0,0095
100 % (1081)	0,9839 ± 0,0082	0,9906 ± 0,0073	0,9890 ± 0,0062	0,9882 ± 0,0076

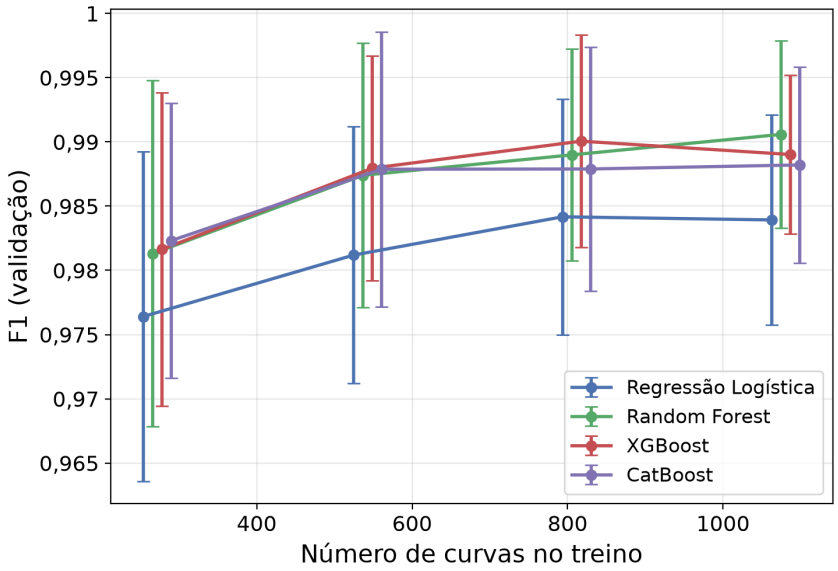


Figura 5.11: F1-score na validação em função do número de curvas de treino (Experimento 1.2b). As barras indicam ±1 desvio padrão entre as 15 dobras (5 dobras × 3 repetições); os pontos dos quatro modelos foram ligeiramente deslocados na horizontal para não se sobreporem.

Com um quarto dos dados de treino (cerca de 270 curvas), os modelos já atingem F1 de ~~treino mais fundo, o que ajuda a explicar suas probabilidades mais polarizadas no estudo de caso de Quaoar (Seção 5.8). Em conjunto com a ablação do tamanho do treino (Apêndice A), que cobre a outra dimensão da~~ 0,976 a 0,982; a partir de metade dos dados, o ganho adicional é de até cerca de 0,3 ponto percentual, menor que o desvio padrão entre dobras. A curva de aprendizado ~~, esses resultados completam o diagnóstico gráfico de generalização introduzido no Capítulo 3.~~ está, portanto, próxima de um patamar dentro do conjunto de desenvolvimento — comportamento incompatível com sobreajuste dominante —, embora isso não autorize extrapolações para conjuntos maiores ou de outra natureza. Mais curvas do mesmo tipo trariam pouco ganho; o que poderia mudar o quadro são curvas de natureza diferente, como negativas reais independentes e eventos rasos ou de baixo SNR.

5.12 Discussão dos resultados

5.12.1 Desempenho e generalização

Os resultados ~~dos seis experimentos~~ indicam que a ~~*pipeline* de detecção automatizada~~ cadeia de processamento atinge **desempenho elevado e estável** na classificação binária de curvas de luz~~: F1-score~~. Na validação cruzada agrupada por evento, o melhor F1 de cada configuração fica entre 0,~~974~~ 983 e 0,~~994 no teste misto (todos os experimentos, exceto o Experimento 3) e~~ 991, com AUC-ROC $\geqslant$ 0,998; no conjunto de teste reservado, a configuração escolhida (Experimento 1.2b) atinge F1 entre 0,~~975~~ 985 e 0,~~982 no teste exclusivamente em curvas reais (Experimento 3); AUC-ROC superior a~~ 988 no teste misto e entre 0,~~995 em todos os cenários. Esse patamar~~ 985 e 0,994 nas curvas reais. Um critério trivial de limiar em uma única característica fica em F1 $\approx$ 0,90, o que mostra, ao mesmo tempo, que a tarefa avaliada é ~~compatível com o objetivo de desenvolver uma ferramenta de triagem que permita priorizar curvas candidatas a análise detalhada.~~ dominada por ocultações profundas, relativamente fáceis de reconhecer, e que os classificadores reduzem a fração de erros em cinco a dez vezes.

~~**Sobre a possibilidade de *overfitting*.** Todas as métricas referem-se ao **conjunto de teste**; portanto, o desempenho descrito é uma estimativa da capacidade de generalização.~~ **Sobre a possibilidade de sobreajuste.** Vários indícios sugerem que o ~~*overfitting*~~ sobreajuste não domina os resultados: (i) ~~as métricas são estáveis entre os seis experimentos e quatro modelos; (ii) a redução de 28 para 14 ou 11 *features* preserva ou melhora ligeiramente o F1; (iii) foram empregados mecanismos de regularização (Ridge na Regressão Logística, `class_weight='balanced'`, limites de profundidade nos *ensembles*);~~ (iv) ~~a~~ o desempenho na validação ~~cruzada *5-fold* (Seção 5.5) apresenta~~ cruzada agrupada por evento — que impede que cordas de um mesmo evento ou recortes de uma mesma curva fiquem em lados opostos da partição — é igual, dentro da incerteza, ao obtido no conjunto de teste reservado; (ii) os desvios padrão ~~pequenos (~~$\approx$entre dobras são pequenos (0,006–0,~~010~~ 009 em F1); (~~v) as curvas de aprendizado (Seção 5.11) mostram o *logloss* de teste convergindo junto ao de treino, sem divergência ao longo das~~ iii) a perda de validação dos modelos de *boosting* não volta a crescer ao longo das iterações; (iv) o desempenho satura com metade dos dados de treino. A taxa de falsos positivos nas negativas reais (2–4 % fora da amostra na configuração escolhida, com limite superior do intervalo de confiança de 95 % entre 5 e 8 %) é maior que nas simuladas, o que indica que as negativas simuladas são mais fáceis que as reais. A confirmação definitiva de boa generalização exigiria validação em dados independentes de outros catálogos, com cordas negativas de eventos distintos, e em curvas difíceis (rasas, de baixo SNR).

5.12.2 Análise de redundância e importância

A análise de redundância (Seção 5.2) identificou 15 variáveis redundantes ou com baixo poder discriminativo. A comparação entre os Experimentos 1 (28 *features*) e 4 (14 *features*) demonstra empiricamente que que podem ser removidas sem perda de desempenho. A ablação das duas variáveis mais importantes nos modelos de árvore mostra que importância e insubstituibilidade são coisas distintas: a remoção dessas distância entre centroides do K-means pode ser eliminada sem custo, porque as variáveis não prejudica — e pode até melhorar — o desempenhodos classificadores. Isso é consistente com a teoria de *machine learning*: variáveis redundantes aumentam a dimensionalidade do espaço de entrada sem acrescentar informação, podendo elevar a variância dos modelos.

A predominância da *feature* `Feature_Savgol_std` no conjunto enxuto (Figura 5.8) é coerente com a física do problema: em uma ocultação, o fluxo normalizado cai durante o intervalo em que a estrela está atrás do corpo, fazendo coexistirem dois patamares (dentro e fora do *dip*); a dispersão da série suavizada cresce nessa situação, ao passo que em curvas ruidosas sem evento o fluxo é aproximadamente homogêneo e a dispersão é baixa. Variáveis correlatas que mediam o mesmo efeito por outra via — como o mínimo da série suavizada colineares a substituem, enquanto o mínimo do fluxo suavizado (`Feature_Savgol_Min`) — mostraram-se redundantes e foram descartadas sem prejuízo de desempenho.

5.12.3 Interpretação da importância das *features*

é necessário para manter baixa a taxa de falsos positivos nas negativas reais. A concordância entre os quatro modelos modelos de árvore quanto às *features* mais importantes do conjunto enxuto — `Feature_Savgol_std`, `Max_Drawdown` e as métricas observacionais de profundidade e duração (à variável dominante (`Occ`Feature_`depth` `Savgol_Min`) e os sinais dos coeficientes da Regressão Logística, coerentes com a física da ocultação, `Occ_duration_s`) — oferece dão confiança de que essas variáveis capturam as assinaturas físicas relevantesde uma ocultação: a magnitude da queda de fluxo, sua localização temporal : a profundidade e a duração da queda e a separação entre os níveis de fluxo dentro e fora do evento. A coerência entre modelos de naturezas distintas (linear vs. árvores, *bagging* vs. *boosting*) reforça a robustez dessa interpretação.

O estudo de ablação (Seção 5.5.1) acrescenta uma nuance importante: embora `kmeans_centroid_dist` seja consistentemente apontada como a *feature* mais importante pelos modelos de árvore — chegando a 63% de importância no XGBoost —, sua remoção não degrada o desempenho. Isso demonstra que a **importância atribuída por algoritmos baseados em árvore não é sinônimo de insubstituibilidade**: uma *feature* pode concentrar alta importância simplesmente por oferecer um ponto de corte mais eficiente, enquanto outras variáveis colineares podem compensar sua ausência

~~redistribuindo a capacidade preditiva. Esse resultado tem implicação prática direta: a *pipeline* pode ser simplificada pela remoção do passo de K-means sem perda de qualidade.~~

5.12.3 Custo assimétrico e ajuste de limiar

Em um cenário real de triagem, o custo de perder uma ocultação genuína (falso negativo) supera ~~amplamente o custo~~ o de revisar uma curva sem evento (falso positivo). A Seção 5.7 ~~demonstra~~ mostra que essa assimetria pode ser incorporada à ~~*pipeline*~~ cadeia de processamento sem retreinamento, ~~simplesmente~~ reduzindo o limiar de decisão τ~~. Essa abordagem explora o fato de que os modelos produzem probabilidades,~~ : com o limiar escolhido na validação cruzada, o XGBoost detectou todas as ocultações do conjunto de teste com 4 falsos positivos. A transferência do limiar para dados novos, contudo, não ~~apenas rótulos binários, e que a separabilidade elevada entre as classes (AUC-ROC $\geqslant 0{,}998$) garante que a precisão se mantenha aceitável mesmo em patamares de sensibilidade próximos de 100%. A possibilidade de ajuste de limiar em pós-processamento~~ é ~~uma vantagem direta da formulação probabilística adotada, e confere à *pipeline* flexibilidade para operar em diferentes cenários de custosem modificação dos modelos~~garantida (o Random Forest, com o limiar escolhido da mesma forma, ainda perdeu 2 ocultações), e reduzir muito o limiar tem custo: com $\tau = 0{,}03$, cerca de 10 % das negativas reais passam a ser sinalizadas.

As limitações deste trabalho e as direções de pesquisa que delas decorrem são sintetizadas no Capítulo 6, à luz do conjunto completo dos resultados.

Capítulo 6

Conclusões

6.1 Resumo dos achados

A ~~*pipeline*~~ cadeia de processamento desenvolvida neste trabalho demonstrou que a detecção automatizada de ocultações estelares em curvas de luz pode atingir desempenho elevado~~(F1-score entre 0, 978 e 0, 994; AUC-ROC superior a 0,995), utilizando *features*~~ utilizando características clássicas extraídas das séries temporais e ~~*ensembles*~~ comitês de árvores de decisão (Random Forest, XGBoost, CatBoost), além de Regressão Logística como ~~*baseline.*~~ modelo linear de referência. Com um conjunto de teste reservado e agrupado por evento e com todas as escolhas feitas por validação cruzada, os modelos da configuração escolhida (Experimento 1.2b, 12 características) atingiram, no teste, F1-score entre 0,985 e 0,988 no conjunto misto e entre 0,985 e 0,994 somente nas curvas reais, com AUC-ROC acima de 0,997. Um critério trivial, de limiar único sobre a profundidade da queda, atinge F1 $\approx$ 0,90: a tarefa avaliada é dominada por ocultações profundas, e os classificadores reduzem a fração de erros em cinco a dez vezes.

~~Os seis experimentos realizados~~ As cinco configurações de características e as duas análises complementares permitiram identificar os seguintes padrões:

1. ~~**O *feature engineering* baseado**~~ **A engenharia de características baseada em domínio é o fator determinante da qualidade da classificação.** A redução de 28 (Tabela 5.1) para ~~11–13 *features*~~ 13 características (Tabela 5.2), com a remoção de variáveis redundantes, não degradou o desempenho ~~(em alguns casos, até o melhorou~~de forma perceptível (na validação cruzada, o melhor F1 passou de 0,9906 para 0,9889, diferença menor que um desvio padrão), indicando que um conjunto compacto de variáveis fisicamente motivadas é suficiente.

2. **A ~~*feature*~~ característica `kmeans_centroid_dist` é dispensável apesar de sua alta importância atribuída pelos modelos de árvore; `Feature_Savgol_Min` não é.** ~~O estudo de ablação (Experimento 6) mostrou que a~~ A remoção ~~dessa~~

variável causa degradação desprezível (⩽0, 3 pp em F1), da distância entre centroides não altera o desempenho, demonstrando que importância de *feature* característica não é sinônimo de insubstituibilidade: outras variáveis colineares (sobretudo `Feature_Savgol_std`) compensam sua ausência. Já a remoção do mínimo do fluxo suavizado reduz o F1 em cerca de 0,5 ponto percentual (com F1 menor em 18 a 19 das 25 dobras, conforme o modelo) e aumenta a taxa de falsos positivos nas negativas reais de 2–3 % para 4–8 %. A configuração 1.2b foi escolhida pela regra de um desvio padrão, mas a margem em relação à configuração 2 (11 características) é pequena: com outras sementes da validação cruzada, a mesma regra indicaria a configuração 2. A conclusão robusta é o papel de `Feature_Savgol_Min`, e não a escolha exata entre as duas configurações.

3. **O ajuste do limiar de decisão permite operar a *pipeline* cadeia de processamento em regime de alta sensibilidade** (minimização de falsos negativos) sem retreinamento. Com o limiar escolhido na validação cruzada ($\tau = 0{,}18$), o XGBoost detectou as 161 ocultações do conjunto de teste (intervalo de confiança de 95 % para a sensibilidade: 97,explorando a separabilidade elevada entre as classes 7–100 %), com 4 falsos positivos; a transferência do limiar para dados novos, contudo, não é garantida, e o Random Forest, com o limiar escolhido da mesma forma, ainda perdeu 2 ocultações. O estudo de caso de Quaoar (Seção 5.8)demonstrou, , feito com os modelos finais, ilustrou em dados reais , que essa alavanca recupera que os anéis finos que passariam despercebidos no limiar padrãorecebem do XGBoost probabilidade de 100 a 250 vezes maior que as janelas de controle e de ruído e podem ser recuperados com um limiar reduzido, ao custo de 3 a 6 % de alarmes falsos por janela nessa curva e de cerca de 10 % nas negativas reais do conjunto de desenvolvimento.

Como verificação complementar, as 67 curvas do banco 58 curvas positivas com Occ_SNR_dip < 3 foram submetidas aos quatro modelos treinados do Experimento 2 (11 *features*); todas foram corretamente classificadas como positivas pelos três *ensembles* de árvores (67/67), e 66 das 67 pela Regressão Logística. Embora essas curvas tenham participado do treinamento e o teste classificadas fora da amostra (predições fora da dobra no conjunto de desenvolvimento e modelos finais no conjunto de teste), e todas foram detectadas pelos quatro modelos. Esse resultado, porém, não inclua negativos de baixo SNRdemonstra robustez a eventos fracos: essas curvas têm, em sua maioria, quedas profundas (mediana de `Feature_Savgol_Min` igual a 0,o resultado indica que os modelos 06) e um ruído estimado fora do evento inflado (mediana de `Occ_baseline_std` de 0,33, contra 0,10 nas positivas em geral), porque a linha de base, estimada pela mediana do fluxo, é contaminada pela própria queda. O baixo SNR da queda reflete, nesses casos, uma limitação da estimativa, e não descartam sistematicamente eventos ruidosos. Essa

~~é uma condição necessária para aaplicabilidade da *pipeline* em cenários de baixa relação sinal-ruído~~um evento difícil. O conjunto de dados não contém, portanto, uma amostra de ocultações genuinamente difíceis (rasas ou de baixo SNR), e o desempenho nesse regime permanece por avaliar. A Figura 4.4 ilustra a diferença entre uma queda profunda, de alto SNR (painel a), e uma queda parcial em uma curva ruidosa (painel b), mais próxima do regime em que a triagem automática seria mais útil.

6.2 Resposta à hipótese de pesquisa

A hipótese formulada na Introdução — de que ~~é possível obter desempenho comparável a abordagens baseadas em redes convolucionais ou inspeção manual usando *features*~~ características clássicas ~~e *ensembles*~~ extraídas das curvas, combinadas a comitês de árvores, ~~com vantagem de interpretabilidade~~ permitem separar com alto desempenho as curvas com e sem ocultação, superando com folga um critério de limiar simples aplicado a uma única grandeza, com vantagens de interpretabilidade e controle sobre cada etapa — é **corroborada nos termos em que foi testada**~~pelos resultados obtidos~~. Os quatro modelos ~~testados atingiram desempenho elevado e consistente;~~ superam com folga o critério trivial (F1 de 0,985–0,988 contra 0,90 no teste, com diferença significativa pelo teste de McNemar exato), e a concordância parcial entre modelos de naturezas distintas (linear vs. árvores, *bagging* vs. *boosting*) quanto ~~à importância das~~ às variáveis relevantes (`Feature_Savgol_Min` está entre as duas mais importantes nos quatro) reforça a interpretabilidade do sistema~~e a solidez das conclusões~~. Duas ressalvas delimitam esse resultado. Primeiro, a avaliação foi feita sobre um conjunto dominado por ocultações profundas e com poucas negativas reais independentes. Segundo, a comparação com redes convolucionais e com a inspeção humana, sobre os mesmos dados, não foi realizada e permanece como perspectiva.

6.3 Contribuições originais

As principais contribuições deste trabalho são:

1. ~~***Pipeline***~~ **Cadeia de processamento completa de detecção:** desde a ingestão de curvas de luz já reduzidas até a classificação binária com reportagem de métricas, importância de variáveis e predições por curva, implementada em Python~~e~~. O código está disponível ~~para reprodução~~em `https://github.com/TLaidler/pipeline_occ_ml`, e o ambiente de software, no Apêndice C.

2. **Conjunto de ~~*features*~~ características baseado em domínio:** ~~11–13~~ 12 variáveis (Experimento 1.2b) que capturam assinaturas físicas de ocultações (estatísticas

de Savitzky-Golay, ~~*Max Drawdown*~~queda máxima acumulada, métricas observacionais de profundidade~~e SNR~~, duração, ruído e χ^2, testes estatísticos entre quartis), selecionadas por análise de redundância e ~~validadas experimentalmente~~avaliadas por validação cruzada.

3. **Estudo de ablação~~da *feature* K-means~~:** demonstração empírica de que a importância atribuída por algoritmos de árvore não implica insubstituibilidade ~~, com implicação prática para simplificação da *pipeline*~~(a distância entre centroides do K-means pode ser eliminada), enquanto uma variável de importância comparável (`Feature_Savgol_Min`) é necessária para manter baixa a taxa de falsos positivos nas negativas reais.

4. **~~Análise~~ Protocolo de ~~curvas de aprendizado~~avaliação sem vazamento entre eventos:** ~~evidência de saturação em suas duas dimensões, a do volume de treino (ablação 65/35, Apêndice A) e a da convergência do *logloss* por iteração de *boosting* (Seção 5.11), orientando futuras decisões sobre coleta de dados~~conjunto de teste reservado e agrupado por evento, validação cruzada repetida e agrupada, escolha da configuração pela regra de um desvio padrão, escolha do limiar fora do teste e comparação com um critério trivial, acompanhados do teste de McNemar exato e de intervalos de confiança para as taxas estimadas em poucas curvas.

5. **Análise de ajuste de limiar:** demonstração de que a assimetria de custo entre falsos negativos e falsos positivos pode ser incorporada em pós-processamento, sem retreinamento, e de que o limiar escolhido na validação cruzada deve ser acompanhado em uso.

6. **~~Validação cruzada estratificada e teste~~ Análise de ~~McNemar~~curvas de aprendizado:** ~~estimativa robusta da variabilidade do desempenho (desvio padrão pequeno entre dobras) e avaliação da significância estatística das diferenças entre modelos, que se mostraram equivalentes no conjunto de teste~~evidência de saturação em suas duas dimensões, a do volume de treino (Análise 2.2, Seção 5.11) e a da convergência da perda logarítmica por iteração de *boosting*, indicando que mais curvas do mesmo tipo trariam pouco ganho e que o progresso depende de curvas de natureza diferente.

7. **Demonstração da capacidade de (re)visitar curvas em busca de eventos sutis:** o estudo de caso de Quaoar (Seção 5.8) mostrou, em dados reais externos ao treino, que o ~~modelo separa~~ XGBoost atribuiu a um anel fino verdadeiro ~~de~~ probabilidade cerca de 190 vezes maior que a de um trecho de ruído semelhante ~~por quase duas ordens de grandeza de probabilidade~~e maior que a de todas as 123 janelas sem evento de mesma duração na curva. Esse contraste, via ajuste de limiar,

permite ~~recuperar~~ priorizar eventos que escapariam à classificação binária padrão. O estudo é ilustrativo: três curvas de um único evento, janelas dos recortes escolhidas conhecendo a posição dos anéis e varredura cega em uma única curva.

6.4 Limitações

As limitações deste trabalho devem ser explicitadas para contextualizar adequadamente os resultados:

1. ~~***Dataset***~~ **Conjunto de dados parcialmente simulado:** das 891 curvas negativas, 702 são simuladas e 186 são negativos por recorte (segmentos reais extraídos de curvas positivas); apenas 3 são ~~detecções~~ cordas negativas nativas. ~~Embora as curvas simuladas tenham sido geradas com base em propriedades estatísticas de curvas reais~~As curvas simuladas contêm apenas ruído branco, sem ruído correlacionado, variações de transparência ou nuvens, e têm ruído típico menor que o das curvas observadas (mediana de `Occ_baseline_std` de 0,021, contra 0,058 nos negativos por recorte); são, por isso, mais fáceis de reconhecer. A taxa de falsos positivos nas negativas reais é a ~~capacidade de generalização para um cenário puramente observacional~~ métrica mais relevante para o uso em campo.

2. **Poucas negativas reais independentes:** as 3 cordas negativas do banco pertencem ao mesmo evento (Umbriel, 2020), que ficou inteiro no conjunto de teste; os demais negativos reais são recortes de curvas positivas, com a mesma estrela, noite e instrumento da ocultação. Somando as predições fora da amostra do desenvolvimento e do teste, o XGBoost classifica como positivas 6 das 189 negativas reais (3,2 %; intervalo de confiança de 95 % de 1,2 % a 6,8 %). A taxa de falsos positivos em cordas negativas de outros eventos ainda não foi ~~validada~~medida.

3. ~~***Split*** **único por experimento**~~**Qualidade heterogênea dos dados de origem:** ~~cada experimento utiliza uma única partição treino/teste. A implementação de validação cruzada estratificada (Seção 5.5)mitiga parcialmente essa limitação; uma validação cruzada repetida com múltiplas sementes fortaleceria as conclusões.~~ 126 das 801 curvas positivas analisadas (16 %) têm valores de fluxo normalizado improváveis em uma curva bem normalizada (máximo do fluxo suavizado acima de 1,5 ou mínimo do fluxo abaixo de $-0{,}5$), o que sugere problemas de normalização ou de fotometria em parte do catálogo. Além disso, 18 cordas de Umbriel tinham o tempo registrado em dias julianos, e não em segundos (corrigido neste trabalho), uma curva está duplicada sob dois nomes de observador e a observação de Chiron consta no banco sem pontos de curva de luz (arquivo em formato CSV, incompatível com o programa de importação). As características calculadas sobre curvas com esses problemas podem refletir artefatos, e não a física do evento.

4. **Ausência de validação em catálogos externos:** as curvas reais utilizadas neste trabalho provêm de duas fontes distintas: o catálogo `B/occ/asteroid` do VizieR (agregador público que reúne campanhas independentes envolvendo múltiplos observadores, telescópios e corpos) e o banco do Grupo do Rio (~~campanhas específicas de Umbriele Chiron~~cordas da campanha de Umbriel). Embora a heterogeneidade interna do VizieR já garanta diversidade observacional considerável, a generalização da ~~*pipeline*~~ cadeia de processamento para curvas oriundas de outros agregadores ou de levantamentos específicos não foi avaliada sistematicamente. Apesar disso, o ~~*script*~~ programa utilizado para popular o banco SQL com dados do Grupo do Rio serve para qualquer tipo de curvas de luz, contanto que estejam em formato `.dat` de texto, com colunas separadas por espaço, a primeira coluna com o tempo e a segunda com o fluxo (uma terceira coluna, com a incerteza fotométrica, é lida mas não utilizada).

5. **Hiperparâmetros fixos:** os hiperparâmetros dos modelos foram definidos manualmente com base em valores recomendados pela literatura; não foi realizada busca em grade ou otimização bayesiana.

6. **Predominância de curvas com ocultações bem definidas:** o elevado desempenho dos modelos reflete, em parte, a predominância de curvas com ocultações claras (alto SNR, queda pronunciada) no conjunto de dados~~. Para~~: um único limiar sobre a profundidade já atinge F1 $\approx$ 0,90. As curvas com baixo SNR ~~ou eventos rasantes, a tarefa de classificação é substancialmente mais difícil e o desempenho real da *pipeline* nessas condições~~ da queda são, em sua maioria, quedas profundas com ruído superestimado, de modo que o desempenho da cadeia de processamento em eventos rasos, rasantes ou de baixo SNR ainda não foi avaliado~~sistematicamente~~.

7. **Configurações candidatas não independentes do teste:** as configurações comparadas foram definidas em análises exploratórias anteriores à separação do conjunto de teste, que tinham acesso a todas as curvas, de modo que a estimativa no teste pode ser levemente otimista. Além disso, a escolha entre as configurações 1.2b e 2 depende das sementes da validação cruzada.

8. **Estudo de caso de Quaoar restrito a um evento:** as três curvas analisadas são do mesmo evento, as janelas dos recortes foram escolhidas conhecendo a posição dos anéis e a varredura cega cobriu uma única curva, de SNR alto. Nela, com janelas não alinhadas aos anéis, uma ou duas janelas sem evento receberam probabilidade maior que a melhor janela sobre o anel Q2R em três das quatro combinações de travessia e duração da janela.

9. **Barras de erro fotométricas não utilizadas:** as incertezas fotométricas de cada ponto não são armazenadas no banco nem usadas nas ~~*features*~~características. As

escalas de ruído (por exemplo, no χ^2 e no SNR ~~do *dip*~~da queda) são estimadas da dispersão da própria curva. Incorporá-las permitiria um χ^2 propriamente dito e uma comparação mais justa entre curvas de qualidades diferentes.

6.5 Trabalhos futuros

Com base nos resultados e limitações identificados, sugerem-se as seguintes direções para trabalhos futuros:

- ~~**Validação cruzada repetida**~~**Negativas reais independentes:** ~~executar a validação cruzada com múltiplas sementes (e.g., 10 repetições × 5 dobras) para obter intervalos de confiança robustos das métricas~~reunir cordas negativas de campanhas distintas (registros de observadores que não detectaram o evento) para estimar com precisão a taxa de falsos positivos em dados de campo e substituir parte das negativas simuladas.

- ~~**Experimento *real holdout***~~**Avaliação por fonte e treino apenas com simulações:** reservar ~~todas as curvas reais (positivas e negativas genuínas) para o conjunto de teste, treinando apenas com curvas simuladas e negativos por recorte, para avaliar~~ campanhas ou catálogos inteiros para o teste (validação por fonte) e, com o simulador gerando também curvas positivas (corpo ocultante de diâmetro não nulo, anéis e difração), treinar apenas com simulações e testar em todas as curvas reais, para medir a transferibilidade do modelo.

- ~~***Features* baseadas em difração~~ **Controle de ~~Fresnel~~qualidade na ingestão:** verificar automaticamente, no momento da carga do banco, a unidade de tempo, a normalização do fluxo, a presença de pontos de curva de luz e a existência de duplicatas.

- **Características baseadas em difração de Fresnel:** incorporar características derivadas de modelos físicos mais sofisticados (escala de Fresnel, opacidade parcial, diâmetro aparente da estrela, etc.), que poderiam melhorar a discriminação em eventos de baixo SNR.

- **Detecção em regime de baixo SNR:** construir um subconjunto de teste composto exclusivamente por curvas difíceis (baixo SNR, ocultações rasantes, eventos com poucos pontos ~~no *dip*~~na queda, etc.), com o ruído estimado apenas nos trechos fora do evento, para avaliar o desempenho da ~~*pipeline*~~ cadeia de processamento nas condições em que a triagem automática é de fato necessária, isto é, onde a inspeção visual é ambígua.

- **Janela deslizante, varredura cega e ~~*features*~~ características locais:** o estudo de recortes de Quaoar (Seção 5.8) mostrou que o ajuste de limiar resolve o caso prático de detecção de anéis finos, mas que a causa estrutural da baixa probabilidade absoluta atribuída a esses eventos é, plausivelmente, o caráter **global** das ~~*features*~~ características (estatísticas agregadas sobre toda a janela diluem ~~um *dip*~~ uma queda de poucos segundos). ~~Duas~~ Três direções complementares atacam essa raiz: (i) aplicar a ~~*pipeline*~~ cadeia de processamento por **janela deslizante** de largura compatível com a duração típica do evento alvo, tornando o conjunto atual de ~~*features*~~ características sensível a eventos locais; ~~e~~ (ii) estender a **varredura cega** de janelas de mesma duração, feita aqui em uma única curva de Quaoar, a muitas curvas de qualidades diferentes, o que mediria a taxa de alarmes falsos por janela e permitiria escolher o limiar de triagem com base nela; e (iii) enriquecer o conjunto com ***~~features~~* características locais** (profundidade máxima de qualquer subjanela de N pontos abaixo ~~do *baseline*~~da linha de base, simetria do perfil de ingresso/egresso, ajuste a poço retangular curto).

- **Classificação multi-classe de eventos:** estender a formulação binária (ocultação presente/ausente) para uma classificação multi-classe que distinga o **tipo** de evento observado: ocultação por corpo sólido, assinatura atmosférica (refração e absorção), detecção de anéis e padrões de difração de Fresnel. Essa extensão exigiria ~~*features*~~ características adicionais (por exemplo, simetria do perfil de ingresso/egresso, profundidade relativa de quedas secundárias e ajuste a modelos de difração), além de um ~~*dataset*~~ conjunto de dados curado com rótulos para cada categoria, possivelmente com apoio de curvas geradas por simuladores que incluam esses fenômenos.

Referências Bibliográficas

GÉRON, Aurélin. *Mãos à Obra: Aprendizado de Máquina com Scikit-Learn e TensorFlow*. 2. ed. Rio de Janeiro: Alta Books, 2019.

LEVADA, Alexandre L. M. *Manual completo para aprendizado de máquina: algoritmos para classificação supervisionada, agrupamento de dados e redução de dimensionalidade*. Departamento de Computação, Universidade Federal de São Carlos (UFSCar), 16 jan. 2026.

CAZENEUVE, Dorian; MARCHIS, Franck; BLACLARD, Guillaume; DALBA, Paul A.; MARTIN, Victor; ASENCIO, Joe. "ODNet: A Convolutional Neural Network for Asteroid Occultation Detection". *The Astronomical Journal*, 165(11), 2023.

WALL, J. V.; JENKINS, C. R. *Practical Statistics for Astronomers*. Cambridge University Press, 2003.

IVEZIĆ, Željko; CONNOLLY, Andrew J.; VANDERPLAS, Jacob T.; GRAY, Alexander. *Statistics, Data Mining, and Machine Learning in Astronomy: A Practical Python Guide for the Analysis of Survey Data*. Princeton: Princeton University Press, 2014.

MORETTIN, Pedro A.; BUSSAB, Wilton de O. *Estatística Básica*. 6. ed. Revista e atualizada. São Paulo: Saraiva, 2010.

DEISENROTH, Marc Peter; FAISAL, A. Aldo; ONG, Cheng Soon. *Mathematics For Machine Learning*. Cambridge University Press, 2019. (Draft, October 15, 2019).

KNIELING, Bastian; SCHINDLER, Karsten; SICKAFOOSE, Amanda A.; PERSON, Michael J.; LEVINE, Stephen E.; KRABBE, Alfred. "Stellar Occultations in the Era of Data Mining and Modern Regression Models: Using Gaussian Processes to Analyze Light Curves and Improve Predictions". *The Planetary Science Journal*, 5(104), 2024. `https://doi.org/10.3847/PSJ/ad3819` [1]

FRASER, Wesley C.; PORTER, Simon B.; PELTIER, Lowell; KAVELAARS, J. J.; VERBISCER, Anne J.; et al. "Candidate Distant Trans-Neptunian Objects

Detected by the New Horizons Subaru TNO Survey". *arXiv e-prints*, arXiv:2407.21142v1, 2024.

GOMES-JÚNIOR, A. R.; MORGADO, B. E.; BENEDETTI-ROSSI, G.; BOUFLEUR, R. C.; ROMMEL, F. L.; BANDA-HUARCA, M. V.; KILIC, Y.; BRAGA-RIBAS, F.; SICARDY, B. "SORA: Stellar occultation reduction and analysis". *Monthly Notices of the Royal Astronomical Society*, 511(1), 1167–1181, 2022. https://doi.org/10.1093/mnras/stac032.

ROQUES, F.; MONCUQUET, M.; SICARDY, B. "Stellar occultations by small bodies - Diffraction effects". *The Astronomical Journal*, 93, 1549–1558, 1987. https://doi.org/10.1086/114438.

SICARDY, B.; ORTIZ, J. L.; ASSAFIN, M.; et al. "A Pluto-like radius and a high albedo for the dwarf planet Eris from an occultation". *Nature*, 478(7370), 493–496, 2011. https://doi.org/10.1038/nature10550.

SICARDY, B.; TALBOT, J.; MEZA, E.; CAMARGO, J. I. B.; et al. "Pluto's atmosphere from the 2015 June 29 ground-based stellar occultation at the time of the New Horizons flyby". *The Astrophysical Journal Letters*, 819(2), L38, 2016. https://doi.org/10.3847/2041-8205/819/2/L38.

ASSAFIN, M. *Differential aperture photometry and digital coronagraphy with PRAIA*. Planetary and Space Science, v. 239, p. 105816, dez. 2023. DOI: 10.1016/j.pss.2023.105816.

BRAGA-RIBAS, F.; SICARDY, B.; ORTIZ, J. L.; SNODGRASS, C.; ROQUES, F.; et al. "A ring system detected around the Centaur (10199) Chariklo". *Nature*, 508(7494), 72–75, 2014. https://doi.org/10.1038/nature13155.

ASSAFIN, M.; MARTINS, R.; CAMARGO, J.; ANDREI, A.; NETO, D.; BRAGA-RIBAS, F. "PRAIA - Platform for Reduction of Astronomical Images Automatically". 85–88, 2011.

ASSAFIN, M.; SANTOS-FILHO, S.; MORGADO, B. E.; GOMES-JÚNIOR, A. R.; SICARDY, B.; MARGOTI, G.; BENEDETTI-ROSSI, G.; BRAGA-RIBAS, F.; LAIDLER, T.; CAMARGO, J. I. B.; VIEIRA-MARTINS, R.; et al. "Kilometer-precise (UII) Umbriel physical properties from the multichord stellar occultation on 2020 September 21". *Monthly Notices of the Royal Astronomical Society*, 526(4), ~~619362046193–6204~~, 2023. https://doi.org/10.1093/mnras/stad3093.

~~ORTIZ, J. ;~~

PEREIRA, ~~Chrystian~~C. L.; BRAGA-RIBAS, F.; SICARDY, ~~Bruno; BRAGA-RIBAS, Felipe; TAKEY, Ali; FOUAD, A. ; SHAKER, A. ; KASPI, S.“Changing material around~~ B.; LEIVA, R.; ASSAFIN, M.; MORGADO, B. E.; ORTIZ, J. L.; SANTOS-SANZ, P.; CAMARGO, J. I. B.; MARGOTI, G.; et al. “The rings of (2060) Chiron~~revealed by an occultation on December 15, 2022”.~~ : evidence of an evolving system”. ~~*Astronomy & Astrophysics*~~*The Astrophysical Journal Letters*, ~~676, 2023.~~ 992(2), L19, 2025. `https://doi.org/10.3847/2041-8213/ae0b6d`.

PEREIRA, C. L.; SICARDY, B.; MORGADO, B. E.; BRAGA-RIBAS, F.; FERNÁNDEZ-VALENZUELA, E.; SOUAMI, D.; HOLLER, B. J.; BOUFLEUR, R. C.; MARGOTI, G.; ASSAFIN, M.; ORTIZ, J. L.; et al. “The two rings of (50000) Quaoar”. *Astronomy & Astrophysics*, 673, L4, 2023. `https://doi.org/10.1051/0004-6361/202346365`.

MORGADO, B. E.; SICARDY, B.; BRAGA-RIBAS, F.; ORTIZ, J. L.; SALO, H.; VACHIER, F.; DESMARS, J.; PEREIRA, C. L.; SANTOS-SANZ, P.; SFAIR, R.; DE SANTANA, T.; et al. “A dense ring of the trans-Neptunian object Quaoar outside its Roche limit”. *Nature*, 614(7947), 239–243, 2023. `https://doi.org/10.1038/s41586-022-05629-6`.

GOMES-FERRANTE, W.; BRAGA-RIBAS, F. “Stellar Occultation Simulator: application to Planet 9”. *The European Physical Journal Special Topics*, v. 232, n. 18-19, p. 3113–3118, 2023. DOI: 10.1140/epjs/s11734-023-01031-z.

FORNASIER, Sonia; LELLOUCH, Emmanuel; MÜLLER, Thomas G.; SANTOS-SANZ, Pablo; PANUZZO, Pasquale; KISS, Csaba; LIM, Taeho; MOMMERT, Michael; BOCKELÉE-MORVAN, Dominique; VILENIUS, Essi; STANSBERRY, John; TOZZI, Gian Paolo; MOTTOLA, Stefano; DELSANTI, Audrey; CROVISIER, Jacques; DUFFARD, René; HENRY, Frédéric; LACERDA, Pedro; BARUCCI, Antonella; GICQUEL, Arnaud. *TNOs are Cool: A survey of the trans-Neptunian region VIII. Combined Herschel PACS and SPIRE observations of nine bright targets at 70–500 μm*. Astronomy & Astrophysics, v. 555, p. A15, jul. 2013. DOI: 10.1051/0004-6361/201321329.

GOMES, Rodney da Silva. *On the origin of the Kuiper belt*, 2009.

ZHU, Qinglin; SUN, Mingchen; DONG, Xiang; ZHU, Pengfei. “Design and Simulation of Stellar Occultation Infrared Band Constellation”. *Remote Sens.*, 14(3327), 2022. `https://doi.org/10.3390/rs14143327`

MORBIDELLI, Alessandro; MARROCCHI, Yves; ALI AHMAD, Adnan; BHANDARE, Asmita; CHARNOZ, Sébastien; COMMERÇON, Benoît; DULLEMOND, Cor-

nelis P.; GUILLOT, Tristan; HENNEBELLE, Patrick; LEE, Yueh-Ning; LOVASCIO, Francesco; MARSCHALL, Raphael; MARTY, Bernard; MAURY, Anaëlle; TAMAMI, Okamoto. *Formation and evolution of a protoplanetary disk: Combining observations, simulations, and cosmochemical constraints*. Astronomy & Astrophysics, v. 691, p. A147, nov. 2024. DOI: 10.1051/0004-6361/202451388.

LÓPEZ DE PRADO, Marcos M. *Machine Learning for Asset Managers*. Cambridge: Cambridge University Press, 2020. (Elements in Quantitative Finance).

CARLEO, Giuseppe; CIRAC, Ignacio; CRANMER, Kyle; DAUDET, Laurent; SCHULD, Maria; TISHBY, Naftali; VOGT-MARANTO, Leslie; ZDEBOROVÁ, Lenka. *Machine learning and the physical sciences*, 2019. (Review paper excerpts)

SUDJIANTO, Agus; LIU, Alice J. "Decomposing Global AUC into Cluster-Level Contributions for Localized Model Diagnostics". *arXiv preprint*, arXiv:2508.07495, 2025. `https://arxiv.org/abs/2508.07495`.

GRYAK, J.; HARALICK, R. M.; KAHROBAEI, D. *Solving the Conjugacy Decision Problem via Machine Learning*. Experimental Mathematics, v. 29, n. 1, p. ~~667~~866–78, 2018. Disponível em: `https://doi.org/10.1080/10586458.2018.1434704`.

LIU, Ying. A Comparative Study on Feature Selection Methods for Drug Discovery. *Journal of Chemical Information and Computer Sciences*, v. 44, n. 5, p. ~~18231828~~ 1823–1828, 2004. DOI: 10.1021/ci049875d.

SHEWCHUK, Jonathan. *Concise Machine Learning*. UC Berkeley, Class CS 189/289A Lecture Notes, 2024.

MacQUEEN, James B. "Some Methods for Classification and Analysis of Multivariate Observations". In: *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, v. 1, p. 281–297. Berkeley: University of California Press, 1967.

PEDREGOSA, F.; VAROQUAUX, G.; GRAMFORT, A.; MICHEL, V.; THIRION, B.; GRISEL, O.; BLONDEL, M.; PRETTENHOFER, P.; WEISS, R.; DUBOURG, V.; VANDERPLAS, J.; PASSOS, A.; COURNAPEAU, D.; BRUCHER, M.; PERROT, M.; DUCHESNAY, É. "Scikit-learn: Machine Learning in Python". *Journal of Machine Learning Research*, 12, p. 2825–2830, 2011. `https://jmlr.org/papers/v12/pedregosa11a.html`. API e documentação disponíveis em `https://scikit-learn.org/stable/user_guide.html#user-guide`.

McNEMAR, Quinn. “Note on the sampling error of the difference between correlated proportions or percentages”. *Psychometrika*, 12, n. 2, p. 153–157, 1947. `https://doi.org/10.1007/BF02295996`.

SMITH, Matilda; RUXTON, Graeme. “Effective use of the McNemar test”. *Behavioral Ecology and Sociobiology*, 74, 133, 2020. `https://doi.org/10.1007/s00265-020-02916-y`.

SAITO, Takaya; REHMSMEIER, Marc. “The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets”. *PLOS ONE*, 10(3), e0118432, 2015. DOI: 10.1371/journal.pone.0118432.

ORTIZ, J. L.; SICARDY, B.; CAMARGO, J. I. B.; SANTOS-SANZ, P.; BRAGA-RIBAS, F. “Stellar occultations by Trans-Neptunian objects: from predictions to observations and prospects for the future”. In: PRIALNIK, D.; BARUCCI, M. A.; YOUNG, L. A. (Ed.). *The Trans-Neptunian Solar System*. Amsterdam: Elsevier, 2020. p. 413–437. DOI: 10.1016/B978-0-12-816490-7.00019-9.

GAIA COLLABORATION; PRUSTI, T.; DE BRUIJNE, J. H. J.; et al. “The Gaia mission”. *Astronomy & Astrophysics*, 595, A1, 2016. DOI: 10.1051/0004-6361/201629272.

GAIA COLLABORATION; VALLENARI, A.; BROWN, A. G. A.; PRUSTI, T.; et al. “Gaia Data Release 3: Summary of the content and survey properties”. *Astronomy & Astrophysics*, 674, A1, 2023. DOI: 10.1051/0004-6361/202243940.

HERALD, D.; BREIT, D.; DUNHAM, D.; FRAPPA, E.; et al. *Occultation lights curves*. VizieR On-line Data Catalog: B/occ. Strasbourg: CDS, 2016. DOI: 10.26093/cds/vizier.102033. Disponível em: `https://cdsarc.cds.unistra.fr/viz-bin/cat/B/occ`. Acesso em: 1 jun. 2025.

BREIMAN, Leo. “Random Forests”. *Machine Learning*, 45(1), 5–32, 2001. `https://doi.org/10.1023/A:1010933404324`.

CHEN, Tianqi; GUESTRIN, Carlos. “XGBoost: A Scalable Tree Boosting System”. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. San Francisco: ACM, 2016. p. 785–794. `https://doi.org/10.1145/2939672.2939785`.

PROKHORENKOVA, Liudmila; GUSEV, Gleb; VOROBEV, Aleksandr; DOROGUSH, Anna Veronika; GULIN, Andrey. “CatBoost: unbiased boosting with categorical features”. In: *Advances in Neural Information Processing Systems 31 (NeurIPS 2018)*, p. 6639–6649, 2018. arXiv:1706.09516.

STROBL, Carolin; BOULESTEIX, Anne-Laure; ZEILEIS, Achim; HOTHORN, Torsten. "Bias in random forest variable importance measures: Illustrations, sources and a solution". *BMC Bioinformatics*, 8, 25, 2007. https://doi.org/10.1186/1471-2105-8-25.

ZHONG, Xugang; LIN, Yanze; ZHANG, Wei; BI, Qing. "Predicting diagnosis and survival of bone metastasis in breast cancer using machine learning". *Scientific Reports*, 13, 18301, 2023. https://doi.org/10.1038/s41598-023-45438-z.

CONDORCET, Marie Jean Antoine Nicolas de Caritat, marquis de. *Essai sur l'application de l'analyse à la probabilité des décisions rendues à la pluralité des voix*. Paris: Imprimerie Royale, 1785.

CALIŃSKI, T.; HARABASZ, J. "A dendrite method for cluster analysis". *Communications in Statistics*, 3(1), 1–27, 1974. https://doi.org/10.1080/03610927408827101.

NOCEDAL, Jorge; WRIGHT, Stephen J. *Numerical Optimization*. 2. ed. New York: Springer, 2006. (Springer Series in Operations Research and Financial Engineering). https://doi.org/10.1007/978-0-387-40065-5.

SAVITZKY, A.; GOLAY, M. J. E. "Smoothing and differentiation of data by simplified least squares procedures". *Analytical Chemistry*, v. 36, n. 8, p. 1627–1639, 1964. DOI: 10.1021/ac60214a047.

WELCH, B. L. "The generalization of 'Student's' problem when several different population variances are involved". *Biometrika*, v. 34, n. 1-2, p. 28–35, 1947. DOI: 10.1093/biomet/34.1-2.28.

KOLMOGOROV, A. N. "Sulla determinazione empirica di una legge di distribuzione". *Giornale dell'Istituto Italiano degli Attuari*, v. 4, p. 83–91, 1933.

SMIRNOV, N. "Table for estimating the goodness of fit of empirical distributions". *Annals of Mathematical Statistics*, v. 19, n. 2, p. 279–281, 1948. DOI: 10.1214/aoms/1177730256.

VIRTANEN, P.; GOMMERS, R.; OLIPHANT, T. E.; et al. "SciPy 1.0: fundamental algorithms for scientific computing in Python". *Nature Methods*, v. 17, p. 261–272, 2020. DOI: 10.1038/s41592-019-0686-2.

ASTROPY COLLABORATION; PRICE-WHELAN, A. M.; LIM, P. L.; et al. "The Astropy Project: Sustaining and Growing a Community-oriented Open-source Project and the Latest Major Release (v5.0) of the Core Package". *The Astrophysical Journal*, v. 935, n. 2, 167, 2022. DOI: 10.3847/1538-4357/ac7c74.

GINSBURG, A.; SIPŐCZ, B. M.; BRASSEUR, C. E.; et al. “astroquery: An Astronomical Web-querying Package in Python”. *The Astronomical Journal*, v. 157, n. 3, 98, 2019. DOI: 10.3847/1538-3881/aafc33.

McKINNEY, W. “Data Structures for Statistical Computing in Python”. In: *Proceedings of the 9th Python in Science Conference*, p. 56–61, 2010. DOI: 10.25080/Majora-92bf1922-00a.

Apêndice A

Resultados experimentais complementares

O Capítulo 5 apresenta em detalhe três experimentos — a linha de base com o conjunto completo de *features* (Experimento 1), a configuração enxuta de 11 *features* usada como referência operacional (Experimento 2) e o teste de generalização exclusivamente em curvas reais (Experimento 3) —, além de sintetizar todos os resultados na Tabela ??. Este apêndice reúne os **experimentos intermediários** cujas conclusões já foram incorporadas àquela síntese, mas que se documentam aqui por completude: a redução progressiva do conjunto de *features* para 14 (Experimento 4) e 13 variáveis (Experimento resultados do Capítulo 5), a ablação isolada da *feature* `kmeans_centroid_dist` (Experimento 6) e uma variante do Experimento 3 com divisão 65%/35%, utilizada como ablação do tamanho do conjunto de treino. Todas que não foram incluídos no corpo do texto: todas as métricas da validação cruzada, a verificação da regra de seleção com outras sementes, as estimativas agregadas de falsos positivos nas negativas reais e as métricas referem-se ao no conjunto de teste e seguem o protocolo descrito na Seção 5.4de todas as configurações.

A.1 Experimento 4: subconjunto de 14 *features*Métricas completas da validação cruzada

No Experimento 4 foi utilizado um subconjunto reduzido de **14 *features***, removendo amplitude, desvio padrão do fluxo bruto, máximo do Savitzky-Golay, todas as derivadas e duas A Tabela A.1 apresenta todas as métricas observacionais (`Occ_flux_min` e `Occ_flux_min_over_baseline`). O objetivo é diminuir o risco de *overfitting* e melhorar a razão entre número de variáveis e tamanho do conjunto de treino. A Tabela ?? apresenta os resultados.

Métricas de desempenho no conjunto de teste — Experimento 4. Subconjunto de 14 *features*, divisão 80%/20%.

~~O melhor F1-score foi alcançado pelo **CatBoost** (F1 = 0, 9906). As métricas permanecem muito altas, indicando que a redução de 28 para 14 *features* preserva a informação discriminativa. A Figura ?? apresenta as matrizes de confusão.~~

~~Matrizes de confusão dos quatro modelos no Experimento 4 (14 *features*).~~

A.2 ~~Experimento 5: 13 *features* (sem `Feature_Savgol_Min`)~~

~~No Experimento~~ da validação cruzada (5 ~~foi removida a *feature* `Feature_Savgol_Min`, mantendo 13 *features*. O objetivo é avaliar a contribuição dessa variável, que costuma figurar entre as mais relevantes nos gráficos de importância. A Tabela ?? resume as métricas.~~ dobras × 5 repetições, no conjunto de desenvolvimento, $\tau = 0{,}5$), inclusive as das três configurações suplementares avaliadas depois da escolha, que não participaram da regra de seleção.

Tabela A.1: ~~Métricas de desempenho~~ Validação cruzada no conjunto de ~~teste — Experimento 5. 13 *features*~~ desenvolvimento: média ± desvio padrão sobre as 25 dobras. Entre parênteses, o número de características. As três últimas configurações são suplementares (~~sem `Feature_Savgol_Min`~~avaliadas depois da escolha)~~, divisão 80%/20%~~.

Configuração	Modelo	Acurácia	Precisão	Sensibilidade	F1	AUC-ROC
1 (28)	Regressão Log.	0,9880 ± 0,0058	0,9965 ± 0,0056	0,9781 ± 0,0108	0,9872 ± 0,0062	0,9993 ± 0,0006
	Random Forest	0,9896 ± 0,0065	0,9932 ± 0,0098	0,9850 ± 0,0081	0,9890 ± 0,0068	0,9997 ± 0,0003
	XGBoost	0,9911 ± 0,0058	0,9932 ± 0,0106	0,9881 ± 0,0064	0,9906 ± 0,0061	0,9997 ± 0,0003
	CatBoost	0,9907 ± 0,0058	0,9941 ± 0,0097	0,9862 ± 0,0082	0,9901 ± 0,0061	0,9997 ± 0,0002
1.1 (13)	Regressão Log.	0,9849 ± 0,0066	0,9943 ± 0,0070	0,9737 ± 0,0133	0,9839 ± 0,0071	0,9988 ± 0,0010
	Random Forest	0,9892 ± 0,0055	0,9913 ± 0,0107	0,9859 ± 0,0071	0,9886 ± 0,0058	0,9996 ± 0,0003
	XGBoost	0,9895 ± 0,0060	0,9911 ± 0,0111	0,9869 ± 0,0084	0,9889 ± 0,0063	0,9997 ± 0,0002
	CatBoost	0,9889 ± 0,0066	0,9925 ± 0,0096	0,9841 ± 0,0097	0,9882 ± 0,0070	0,9996 ± 0,0003
1.2a (12)	Regressão Log.	0,9810 ± 0,0084	0,9880 ± 0,0093	0,9719 ± 0,0150	0,9798 ± 0,0090	0,9983 ± 0,0012
	Random Forest	0,9830 ± 0,0064	0,9797 ± 0,0121	0,9847 ± 0,0097	0,9821 ± 0,0067	0,9991 ± 0,0007
	XGBoost	0,9842 ± 0,0063	0,9855 ± 0,0123	0,9812 ± 0,0096	0,9833 ± 0,0065	0,9993 ± 0,0005
	CatBoost	0,9834 ± 0,0073	0,9854 ± 0,0113	0,9797 ± 0,0096	0,9825 ± 0,0077	0,9992 ± 0,0005
1.2b (12)	Regressão Log.	0,9853 ± 0,0057	0,9940 ± 0,0069	0,9750 ± 0,0119	0,9844 ± 0,0061	0,9989 ± 0,0009
	Random Forest	0,9904 ± 0,0066	0,9905 ± 0,0123	0,9894 ± 0,0084	0,9899 ± 0,0069	0,9997 ± 0,0003
	XGBoost	0,9889 ± 0,0064	0,9907 ± 0,0112	0,9859 ± 0,0087	0,9883 ± 0,0067	0,9997 ± 0,0003
	CatBoost	0,9898 ± 0,0059	0,9935 ± 0,0103	0,9850 ± 0,0087	0,9892 ± 0,0062	0,9996 ± 0,0003
2 (11)	Regressão Log.	0,9809 ± 0,0074	0,9868 ± 0,0089	0,9728 ± 0,0134	0,9797 ± 0,0079	0,9982 ± 0,0012
	Random Forest	0,9837 ± 0,0084	0,9806 ± 0,0131	0,9853 ± 0,0109	0,9829 ± 0,0088	0,9992 ± 0,0006
	XGBoost	0,9845 ± 0,0072	0,9845 ± 0,0124	0,9828 ± 0,0117	0,9836 ± 0,0075	0,9993 ± 0,0005
	CatBoost	0,9843 ± 0,0075	0,9863 ± 0,0115	0,9806 ± 0,0104	0,9834 ± 0,0079	0,9992 ± 0,0005
1.2b sem teste t (11)	Regressão Log.	0,9845 ± 0,0061	0,9927 ± 0,0068	0,9744 ± 0,0118	0,9834 ± 0,0066	0,9989 ± 0,0010
	Random Forest	0,9917 ± 0,0059	0,9923 ± 0,0092	0,9903 ± 0,0085	0,9913 ± 0,0062	0,9997 ± 0,0002
	XGBoost	0,9907 ± 0,0050	0,9932 ± 0,0087	0,9872 ± 0,0101	0,9901 ± 0,0053	0,9997 ± 0,0002
	CatBoost	0,9898 ± 0,0062	0,9932 ± 0,0087	0,9853 ± 0,0104	0,9892 ± 0,0066	0,9996 ± 0,0003
1.2b sem testes de quartis (10)	Regressão Log.	0,9837 ± 0,0056	0,9934 ± 0,0074	0,9722 ± 0,0104	0,9826 ± 0,0061	0,9987 ± 0,0012
	Random Forest	0,9911 ± 0,0049	0,9929 ± 0,0082	0,9884 ± 0,0091	0,9906 ± 0,0052	0,9996 ± 0,0005
	XGBoost	0,9917 ± 0,0048	0,9935 ± 0,0082	0,9891 ± 0,0090	0,9912 ± 0,0051	0,9996 ± 0,0004
	CatBoost	0,9908 ± 0,0050	0,9938 ± 0,0080	0,9869 ± 0,0087	0,9903 ± 0,0053	0,9995 ± 0,0005
2 sem testes de quartis (9)	Regressão Log.	0,9781 ± 0,0078	0,9861 ± 0,0093	0,9675 ± 0,0148	0,9766 ± 0,0084	0,9978 ± 0,0015
	Random Forest	0,9854 ± 0,0066	0,9848 ± 0,0100	0,9844 ± 0,0090	0,9845 ± 0,0070	0,9992 ± 0,0005
	XGBoost	0,9846 ± 0,0067	0,9854 ± 0,0095	0,9822 ± 0,0097	0,9837 ± 0,0071	0,9991 ± 0,0007
	CatBoost	0,9836 ± 0,0072	0,9866 ± 0,0100	0,9787 ± 0,0112	0,9826 ± 0,0076	0,9993 ± 0,0005
Referência (1)	Limiar em `Occ_depth`	0,9070 ± 0,0170	0,8972 ± 0,0192	0,9082 ± 0,0279	0,9024 ± 0,0182	0,9071 ± 0,0173

~~O **Random Forest** lidera com~~

A.2 Robustez da regra de seleção

A Tabela A.2 compara o melhor F1 — médio de cada configuração na validação cruzada principal (sementes 0 ,9905. Em relação ao Experimento a 4,) e em uma repetição com outras cinco sementes (2000 a remoção de `Feature_Savgol_Min` causa queda moderada em alguns modelos, mas o desempenho global permanece elevado, indicando que as demais *features* absorvem parte da informação. As matrizes de confusão estão na Figura ??. Vale notar que a análise de ajuste de limiar e a 2004), mantidos a partição de teste e os modelos. Na validação cruzada apresentadas no Capítulo 5 (Seções 5.7 e 5.5) foram conduzidas sobre esta principal, a regra de um desvio padrão escolhe a configuração de 13 *features*. 1.2b; na repetição, a configuração 2 fica acima do limite, e a mesma regra a escolheria.

Matrizes de confusão dos quatro modelos no Experimento 5 (13 *features*, sem `Feature_Savgol_Min`).

A.3 Experimento 6: ablação isolada do K-means

No Experimento 6 foi removida `kmeans_centroid_dist`, mantendo 12 *features* (sem `Feature_Savgol_Min`), com divisão 80%/20%. A pergunta investigada é se a alta importância atribuída a essa variável pelos modelos de árvore reflete uma contribuição insubstituível ou se as demais *features* absorvem sua capacidade preditiva. A Tabela ?? apresenta as métricas.

Tabela A.2: Métricas Melhor F1 médio de desempenho no conjunto de teste Experimento 6. 12 *features* cada configuração (sem `kmeans_centroid_dist`e modelo correspondente) na validação cruzada com dois conjuntos de sementes, divisão 80%/20%e limite da regra de um desvio padrão.

	Sementes 0–4		Sementes 2000–2004	
Configuração	**Melhor F1**	**Modelo**	**Melhor F1**	**Modelo**
1 (28)	0,9906	XGBoost	0,9895	XGBoost
1.1 (13)	0,9889	XGBoost	0,9889	Random Forest
1.2a (12)	0,9833	XGBoost	0,9838	XGBoost
1.2b (12)	0,9899	Random Forest	0,9892	XGBoost
2 (11)	0,9836	XGBoost	0,9849	CatBoost
Limite (melhor − 1 DP)	0,9845		0,9835	
Configuração escolhida	1.2b		2	

Random Forest e XGBoost empatam com A Tabela A.3 mostra, para cada modelo, a diferença de F1 — 0,9906 — desempenho igual ou superior ao da configuração que mantém o K-means. A Figura ?? apresenta as matrizes de confusão.

Matrizes de confusão dos quatro modelos no Experimento 6 (12 *features*, sem `kmeans_centroid_dist`).

A Tabela ?? confronta os F1-scores do Experimento 5 (13 *features*, com `kmeans`), do Experimento 6 (12 *features*, sem `kmeans`) edo Experimentoentre as configurações 1.2b e 2

(11 *features*, sem `Feature_Savgol_Min` e sem `kmeans`), evidenciando que a remoção calculada dobra a dobra (mesmas partições da *feature* de K-means não degrada o desempenho globalvalidação cruzada principal). Em todos os modelos, a configuração com `Feature_Savgol_Min` vence na maioria das dobras.

Tabela A.3: Comparação do F1-score: com `kmeans` (Exp. 5), sem `kmeans` (Exp. 6) Diferença pareada de F1 entre as configurações 1.2b eablação combinada (Exp. 2 nas 25 dobras da validação cruzada (positiva quando a 1.2b é melhor).Divisão 80%/20%.

Modelo	Diferença média ± DP	1.2b melhor	2 melhor	Empates
Regressão Log.	0,0047 ± 0,0039	18	2	5
Random Forest	0,0070 ± 0,0075	19	4	2
XGBoost	0,0047 ± 0,0052	18	3	4
CatBoost	0,0058 ± 0,0062	19	4	2

A importância antes concentrada em `kmeans_centroid_dist` é redistribuída entre variáveis como `Feature_Savgol_std`, `Occ_depth`, `Occ_duration_s` e `MinLogP_Ttest`. Esse resultado sustenta a conclusão discutida no Capítulo 5: `kmeans_centroid_dist` e `Feature_Savgol_std` capturam o mesmo fenômeno físico (a dispersão do fluxo causada pelos dois patamares dentro e fora do *dip*), de modo que a alta importância atribuída ao K-means não reflete informação insubstituível. Na prática, isso permite simplificar a *pipeline* eliminando o passo de K-means sem perda de desempenho.

Por fim, a Figura ?? apresenta as matrizes de confusão da configuração enxuta de 11 *features* (Experimento 2), discutida em detalhe na Seção ?? do Capítulo 5.

Matrizes de confusão dos quatro modelos no Experimento 2 (11 *features*).

A.3 Variante do Experimento 3 com divisão 65/35: ablação do tamanho do treino

A.3 Falsos positivos nas negativas reais

O Experimento 3 do Capítulo 5 avalia a generalização para curvas exclusivamente reais sob a mesma divisão 80%/20% dos demais experimentos. Esta seção documenta uma variante com divisão 65%/35%, que cumpre dois papéis: (i) ampliar o conjunto de teste real avaliado (347 curvas: 281 positivas e 66 negativas, contra 198 Como o conjunto de teste contém apenas 34 negativas reais, a Tabela A.4 soma as predições fora da amostra das negativas reais do desenvolvimento (predições fora da dobra da primeira repetição da validação cruzada) e do teste (modelos finais), na configuração principal), reduzindo a incerteza amostral das métricas; e (ii) servir de **ablação do tamanho do conjunto de treino**. Ao remover cerca de 15% dos dados de treinamento, mede-se a sensibilidade do desempenho à quantidade de exemplos disponíveis1.2b e no limiar $\tau = 0{,}5$. Os intervalos

de confiança de 95 % são de Clopper–Pearson.

Tabela A.4: Métricas de desempenho no conjunto de teste — variante do Experimento 3 com divisão 65%/35% (teste somente em curvas Negativas reais : 347 curvas, 281 classificadas como positivase 66 negativas, fora da amostra (configuração 1.2b, $\tau = 0{,}5$).

Modelo	Desenvolvimento	Teste	Total	Taxa	IC 95 %
Regressão Log.	4/155	3/34	7/189	3,7 %	1,5 % – 7,5 %
Random Forest	4/155	2/34	6/189	3,2 %	1,2 % – 6,8 %
XGBoost	5/155	1/34	6/189	3,2 %	1,2 % – 6,8 %
CatBoost	3/155	1/34	4/189	2,1 %	0,6 % – 5,3 %
Limiar em `Occ_depth`	12/155	4/34	16/189	8,5 %	4,9 % – 13,4 %

A comparação com a configuração principal (Tabela 5.6, Capítulo

A.4 Métricas no conjunto de teste de todas as configurações

A Tabela 5) é direta: com 15% menos dados de treino, o melhor F1 recua de 0,9906 para 0, 9838 (queda de apenas ≈0, 7 ponto percentual) e a AUC-ROC permanece ⩾ 0,9956 em todos os modelos. Essa estabilidade indica que a curva de aprendizado dos modelos está **saturada** na região de operação: o desempenho depende fracamente do volume de treino, comportamento incompatível com sobreajuste dominante (um modelo sobreajustado degradaria de forma acentuada ao perder dados de ajuste). O resultado converge com a A.5 apresenta, apenas para registro, as métricas no conjunto de teste das cinco configurações, cada uma treinada em todo o conjunto de desenvolvimento. Essas métricas **não** foram usadas em nenhuma escolha. As diferenças entre configurações correspondem a poucas curvas e não coincidem com a ordem da validação cruzada estratificada (Seção 5.5), que apresenta desvios padrão pequenos entre dobras. As Figuras ?? e ?? apresentam as matrizes de confusão e as curvas ROC desta variante.

Matrizes de confusão dos quatro modelos na variante 65/35 do Experimento 3 (teste somente em curvas reais).

Curvas ROC — variante 65/35 do Experimento 3 (teste somente em curvas reais).

A.5 Curvas ROC dos experimentos complementares

As curvas ROC do Experimento 1 são apresentadas no Capítulo 5 (Figura 5.3); as da variante 65/35 do Experimento 3 estão na Seção ?? (Figura ??). Para completude, as Figuras ?? ?? reúnem as curvas ROC dos demais experimentos ((por exemplo, a configuração 2 aparece à frente no XGBoost), 4, 5 o que ilustra por que a comparação entre configurações deve ser feita por validação cruzada, e 6). Em todos os casos a AUC

permanece acima de 0, 999, confirmando a elevada separabilidade das classes no não em um único conjunto de testemisto.

Curvas ROC — Experimento 4 (14 *features*).

Curvas ROC — Experimento 5 (13 *features*).

Curvas ROC — Experimento 6 (12 *features*, sem `kmeans`).

Curvas ROC — Experimento 2 (11 *features*).

A.5 Importância das *features* nos Experimentos 4 e 5

O Capítulo 5 discute a importância das variáveis com base na figura do Experimento 1 (conjunto completo). As Figuras ?? e ?? apresentam os gráficos análogos para os Experimentos 4 e 5, úteis para acompanhar como a relevância relativa das variáveis se redistribui à medida que o conjunto é reduzido. A interpretação dos valores deve considerar as diferenças metodológicas entre os métodos de cada modelo, discutidas na Seção 5.3.

Experimento 4 (14 *features*).(a) Regressão Log. (b) Random Forest (c) XGBoost (d) CatBoost

Tabela A.5: Importância Métricas no conjunto de variáveis por modelo — Experimento 4 teste (14 *features*τ = 0,5) de todas as configurações. (a) Regressão Logística, (b) Random Forest, (c) XGBoost, (d) CatBoost"Misto": 341 curvas; "Só reais": 195 curvas. FP/FN no teste misto.

		Misto			Só reais	
Configuração	**Modelo**	**F1**	**AUC-ROC**	**FP / FN**	**F1**	**AUC-ROC**
1 (28)	Regressão Log.	0,9845	0,9983	3 / 2	0,9845	0,9923
	Random Forest	0,9907	0,9994	2 / 1	0,9938	0,9984
	XGBoost	0,9845	0,9997	3 / 2	0,9907	0,9995
	CatBoost	0,9876	0,9998	2 / 2	0,9907	0,9995
1.1 (13)	Regressão Log.	0,9845	0,9977	3 / 2	0,9845	0,9887
	Random Forest	0,9877	0,9995	3 / 1	0,9907	0,9982
	XGBoost	0,9877	0,9997	3 / 1	0,9938	0,9995
	CatBoost	0,9845	0,9993	3 / 2	0,9876	0,9976
1.2a (12)	Regressão Log.	0,9783	0,9965	4 / 3	0,9783	0,9821
	Random Forest	0,9907	0,9993	2 / 1	0,9907	0,9963
	XGBoost	0,9938	0,9989	1 / 1	0,9938	0,9943
	CatBoost	0,9907	0,9992	1 / 2	0,9907	0,9960
1.2b (12)	Regressão Log.	0,9845	0,9976	3 / 2	0,9845	0,9885
	Random Forest	0,9845	0,9993	3 / 2	0,9876	0,9980
	XGBoost	0,9877	0,9997	3 / 1	0,9938	0,9991
	CatBoost	0,9876	0,9992	2 / 2	0,9907	0,9976
2 (11)	Regressão Log.	0,9783	0,9955	4 / 3	0,9783	0,9770
	Random Forest	0,9907	0,9991	2 / 1	0,9907	0,9953
	XGBoost	0,9969	0,9993	1 / 0	0,9969	0,9962
	CatBoost	0,9938	0,9993	1 / 1	0,9938	0,9962

Experimento 5 (13 *features*, sem `Feature_Savgol_Min`).(a) Regressão Log.

(b) Random Forest (c) XGBoost (d) CatBoost Importância de variáveis por modelo — Experimento 5 (13 *features*, sem `Feature_Savgol_Min`). (a) Regressão Logística, (b) Random Forest, (c) XGBoost, (d) CatBoost.

Apêndice B

Hiperparâmetros dos classificadores

Este apêndice documenta os hiperparâmetros utilizados no treinamento dos classificadores (Regressão Logística, Random Forest, XGBoost, CatBoost) descritos no Capítulo 4. Os valores foram fixados ~~no *script*~~ nos programas `train_model.py` e `reanalise_banca.py` e utilizados em todos os experimentos, sem busca em grade nem validação cruzada para seleção de hiperparâmetros~~; a semente aleatória (~~. Para reprodutibilidade, as sementes aleatórias são fixas: 42 nos modelos finais e, em cada repetição da validação cruzada, a semente daquela repetição. Em todos os modelos, valores ausentes são imputados pela mediana do treino (~~`random_state=42)`~~foi mantida para reprodutibilidade~~ `SimpleImputer`).

Regressão Logística:

- Regularização: Ridge (ℓ_2), valor padrão do scikit-learn (`penalty='l2'`).
- Força da regularização: $C = 1{,}0$ (valor padrão).
- ~~Solver~~Algoritmo de otimização: `lbfgs` (padrão para regularização ℓ_2).
- `max_iter`: 1000.
- `class_weight`: `balanced`.
- Pré-processamento: padronização das características (`StandardScaler`, média zero e desvio unitário).
- `random_state`: 42.

Random Forest:

- `n_estimators`: 100.
- `max_depth`: 10.
- `min_samples_split`: 5.

- `min_samples_leaf`: 2.
- `class_weight`: `balanced`.
- `random_state`: 42.

XGBoost:

- `n_estimators`: 100.
- `max_depth`: 6.
- `learning_rate`: 0,1.
- `subsample`: 0,8.
- `colsample_bytree`: 0,8.
- Ponderação de classes: ~~utilizada a opção padrão do XGBoost (sem~~ nenhuma (`scale_pos_weight` ~~explícito no *script*; o desbalanceamento~~ no valor padrão, 1). O XGBoost não corrige o desbalanceamento por si só; a ponderação foi dispensada porque o conjunto é ~~tratado indiretamente pelo algoritmo~~aproximadamente equilibrado (47 % de positivas).
- `random_state`: 42.
- ~~`use_label_encoder: False;`~~ `eval_metric`: `logloss`.

CatBoost:

- `iterations`: 100.
- `depth`: 6.
- `learning_rate`: 0,1.
- `auto_class_weights`: `Balanced`.
- `random_state`: 42.

Não foi utilizada busca em grade (*grid search*) nem validação cruzada para escolha desses hiperparâmetros; os valores acima correspondem a uma configuração ~~*baseline*~~ de referência fixa, mantida em todos os experimentos para permitir uma comparação justa entre eles, variando-se apenas o conjunto de ~~*features* e a composição do conjunto de teste. Para~~ características. Em trabalhos futuros, ~~pode-se explorar~~ os hiperparâmetros podem ser ajustados por validação cruzada ~~estratificada com otimização de F1-score ou AUC-ROC para refinar os hiperparâmetros~~aninhada no conjunto de desenvolvimento, mantendo o conjunto de teste reservado.

Apêndice C

Ambiente de software e versões

O código da cadeia de processamento está disponível em `https://github.com/TLaidler/pipeline_occ_ml`. Para reprodutibilidade dos experimentos, segue a lista das principais ferramentas e bibliotecas utilizadas no projeto~~. As versões abaixo referem-se ao ambiente em que a *pipeline* de treinamento (`train_model.py`) e a construção do *dataset* foram executadas, conforme~~, em dois ambientes: o da construção do conjunto de dados e do programa de treinamento `train_model.py`, conforme o arquivo `requirements.txt` (ou `requirements_frozen.txt`) do repositório~~do projeto~~, e o dos experimentos do Capítulo 5 (programa `reanalise_banca.py`).

~~Pacotes principais~~Construção do conjunto de dados e treinamento (`train_model.py`):

- Python ~~: 3.x (recomenda-se~~ 3.10 ou superior~~para compatibilidade com as bibliotecas listadas)~~.
- numpy — 1.26.4
- pandas — 2.2.2
- scikit-learn — 1.4.2
- xgboost — 2.0.3
- catboost — 1.2.5
- matplotlib — 3.8.4
- seaborn — 0.13.2
- joblib — 1.4.2
- astropy — 5.3.1
- scipy — 1.13.1

Experimentos do Capítulo 5 (`reanalise_banca.py`):

- Python — 3.14.6
- numpy — 2.4.6
- pandas — 2.3.3
- scikit-learn — 1.9.0
- xgboost — 3.3.0
- catboost — 1.2.10
- scipy — 1.18.0
- matplotlib — 3.11.0

Outras dependências (aquisição de dados, persistência, testes): SQLAlchemy 2.0.31, requests 2.32.3, python-dotenv 1.0.1, pyyaml 6.0.1, pytest 7.4.3. A aquisição de curvas de luz a partir do VizieR e do Grupo do Rio pode utilizar ainda `astroquery` e `aiohttp`; nesse caso, as versões devem ser registradas com `pip freeze` no ambiente em que os ~~*scripts*~~ programas de ingestão forem executados.

Para replicar o ambiente de treinamento, recomenda-se criar um ambiente virtual (venv ou conda) e instalar as dependências com `pip install -r requirements.txt` (ou `pip install -r requirements_frozen.txt` para versões fixas). ~~A data de geração do ambiente utilizado nos~~ Os experimentos do Capítulo 5 ~~deve ser registrada pelo autor ao finalizar a dissertação~~são reproduzidos executando `python reanalise_banca.py` no diretório `pipeline/model_training`: o programa lê o conjunto de dados e o banco de dados, grava as tabelas de resultados em `outputs/reanalise_banca` e as figuras do Capítulo 5 em `writing_latex/Tese/pngs/reanalise`. A partição do conjunto de teste depende da ordem dos rótulos de grupo (no formato `objeto_AAAA-MM-DD`) e da versão do `scikit-learn`; com outra versão, a partição pode mudar. As versões desse ambiente estão fixadas no arquivo `requirements_reanalise.txt`. O estudo de caso de Quaoar (Seção 5.8) é reproduzido executando `python quaoar_reanalise.py` no diretório `pipeline/model_in_practice`: o programa carrega os modelos finais gravados por `reanalise_banca.py` e grava os resultados em `outputs_quaoar_1.2b` e a figura dos recortes em `writing_latex/Tese/pngs/reanalise`.